

Deep Sets

Zaheer et al., in Proc. NIPS, 2017

펀더멘털 팀: 고희권, 김동희, 김창연, 이민경, 이재윤
발표자: 송헌 (songheony@gmail.com)

-
- 뉴럴 네트워크에서 입력데이터와 출력데이터로 집합을 다룰 수 있는 모델을 제시.
 - 다양한 응용방법을 제시하며, 실험적으로 좋은 성능을 얻었음을 보임.

01

문제점

- 기존 뉴럴넷은 고정된 차원의 데이터만을 다루며, 특히 입력 데이터의 순서가 바뀔 경우 출력 데이터가 굉장히 많이 달라짐.
- 이러한 이유로 Point Cloud등의 집합 데이터를 다룰 때 많은 문제점이 있음.
3차원 좌표계에 속한
점들의 집합
- 논문에서는 특히 집합 데이터의 특성 중에서도 데이터의 순서에 주목하여, 입력 데이터의 순서가 바뀌어도 같은 결과를 출력하거나 (permutation invariant) 입력 데이터의 순서에 따라 출력 데이터의 순서도 바뀌는 (permutation equivariant)에 초점을 맞춤.


01

간단한 예

- Permutation **invariant** : 덧셈 문제



- Permutation **equivariant** : 이상치 검출



01

문제 정의

- 데이터 $X = \{x_1, \dots, x_M\}$ 가 주어졌을 때, 어떠한 permutation π 에 대해서 함수 f 는 다음을 성립해야 한다.
- Permutation **invariant** :

$$f(\{x_1, \dots, x_M\}) = f(\{x_{\pi(1)}, \dots, x_{\pi(M)}\})$$

- Permutation **equivariant** :

$$f([x_{\pi(1)}, \dots, x_{\pi(M)}]) = [f_{\pi(1)}(\mathbf{x}), \dots, f_{\pi(M)}(\mathbf{x})]$$

Q & A

Q&A

- 집합의 크기가 유한할 때, 함수 f 는 반드시 다음과 같은 형태를 가져야만 하며, 다음의 형태를 가지면 permutation invariant하다.


$$f(X) = \rho \left(\sum_{x \in X} \phi(x) \right)$$

- 이때 ρ 와 ϕ 는 적절한 변형함수이다.
- 논문에서는 무한한 크기의 집합에서도 비슷한 증명이 가능할지도 모른다는 여지를 남겨두었음.

02

Invariant

- 즉, 다음과 같은 모델을 생각할 수 있음.



02 Equivariant

- 뉴럴넷중 한 layer를 $f_{\theta}(\mathbf{x}) = \sigma(\theta\mathbf{x})$ 라고 나타낼 때, 파라미터 θ 는 반드시 다음과 같은 형태를 가져야만 하며, 다음의 형태를 가지면 permutation equivariant하다.


$$\theta = \Lambda\mathbf{I} + \mathbf{1}\mathbf{1}^T\Gamma$$

단 $\mathbf{x} \in \mathbb{R}^{M \times D}$ 일 때, $\Lambda, \Gamma \in \mathbb{R}^{D \times D'}$ 이며 $\mathbf{1} = [\mathbf{1}, \dots, \mathbf{1}]^T \in \mathbb{R}^M$ 이다.

- 즉 각각의 입력 $\mathbf{x}$ 와 그것의 합 $\mathbf{1}\mathbf{1}^T\mathbf{x}$ 의 가중치(Λ, Γ) 합을 나타낸다.

02 Equivariant

- 즉, 다음과 같은 모델을 생각할 수 있음.



02 Set-expansion

- 집합 X 가 주어져 있을 때, 새로운 데이터 x 가 해당 집합의 데이터들과 유사함을 다음과 같이 나타낼 수 있음.

$$s(x|X) = \log p(X \cup \{x\}) - \log p(X)p(\{x\})$$

- 이를 이용하여 다음과 같은 손실 함수를 설정하고 학습할 수 있다.

$$l(x, x'|X) = \max(0, s(x'|X) - s(x|X) + \Delta(x, x'))$$

Q & A

Q&A


- 논문에서는 permutation invariant, equivariant와 더불어, set-expansion에 관한 실험도 진행하였음.
- 제안방법의 permutation invariant에 대한 유효성을 증명하기 위해 인구통계, **딛셈 문제, point cloud의 분류 문제**, 적색편이 실험을 진행.
- 제안방법의 permutation equivariant에 대한 유효성을 증명하기 위해 **이상치 검출** 실험을 진행

제안방법의 set-expansion에 대한 유효성을 증명하기 위해 text retrieval, **이미지 태깅** 실험을 진행

03

덧셈 문제


- 10개의 숫자 집합의 합을 학습시킨 모델을
숫자의 수가 5개부터 100개인 집합에 대해서 성능을 확인하였다.
- RNN계열은 10개보다 많은 데이터에 대해 굉장히 성능이 떨어짐



03


덧셈 문제

- 10개의 MNIST 이미지 집합의 합을 학습시킨 모델을 이미지의 수가 5개부터 50개인 집합에 대해서 성능을 확인하였다.
- RNN계열은 10개보다 많은 데이터에 대해 굉장히 성능이 떨어짐



03 Point cloud

- Point cloud 데이터를 다루는 많은 방법론들이, 데이터를 voxel 이나 메쉬 형태로 표현후에 학습을 한다.
- 하지만 제안방법을 이용함으로써, 센서에서 얻어진 정보를 직접적으로 사용 가능하며, 회전등 다양한 변환이 3D이미지보다 손쉽게 가능하다.



03 Point cloud

- 포인트를 100개와 5000개를 샘플링하여 모델을 학습시켰다.
- 비교적 낮은 차원의 데이터 (instance size)로도 다른 방법들보다도 높은 정확도를 얻을 수 있었다.

Model	Instance Size	Representation	Accuracy
3DShapeNets [25]	30^3	voxels (using convolutional deep belief net)	77%
VoxNet [26]	32^3	voxels (voxels from point-cloud + 3D CNN)	83.10%
MVCNN [21]	$164 \times 164 \times 12$	multi-view images (2D CNN + view-pooling)	90.1%
VRN Ensemble [27]	32^3	voxels (3D CNN, variational autoencoder)	95.54%
3D GAN [28]	64^3	voxels (3D CNN, generative adversarial training)	83.3%
DeepSets	5000×3	point-cloud	$90 \pm .3\%$
DeepSets	100×3	point-cloud	$82 \pm 2\%$

03 이상치 검출

- 여러개의 이미지가 주어지면, 그중 이상치를 분류하는 문제를 구성
- 훈련 이미지와 테스트 이미지는 완전히 다름




03

이상치 검출

- CNN에 대해서 마지막 분류층이 다음과 같은 두개의 모델을 비교
 - FC layer를 3개 사용한 모델
 - Permutation equivariant layer를 3개 사용한 모델
- FC layer를 사용한 경우
테스트 정확도가 6.3%로 거의 랜덤한 선택과 같은 정확도를 얻었다.
- Permutation equivariant layer를 사용한 경우
75%의 매우 높은 테스트 정확도를 얻었다.

03 이미지 태깅

- 이미지의 태그중 일부분만이 주어졌을때, 그와 연관있는 다른 태그들을 예측하는 실험을 진행.



03 이미지 태깅

- Precision을 제외하고, 대부분의 지표에서 가장 좋은 성능을 보인 방법론과 비슷한 성능을 보였음.
- Precision이 낮은 이유는, 비슷한 태그를 예측은 하지만 정답 라벨에는 있지 않는 경우가 많았기 때문이라고 설명

Method	ESP game				IAPRTC-12.5			
	P	R	F1	N+	P	R	F1	N+
Least Sq.	35	19	25	215	40	19	26	198
MBRM	18	19	18	209	24	23	23	223
JEC	24	19	21	222	29	19	23	211
FastTag	46	22	30	247	47	26	34	280
Least Sq.(D)	44	32	37	232	46	30	36	218
FastTag(D)	44	32	37	229	46	33	38	254
DeepSets	39	34	36	246	42	31	36	247

03 이미지 태깅

- 노란색 태그가 주어졌을 때, 제대로 예측한 태그는 초록색으로 표시



GT	Pred
building	building
sign	street
brick	city
picture	brick
empty	sidewalk
white	side
black	pole
street	white
image	stone



GT	Pred
standing	person
surround	group
woman	man
crowd	table
wine	sit
person	room
group	woman
table	couple
bottle	gather




GT	Pred
traffic	clock
city	tower
building	sky
tall	building
large	tall
tower	large
European	cloudy
front	front
clock	city

03 이미지 태깅

- 틀린 태그를 보면, 굉장히 이미지와 유사하거나 주어진 태그와 유사한 태그들이 예측된 것을 알 수 있음.



GT	Pred
photograph	ski
snowboarder	snow
snow	slope
glide	person
hill	snowy
show	hill
person	man
slope	skiing
young	skier



GT	Pred
laptop	refrigerator
person	fridge
screen	room
room	magnet
desk	cabinet
living	kitchen
counter	shelf
computer	wall
monitor	counter



GT	Pred
beach	jet
shoreline	airplane
stand	propeller
walk	ocean
sand	plane
lifeguard	water
white	body
person	person
surfboard	sky

Q & A

Q&A