

딥러닝논문읽기모임

이미지처리

Effectively Leveraging Attributes for Visual Similarity (arXiv.21)

2022.04.10

이예은 김병현 김준철 조경진

Index

01 Abstract

02 Prior work 및 네트워크

2-1. Prior work

2-2. PAN 간략한 네트워크

03 논문 내용

3-1. Contribution

3-2. PAN network

3-3. 학습

3-4. Dataset


3-5. 결론

04 Conclusion

01

Abstract

Abstract




capturing similarity conditions $\rightarrow$ relevance scores from a joint representation

PAN은 4-9% increase on clothing items(Polyvore Outfits),
5% 상승 on few shot classification of images using Caltech-UCSD Birds (CUB),
and over 1% boost to Recall@1 on In-Shop Clothes Retrieval,

02

Prior work

(a) Prior work: Attributes from single images




현재 Prior 연구의 문제

- 유사도에 영향을 끼치는 모든 특성들을 annotation하는 것은 불가능
- 유사도에 영향을 끼치는 속성을 명확히 하는것도 힘들
- 각 이미지의 속성을 직접 예측하므로 노란색 음영과 같은 속성 표현의 미묘한 차이에 대한 정보를 잃는 경향이 있음

PAN(Pairwise Attribute-informed similarity Network) : 속성 공간이 아닌 특징 공간 (joint Feature)에서

(b) PAN (ours): Attributes from joint image features



Joint features
= > 1.similarity score (속성)
+ 2.relevance score
(미세한 차이)

같은 특징을 가지고 있지만
-> pick up finer attribute
difference


03

논문 내용


- 1.fine grained attribute에 대한 정보의 손실을 이전 연구보다 피함
→ joint representation을 통해서
- 2.PAN 네트워크는 기존 데이터셋의 기존 네트워크보다 정확도가 높아짐
- 3.유사도에 따른 속성에 대한 supervising predictions의 다른 방식의 인사이트
- 4.배치크기에 따른 정확도차이에 대해 서술

PAN Network를 통해서 incomplete attribute label $\rightarrow$ supervisory signal

- PAN Network는 attributes와 같은 추가 데이터셋이 없거나 attribute가 sparse 할 때도 자동으로 학습




1. PAN Network's Image Encoder





1. PAN Network의 Image Encoder

1.1 Convolutional Network를 통해서 : ResNet 으로 feature representation




1. PAN Network의 Image Encoder

1.2 Graph Encoder (GE) : 패션이미지 쪽에서는 CNN으로 피쳐 추출후 그 래프 인코더를 사용해 연관성을 찾는 경우가 많음




1. PAN Network의 Image Encoder

1.3 ProxyNCA++ : GE가 비용적으로 비쌀때 , it relies on annotated categories for images



3 .PAN Network의 CSM 및 최종유사도 값 P



3 .PAN Network의 CSM 및 최종유사도 값 P

이미지 인코더를 통해서 나온 h_1 과 h_2 를 통해 similarity score p 와 relvance weights w

$$\rho = \sigma \left(\mathbf{W}_1^\top |\mathbf{h}_i - \mathbf{h}_j| + \mathbf{b}_1 \right) \quad (1)$$

$$\omega = \text{softmax} \left(\mathbf{W}_2^\top |\mathbf{h}_i - \mathbf{h}_j| + \mathbf{b}_2 \right) \quad (2)$$


$\mathbf{W}_1, \mathbf{W}_2 \in \mathbb{R}^{d \times M}$, and $\mathbf{b}_1, \mathbf{b}_2 \in \mathbb{R}^M$ are learnable parameters.
 w 는 잠재변수, p 는 supervised 속성변수

$$p = \sum_{m=1}^M \rho_m \omega_m = \boldsymbol{\rho}^\top \boldsymbol{\omega}.$$



최종 유사도 값 p 는 다음 값의 합

4. PAN Network의 Defining Similarity Conditions



Unsupervised similarity conditions : h_1, h_2 를 통해(image encoder)

Supervised similarity conditions

: image encoder + M labeled binary attributes, $a_i \in \{0,1\}^M$

$\rightarrow f_a : \{0,1\} \times \{0,1\} \rightarrow [0,1]$ = attribute labels1 + attribute labels2 $\Rightarrow f_a$

$$\mathcal{L}(\mathbf{x}_i, \mathbf{x}_j, e_{i,j}, \mathbf{a}_{i,j}) = \mathcal{L}^{BCE}(e_{i,j}, p) + \lambda \mathcal{L}_{el}^{BCE}(\mathbf{a}_{i,j}, \boldsymbol{\rho}), \quad (4)$$

= unsupervised similarity + supervised similarity

λ is a tunable hyperparameter, $e_{i,j} \Rightarrow$ ground truth similarity label between images x_i and x_j ,

→ 람다에 따른 PAN model 의 민감도

1 Polyvore Outfits

- 53K outfits (sets of fashion items) for training, 5K for validation and 10K for testing. 205 sparsely annotated **attributes**
- task1_FITB(Fill In The Blank) : 4가지 선택지 중에서 현재 있는 패션과 어울리는 선택지를 찾는 것 : Performance는 얼마나 자주 정답이 맞는지로 측정
- task2_outfit compatibility : 패션이 잘 compatible하는지 확인하는 것 AUC의 지표로 측정

Fill in the Blank



Fashion Compatibility Prediction




- 기존 polyvore outfit의 데이터셋에는 두 task 모두 perfect performance를 보임
- → **PAN 논문 dataset** : 기존의 데이터 셋보다 어렵게 만들
- task1 : 4개의 후보군에서 10개의 후보군으로 늘림
- task2 : 모든 항목을 달리해 부정적인 데이터셋을 만드는 것에 반해, 한 카테고리만 다르게 하여 더 어려운 데이터셋을 생성

2 CUB-200-2011

- 200개의 class (100개 트레인, 50개 val, 50개 novel), 312 fine-grained binary attributes (4점 척도의 신뢰도 점수/ 신뢰도 점수가 2점 이하인것은은 삭제)
- 5-way 5-shot 분류 작업에 이용 → 95% 신뢰도 구간의 무작위 초기화

3 In-Shop Retrieval



- 52,712 images of clothes from 11,967 classes.
- 14,218 query images and 12,612 gallery images for testing.
- training 과 test는 다름
- 463개의 attributes

Polyvore Outfits

	Method	Original		Resampled	
		FITB	AUC	FITB	AUC
(a)	TAN [45]	57.6	0.88	38.1	0.66
	SCE-Net [44]	61.6	0.91	43.4	0.68
	CSA-Net [23]	63.7	0.91	—	—
	CGAE [7]	74.1	0.99	60.8	0.67
(b)	X + Attr. Multitask-GE	73.8	0.99	57.6	0.65
	Attr. Similarity-GE	69.5	0.98	52.9	0.65
	PAN-Unsupervised-GE	78.4	0.99	64.1	0.70
	PAN-Supervised-GE	82.3	0.99	69.7	0.71

Table 1: Comparison of PAN on fashion compatibility on Polyvore Outfits to (a) results reported in prior work or reproduced with the author's code and (b) other PAN and attribute supervision approaches.

CUB-200-2011

	Method	Accuracy
(a)	Baseline++ [4]	83.58
	ProtoNet [40]	87.42
	TriNet [5]	84.10
	TEAM [34]	87.17
	CGAE [7]	88.00 ± 1.13
(b)	X + Attr. Multitask-GE	89.29 ± 0.57
	Attr. Similarity	92.21 ± 0.21
	PAN-Unsupervised	92.60 ± 0.10
	PAN-Supervised	92.77 ± 0.30

Table 2: Comparison of PAN on 5-way 5-shot classification on CUB-200-2011 to (a) results reported in prior work or reproduced with the author's code and (b) other PAN and attribute supervision approaches. Intervals provided are 95% confidence intervals over 3 different runs with different random model initializations

In-Shop Retrieval

	Method	Recall@1
(a)	MS [50]	89.7
	NormSoftMax[55]	89.4
	HORDE [15]	90.4
	Cont. w/M [51]	91.3
	ProxyNCA++[52]	90.9
(b)	ProxyNCA++ & Attr. Multitask	90.8
	ProxyNCA++ & Attr. Similarity	86.4
	ProxyNCA++ & PAN-Unsupervised	91.4
	ProxyNCA++ & PAN-Supervised	92.1

Table 3: Comparison of PAN on In-Shop Clothing Retrieval to (a) results reported in prior work and (b) other PAN and attribute supervision approaches.

•PAN 구조는 FITB와 AUC 모두 높은 정확도를 나타냄 특히 no supervision일때도 유용

Choice of image encoder and image batch (Contribution 4.4)

이전 방법은 해당테스크에 대한 배치 크기와 매개변수의 차이에 따른 일관성이 없었음

Method	Single Batch Training	Polyvore Outfits-Resampled			CUB-200-2011	
		M	FITB	AUC	M	Accuracy
Siamese Network	–	–	36.4	0.63	–	76.87 ± 0.72
X + Attr. Multitask	–	–	37.2	0.63	–	81.96 ± 1.01
Siamese Network	✓	–	44.7	0.69	–	89.01 ± 0.25
X + Attr. Multitask	✓	–	46.1	0.69	–	75.82 ± 0.42
Attr. Similarity	✓	–	31.1	0.63	–	92.21 ± 0.21
PAN-Unsupervised	✓	50	27.3	0.62	200	92.60 ± 0.10
PAN-Supervised	✓	206	28.2	0.62	312	92.77 ± 0.30
X + Attr. Multitask-GE	✓	–	57.6	0.65	–	89.29 ± 0.57
Attr. Similarity-GE	✓	–	52.9	0.65	–	87.02 ± 1.27
PAN-Unsupervised-GE	✓	50	64.1	0.70	200	89.55 ± 0.48
PAN-Supervised-GE	✓	206	69.7	0.71	312	90.16 ± 0.51

Table 4: Effect of batch size and image encoder on performance on the fashion compatibility and few-shot tasks. GE refers to the graph image encoder. Refer to Section 5.2 for discussion.

- by comparing training with the whole training split vs. using minibatches.
- compares the effect of using a graph encoder (GE) instead of a simple CNN(Siamese network trained using a triplet loss)
- polyvore outfit에서는 PAN GE encoder가 , CUB에서는 삼보다 PAN 기반 네트워크

fa에 따른 데이터셋의 특징


Attribute supervision label (f_a)	Polyvore Outfits				CUB-200-2011	In-Shop
	Original		Resampled		Accuracy	R@1
	FITB	AUC	FITB	AUC		
Present in either (<i>OR</i>)	82.4	0.99	69.7	0.71	92.77 $\pm$ 0.27	91.5
Present in both (<i>AND</i>)	76.3	0.98	62.4	0.62	92.61 $\pm$ 0.36	91.6
Present in both or neither (<i>XNOR</i>)	76.1	0.99	60.8	0.66	92.60 $\pm$ 0.41	92.1
Present exclusively in one (<i>XOR</i>)	69.0	0.98	51.8	0.65	92.61 $\pm$ 0.20	91.6
<i>AND</i> concat <i>XOR</i> *	78.9	0.99	64.7	0.71	92.39 $\pm$ 0.13	91.9

Table 5: Effect of different kinds of attribute supervision resulting from different functions f_a . *includes twice the number of similarity conditions as others


•두 이미지에 속성이 있거나 둘 다 없는 경우(즉, XNOR 사용) 유사성 1을 예측하는 것은 직관적인 선택처럼 보임 → 다른 속성을 포함하기 때문에 이미지가 일치할 수 있는 패션 호환성의 Polyvore Outfit 데이터셋은 XNOR이적절하지 않음

•Polyvore 의상의 패션 호환성에서 OR이 가장 우수한 것을 볼 수 있습니다. 특히, OR은 CUB 데이터 세트에서 여전히 XNOR와 경쟁력이 있음을 알 수 있습니다..

PAN sensitivity to λ



(a) FITB accuracy of PAN-Supervised-GE on Polyvore Outfits.



(b) 5-way 5-shot classification accuracy of PAN-Supervised on CUB

- On Polyvore Outfits, PAN-Supervised-GE model performs well when attribute supervision weight is relatively high (best accuracy at $\lambda = 10$).
- CUB $\rightarrow \lambda = 10^{-5}$, which is much lower, indicating relatively lower attribute supervision is optimal for the task.

04

결론

- We saw that PAN's method of decomposing similarity prediction into multiple conditions is general, functions with a range of different image encoders and is flexible in using attribute annotation, possibly sparse, when available
- PAN은 Polyvore Outfits의 패션 아이템 호환성 예측에서 4-9%, CUB에서 5%, In-Shop Clothing에서 1% 이상의 Recall@1 등 세 가지 작업의 다양한 세트에서 최신 기술을 능가
- Attribute가 sparse 할 때도 자동으로 학습 될 수 있다는 것이 포인트 이미지 인코더를 통해 히든 레이어를 함께 정확도를 높이는데 의의

THE

END

감 사 합 니 다
