

ICLR 2022

# **Multitask Prompted Training Enables Zero-Shot Task**

---

딥러닝 논문 읽기 모임

자연어처리 2팀

김수빈(발표자), 박희수, 조진욱, 진명훈, 황경진

# 목차

---

## 1. 배경

- Implicit multitask training
- explicit multitask training

## 2. 접근법

## 3. 실험

- Generalization Performance
- Prompt Robustness

## 4. FLAN vs T0

# 배경

## 기존 연구

---

### 1. Implicit multitask learning

최근 Language model 연구들은 여러 NLP task에서 준수한 zero-shot 성능을 보임

Next word를 예측하는 pretraining 과정에서,

언어 모델은 pretraining corpus 내의 여러 task들에 학습됨

⇒ Unseen task에 대해 일반화할 수 있는 능력을 얻을 수 있다.

#### 한계점

⇒ 충분히 큰 크기의 모델이어야 함

⇒ Prompt wording에 민감함


# 배경

## 기존 연구

### 1. Explicit multitask learning

#### Natural Instructions (Mishra et al., 2021)

multitask prompted training을 통해  
unseen task에 대한 few-shot 성능을 개선한 연구




Natural Instructions 구조  
Task에 대한 설명과 예시가 포함됨

#### FLAN (Wei et al., 2021)

instruction tuning (=multitask prompted training)을 통해  
unseen task에 대한 zero-shot 성능을 개선한 연구

#### Finetune on many tasks ("instruction-tuning")



# 배경

## 기존 연구

### 1. Explicit multitask learning

Q. Prompt로 어떻게 Generalization에 성공하였는가?

..., in explaining the success of prompts, the leading hypothesis is that models learn to understand the prompts as **task instructions** which help them generalize to unseen tasks.

⇒ 이러한 성공은 prompt의 semantic meaningfulness에 민감함

본 논문에서는 prompt는 단지 **natural format** 역할을 할 뿐이라 주장

# Q & A

- 기존의 multi-task training

# T0 Framework

T0 여러 unseen task에 대한 zero-shot 성능을 일반화하기 위한 모델






Figure 1. T0 model and prompt format

# T0 Framework

## T0 vs T5

T0는 T5에 기반한 encoder-decoder 구조의 모델

Classification, Question Answering, Translation 등 여러 task들을 모두 text-to-text task로 접근



T5 (Text-to-Text Transfer Transformer)

: A huge version of the original encoder-decoder Transformer




# T0 Framework

## T0 Architecture

본 연구에서는 LM-adapted T5를 사용

prefix가 주어지면, 모델은 주어진 prefix에 대해 정답을 생성하도록 학습



### Prefix LM 예시

Translate English to German: That is good. Target: Das is gut

prefix  
양방향 Attention

target  
단방향 Attention

# T0 Framework

## Dataset

본 논문에서는 62개의 NLP dataset들을 12개의 task로 분류하여 사용함

unseen task에 대해 성능을 평가하기 위해 8개의 task로 학습 후, 나머지 4개의 task로 성능을 평가함





Figure 2. T0 datasets and task taxonomy.

# T0 Framework

## Dataset


Heuristic하게 분류하여 완벽하지 않음



Training task과 Evaluation task를 완벽하게 분류하는 것은 아직 Open question으로 남아있다.

# T0 Framework

## Dataset



## Held-out task

### Natural Language Inference

사람은 NLI 문제를 직접 학습하여 풀지 않기 때문에,  
Language model의 성능을 평가하기 위해서 NLI task를 explicit하게 학습하지 않음

Coreference Resolution, Word Sense Disambiguation, Sentence Completion도  
같은 이유로 Training task에서 제외함

# T0 Framework

## Prompt Format

각 데이터셋의 input과 target을 자연어 형태로 변환하기 위해 template을 개발하여 사용했음




Figure 3. Prompt templates from the P3 prompt collection

# T0 Framework

## Prompt Format

각 데이터셋의 input과 target을 자연어 형태로 변환하기 위해 template을 개발하여 사용했음

Data

Example

| Key         | Value                                                 |
|-------------|-------------------------------------------------------|
| idx         | 0                                                     |
| label       | 0                                                     |
| span1_index | 0                                                     |
| span1_text  | Mark                                                  |
| span2_index | 13                                                    |
| span2_text  | He                                                    |
| text        | Mark told Pete many lies about himself, which Pete... |

template

```
{{ text }} In the previous sentence, does the pronoun "{{ span2_text.lower() }}" refer to {{ span1_text }}? Yes or no?
```

```
{{ text }} Here, by "{{ span2_text }}" they mean "{{ span1_text }}". Yes or no?
```

```
{{ text }}
```


```
In other words, {{ text.split(" ")[span2_index:] | join(" ") | replace(span2_text, span1_text) }} True or false?
```

# Q & A

- 접근 방법

# Experiments Generalization performance

## 1. 일반화 성능(Generalization performance)이 개선되었는가?



T5 + LM : Baseline

T0 : Baseline + multitask prompted training

T5+LM과 비교했을 때, T0가 더 높은 성능을 보임


Multitask prompted training이 성능 개선을 이루어 냄



# Experiments

## Generalization performance

### 1. 일반화 성능(Generalization performance)이 개선되었는가?



T5 + LM : Baseline

T0 : Baseline + multitask prompted training


GPT-3와 비교했을 때,  
T0가 더 높은 성능을 보이는 경향이 있음

11B 크기의 T0가 175B 크기의 GPT-3보다 높은 성능을 보임

# Experiments

## Generalization performance

### 1. 일반화 성능(Generalization performance)이 개선되었는가?



T5 + LM : Baseline

T0 : Baseline + multitask prompted training


Winogrande와 HellaSwag에서 낮은 성능을 보임

GPT-3는 best prompt에 대한 성능을 보고하였으며,  
본 연구는 best prompt, best case를 선택하는  
cherry picking을 사용하지 않았음

# Experiments Generalization performance

## 1. 일반화 성능(Generalization performance)이 개선되었는가?

BIG-bench는 training task에 포함되지 않은 다양하고 새로운 기술들을 포함



LM : Baseline of BIG-Bench

T5 + LM : Baseline

T0 : Baseline + multitask prompted training

T0+ : T0 + GLUE dataset

T0++ : T0 + GLUE dataset + SuperGLUE dataset


T0 family가 LM보다 높은 성능을 보임

기본적으로  $T0 < T0+ < T0++$ 인 성능을 보임  
그렇지 않은 데이터셋도 존재 (Logical Deduction)

# Experiments Prompt Robustness

## 2. Prompt wording에 견고한 성능을 보이는가? : A/B Study

### 1) 학습에 사용된 Prompt 개수에 따른 T0 성능 비교



$p=0$  : Baseline (T5 + LM)

$p=1$  : 랜덤하게 선택된 한 개의 Prompt에 대한 성능


$p=5.7$  : 모든 original-task prompt에 대한 성능

$p=8.03$  : original-task prompt  
및 non-original-task prompt에 대한 성능

# Experiments Prompt Robustness

## 2. Prompt wording에 견고한 성능을 보이는가? : A/B Study

1) 학습에 사용된 Prompt 개수에 따른 T0 성능 비교



Median performance

대체로 Prompt의 개수가 증가할수록 중앙값이 개선됨


IQR (InterQuartile Range)

대체로 spread가 축소되며 개선된 성능을 보임

# Experiments Prompt Robustness

## 2. Prompt wording에 견고한 성능을 보이는가? : A/B Study

2) 학습에 사용된 데이터셋 개수에 따른 T0 성능 비교





### Median performance과 IQR

데이터셋을 늘린다고 성능이 개선되지는 않음

본 연구에서는 Spread가 커지는 것에 대해,  
데이터셋을 늘렸을 때 개선되는 경우가 있는 반면, 개선되지 않는 경우도 있는데  
이로 인해 spread가 넓어진다고 보고함

# FLAN vs T0


Google의 FLAN    multitask prompted training을 수행함으로써 zero-shot generalization performance를 개선한 연구



# FLAN vs T0

## FLAN


Single heldout task에 대한 성능을 보고함



Decoder-only language model

## T0

Training task와 Heldout task를 고정하여  
Multiple heldout task에 대한 성능을 보고함




Encoder-Decoder Architecture



# FLAN vs T0


## FLAN

8B 크기 이하의 FLAN은  
instruction tuning 이전보다 더 낮은 성능을 보임



## T0

3B 크기의 T0 또한 T5+LM을 능가하는 성능을 보임




# FLAN vs T0

## FLAN

한 줄 이내의 문장으로 이루어진 prompt를 사용


Prompt의 개수가 증가했을 때, 성능에 큰 차이가 없음



## T0

36명의 Contributor마다 각자의 방식으로 자유롭게 template 구성

Prompt의 개수가 증가할 때 성능이 개선됨



# Contribution

---

1. **Massively Multitask prompted training**을 통해  
unseen task에 대한 Zero-Shot 성능을 개선한 T0 제안

“Our core hypothesis is that massively multitask prompted fine-tuning enables strong zero-shot task generalization.”

2. 제안한 프레임워크의 Prompt Robustness를 증명하기 위한 Ablation Study 제공
3. 본 연구에 사용한 Prompt 및 Template 공개

# Q & A

- Experiments
- Contribution 정리

Thank you