

NeurIPS 2023

STABLE REP


Synthetic Images from
Text-to-Image Models Make
Strong Visual Representation Learners

이미지처리팀 | **강인하** 장보아 안가영 김수용 황장훈



PROBLEM STATEMENTS

Good Data improve performance of Machine Learning



(A) Traditional Representation Learning

1990s: 실제 데이터를 얻기 위해서 사진을 찍고 수집하는 데에 많은 노력을 들임


2000s: Web에서 대용량 데이터셋을 얻을 수 있었으나, Noisy하고 Unlabeled 이미지인 경우가 많아 Annotation에 많은 비용 발생함.

2010s: 대용량 Unlabeled 이미지 데이터셋으로 사전 학습하여 Down Stream Task들에서 좋은 성능을 내는 Self-supervised Learning 연구 발전.



PROBLEM STATEMENTS

Good Synthetic Data improve performance of Machine Learning



by Stable Diffusion!
(Text-to-Image)



PROBLEM STATEMENTS

Good Synthetic Data make strong visual representation learners




Figure 3: Training self-supervised methods on synthetic images can be better than, or on par with, real images of the same sample size. **Left:** CC3M dataset; **Right:** CC12M dataset



PROBLEM STATEMENTS

Good Synthetic Data make strong visual representation learners




StableRep: Representation Learning with Stable Diffusion

- 하나의 text prompt로 여러 개의 이미지 생성 가능하므로 손 쉽게 multi-positive pair를 만들 수 있음
- 이를 활용한 Multi-positive Contrastive Learning을 진행했을 때 기존 self-supervised learning 방법들보다 좋은 성능을 보임
- 심지어 Real Dataset으로 학습한 것보다 같은 크기의 Synthetic Dataset으로 학습한 것이 더 좋은 성능을 보임
- Stable Diffusion을 활용하여 생성한 multi-positive pair들이 좋은 visual representation을 추출하는 데에 기여했음을 알 수 있음.

Diffusion Model

: 이미지에 Noise를 여러 단계에 걸쳐 추가하고, 여러 단계에 걸쳐 Noise를 제거함으로써, 입력 이미지와 유사한 확률 분포를 가진 결과 이미지를 생성하는 모델




- **Forward Diffusion Process:** 이미지에서 Fixed 된 정규 분포로 생성된 noise가 추가
- **Reverse Diffusion Process:** Noise로부터 이미지를 복원하는 과정. Reverse Process를 활용하여 이미지 생성 가능



STABLE DIFFUSION

Stable Diffusion Model

: 텍스트를 input으로 받고, 이미지를 output으로 내는 model



- Stable Diffusion 모델은 Latent Diffusion 모델의 일종으로, latent space에서 Denosing을 수행하는 방식을 채택
- **Text Conditioning**
 - Text-to-Image, 즉 text prompt가 이미지를 생성에 관여하기 위해 필요한 것이 Conditioning
 - Conditioning은 Reverse Diffusion 과정에서 Noise Predictor가 추정된 노이즈 혹은 Latent 노이즈를 제거하고 원하는 이미지를 생성할 수 있도록 Noise Predictor를 조정하는 것


Figure 3. We condition LDMs either via concatenation or by a more general cross-attention mechanism. See Sec. 3.3



SELF-SUPERVISED LEARNING (SSL)

Stream of SSL


: instead of finding high-level patterns for clustering, SSL attempts to train general “representations” of input data



SELF-SUPERVISED LEARNING (SSL)

Stream of SSL

: instead of finding high-level patterns for clustering, SSL attempts to train general “representations” of input data



1. Pretext task:

목표 task와 상관 없는 task 수행. 이 과정을 통해 feature extractor를 강화하게 됨.


2. Fine-tuning (or Linear Probing):

실제 목표 task를 수행하는 training을 진행하는 단계



SELF-SUPERVISED LEARNING (SSL)

SimCLR





- Loss: 같은 이미지에서 augmentation된 이미지들의 similarity를 높게 함
- $f, g \rightarrow$ 유의미한 representation 학습 + augmentation에 둔감해지는 방향으로 학습
- f : 유의미한 representation이 학습되는 과정
- g : augmentation으로 인한 변화를 무시하는 방향으로 학습



SELF-SUPERVISED LEARNING (SSL)


Supervised Contrastive Learning





MULTI-POSITIVE CONTRASTIVE LEARNING

Multi-Positive Pair




Single-positive Contrastive loss



MULTI-POSITIVE CONTRASTIVE LEARNING




Multi-Positive Pair



Contrastive Loss between
Text Features and Visual Features

MULTI-POSITIVE CONTRASTIVE LEARNING

Multi-Positive Pair



- 같은 Caption이더라도 다른 Latent Noise를 사용하면 서로 다른 이미지들을 얻을 수 있게 됨.
- 이 이미지들은 같은 Caption으로 생성되었기 때문에 유사한 visual semantic 정보를 담고 있음
- 그렇기 때문에 이 이미지들은 서로 'positive pair'가 됨



MULTI-POSITIVE CONTRASTIVE LEARNING

- n : captions
- m : images
- $n * m$: # of images for each batch

Multi-Positive Contrastive Loss

Algorithm 1 Multi-Pos CL: PyTorch-like Pseudocode

```
# f: encoder: backbone + proj mlp
# tau: temperature

# minibatch x: [n, m, 3, h, w]
# n captions, m images per caption
for x in loader:
    x = augment(x)
    x = cat(unbind(x, dim=1)) # [n*m, 3, h, w]
    h = f(x)

    # compute ground-truth distribution p
    label = range(n * m) %
    p = (label.view(-1, 1) == label.view(1, -1))
    p.fill_diagonal(0) # self masking
    p /= p.sum(1)

    # compute contrastive distribution q
    logits = h @ h.T / tau
    logits.fill_diagonal(-1e9) # self masking
    q = softmax(logits, dim=1)

    H(p, q).backward()

def H(p, q): # cross-entropy
    return - (p * log(q)).sum(1).mean()
```

Notes: $h.T$ is h 's transpose. The ℓ_2 normalization operator is included in the encoder f .

- Multi-positive Contrastive Loss는 p 가 one-hot vector가 되도록 감소시킨다는 점에서 흔히 사용되는 Single-positive Contrastive loss의 Generalized Form이라할 수 있음.
- Multi-positive Contrastive Loss에서는 Label을 활용하지 않고, 같은 캡션에서 생성된 이미지인가 아닌가만 고려한다는 점이 Supervised Contrastive Loss와 다름
- 생성 이미지를 사용하지만, 생성 이미지에도 Data Augmentation을 적용해 줌



MULTI-POSITIVE CONTRASTIVE LEARNING

Multi-Positive Contrastive Loss

- anchor sample: a , (ℓ_2 normalized)
- encoded candidates: $\{b_1, b_2, \dots, b_K\}$, (ℓ_2 normalized)
- contrastive categorical distribution: q
- scalar temperature: τ (hyper-parameter)

Algorithm 1 Multi-Pos CL: PyTorch-like Pseudocode

```
# f: encoder: backbone + proj mlp
# tau: temperature

# minibatch x: [n, m, 3, h, w]
# n captions, m images per caption
for x in loader:
    x = augment(x)
    x = cat(unbind(x, dim=1)) # [n*m, 3, h, w]
    h = f(x)

    # compute ground-truth distribution p
    label = range(n * m) % m
    p = (label.view(-1, 1) == label.view(1, -1)).float()
    p.fill_diagonal(0) # self masking
    p /= p.sum(1)

    # compute contrastive distribution q
    logits = h @ h.T / tau
    logits.fill_diagonal(-1e9) # self masking
    q = softmax(logits, dim=1)

    H(p, q).backward()

def H(p, q): # cross-entropy
    return - (p * log(q)).sum(1).mean()
```

Notes: $h.T$ is h 's transpose. The ℓ_2 normalization operator is included in the encoder f .

- **Multi-positive Contrastive Loss:** GT distribution에 해당하는 p 와 Contrastive distribution에 해당하는 q 간의 Cross-entropy

$$\mathcal{L} = H(p, q) = - \sum_{i=1}^K p_i \log q_i$$

$$q_i = \frac{\exp(a \cdot b_i / \tau)}{\sum_{j=1}^K \exp(a \cdot b_j / \tau)}$$

Categorical Distribution: anchor sample인 a 가 b 와 매칭될 확률을 나타내며, 직관적으로는 encoded candidate들에 대한 *K-way Softmax Classification Distribution*을 뜻함.



MULTI-POSITIVE CONTRASTIVE LEARNING

Multi-Positive Contrastive Loss

- anchor sample: a , (ℓ_2 normalized)
- encoded candidates: $\{b_1, b_2, \dots, b_K\}$, (ℓ_2 normalized)
- contrastive categorical distribution: q
- scalar temperature: τ (hyper-parameter)

Algorithm 1 Multi-Pos CL: PyTorch-like Pseudocode

```
# f: encoder: backbone + proj mlp
# tau: temperature

# minibatch x: [n, m, 3, h, w]
# n captions, m images per caption
for x in loader:
    x = augment(x)
    x = cat(unbind(x, dim=1)) # [n*m, 3, h, w]
    h = f(x)

    # compute ground-truth distribution p
    label = range(n * m) % m
    p = (label.view(-1, 1) == label.view(1, -1)).float()
    p.fill_diagonal(0) # self masking
    p /= p.sum(1)

    # compute contrastive distribution q
    logits = h @ h.T / tau
    logits.fill_diagonal(-1e9) # self masking
    q = softmax(logits, dim=1)

    H(p, q).backward()

def H(p, q): # cross-entropy
    return - (p * log(q)).sum(1).mean()
```

Notes: $h.T$ is h 's transpose. The ℓ_2 normalization operator is included in the encoder f .

- **Multi-positive Contrastive Loss:** GT distribution에 해당하는 p 와 Contrastive distribution에 해당하는 q 간의 Cross-entropy

$$\mathcal{L} = H(p, q) = - \sum_{i=1}^K p_i \log q_i$$

$$p_i = \frac{\mathbb{1}_{\text{match}(a, b_i)}}{\sum_{j=1}^K \mathbb{1}_{\text{match}(a, b_j)}}$$

Ground-truth Categorical Distribution: anchor a 와 매칭되는 candidate가 적어도 하나 이상일 때, anchor와 candidate가 매칭되는지를 확인함.





SETTINGS

Model

- Backbone: ViT 모델 (ViT-B/16)
- Batch Size: 8192 (*i.e.* $m * n = 8192$)
- Optimizer: AdamW

Dataset

Text Prompt:
“Dog”

Pre-generate



- n : captions
- m : images
- $n * m$: # of images for each batch



04. Experiments

SETTINGS

Model

- Backbone: ViT 모델 (ViT-B/16)
- Batch Size: 8192 (*i.e.* $m * n = 8192$)
- Optimizer: AdamW

Dataset

Text Prompt:
“Dog”

Pre-generate



Training

Randomly select 6 images for every iteration



“Dog”



04. Experiments

SETTINGS

Model

- Backbone: ViT 모델 (ViT-B/16)
- Batch Size: 8192 (*i.e.* $m * n = 8192$)
- Optimizer: AdamW

Dataset

Text Prompt:
“Dog”


Pre-generate



Training



2 positive images




SimCLR 3 epochs



StableRep 1 epoch

6 positive images





MAIN RESULTS

Main Results on CC12M and RedCaps

- CLIP은 30 epoch부터 over-fitting이 되기 시작했지만, StableRep은 더 오래 학습하더라도 over-fitting이 되지 않았음
- Real Data로 학습한 SimCLR보다 Synthetic Data로 학습한 SimCLR가 CC12M과 RedCaps에 대해서 각각 2.2%, 1.0%정도 더 높은 성능을 보임
- CLIP의 경우 Synthetic Data로 학습했을 때 CC12M과 RedCaps에 대해서 각각 2.6%, 2.7%정도 성능이 하락함
- 반면에 StableRep의 경우 모든 경우의 다른 모델들보다 더 좋은 성능을 보임

Epochs	CC12M	RedCaps
35	72.8	73.7
70	75.0	76.3
105	75.7	76.7

(c) **Training epochs.** Longer training further improves accuracy.

	Real		Syn		
	SimCLR	CLIP	SimCLR	CLIP	StableRep
acc.	61.5	70.3	63.7	67.8	73.5

(a) CC12M

	Real		Syn		
	SimCLR	CLIP	SimCLR	CLIP	StableRep
acc.	61.8	71.9	62.8	69.2	74.5

(b) RedCaps

Table 1: Comparison under the linear probing protocol on ImageNet [15]; measuring top-1 accuracy on a frozen pre-trained backbone. We compare our StableRep with SimCLR [10] and CLIP [58] with either synthetic or real images, on CC12M [9] and RedCaps [16]. All models are pre-trained with 35 epochs using ViT-B/16 [18].



MAIN RESULTS

Linear Probing on Various Datasets

- 그 외 다양한 데이터셋에 대해서 Linear Probing한 결과도 StableRep이 가장 좋은 성능을 보임

		CIFAR-10	CIFAR-100	Aircraft	Cars	DTD	Flowers	Pets	SUN397	Caltech-101	Food-101	VOC2007	Average
Real	SimCLR	88.3	70.3	47.1	45.5	76.2	92.5	70.1	65.4	83.8	75.0	81.2	72.3
	CLIP	94.0	79.0	53.2	75.8	75.7	96.0	86.7	72.5	92.7	81.6	86.1	81.2
Syn	SimCLR	84.8	65.2	51.0	53.2	74.5	93.3	74.2	65.0	81.7	74.8	81.8	72.7
	CLIP	87.3	69.5	53.5	79.5	75.8	95.4	85.8	69.2	90.9	78.3	84.5	79.1
	StableRep	96.2	84.1	58.3	80.9	78.1	97.2	87.5	73.0	94.6	83.6	87.2	83.7

Table 2: Linear probing experiments on image datasets from various domains. Pre-training is conducted on CC12M, with either synthetic or real images. Best results for each dataset are highlighted with **bold**.



MAIN RESULTS

Few-shot Image Classification

- 5-way, 5-shot classification을 수행
- 10개의 데이터셋 중 9개의 데이터셋에서 가장 좋은 성능을 보이고 있음
- Few-shot Image Classification 결과를 통해 StableRep01 Representation Learning을 잘 했음을 입증할 수 있음.

		CIFAR-10	CIFAR-100	Aircraft	Cars	DTD	Flowers	Pets	SUN397	Caltech-101	Food-101	Average
Real	SimCLR	64.0	70.4	40.7	50.9	82.2	92.1	74.4	94.0	90.4	70.4	73.0
	CLIP	77.5	82.1	62.0	90.9	83.3	97.6	91.1	97.2	98.2	87.0	86.7
Syn	SimCLR	50.0	58.9	45.2	54.2	79.8	92.0	74.6	92.9	89.1	71.0	70.8
	CLIP	63.1	73.5	61.3	92.5	81.7	96.9	91.5	96.7	96.8	82.5	83.7
	StableRep	92.3	91.8	62.6	91.8	86.4	98.2	91.7	97.3	98.8	87.3	89.8

Table 3: Few-shot experiments. We report 5-way, 5-shot classification performance. Best results for each dataset are highlighted with **bold**.



MAIN RESULTS

Semantic Segmentation

- 다른 Downstream task도 잘 수행할 수 있는지 알아보기 위해 Semantic Segmentation 실험 진행
- ImageNet-1k의 Real Images로 학습된 MAE보다 StableRep이 더 좋은 성능을 보이고 있음을 알 수 있음

	MAE	StableRep			
	IN1k, Real	cc12m, 35ep	cc12m, 105ep	redcaps, 35ep	redcaps, 105ep
mIoU	48.1	48.8	49.4	47.3	48.4

Table 4: ADE20k semantic segmentation (mIoU) using UperNet. StableRep models are trained by 35 or 105 SimCLR-equivalent epochs.



ABLATION STUDY

- n : captions
- m : images
- $n * m$: # of images for each batch

최대한 많은 이미지 생성 vs. 최대한 많은 캡션을 사용하여 생성

- 전체 데이터셋의 개수 ($=T$)는 2.7M개, batch size는 8192개로 고정함
- 한 캡션에 대해서 몇 개의 이미지를 생성하는가 ($=l$)와 한 개의 캡션으로 생성된 이미지 중 몇 개의 이미지 중 몇 개의 이미지를 사용해야 하는가 ($=m$)에 대한 실험 진행
- 즉 최대한 많은 positive pair를 사용하는 것이 좋은지, 혹은 최대한 다양한 캡션을 사용하는 것이 좋은지를 알아봄

l	1	2	4	6	8	10
acc.	61.2	64.2	65.6	66.0	66.2	66.2

(a) Given a generation budget T , we use T/l captions and generate l images per caption. When $l = 1$, we train a SimCLR model.

m	1	2	4	6	8	10
acc.	60.5	68.7	69.6	69.6	69.8	69.5

(b) Given a batch size of C , we form each batch by sampling C/m captions and m images per caption. We “abuse” $m = 1$ to represent SimCLR.



ABLATION STUDY

- n : captions
- m : images
- $n * m$: # of images for each batch

최대한 많은 이미지 생성 vs. 최대한 많은 캡션을 사용하여 생성

- 전체 데이터셋의 개수 ($=T$)는 2.7M개, batch size는 8192개로 고정함
- 한 캡션에 대해서 몇 개의 이미지를 생성하는가 ($=l$)와 한 개의 캡션으로 생성된 이미지 중 몇 개의 이미지 중 몇 개의 이미지를 사용해야 하는가 ($=m$)에 대한 실험 진행
- 즉 최대한 많은 positive pair를 사용하는 것이 좋은지, 혹은 최대한 다양한 캡션을 사용하는 것이 좋은지를 알아봄

- ✓ 한 개의 캡션 당 두 개 이상의 이미지를 생성했을 때 더 좋은 성능을 보임
- ✓ l 이 커질수록 더 좋은 성능을 보이고 있었기 때문에 $l=10$ 으로 설정하여 사용
- ✓ l 이 10보다 큰 경우는 성능 차이가 거의 없어 10으로 사용

l	1	2	4	6	8	10
acc.	61.2	64.2	65.6	66.0	66.2	66.2

(a) Given a generation budget T , we use T/l captions and generate l images per caption. When $l = 1$, we train a SimCLR model.

m	1	2	4	6	8	10
acc.	60.5	68.7	69.6	69.6	69.8	69.5

(b) Given a batch size of C , we form each batch by sampling C/m captions and m images per caption. We “abuse” $m = 1$ to represent SimCLR.



ABLATION STUDY

- n : captions
- m : images
- $n * m$: # of images for each batch

최대한 많은 이미지 생성 vs. 최대한 많은 캡션을 사용하여 생성

- 전체 데이터셋의 개수 ($=T$)는 2.7M개, batch size는 8192개로 고정함
- 한 캡션에 대해서 몇 개의 이미지를 생성하는가 ($=l$)와 한 개의 캡션으로 생성된 이미지 중 몇 개의 이미지 중 몇 개의 이미지를 사용해야 하는가 ($=m$)에 대한 실험 진행
- 즉 최대한 많은 positive pair를 사용하는 것이 좋은지, 혹은 최대한 다양한 캡션을 사용하는 것이 좋은지를 알아봄

- ✓ m 이 커지면 positive 비율이 더 커지는 것이므로 representation이 응집되는 경향이 있고, n 이 커질 수록 negative의 비율이 더 많아지는 것이므로 representation 간의 분리성이 더 커짐
- ✓ $m=4$ 이상부터는 성능 차이가 크지 않아 $m=6$ 으로 설정하여 사용함

l	1	2	4	6	8	10
acc.	61.2	64.2	65.6	66.0	66.2	66.2

(a) Given a generation budget T , we use T/l captions and generate l images per caption. When $l = 1$, we train a SimCLR model.

m	1	2	4	6	8	10
acc.	60.5	68.7	69.6	69.6	69.8	69.5

(b) Given a batch size of C , we form each batch by sampling C/m captions and m images per caption. We “abuse” $m = 1$ to represent SimCLR.



ABLATION STUDY

Free-Guidance Scale (w)

- Prompt를 얼마나 따를지 결정하는 Hyper-parameter
- 높은 w 의 경우 representation간의 분리성(=separability)이 더 커진다는 것을 의미함
- 낮은 w 의 경우 representation간의 응집성이 더 커진다는 것을 의미함



Figure 2: The effect of guidance on a mixture of three Gaussians, each mixture component representing data conditioned on a class. The leftmost plot is the non-guided marginal density. Left to right are densities of mixtures of normalized guided conditionals with increasing guidance strength.




ABLATION STUDY

Free-Guidance Scale (w)

- Prompt를 얼마나 따를지 결정하는 Hyper-parameter
- 높은 w의 경우 representation간의 분리성(=separability)이 더 커진다는 것을 의미함
- 낮은 w의 경우 representation간의 응집성이 더 커진다는 것을 의미함

Text Prompt: “A Panda Playing Guitar”





ABLATION STUDY

- Prompt를 얼마나 따를지 결정하는 Hyper-parameter
- 높은 w 의 경우 representation간의 분리성(=separability)이 더 커진다는 것을 의미함
- 낮은 w 의 경우 representation간의 응집성이 더 커진다는 것을 의미함

Case	IN	avg.
small	72.8	82.2
large	70.8	80.4
mixed	71.9	81.5

(a) **Guidance scale w . Smaller w yields better linear accuracy.**

- large scale: $w \in 8, 10$
- small scale: $w \in 2, 3$
- mixed scale: $w \in 2, 3, 4, 5, 6, 8, 10, 12$

- Small Scale의 w 를 사용했을 때 ImageNet 및 Fine-grained Classification Dataset에서 가장 좋은 Linear Transfer Accuracy를 보임
- 작은 w 값을 사용할 경우 이미지 간의 큰 intra-caption variation이 발생함
- 따라서 StableRep이 Stronger Invariance를 학습할 수 있게 되어 높은 성능을 보일 수 있었다고 분석함
- 이와 반대로 SimCLR는 large scale w 를 사용했을 때 가장 좋은 성능을 보였는데, 이를 통해 SimCLR에서는 intra-image invariance만을 사용하여 높은 이미지 퀄리티를 가진 것이 더 도움이 되기 때문이라고 말함



ADDING LANGUAGE SUPERVISION

ImageNet Zero-shot Accuracy



Figure 7: Examples of misalignment between input text and synthesized image, which can lead to suboptimal performance for CLIP trained on synthetic images. **Upper:** require headhammer shark but Stable Diffusion often generates sharks without headhammer; **Lower:** “Andrex Puppies” is a brand of toilet rolls.

- "Head Hammer Shark"에 대한 캡션으로 생성한 이미지에 종종 그냥 "Shark"가 생성된 경우가 있었음
- Toilet Roll (화장지) 브랜드인 "Andrex Puppies"를 생성해 달라고 했지만, 그냥 강아지를 생성한 경우도 있었음
- 이런 Misalignment는 Fine-grained Class들에 대한 성능 저하에 분명히 영향을 끼쳤을 것

ADDING LANGUAGE SUPERVISION

ImageNet Zero-shot Accuracy




Figure 5: ImageNet zero-shot accuracy with different Stable Diffusion generation guidance scale w , using CLIP as pre-training.

- 합성 이미지를 사용한 CLIP이 어떤 원리로 학습되는 것인지를 분석하는 실험 진행
- Guidance Scale w 의 값을 다양하게 변경해 가면서 하나의 캡션 당 하나의 이미지를 생성
- 각 데이터셋으로 CLIP을 학습한 뒤 ImageNet에 대한 zero-shot 성능을 비교함
- 다른 SSL method에서는 높은 w 값에서 좋은 성능을 보였지만, CLIP은 낮은 w 에서 더 좋은 성능을 보이고 있음
- 이전 이미지에서 확인했듯이 낮은 w 값을 쓸 수록 generated image와 caption 간의 misalignment가 발생할 수 있기 때문이라고 말함

ADDING LANGUAGE SUPERVISION

StableRep+




Figure 6: ImageNet linear probing accuracy comparison between StableRep+ on synthetic images and CLIP on real images on LAION subsets. For this experiment, only 2 images are generated for each caption.

- **Multi-positive Contrastive Loss:** GT distribution에 해당하는 p 와 Contrastive distribution에 해당하는 q 간의 Cross-entropy

$$\mathcal{L} = H(p, q) = - \sum_{i=1}^K p_i \log q_i$$

+

$$L_{LangSup} = 0.5 * (L_{i2t} + L_{t2i})$$

StableRep+

Language Supervision

- L_{i2t} : image-to-text contrastive loss
- L_{t2i} : text-to-image contrastive loss



ADDING LANGUAGE SUPERVISION

Fairness and Compositionality

- Fairness를 평가하기 위해 FairFace에 대해 Zero-shot Classification을 수행했을 때, 인종이나 성별에 관계 없는 균등한 결과가 나왔다고 함
- CC12M의 Real Image로 학습한 CLIP의 경우 동남아시아 남성에 대한 정확도가 0.3%밖에 되지 않았지만, CC12M을 활용한 Synthetic Image로 학습한 CLIP의 경우 동남아시아 남성에 대한 정확도가 3.1%로 올라감
- StableRep+의 경우 동남아시아 남성에 대한 정확도가 27.2%로 가장 높은 결과였음
- 합성 데이터로 학습할 경우 worst-class에 대한 정확도를 올리는 데에 도움이 될 수 있다는 것을 알 수 있음

		pre-train data	FairFace			ARO
			mean acc.	best-class acc.	worst-class acc.	relation acc.
cc12m	CLIP	Real	28.2	60.2	0.3	46.4
		Syn	30.4	64.0	3.1	50.0
	StableRep+	Syn	37.2	74.9	10.0	47.3
redcaps	CLIP	Real	9.3	31.1	0.4	59.0
		Syn	22.3	52.4	1.0	56.0
	StableRep+	Syn	27.3	64.4	2.1	52.3

Table 7: Results of fairness and compositionality evaluation.



CONTRIBUTIONS

-  text-to-image 분야의 State-of-the-Art 모델인 Diffusion Model을 사용하여 생성한 Synthetic Image들로 모델을 사전 학습 (Pretraining) 시킨 "StableRep"은 다양한 Down-stream Task에 대해서 좋은 성능을 보임.
-  Stable Diffusion을 활용하여 하나의 캡션에 대해 다양한 Synthetic Image들을 생성할 수 있기 때문에 multi-positive를 활용할 수 있었고, multi-positive contrastive loss를 적용하여 더 좋은 representation을 학습할 수 있었음을 보임.
-  이를 통해 같은 양의 Real Dataset으로만 학습시킨 모델보다 Synthetic Dataset으로 학습한 모델이 더 좋은 성능을 보임.



LIMITATIONS

- 1. Training on Synthetic Images vs. Real Images:** 다른 SSL 방법들을 합성 이미지에서 실제 이미지와 동일한 양으로 훈련하는 효과에 대한 이유를 아직 완전히 이해하지 못했기 때문에, 이 방법이 일반적인 상황에서 적용 가능한지 불확실 함
- 2. Slow Image Generation Process:** 이미지 생성 프로세스가 느림 (GPU에서 이미지당 약 0.8초(A100 GPU) 또는 2.2초(V100 GPU with xFormers)가 걸림). 따라서 매 epoch마다 실시간으로 생성된 이미지로 학습시키는 것이 어려움.
- 3. Semantic Mismatch and Quality of Synthetic Data:** 입력 프롬프트와 생성된 이미지 간의 의미적 불일치 문제가 존재하므로, 이는 합성 데이터의 품질과 유용성에 영향을 미칠 수 있음.
- 4. Potential for Bias and Mode Collapse:** 합성 데이터는 Mode Collapse로 인해 다양한 변형이 부족한 상황에서 특정 유형의 이미지만 생성되는 현상이 생길 수도 있음.
- 5. Challenges with Image Attribution:** 합성 데이터를 사용할 때 이미지 속성을 추적하는 것이 어려울 수 있음 (=합성된 데이터의 특성이나 원본 소스를 명확하게 식별하는 것이 어려울 수 있다)

