

AnyGrasp: Robust and Efficient Grasp Perception in Spatial and Temporal Domains

Hao-Shu Fang, Chenxi Wang, Hongjie Fang, Minghao Gou, Jirong Liu, Hengxu Yan, Wenhai
Liu, Yichen Xie, Cewu Lu

T-RO (Transactions on Robotics)

이미지 처리팀

안종식, 이찬영, 최승준

AnyGrasp?

- 카메라를 통해 수집된 장면에서 집을 물체에 대해 로봇팔이 집을 위치를 추정
- **input: visual → output: poses**



Related Works: Grasp Pose Detection




- 초기 방법은 물체의 2D 또는 3D 정보를 모두 알고 있다면 단순한 기본 도형으로 근사하는 방식을 사용
- 포인트 기반, 점-쌍 기반, 사각형 기반, 잡기 품질 맵 등 다양한 방식으로 발전
- 실제 환경에서 물체의 3D 모델을 얻기 어렵다는 한계
- 학습 기반 방식은 대규모 데이터를 사용하고 특징을 자동으로 추출하여 이러한 어려움을 완화하는 데 도움을 줌.
- 주요 한계: 대부분의 초기 학습 기반 방법은 4-자유도(DoF) 잡기 자세만 생성.
- 4-자유도(DoF): 카메라 평면 위에서의 위치, 회전, 그리퍼의 폭. (ex. 인형 뽑기 + 그리퍼 회전)

Related Works: Grasp Pose Detection

포인트 기반, 점-쌍 기반




A. Saxena, J. Driemeyer, J. Kearns, and A. Ng, "Robotic grasping of novel objects," *Advances in neural information processing systems*, vol. 19, 2006.



Q. V. Le, D. Kamm, A. F. Kara, and A. Y. Ng, "Learning to grasp objects with multiple contact points," in *2010 IEEE International Conference on Robotics and Automation*. IEEE, 2010, pp. 5062–5069.

Related Works: Grasp Pose Detection

사각형 기반





J. Mahler, J. Liang, S. Niyaz, M. Laskey, R. Doan, X. Liu, J. Aparicio, and K. Goldberg, "Dex-net 2.0: Deep learning to plan robust grasps with synthetic point clouds and analytic grasp metrics," in Proceedings of Robotics: Science and Systems (RSS), Cambridge, Massachusetts, July 2017.

Related Works: Continuous Action Learning for Grasping

잡기 자세를 개별적으로 예측하고 동작 계획을 수립하는 기존 방법들과 달리, 센서에서 얻은 관찰 정보(예: 이미지)를 로봇의 모터 명령과 같은 **연속적인 동작**으로 직접 변환

Ex) 최종적인 6d grasp pose vs 각 모터의 pose 명령



Song et al. [43]: 저렴한 휴대용 그리퍼를 사용하여 잡기 동작을 수집.

단점: **도메인 전환(domain shift)** 문제에 취약. 예를 들어, 시뮬레이션 환경에서 학습한 모델이 실제 환경에서 예상치 못한 노이즈나 변화에 제대로 대응하지 못하는 경우가 발생

Related Works: Training Data for 6-DoF Grasping

- 기존 **DexNet, EGAD, Acronym**: 수천 개가 넘는 물체를 포함하는 대규모 시뮬레이션 데이터셋을 구축
- 매년 물체의 수가 계속 증가 실제로 얼마나 많은 가상 훈련용 물체가 필요한지는 불분명하며, 물체의 수가 많아질수록 훈련 과정은 점점 더 부담
- 저자들은 144개의 물체로만 구성된 실제 환경 데이터셋을 사용: 학습시킨 모델이 **인간과 비교해도 손색없는 잡기 성능**
- 잡기 문제를 해결하는 데 있어서 단순히 물체의 양을 늘리는 것보다, 핵심적인(critical) 물체를 식별하고 이를 활용하는 것이 더 중요함.

Anygrasp Design Principles: Problem Definition

- parallel jaw-based grasping에서 grasp pose를 $\mathbf{G} = [\mathbf{R}, \mathbf{t}, \mathbf{w}]$ 로 정의.
- 각각 Rotation (그리퍼 자세), translation (그리퍼 중심 위치), width (그리퍼 사이 물체를 집는 최소 폭)
- 3 + 3 + 1 해서 7-DOF grasp configuration
- 목표: 고정된 n개의 grasp poses에서 최대한 집는 성공률을 높일 수 있도록

$$\{\mathcal{G}_1^*, \mathcal{G}_2^*, \dots, \mathcal{G}_n^*\} = \arg \max_{|\mathbf{G}|=n} \sum_{\mathcal{G}_i \in \mathbf{G}} \text{Prob}(s = 1 | \mathcal{E}, \mathcal{P}, \mathcal{G}_i).$$

- **Temporal:** 시간에 따라 변화하는 경우

$$\{\mathcal{G}_1^*, \mathcal{G}_2^*, \dots, \mathcal{G}_n^*\}^{(t)} = \arg \max_{|\mathbf{G}^t|=n} \sum_{\mathcal{G}_i \in \mathbf{G}^t} \text{Prob}(s = 1 | \mathcal{E}^t, \mathcal{P}^t, \mathcal{G}_i),$$

$$\text{s.t. } \text{dist}(\mathcal{G}_k^t, \mathcal{G}_k^{t-1} | \mathcal{E}^t, \mathcal{E}^{t-1}) \leq \delta, \forall \mathcal{G}_k^{t-1} \in \mathbf{G}^{t-1},$$

- 시그마는 tolerance error로 이전 잡기 자세와 현재 잡기 자세가 같은 pose인지 아닌지를 인식하는 파라미터

Anygrasp Design Principles: Spatial Continuous Learning

- **이전의 방식:** 그리퍼 공간 내의 잘린(cropped) 로컬 포인트 클라우드만으로 잡기 품질을 판단
- **AnyGrasp:** 전체 장면을 입력으로 사용, 바로 모든 pointcloud 보고 grasp quality를 예측
- **밀집된 잡기 자세**를 예측, 원하는 어떤 위치에서든 실현 가능한 잡기 자세 즉시 추론 -> '공간-연속 학습'(Spatial Continuous Learning)
- **장점:**
 - **물체의 질량 중심(COG) 인식:** AnyGrasp의 네트워크는 전체 장면을 직접 인식함으로써 이러한 인간의 직관을 모델링
 - 각 잡기 자세에 대해 그리퍼 평면에서 물체의 질량 중심까지의 **수직 거리를 예측**
 - **장애물 인식 및 회피:** 물체를 잡기 전에 주변의 **장애물**도 함께 고려하고 충돌을 피함.
 - 잡기 자세 주변에 장애물이 있어 그리퍼가 들어갈 공간이 없다면, 해당 잡기 자세의 품질 점수를 '**0**'으로 설정

Anygrasp Design Principles: Temporal Continuous Learning

- **이전의 방식:** 기존의 샘플링 기반 방법들은 이전 프레임의 잡기 자세에 약간의 변화(disturbance)를 주고, 현재 프레임에서 이 후보들을 평가 -> 계산 효율성을 위해 후보 자세들이 **밀집되어 있지 않고 듬성듬성**했기 때문에, 물체의 가능한 모든 움직임을 커버 X
- **AnyGrasp:** generation-association methodology -> 속도와 정확 보장
- **동작 원리:**
 - **밀집된 잡기 자세 생성:** geometry processing module이 서로 다른 두 시점의 관찰 정보를 바탕으로 장면 전체에 걸쳐 밀집된 잡기 자세를 생성
 - **연관성 점수 계산:** temporal association module은 생성된 잡기 자세와 공간 모델이 인코딩한 형상적 특징을 입력받아 many-to-many association score matrix 생성
 - **일관성 측정:** 연관성 점수는 잡기 대상 물체의 좌표계에서 두 잡기 자세 사이의 **SE(3) (Rotation + Translation)** 거리를 측정하여 시간적 일관성 유지

Anygrasp Design Principles: Training Data

시뮬레이션 데이터

- **장점:** 훈련 데이터 구축이 쉽고 비용이 적게 듦.
- **한계:** 현실 세계의 카메라 노이즈를 반영하지 못해, 실제 환경에서 사용하려면 고가의 정밀한 카메라가 필요.



실제 데이터

- **장점:** 데이터 수집은 어렵지만, **실제 환경의 다양한 노이즈에 강인한 모델**. 특히 저가형 카메라에서도 좋은 성능
- **결론:** 이 논문은 실제 데이터로 직접 학습하여 시뮬레이션 모델보다 훨씬 **높은 성공률과 강인함**.

Method And Matrials: Data Collection And Annotation

GraspNet-1B 데이터셋에 추가로 104개의 새로운 물체로 구성된 168개의 Extra Scenes을 수집하여 데이터셋 구성


GraspNet-1Billion: A Large-Scale Benchmark for General Object Grasping



물체의 3D Mesh는 상용 3D 스캐너로 획득하고, Analytics Antipodal Score를 이용해서 Dense한 Grasp Pose를 계산

Method And Materials: Data Collection And Annotation

Antipodal Grasp: 미끄러지지 않고 안정적으로 버틸수 있는 상태로, 두 개의 gripper finger가 서로 물체의 반대쪽을 잡게 되는데, friction cone이 반대쪽 finger의 normal vector와 겹치는 경우



Antipodal Score: Normal Vector n_1, n_2 와 마찰 계수에 따라 friction cone 확인하여 각 contact point에서 Normal vector와 gripper 방향과 얼마나 잘 맞는지 평가하고, Normal Vector가 Friction Cone 안에 들어오는지 확인


Method And Matirials: Data Collection And Annotation

데이터셋 구축 및 특징

- **데이터셋**: 144개 물체로 구성된 268개 장면(scene) 학습 데이터를 사용.
- **데이터 수집**: 각 장면에 10개 물체를 무작위로 배치하고, 256개 시점에서 이미지를 촬영함.
- **자세(Pose) 및 그립(Grasp)**: 수동으로 6D 물체 자세를 기록하고, 이를 바탕으로 그립 데이터를 획득. 충돌 감지는 그리퍼 모델을 단순화하여 수행.

AnyGrasp 모델 학습 개선 (이전 연구 GSNet 과 비교)

- **Approach Depth**: 0.5cm를 추가해 해상도를 높여 작은 물체도 잘 잡을 수 있게 함.
- **Stable Score**: 물체 무게 중심(COG)에서 그리퍼 면까지의 수직 거리를 정규화한 값으로, 그립의 안정성을 나타냄.



Method And Matrials: Data Collection And Annotation

- **Temporal Association Label:** 잡기자세(Grasp Pose)의 시간적 일관성을 위해 두 frame 사이의 동일한 pose를 표현하기 위한 label을 수행
- 시간적으로 같은 물체에 대한 다른 View Point에서의 Grasp pose가 서로 어떤 관계를 맺는지 Label 수행
- Original Dataset이 동적 장면을 포함하지 않지만 256개의 다른 View Point에서 촬영한 데이터가 있고, 이는 물체 배치는 동일하지만 View Point만 다름.
- 같은 물체에서 나온 **Grasp Pose는 Matching**될 수 있다라는 가정에서 출발

$$\Delta \mathbf{R} = \arccos \frac{\text{trace}(\mathbf{R}_1^\top \mathbf{R}_2) - 1}{2}, \quad (4)$$
$$\Delta \mathbf{t} = \|\mathbf{t}_1 - \mathbf{t}_2\|,$$


where $\mathcal{G}_1 = [\mathbf{R}_1 \ \mathbf{t}_1 \ w_1]$ and $\mathcal{G}_2 = [\mathbf{R}_2 \ \mathbf{t}_2 \ w_2]$ are the transformed grasp poses, $\text{trace}(\cdot)$ is the trace of a matrix, $\Delta \mathbf{R}$ and $\Delta \mathbf{t}$ are the rotation distance and the translation distance respectively. The distance between two grasp poses is defined as

$$d(\mathcal{G}_1, \mathcal{G}_2) = \frac{\Delta \mathbf{t}}{w_{\max}} + \gamma \frac{\Delta \mathbf{R}}{\pi}, \quad (5)$$


where $w_{\max}$ is the maximum gripper width, γ is a distance balancing weight. In practice, we set $w_{\max} = 0.01\text{m}$ and $\gamma = 0.1$. The distance between grasps on different objects is set to infinity.

- R : Roation 행렬 (Gripper 방향), t : Translation Distance (Gripper 중심)
- 두 Grasp Pose 간 Rotation / Translation 변위 정의
- 두 포즈가 얼마나 같은 Grasp Pose인지 판단하기 위해 d를 계산

Method And Matirials: Grasp Perception Model Details



Method And Materials: Geometry Processing Module



- Graspable 영역을 찾고 점수가 높은 일부 점을 선택해 seed(출발점)로 사용해 Grasp 후보 생성

Backbone (Point Encoder, Decoder) -> MLP -> Graspable FPS -> MLP -> Graspable PVS -> Cylinder Grouping -> MLP

Method And Matirials: Geometry Processing Module



- **GSNet과 달라진 점:** GSNet 구조 베이스에 Stable Score 추가
- R, T, w를 바로 구하는게 아니라, GSNet은 이러한 파라미터를 **Grasp Point, View, in-plane rotation, approach depth, width**로 세분화. View: 어느 방향에서 물체를 바라볼지

파이프라인

- **Backbone & 1st MLP & Graspable FPS (Farthest Point Sampling: 하나의 점으로부터 먼거리의 점 샘플링)**
 - Point Cloud 입력 → 3D cov backbone → MLP Block을 통한 objectness mask와 graspable heatmap 생성
 - graspable FPS로 시드 M개 Sampling (M=1024)
- **Graspable PVS (Probablistic View Selection) & Cylinder Grouping**
 - 각 시드마다 View Score 300개를 예측해서 가장 그림 친화적인 View 선택
 - 선택한 View 축을 따라 Cylinder grouping으로 local geometric feature를 모음
- **각 Seed/ View 에서 Grasp pose 세분화**
 - GSNet - 한 그룹에 대해 **48개의 Grasp Pose Score와 48개의 Grasp width** 예측 (48개 : 12개의 in-plane 회전 x 4개의 Approach depth)
 - Anygrasp- Approach Depth를 5단으로 확장했고, 회전 각도별 Stable Score를 함께 예측하도록 마지막 Layer를 수정. (안정성 점수는 Approach Depth와는 무관, 각도별로 공유함)
- **Reparameterize**
 - 최종 점수 = grasp score x (1 - stable score)
 - 예측한 Seed Point, View, in-plane, depth, width 를 R(3x3), t(3), w의 7-DOF Pose로 reparameterize 하고 상위 N개를 최종 후보로 선택

Method And Matirials: Temporal Association Module

- 연속된 두 프레임에서 같은 물체에서, 같은 Grasp Pose가 무엇인지 **correspondence matrix**을 계산하여 산출
- 먼저 각 Grasp Pose마다 하나의 **Feature Vector**를 만듦.
 - **Seed Feature & Grasp Feature** : 두 MLP 결과로 뽑은 Feature
 - **Color Feature (RGB)** : 예측된 Grasp Pose의 방향을 따라 cylinder grouping (K=16개의 Point를 모음)으로 Color Point를 모아 MLP+Pooling 수행
 - **Grasp Pose Prameter(Length = 12)** : GSNet Output, 회전행렬 9개 + Translation Matrix 3개
 - 위 네가지를 Concat 및 MLP를 통해 $c=256$ feature vector로 뽑음
- 두 프레임에서 모든 grasp pair에 대해 cosine sim을 통해 대응 점수 계산 및 대응 matrix 생성
- 추론 시 현재 Frame만 네트워크를 통과해서 직전 프레임의 feature 와 cosine sim 비교하고, 이전 grasp와 유사한 grasp를 획득해서 시간적으로 부드러운 grasp 선택 가능



Method And Matirials: Loss Function, Training Details, PostProcessing

Loss Function


- Geometry module Loss : Softmax, smooth-L1
- **Geometry Module**을 먼저 **from scratch**로 학습하고, 가중치 Freeze 및 temporal module을 point cloud pair 로 학습

Training Details

- 입력 point cloud를 0.005 m voxel로 voxelization, 각 scene 별 $M = 1024$, 각 feature vector 별 $C = 256$, $K = 16$ 로 **cylinder grouping** 수행하도록 설정.
- Adam optim, init learning rate 0.001, "poly" scheduler 사용 (power = 0.9), Deeplab에서 사용
- Geometry module을 먼저 학습하고 freeze, temporal module 학습
- augmentation으로 randome flip, XYZ 축 랜덤이동, 일부객체 제거 등 사용

Detection Postprocessing


- Collision Detection : 상위 100개의 grasp 후보에 대해 gripper를 세개의 큐브로 단순화해 충돌 여부 검사
- Gripper Centering : 양쪽 Finger tip이 동시 접촉하도록 gripper를 이동시켜 물체 밀림 현상 방지
- GPU상에서 병렬연산을 통해 100개의 grasp pose에 대해 80ms 소요



on of the hardware setting in the fish-catching task. An in-

Question?

Experiment: Hardware and Human Subject



정적 실험 (Static Grasping)

- **로봇:** UR5 로봇 팔과 천장에 설치된 **인텔 리얼센스 D415/D435 카메라**를 사용
- **특징:** 특수 부품 대신 누구나 쉽게 구할 수 있는 **탁구채 고무**를 로봇 손가락에 붙여 사용
- **인간과 비교:** 로봇의 시각 인식 능력을 공정하게 평가하기 위해, 사람도 로봇과 똑같은 조건의 집게를 들고, 물체에 닿은 후에는 자세를 고치지 않는 방식(오픈 루프)으로 실험에 참여

동적 실험 (Dynamic Grasping)

- **로봇:** 더 부드러운 움직임이 가능한 **Flexiv Rizon** 로봇 팔을 사용
 - **특징:** 로봇 팔이 시야를 가리는 것을 막고, 가까운 거리 인식을 위해 **L515 카메라**를 로봇 손목에 직접 부착
 - **안전:** 안전을 위해 3D 프린터로 만든 부품을 이용해 그리퍼(집게) 길이를 늘림
- 모든 실험은 **우분투 20.04** 운영체제, **인텔 i9-10900K CPU**, **Nvidia 2060 GPU**가 장착된 컴퓨터에서 **파이썬**으로 개발됨

Experiment: Experimental Procedure

정적 실험 (Static Grasping)

1. **실험 준비** : 아루코 마커를 이용해 카메라와 로봇 팔의 위치를 맞추고, 통 안에 물건들을 무작위로 쏟아놓음
2. **물체 집기 과정** :
 - 로봇이 3D 스캔으로 주변 상황을 인식하고, 물건을 집을 수 있는 여러 방법을 계산
 - 그중 '**가려지지 않고, 안전 구역 안에 있으며, 성공 확률이 가장 높은**' 최적의 방법을 선택
 - 충돌을 피하기 위해, 물체에 바로 접근하지 않고 **10cm** 뒤의 **안전한 지점을 먼저 거쳐** 다가감
 - 물건을 집어서 목표 지점으로 옮기면 '성공'으로 기록

동적 실험 (Dynamic Grasping)

1. **실험 종료 조건** : 로봇이 물건을 집을 방법을 **10번 연속으로 찾지 못하면** 실험이 끝남
2. **인간과 비교** : 로봇의 성능을 비교하기 위해, **사람도 2명이 똑같은 조건으로** 물건 집기 과제를 수행함
3. **미래 위치 예측** :
 - 로봇은 단순히 물고기의 현재 위치를 노리는 것이 아니라, 물고기의 최근 움직임(과거 10개 프레임)을 분석
 - 이 데이터를 바탕으로 물고기의 속도와 방향을 계산하여 **잠시 후 물고기가 어디에 있을지를 예측**
4. **안전한 추적 HOVER** :
 - 예측된 위치를 바로 잡으러 가지 않고, **3.5cm 위에서 안전거리를 유지하며** 물고기를 따라다님
 - 추적 중에 물고기를 건드려 움직임을 방해 X
5. **결정적 순간에 잡기** :
 - 로봇 손이 예측 위치에 충분히 가까워지고(거리 5.5cm, 2cm 이내) 각도가 잘 맞으면(20도 이내), 그 즉시 아래로 내려가 물고기를 잡음

Experiment: Evaluation Metrics

Object	Attempt-Centric Success Rate (%)			Object-Centric Success Rate (%)		
	Dex.	Any.	Human	Dex.	Any.	Human
Hardware	59.3	81.5	91.4	97.2	100.0	100.0
Snack	52.3	100.0	93.9	93.9	100.0	100.0
Ragdoll	87.4	100.0	96.6	100	100.0	100.0
Toy	72.8	93.1	91.8	99.6	99.6	100.0
Household	64.6	85.5	94.4	98.1	100.0	100.0
All	72.2	93.3	93.9	98.9	99.8	100.0

•로봇의 물건 집기 성공 여부를 평가하는 두 가지 기준이 있음

1. 시도 중심 성공률 (Attempt-centric)

• 개념: 로봇이 총 100번을 시도해서 90번 성공했다면 성공률은 90%

• 비유: 야구 선수의 타율과 같음, 시도 하나하나의 성공이 중요함

• 특징: 더 엄격한 평가 방식

2. 객체 중심 성공률 (Object-centric)

• 개념: 통 안에 물건이 10개 있는데, 그중 9개를 집어 올리는 데 성공했다면 성공률은 90%

(그 과정에서 몇 번 실패했는지는 중요하지 않음)

• 비유: 게임의 스테이지 클리어율과 같음, 중간에 몇 번 실패하더라도 결국 목표를 완수했는지가 중요

• 특징: '과제 완수'에 초점을 맞춘 덜 엄격한 평가 방식

이후의 결과에 대해서는 Attempt-Centric Success Rate 방식을 따름.

Experiment: Experimental Results

- 자신들이 개발한 로봇 시스템이 얼마나 뛰어난지 **4가지 관점**에서 테스트
- **일반화** : 처음 보는 새로운 물건이나 다른 종류의 카메라(센서)를 사용해도 잘 작동하는가?
- **정확성** : **사람과 비교했을 때** 얼마나 정확하게 물건을 집는가?
- **일관성** : 마구 움직이는 물체를 얼마나 안정적으로, 끊임 없이 잘 추적하는가?
- **효율성** : 전체 시스템이 얼마나 빠르고 효율적으로 작동하는가?

이 실험은 300개 이상의 일상생활 물건을 이용해 자신들이 개발한 로봇 시스템의 성능을 테스트한 결과

1. 정확도: 인간과 거의 동급

- 로봇의 물건 집기 성공률은 평균 93.3% 로, 인간의 93.9%와 거의 차이가 없었음
- 다만, 인간이 로봇보다 더 꾸준하고 안정적인 성능을 보임





2. 속도: 이전 기술을 압도

- 로봇의 '생각하는 시간'은 0.2초 미만으로 매우 빠름
- **팔 하나로 시간당 900개 이상의 물건을 집어, 팔 두 개로 시간당 300개를 집었던 이전 기술보다 3배 이상 빠름**
(참고로 인간은 시간당 1,000~1,500개를 집을 수 있음)

3. 강건함: 저품질 카메라 사용해도 OK

- 성능이 약간 떨어지는 '노이즈'가 심한 3D 카메라를 사용해도, 시스템은 **문제없이 물건을 잘 집음**
- 이는 실제 장비로 데이터를 수집해 훈련했기 때문에, 시스템이 약간의 오차에 잘 적응하도록 만들어졌다는 것을 의미함

Experiment: Static Scenes




일상 사물에 대한 파지 (grasping) 실험 결과: unseen object에 대해 실험.

다른 깊이 센서(depth sensors)를 사용했을 때의 성능: AnyGrasp가 센서의 노이즈에 얼마나 강건한지를 평가.

Experiment: Static Scenes



(a)



(b)


도전적인 적대적(adversarial) 사물에 대한 성능

적대적 사물 예시: 13개의 object(DexNet2.0) 및 49개의 object(EGAD)인 총 62개의 복잡하고 잡기 어려운 사물들의 예시 - 3D 프린터로 뽑음.

DexNet보다는 낫지만, 그래도 낮아짐.

로봇은 한 번 실패하면 **실패로부터 배우지 못하고 같은 실수를 반복**하는 경향이 있었음. (사람은 실패하면 다른 방법으로 다시 시도함.)

Experiment: Static Scenes




- **깨진 얇은 파편:** 두께 3mm 미만의 깨진 토기 파편을 정리하는 도전적인 과제를 수행.
- **정확성 요구:** 얇은 파편과 노이즈가 많은 깊이 데이터로 인해 매우 높은 파지 정확도를 요구.
- **성공:** 어려운 시나리오에서도 성공적인 파지 성능을 보여주며, 기존 알고리즘이 해결하기 어려웠던 문제를 해결.

Experiment: Dynamic Scenes



(a)



(b)

실험이 어려운 이유



단순히 움직이는 물체를 잡는 것보다 훨씬 어려움

- **미끄러움**: 물 속이라 마찰력이 거의 없어 잡기가 힘들
- **작은 목표물**: 물고기가 작아 매우 정밀해야 함
- **끊임없는 움직임**: 사람은 물건을 건네줄 때 멈춰주지만, 물고기는 계속 움직임
- **시야 방해**: 물 때문에 빛이 굴절되어 3D 카메라의 정확도가 떨어짐

실험 결과

- 이러한 악조건 속에서도 로봇은 **평균 75.5%의 높은 성공률**을 보임
- 단순히 '가장 가까운 목표를 따라가는' 방식과 비교했을 때 더 높은 성공률 (75.5% vs 62.5%)과 빠른 반응 속도를 보임


Experiment: Dynamic Scenes




실패 원인 분석

1. 가장 큰 이유 (약 50%): 잘 잡았지만 너무 미끄러워서 놓침
2. 두 번째 이유: 물고기가 갑자기 속도를 바꿔서 로봇의 예측이 빗나감
3. 기타 이유: 로봇이 비슷한 물고기 두 마리를 혼동하여 목표를 놓침


Experiment: Train in Simulation




(a)



(b)



(c)



(d)


로봇을 **실제 사진**으로 학습시킨 경우와 가상 그래픽(PyRender)으로 학습시킨 경우의 성능 차이, 즉 'Sim-to-Real Gap' 을 분석한 실험

- 가짜 이미지를 더 현실처럼 보이게 하기 위해 데프스에 가우시안 노이즈를 섞는 것도 실험.

- TOP1~TOP50개의 Grasp Pose를 선정해 force-closure analysis 방식(로봇 그리퍼가 물체를 안정적으로 파지했는지 여부 판단)으로 AP(Average Precision)를 구함.

- 한번도 보지 않은 경우에 성능 차이가 더 많이 남.


Experiment: Train in Simulation



로봇을 **실제 사진**으로 학습시킨 경우와 가상 그래픽(PyRender)으로 학습시킨 경우의 성능 차이, 즉 'Sim-to-Real Gap' 을 분석한 실험

- 가짜 이미지를 더 현실처럼 보이게 하기 위해 데스에 가우시안 노이즈를 섞는 것도 실험.
- 시뮬레이션으로 학습한 경우 성능이 실제 Grasp시 더 많이 떨어짐.

Experiment: Train in Simulation



로봇이 물건을 잡을 때 '**무게 중심**'을 고려하는 것이 얼마나 중요한지

실험 대상: 길고 무거운 물체 (무게 중심의 영향이 크기 때문)


실험 방법: 로봇에게 두 가지 방식으로 물건을 25번씩 잡게 함

- **무게 중심 무시:** 그냥 잡기 편한 곳을 잡음
- **무게 중심 고려:** 균형이 잘 잡히는 무게 중심 근처를 잡음


결론

- 무게 중심을 **무시**하고 잡았을 때 -> **16번** 미끄러짐
- 무게 중심을 **고려**하고 잡았을 때 -> **11번** 미끄러짐
- 물체의 무게 중심을 알고 잡는 것이 훨씬 더 안정적이며, 물건이 미끄러지거나 떨어질 확률을 줄여줌


Experiment: Dense Supervision Strategy




(a)



(b)



(c)



(d)

AI 학습 데이터의 세 가지 요소를 줄여보며 무엇이 가장 중요한지 비교함

- **pose의 양**: 한 물체를 잡는 방법을 몇 가지나 알려주는가?
- **이미지의 양**: 학습에 사용하는 사진의 총 개수
- **장면의 다양성**: 얼마나 다양한 상황(물체 배치)을 보여주는가?


결과 1(주석 vs 이미지): pose의 양을 줄이는 것은 이미지의 양'을 줄이는 것과 거의 똑같이 성능을 떨어뜨림

- **결론**: '얼마나 많은 잡는 법을 알려주는가' 는 '얼마나 많은 사진을 보여주는가' 만큼이나 동등하게 중요

결과 2(장면의 중요성): '장면의 다양성' 을 줄였을 때, 성능이 가장 크게 하락 (학습용 장면이 단 2개일 때는 아예 학습에 실패함)

- **결론**: 로봇 AI에게는 단순히 정보의 양보다 '얼마나 다채롭고 다양한 상황'을 경험하게 하는지가 가장 중요할 수 있음

Experiment: Comparison with 6D Pose Tracking



로봇이 움직이는 물체를 잡을 때, "물체 전체"를 추적하는 것과 "잡을 지점"만 추적하는 것 중 무엇이 더 나은지에 대해 설명 -> '잡을 지점'만 추적하는 방식이 더 우월하다고 주장

"잡을 지점"만 추적하는 것이 더 좋은 이유

- **변형되는 물체에 강함**

- **물체 전체:** 봉지 과자나 천처럼 모양이 찌그러지는 물체는 전체적인 자세를 정의하기 어려워 추적에 실패
- **잡을 지점:** 물체 전체 모양과 상관없이, 잡을 수 있는 그 부분만 보이면 되므로 문제가 없음

- **가려진 물체에 강함**

- **물체 전체:** 물체의 일부가 다른 것에 가려져 안 보이면, 전체적인 자세를 파악하기 힘들어 추적에 실패할 수 있음
- **잡을 지점:** 물체의 대부분이 가려져 있어도, 내가 잡으려는 그 부분만 보인다면 추적하고 잡는 데 문제가 없음

→ 결론적으로, '잡을 지점'만 추적하는 방식이 다양한 실제 상황에서 더 유연하고 안정적으로 작동할 수 있음

Experiment: Closed-loop Grasp Adjustment under Occlusion + Conclusion

- **폐쇄 루프란:** 사람처럼 로봇이 물체를 잡는 동안 지속적으로 시각 피드백을 받아 파지 자세를 조정.
- **AnyGrasp의 한계:** AnyGrasp는 연속적인 파지 예측을 통해 폐쇄 루프 파지가 가능하지만, 로봇 그리퍼가 물체를 가릴 때(occlusion), 시각 센서가 대상을 인식하지 못해 파지가 실패.
- **향후 연구:** 이러한 시각적 한계를 극복하기 위해 촉각 센서(tactile perception)를 이용한 미끄러짐 감지 및 파지 조정 기능이 필요하며, 이는 향후 연구 과제.

AnyGrasp의 주요 성과:

- **고밀도 및 연속적인 파지 예측:** 공간적으로 밀도 높고 시간적으로 부드러운 파지 포즈를 생성합니다.
- **통합 모델:** 기하학적 정보 처리와 시간적 연관성 모듈을 결합한 통합 모델을 제안합니다.
- **강건성:** 실제 데이터 학습 덕분에 다양한 센서 노이즈에 강한 성능을 보입니다.
- **효율성:** 정확하고, 강건하며, 효율적인 파지 시스템임을 실험으로 입증했습니다.
- **향후 과제:**
 - 시각/촉각 피드백을 이용한 파지 오류 복구 기능 개발.
 - 두 손가락 그리퍼 외에 다양한 로봇 핸드로 기술을 확장하는 연구.

Thank you!