

APHQ-ViT: Post-Training Quantization with Average Perturbation Hessian Based Reconstruction for Vision Transformers

발표자 : 이진주

자료조사 : 최승준, 이찬영, 허정원, 황장훈

Introduction

➡ 연구 배경

Transformer의 성공(NLP) → 비전 분야(분류/검출/인스턴스 분할)로 확산

ViT는 성능은 뛰어나지만 연산량·메모리 요구가 커서 자원 제한 디바이스 배포가 어려움

모델 양자화는 FP → 저비트로 변환해 추론 비용을 줄이는 유망한 방법

➡ QAT vs PTQ

QAT: 전체 데이터로 end-to-end 학습 → 정확도는 높지만 시간/자원 소모 크고 데이터 접근 필요

PTQ: 소량의 라벨 없는 calibration 데이터만 사용 → 적용이 쉬움

PTQ는 calibration-only 방식과 reconstruction-based(짧은 fine-tuning 포함) 방식으로 구분되며, 후자가 보통 더 정확함

Introduction

▶ ViT에서 reconstruction-based PTQ가 겪는 핵심 한계 2가지

1. 출력 중요도(output importance) 추정 실패

- 기존 block-reconstruction은 양자화 블록 출력이 FP 출력과 같게 하려 AdaRound 등을 최적화
- 주로 MSE를 쓰는데, 모든 토큰/채널을 동일 중요도로 취급
- ViT에서는 class token 중요 + 채널별 중요도 차이가 커서 MSE가 비효율적
- Fisher/Hessian 기반 중요도 반영 시도도 있으나 Hessian 근사 오차로 MSE보다 못한 경우 존재

2. post-GELU activation 양자화 성능 저하

- post-GELU 분포는 불균형(음수는 좁은 구간에 밀집, 양수는 sparse)
 - 레이어별 activation range 변동이 큼(일부 레이어는 매우 큰 값)
 - twin-uniform(양/음 분리)·log quantizer 등 시도가 있으나 특수 하드웨어 지원 필요로 실용성 제한
-

Introduction

▶ 제안: APHQ-ViT


- ViT PTQ를 위한 새로운 방법 APHQ-ViT
- 출력 중요도 문제 → Average Perturbation Hessian(APH) loss로 block reconstruction 안정화/정확도 향상
- post-GELU 문제 → MLP Reconstruction(MR): MLP의 GELU를 ReLU로 교체 후 재구성
: 가중치 범위는 유지하면서, activation range를 줄이고 분포 불균형 완화 → 양자화 오차 감소

▶ 주요기여


APH loss 제안(블록 재구성 + MLP 재구성에 적용)

MR 제안(GELU 문제 해결, 양자화 친화적 활성화값)

다양한 작업/아키텍처에서 linear quantizer만으로도 3/4bit에서 SOTA 대비 큰 개선



(a) activation statistics of linear layers



(b) activation distribution of *mlp.fc2* (c) weight distribution of *mlp.fc2*

Related Work

방법	분류	타깃	장점	한계
QAT	QAT	전반	정확도 최고 수준	학습비용·데이터 필요
PTQ4ViT	PTQ-Calib	post-GELU	twin-uniform + Hessian scale	특수 quant/저비트 한계
RepQ-ViT	PTQ-Calib	post-LN	채널 변동 직접 대응	구조복잡/초저비트 한계
NoisyQuant	PTQ-Calib	quant error	구현 간단(노이즈)	근본 해결 제한
IGQ-ViT	PTQ-Calib	activation	group-wise로 절충	설정 의존/한계
ERQ	PTQ-Calib	rounding	GPTQ+proxy로 라운딩 개선	구현 복잡/한계
AdaLog	PTQ-Calib	post-GELU	로그(비균일)로 long-tail 대응	HW/지원 제약
AdaRound	PTQ-Recon	rounding	라운딩 최적화로 정확도	ViT 초저비트 취약
BRECQ	PTQ-Recon	block-recon	블록 재구성으로 누적오차	ViT에서 suboptimal
QDrop	PTQ-Recon	recon 안정	act dropout으로 안정화	ultra-low bit 한계
I&S-ViT	PTQ-Recon	안정성	3-stage smooth 최적화	절차 복잡/한계
DopQ-ViT	PTQ-Recon	outlier	스케일 선택으로 outlier 완화	다른 병목 남음
OASQ	PTQ-Recon	outlier	granularity로 outlier 대응	설정 복잡/한계

Proposed Approach

➡ Pipeline Overview

-블록 단위(block-wise) 양자화 파이프라인을 따름
각 블록에서 순서:


1. MLP Reconstruction

: (GELU→ReLU로 바꾸고 작은 데이터로 MLP만 재구성)

2. Quantization Reconstruction

: (QDrop로 양자화하고 AdaRound로 weight rounding 최적화)

두 재구성 모두 APH loss로 “출력 중요도”를 반영



Algorithm 1 APHQ-ViT for Block-wise Quantization.

Input: The full-precision model $\mathcal{M}$, the full-precision block $\mathcal{B}$ to be quantized, the calibration data $\mathcal{D}_{calib}$, and the loss function $\mathcal{L}$.

Calculate the Average Perturbation Hessian:

- 1: Compute the raw output O of $\mathcal{B}$ based on $\mathcal{D}_{calib}$.
- 2: Calculate the perturbed outputs O^+ and O^- .
- 3: Compute $f(O)/f(O^+)/f(O^-)$ by forward passing $O/O^+/O^-$ through the remaining blocks of $\mathcal{M}$.
- 4: Calculate $\mathcal{L}(f(O), f(O^+))$ and $\mathcal{L}(f(O), f(O^-))$ and obtain $\bar{J}(O^+)$ and $\bar{J}(O^-)$ by backward propagation.
- 5: Calculate the average perturbation Hessian matrix $\bar{H}$ based on Eq. (8).

MLP Reconstruction:

- 6: Replace the GELU activation of MLP by ReLU.
- 7: **for** $i = 0, \dots, \text{max_iter}$ **do**
- 8: Calculate O_{Direct} and O_{Clamp} by Eqs. (11) and (12).
- 9: Calculate $\mathcal{L}_{\text{Distill}}$ by Eq. (14).
- 10: Perform backward propagation and update MLP.
- 11: **end for**

Quantization Reconstruction:

- 12: **for** $i = 0, \dots, \text{max_iter}$ **do**
- 13: Calculate the quantized output $\hat{O}$ by QDrop [46].
- 14: Calculate $\mathcal{L}_{\text{APH}}$ based on Eq. (9).
- 15: Perform backward propagation and update the AdaRound [39] weights in $\mathcal{B}$.
- 16: **end for**

Output: The quantized block $\hat{\mathcal{B}}$.

Proposed Approach

➡ 왜 “출력 중요도(importance)”가 핵심인가?

- 기존 block reconstruction은 보통 MSE로 FP 출력과 양자화 출력의 차이를 줄임
 - 하지만 ViT는 토큰/채널 중요도가 균일하지 않음
 - : 어떤 출력 차원의 작은 오차가 최종 성능에 훨씬 큰 영향
 - 따라서 손실 함수가 “모든 차원을 동일하게” 보지 말고
 - 중요한 출력 차원에 더 큰 페널티를 줘야 함
 - APHQ-ViT는 이 중요도를 (대각 diagonal) Hessian 기반으로 추정해 가중치로 사용
-

Proposed Approach

▶ 사전 지식: BRECQ에서의 Hessian-guided loss

BRECQ의 기본 가정: “양자화는 작은 섭동(perturbation)”

BRECQ는 “양자화 후 역양자화된 가중치” 를 다음처럼 가정 : $\widehat{W} = W + \epsilon$

W : 원래 FP 가중치

$\widehat{W}$: 양자화→역양자화된 가중치(실제로는 원래보다 약간 틀어짐)

ϵ : 양자화로 인해 생긴 작은 오차(섭동)

이 가정이 의미하는 바:

- 양자화가 “모델을 완전히 바꾸는 것”이 아니라, 가중치에 작은 잡음이 들어간 것으로 보고
- 그 작은 변화가 손실을 얼마나 증가시키는지를 근사로 계산하겠다는 접근

Proposed Approach

▶ 사전 지식: BRECQ에서의 Hessian-guided loss

Taylor expansion으로 “손실 증가량”을 1차/2차로 근사(Eq.1)

손실 함수 $L(\cdot)$ 는 가중치가 바뀌면 변함

Taylor 전개를 쓰면, 작은 변화 ϵ 에 대해 손실 변화는 대략 :

$$\mathbb{E}[\mathcal{L}(\widehat{W})] - \mathbb{E}[\mathcal{L}(W)] \approx \epsilon^\top \bar{J}^{(W)} + \frac{1}{2} \epsilon^\top \bar{H}^{(W)} \epsilon,$$

각 항의 의미(직관)

$J(W)$: (Jacobian/gradient): “어느 방향으로 바뀌면 손실이 빨리 증가하나?” (1차 민감도)

$H(W)$: (Hessian): “그 민감도가 얼마나 급격히 변하나?” (2차 민감도/곡률)

-> 결론적으로 BRECQ는 “양자화 오차 ϵ ”가 손실을 얼마나 키우는지 2차까지 보겠다는 것

Proposed Approach

▶ 사전 지식: BRECQ에서의 Hessian-guided loss

BRECQ가 Eq.(1)을 실제로 쓰기 위해 하는 근사 (Eq.2로 연결)

실제 사전학습 모델은 이미 수렴했다고 보고, 흔히 다음을 가정:

수렴점 근처에서는 gradient가 작다 $\rightarrow$ 1차항 $\epsilon^T \nabla(W)$ 를 버림

문제: Hessian $H(W)$ 는 계산이 너무 비싸고(파라미터 수가 많음) 직접 구하기 어려움

$\rightarrow$ 그래서 BRECQ는 Hessian을 우회해서 근사한다

결과적으로 얻는 형태가 Eq.(2)이며, 출력 오차에 gradient를 곱한 형태:

$$\mathbb{E}[\mathcal{L}(\hat{W})] - \mathbb{E}[\mathcal{L}(W)] \approx \sum_i \left((\hat{o}_i - o_i) \cdot \frac{\partial \mathcal{L}}{\partial o_i} \right)^2,$$

해석 :

O : 원래 FP 출력

$\hat{O}$: 양자화 $\rightarrow$ 역양자화된 출력

$\partial \mathcal{L} / \partial O_i$: 출력 i 가 손실에 미치는 민감도(gradient)

출력 i 에서 오차가 크고($\hat{O}-O$),

그 출력이 손실에 민감하면

더 큰 페널티를 주는 방식 $\rightarrow$ "중요도 가중"의 시도

Proposed Approach

▶ 사전 지식: BRECQ에서의 Hessian-guided loss

BRECQ Eq.(2) 근사 체인 한계 (왜 ViT에서 MSE보다 못할 수 있나?)

Eq.(2) = 'Hessian 기반 중요도 가중' 아이디어지만, 근사 오류가 큼
근사 체인(2-step)

- Hessian $\approx$ FIM(Fisher Information Matrix)
- FIM(diagonal) $\approx$ (gradient)²

이상적 상황

Task loss가 CE(Cross-Entropy)

모델 예측 분포 $\approx$ 실제 데이터 분포 (거의 일치)

실제 문제점

현실에서는 예측 분포 $\neq$ 실제 분포 $\rightarrow$ 근사 오차 발생
검출/분할 등 CE 구조가 다른 task로 일반화 어려움

결과: ViT에서 BH가 중요도를 잘못 추정할 수 있음

Table 4 근거(W3/A3, ImageNet)

ViT-S / DeiT-S: BH가 MSE 대비 큰 개선 "중요도 가중은 필요"

ViT-B: BH가 MSE보다 더 나쁨 "중요도 추정이 틀리면 성능 하락"
(핵심 사례)

결론(다음 섹션 연결)

"Hessian을 쓰되, FIM/grad² 근사 오류를 줄여야 함"

PH/APH(섭동 기반 Hessian)로 개선 방향 제시

Proposed Approach

➡ Average Perturbation Hessian Loss

APH는 BRECQ처럼 FIM으로 우회하지 않고,

Hessian의 정의(2차 미분) 에서 출발해서 대각 성분만 계산

Hessian-guided loss 한계를 해결하기 위해, 섭동(perturbation) 기반 추정 방법을 개발
대신 계산량을 줄이기 위해 아래 두 가정만 둬:

A.1 (Taylor truncation): 3차 이상 항은 무시 가능

A.2 (Diagonal Hessian): 요소 영향 독립 가정 → full Hessian 대신 diagonal만 사용

결과: FIM 근사 오류를 피하면서도, “importance”를 반영한 loss를 구성

Proposed Approach

➡ Average Perturbation Hessian Loss

원래 BRECQ는 CE 기반 가정이 강함

APH는 양자화를 지식증류(distillation)로 해석해서, 태스크별로 손실을 통일

Classification: logits 간 **KL divergence**

Two-stage detection / instance segmentation:

- classification head: **KL divergence**

- regression head: **Smooth L1 distance**

- 두 항을 결합해 distillation loss 구성

이러한 증류 손실은 $L(\hat{O}, O) \geq 0$ 이며, $O = \hat{O}$ 일 때만 $L(\hat{O}, O) = 0$ 이라는 공통적인 특징을 가짐

- *손실 값은 항상 0이상

- *손실이 0이면, 두 출력이 완전히 동일

- *출력이 완전히 같으면 손실은 당연히 0

Proposed Approach

► Average Perturbation Hessian Loss

$\hat{O}$ 를 “학생 출력”, O 를 “교사 출력”이라 하면 loss $L(\hat{O}, O)$ 는 $\hat{O} = O$ 에서 최소값(0)을 가짐
미분 가능하다면, 최소점에서의 기울기(gradient)는 0:

$$\bar{J}(O) = \left. \frac{\partial \mathcal{L}(\hat{O}, O)}{\partial \hat{O}} \right|_{\hat{O}=O} = 0.$$

의미 :

- 완벽히 따라간 상태($\hat{O} = O$)에서는 더 줄일 방향이 없으니 1차 변화율이 0
 - 그래서 Taylor 전개에서 1차항이 사라질수 있음
 - jacobian 0
-

Proposed Approach

► Average Perturbation Hessian Loss

테일러 전개와 Hessian (식 4):

$$\begin{aligned}\mathcal{L}(O+\epsilon) - \mathcal{L}(O) &= \epsilon^\top \bar{J}^{(O)} + \frac{1}{2} \epsilon^\top \bar{H}^{(O)} \epsilon + O(\|\epsilon\|^3) \\ &= \frac{1}{2} \epsilon^\top \bar{H}^{(O)} \epsilon + O(\|\epsilon\|^3) \approx \frac{1}{2} \epsilon^\top \bar{H}^{(O)} \epsilon,\end{aligned}$$

- 양자화 또는 MLP 재구성에 의해 발생하는 오류(ϵ)를 작은 섭동(perturbation)으로 간주
- 손실 함수 $L(O + \epsilon)$ 를 $L(O)$ 를 기준으로 테일러 전개
- 여기서 $L(O)$ 와 $J(O)$ 는 0이므로, 1차 항 $\epsilon^\top J(O)$ 는 사라지고 2차 항 $\frac{1}{2} \epsilon^\top H(O) \epsilon$ 만 남음
(가정 A.1에 따라 3차 이상의 항 $O(\|\epsilon\|^3)$ 은 무시.)

O : 원본 출력

ϵ : 양자화 등으로 인한 섭동 (오차)

$J^-(O)$: O 에 대한 손실 함수의 야코비안 행렬. 최적 상태에서는 0

$H^-(O)$: O 에 대한 손실 함수의 헤시안 행렬.

$O(\|\epsilon\|^3)$: 3차 이상의 고차 미분 항. 가정 A.1에 따라 무시

작은 오차가 있을 때 loss가 얼마나 증가하는지는 “곡률(curvature)”인 Hessian이 결정, 즉 Hessian은 “출력 중요도”로 해석 가능

Proposed Approach

► Average Perturbation Hessian Loss

대각 Hessian 계산 (A.2 적용: full Hessian 대신 diagonal만 사용)

가정 A.2에 따라 block-diagonal Hessian을 사용하고, 블록 간 의존성(inter-block dependency)은 무시
full Hessian은 $d \times d$ 라서 계산 비용이 큼

Hessian의 대각 성분은 손실의 2차 편미분으로 정의:

$$\bar{H}_{i,i}^{(O)} = \frac{\partial^2 \mathcal{L}}{\partial O_i^2} = \frac{\partial}{\partial O_i} \left(\frac{\partial \mathcal{L}}{\partial O_i} \right).$$

해석 :

값이 클수록 그 출력 차원의 오차가 더 치명적(importance↑), i 번째 출력이 조금 틀어졌을 때 loss가 얼마나 민감하게 변하는지

Proposed Approach

► Average Perturbation Hessian Loss

Hessian diagonal을 “섭동 + 역전파”로 근사

목표 : $-H(O)_{(i,i)}$ 계산

방법 : 출력 O 에 작은 섭동 $\Delta O = 10^{-6}$ 를 적용해 두 개의 perturbed output 생성

$O^+ = O + \Delta O \cdot \mathbf{1}$ and $O^- = O - \Delta O \cdot \mathbf{1}$ ($\mathbf{1}$ 은 모든 요소가 1인 벡터).

각각에 대해 loss를 뒤쪽 네트워크까지 통과시켜(논문 Algorithm1의 $f(O)$ 개념) 역전파로 Jacobian(gradient) 계산

평균값 정리 기반 중앙차분 :

$$\bar{H}_{i,i}^{(O')} = \frac{\bar{J}_i^{(O^+)} - \bar{J}_i^{(O^-)}}{2 \cdot \Delta O_i},$$

$\bar{J}^{(O^+)}, \bar{J}^{(O^-)}$: O^+ 와 O^- 에서의 야코비안 행렬. 역전파(backward-propagation)를 통해 계산.

ΔO_i : i 번째 요소의 섭동량.

-> FIM을 쓰지 않고, “정의에 가까운 방식(gradient 차분)”으로 Hessian 대각을 얻음

Proposed Approach

► Average Perturbation Hessian Loss

Perturbation Hessian Loss: L_{PH} : “오차² × Hessian 중요도”

샘플 하나에 대해 Hessian 대각을 얻었으면 중요도 가중 reconstruction loss를 구성:

$$\mathcal{L}_{\text{PH}} = \sum_i \left(\hat{O}_i - O_i \right)^2 \cdot \bar{H}_{i,i}^{(O)}.$$

$\hat{O}$: 양자화/재구성된 출력(de-quantized output)

O : 원본(full-precision) 출력

$H(O)_{(i,i)}$: 출력 i 의 중요도(2차 민감도)

의미 :

- MSE는 $(\hat{O}_i - O_i)^2$ 만 보지만, PH는 여기에 $-H_{(i,i)}$ 를 곱해 “중요한 출력 차원의 오차를 더 크게 벌점” 줌

Proposed Approach

► Average Perturbation Hessian Loss

Average Perturbation Hessian Loss: $\mathcal{L}_{\text{APH}}$: 샘플 평균으로 안정화(variance 감소)

샘플마다 Hessian이 달라지면 학습이 불안정할 수 있음 → 미니배치(또는 calibration set) 평균 Hessian 사용

$$\bar{H}_{i,i} = \frac{1}{N} \sum_{n=1}^N \bar{H}_{i,i}^{(O^{(n)})}, \quad \mathcal{L}_{\text{APH}} = \sum_i \left(\hat{O}_i - O_i \right)^2 \cdot \bar{H}_{i,i},$$

- $O^{(n)}$: n번째 샘플의 출력
- N : 샘플 수(배치 크기/캘리브레이션 샘플 수)

해석 : 각 샘플의 noisy 중요도가 아니라

“캘리브레이션 데이터 평균 중요도”로 가중치 고정

reconstruction이 더 안정적으로 진행

Proposed Approach

➡ Average Perturbation Hessian Loss

이상적으로 L_{APH} 와 L_{PH} 는 다음 성질을 지님

정리 3.1: 특정 독립성 가정 하에서 APH loss의 기댓값은 PH loss의 기댓값과 동일하다: $E[L_{APH}] = E[L_{PH}]$

정리 3.2: mini-batch gradient descent를 사용할 때, 특정 독립성 가정 하에서 APH loss에 대한 양자화 파라미터 θ 의 gradient 분산은 PH보다 작다:

-> mini-batch GD에서 gradient 분산이 줄어 수렴 속도↑ / 학습 안정성↑ 기대

계산비용:

BRECQ Hessian 방식 대비 forward 1회 + backward 1회 추가

전체 training complexity는 유지 → 오버헤드는 작음

장점:

Hessian을 정의에서 직접 추정 → FIM 근사 오류 제거

distillation loss 기반 → classification뿐 아니라 detection/segmentation으로 일반화 가능

Proposed Approach

➡ MLP Reconstruction

문제: ViT에서 post-GELU activation 양자화가 어려운 이유

ViT의 MLP는 보통 GELU를 사용 → post-GELU activation이 초저비트에서 큰 병목

2가지 핵심 문제

1. 분포 불균형(imbalanced distribution)

- 음수 값이 좁은 구간 $(-0.17, 0]$ 에 밀집 → 양자화 근사 오차 증가
- 양수 값은 sparse하게 퍼져 있음

2. 활성화값 범위(range) 변동 큼

- 레이어마다 값의 최대 범위가 크게 달라짐 → 일부 레이어는 큰 값(아웃라이어)로 스케일이 커져 정밀도 손실
-

Proposed Approach

➡ MLP Reconstruction

제안: MLP Reconstruction(MR)의 핵심 아이디어

목표: post-GELU 분포/범위 문제를 동시에 완화해서 양자화 친화적으로 만들기

방법 개요 :

- MLP 안의 GELU를 ReLU로 교체
 - 라벨 없는 calibration 데이터로 feature knowledge distillation 수행
 - MLP를 레이어별로 “개별 재구성”(block 전체가 아니라 MLP 모듈 단위)
 - 출력 중요도 가중치로 APH(평균 섭동 Hessian) 사용
-

Proposed Approach

➡ MLP Reconstruction

왜 GELU → ReLU가 가능한가?

GELU는 깊은 Transformer에서 dying ReLU 위험 때문에 학습 시 자주 사용됨
하지만 ReLU 네트워크도 이론적으로 universal approximation 성질을 가짐

이 논문은 MLP를 레이어별로 얇은 깊이(shallow)로 개별 재구성

→ dying ReLU 문제가 심각하지 않음

→ GELU에 가까운 표현력 유지 가능

Proposed Approach

➡ MLP Reconstruction

Direct Reconstruction Loss (Eq.11): “ReLU MLP 출력이 GELU MLP 출력 따라가게”

ReLU로 바꾼 MLP의 출력이 원래 GELU MLP 출력과 같아지도록 distillation 수행

출력 중요도는 APH -H로 가중(중요한 출력 차원을 더 강하게 맞춤)

$$\mathcal{L}_{\text{Direct}} = (\mathbf{O}_{\text{GELU}} - \mathbf{O}_{\text{Direct}})^2 \odot \bar{\mathbf{H}},$$

정의

- $\mathbf{O}_{\text{Direct}} = \text{FC2}(\text{ReLU}(\text{FC1}(\mathbf{X})))$: ReLU로 재구성한 MLP 출력
 - $\mathbf{O}_{\text{GELU}}$: 원래 GELU MLP 출력(teacher)
 - $-\mathbf{H}$: average perturbation Hessian(출력 중요도)
 - $\odot$: element-wise 곱
-

Proposed Approach

► MLP Reconstruction

Range 문제 대응: Clamp 기반 출력 설계

activation range가 큰 레이어에서 양자화 오차가 커지므로

양수 activation을 p-분위수(p-th percentile)로 제한(clamp)

$$A_{FC2} = \text{ReLU}(\text{FC1}(X)), \quad O_{\text{clamp}} = \text{FC2}(\text{clamp}(A_{FC2}, \text{Quantile}_p(A_{FC2}))).$$

의미

- $\text{Quantile_op}(\cdot)$: 양수 값들의 p-percentile
- clamp로 큰 activation(outlier)을 잘라 effective range를 줄임

Clamp Reconstruction Loss (Eq.13): “클리핑된 출력도 teacher 따라가게”

$$\mathcal{L}_{\text{Clamp}} = (O_{\text{GELU}} - O_{\text{clamp}})^2 \odot H.$$

핵심 : outlier를 줄인상태(O_{clamp})에서도 원래 GELU 출력과의 차이를 줄이도록 학습

Proposed Approach

➡ MLP Reconstruction

최종 MLP Reconstruction Loss (Eq.14)

Direct + Clamp를 결합해 “분포 불균형 + range 문제” 동시 대응

$$\mathcal{L}_{\text{Distill}} = \mathcal{L}_{\text{Direct}} + \alpha \cdot \mathcal{L}_{\text{Clamp}},$$

왜 $\mathcal{L}_{\text{Direct}}$ 가 반드시 필요한가?

- $\mathcal{L}_{\text{Direct}}$ 만 쓰면 hard-clipping 영역에서 gradient가 0에 가까워져 gradient vanishing 발생
 - $\mathcal{L}_{\text{Direct}}$ 는 unclamped activation을 사용 → 학습 신호가 살아있음
 - 결론 : $\mathcal{L}_{\text{Direct}}$ 가 clamp 학습의 안정성을 보장
-

Proposed Approach

➡ MLP Reconstruction

MR의 기대 효과

GELU → ReLU로 분포 불균형 완화 → 양자화 근사 오차 감소

clamp(loss)로 activation range 축소 → 초저비트에서 스케일 손실 감소

출력 중요도는 APH로 가중 → “중요한 출력 차원”을 더 잘 보존

결과적으로 MLP가 “양자화하기 쉬운 형태”로 바뀐 후, 다음 단계(블록 양자화 재구성)로 넘어감

Experimental Results and Analysis

➡ Experimental Results & Analysis — 개요

평가 목표: APHQ-ViT의 PTQ 성능/안정성/효율성 검증

평가 태스크

- ImageNet 분류
- COCO 검출 + 인스턴스 분할

추가 분석

- Ablation(APH, MR 각각의 기여)
 - MR의 추론 효율(속도)
 - 학습 효율(추가 오버헤드)
-

Experimental Results and Analysis

➡ Experimental Setup

Datasets and Models

분류 Datasets : ImageNet

검출/분할 Datasets : COCO

분류 Models (ImageNet): 대표 ViT 계열

- ViT, DeiT, Swin

검출/분할 Models (COCO):

- Mask R-CNN, Cascade Mask R-CNN

- 백본: Swin

Pretrained 모델 소스

분류용 FP ViT: timm, 검출/분할 FP 모델: MMDetection

Calibration set (라벨 없음)

ImageNet: 1024장

COCO: 256장 (기존 PTQ 연구들과 동일 프로토콜)

Experimental Results and Analysis

➡ Experimental Setup

Quantizer 설정

- Weight: channel-wise uniform quantizer
- Activation: layer-wise uniform quantizer
: attention map 포함

학습/최적화 하이퍼파라미터(QDrop 설정 따름)

- batch size: 32
 - lr (activation quantization): $4e-5$
 - lr (tuning weight): $1e-3$
 - max iteration (MR & QDrop recon): 20000
 - clamp percentile (Eq.12): $p = 0.99$
-

Experimental Results and Analysis

Quantization Results on ImageNet

ImageNet에서 ViT PTQ SOTA와 비교

(1) Calibration-only PTQ

- PTQ4ViT, APQ-ViT, RepQ-ViT, ERQ, IGQ-ViT, AdaLog

(2) Reconstruction-based PTQ

- DopQ-ViT, QDrop, OASQ

ImageNet 결과 — 핵심 관찰(4-bit / 3-bit)

[4-bit]

일부 기존 방법: weight/activation quant loss로 정확도 크게 하락

APHQ-ViT: FP 대비 경쟁력 유지 + 기존 방법 consistently outperform

[3-bit]

calibration-only: 대부분 시나리오에서 극단적으로 낮은 성능(예: 0.1%)

reconstruction-based도 어려운 모델(ViT-S, DeiT-T)에서 성능 크게 떨어짐

APHQ-ViT: 32→3bit로 내려가도 정확도 더 안정적으로 유지

- DeiT-T에서 2등(DopQ-ViT) 대비 +10.71% 평균적으로 +7.21% 개선

Method	Opt.	PSQ	PGQ	W/A	ViT-S	ViT-B	DeiT-T	DeiT-S	DeiT-B	Swin-S	Swin-B
Full-Prec.	-	-	-	32/32	81.39	84.54	72.21	79.85	81.80	83.23	85.27
PTQ4ViT [50]	×	TUQ	TUQ	3/3	0.10	0.10	3.50	0.10	31.06	28.69	20.13
RepQ-ViT [27]	×	$\log \sqrt{2}$	Uniform	3/3	0.10	0.10	0.10	0.10	0.10	0.10	0.10
AdaLog [47]	×	AdaLog	AdaLog	3/3	13.88	37.91	31.56	24.47	57.47	64.41	69.75
I&S-ViT [54]	✓	SULQ	Uniform	3/3	45.16	63.77	41.52	55.78	73.30	74.20	69.30
DopQ-ViT [49]	✓	TanQ	Uniform	3/3	54.72	65.76	44.71	59.26	74.91	74.77	69.63
QDrop* [46]	✓	Uniform	Uniform	3/3	38.31	73.79	46.69	52.55	74.32	74.11	75.28
APHQ-ViT(Ours)	✓	Uniform	Uniform	3/3	63.17	76.31	55.42	68.76	76.31	76.10	78.14
PTQ4ViT [50]	×	TUQ	TUQ	4/4	42.57	30.69	36.96	34.08	64.39	76.09	74.02
APQ-ViT [8]	×	MPQ	Uniform	4/4	47.95	41.41	47.94	43.55	67.48	77.15	76.48
RepQ-ViT [27]	×	$\log \sqrt{2}$	Uniform	4/4	65.05	68.48	57.43	69.03	75.61	79.45	78.32
ERQ [55]	×	$\log \sqrt{2}$	Uniform	4/4	68.91	76.63	60.29	72.56	78.23	80.74	82.44
IGQ-ViT [38]	×	GUQ	GUQ	4/4	73.61	79.32	62.45	74.66	79.23	80.98	83.14
AdaLog [47]	×	AdaLog	AdaLog	4/4	72.75	79.68	63.52	72.06	78.03	80.77	82.47
I&S-ViT [54]	✓	SULQ	Uniform	4/4	74.87	80.07	65.21	75.81	79.97	81.17	82.60
DopQ-ViT [49]	✓	TanQ	Uniform	4/4	75.69	80.95	65.54	75.84	80.13	81.71	83.34
QDrop* [46]	✓	Uniform	Uniform	4/4	67.62	82.02	64.95	74.73	79.64	81.03	82.79
OASQ [36]	✓	Unifrom	Uniform	4/4	72.88	76.59	66.31	76.00	78.83	81.02	82.46
APHQ-ViT(Ours)	✓	Uniform	Uniform	4/4	76.07	82.41	66.66	76.40	80.21	81.81	83.42

Experimental Results and Analysis

► Quantization Results on COCO

결과 :

baseline(Uniform quantizer + QDrop만) → 다른 방법(특수 quantizer 사용) 대비 정확도 낮음

APH loss + MR 적용 시 특수 **quantizer**를 쓰는 방법들과 동급 또는 더 좋은 성능

-> “linear/uniform quantizer만 써도, APH+MR로 COCO 테스트에서 성능 확보 가능”

Method	Opt.	PSQ	W/A	Mask R-CNN				Cascade Mask R-CNN			
				Swin-T		Swin-S		Swin-T		Swin-S	
				AP ^b	AP ^m	AP ^b	AP ^m	AP ^b	AP ^m	AP ^b	AP ^m
Full-Precision	-	-	32/32	46.0	41.6	48.5	43.3	50.4	43.7	51.9	45.0
Baseline*	×	Uniform	4/4	34.6	34.2	40.8	38.6	45.9	40.2	47.9	41.6
RepQ-ViT [27]	×	$\log \sqrt{2}$	4/4	36.1	36.0	44.2 _{42.7} [†]	40.2	47.0	41.1	49.3	43.1
ERQ [55]	×	$\log \sqrt{2}$	4/4	36.8	36.6	43.4	40.7	47.9	42.1	50.0	43.6
I&S-ViT [54]	✓	SULQ	4/4	37.5	36.6	43.4	40.3	48.2	42.0	50.3	43.6
DopQ-ViT [49]	✓	TanQ	4/4	37.5	36.5	43.5	40.4	48.2	42.1	50.3	43.7
QDrop* [46]	✓	Uniform	4/4	36.2	35.4	41.6	39.2	47.0	41.3	49.0	42.5
APHQ-ViT (Ours)	✓	Uniform	4/4	38.9	38.1	44.1	41.0	48.9	42.7	50.3	43.7

Experimental Results and Analysis

➡ Ablation Studies - Main Components

APH loss 효과

- QDrop reconstruction에 APH 적용만으로도 top-1 크게 상승
- W3/A3에서 항상 폭(대표 예시)
 - : ViT-S: +20.80%
 - : DeiT-S: +14.85%
 - : DeiT-T: +7.13%

MR 효과

- APH와 결합 시 MR이 추가로 정확도 향상을 “일관되게” 제공

Method	ViT-S	ViT-B	DeiT-T	DeiT-S	Swin-S
Full-Prec.	81.39	84.54	72.21	79.85	81.80
QDrop	38.31	73.79	46.69	52.55	74.11
+APH	59.11	76.05	53.82	67.40	75.44
+APH +MR	63.17	76.31	55.42	68.76	76.10

Experimental Results and Analysis

➡ Ablation Studies - APH vs 다른 loss

비교 loss:

- MSE
- BH(BRECQ-based Hessian, FIM/grad² 근사)
- PH(Perturbation Hessian, averaging 없음)
- APH(Average Perturbation Hessian)

결론:

- PH가 대부분 ViT에서 다른 loss보다 우수
- APH는 PH보다도 추가 개선

의미:

“Hessian 중요도 자체는 유효하지만, 평균화로 안정성/성능이 더 좋아짐”

Method	ViT-S	ViT-B	DeiT-T	DeiT-S	Swin-S
Full-Prec.	81.39	84.54	72.21	79.85	83.23
MSE [46]	38.31	73.79	46.69	52.55	74.11
BH [25]	54.33	66.62	49.27	63.72	75.20
PH	55.14	72.80	52.25	66.12	75.40
APH	59.11	76.05	53.82	67.40	75.44

Experimental Results and Analysis

➡ Ablation Studies - MLP Reconstruction 단독 효과

QDrop 없이 MLP만 레이어별로 재구성(MR만 단독 적용) 했을 때

- (예외) DeiT-T에서 1% 이상 성능 하락
- 그 외 모델들은 정확도 손실 0.5% 미만
- ViT-B는 MR 적용 시 FP보다 성능이 더 높아지기도 함

해석 :

MR 자체가 “모델 표현을 크게 망치지 않고” GELU→ReLU 전환을

가능하게 함

Method	ViT-S	ViT-B	DeiT-T	DeiT-S	Swin-S
Full-Prec.	81.39	84.54	72.21	79.85	83.23
MLP Recon.	80.90	84.84	71.07	79.38	83.12

Experimental Results and Analysis

➡ MR의 Inference Efficiency 분석

MR은 GELU → ReLU 교체

- GELU: 추가 연산 오버헤드 존재
- ReLU: preceding linear layer로 folding 가능

결과: MR은 양자화 정확도 향상 + 추론 가속 둘 다 얻음

벤치마크:

- 8-bit 미만은 특수 HW 필요 → CPU 테스트는 W8A8로 수행
- CPU: Intel i5-12400F

결과: W8A8 자체로 1.4~1.6× speedup, MR 적용 시 추론 효율 추가 개선

Model	AF	Bits	Lat.	TP	SR
DeiT-T	GELU	32	30.93	32.08	×1
	GELU	8	22.34	44.76	× 1.40
	ReLU	8	20.66	48.40	× 1.51
DeiT-S	GELU	32	100.03	9.97	×1
	GELU	8	63.89	15.65	× 1.57
	ReLU	8	58.40	17.12	× 1.72
DeiT-B	GELU	32	346.93	2.88	×1
	GELU	8	217.96	4.59	× 1.59
	ReLU	8	198.80	5.03	× 1.75
Swin-S	GELU	32	255.56	3.90	×1
	GELU	8	180.42	5.54	× 1.42
	ReLU	8	171.88	5.82	× 1.49
Swin-B	GELU	32	411.07	2.43	×1
	GELU	8	282.28	3.54	× 1.44
	ReLU	8	264.38	3.78	× 1.54

Experimental Results and Analysis

► Training Efficiency 논의

MR 때문에 추가 학습 오버헤드가 생기지만 수용 가능
QAT(예: LSQ) 대비:

- 학습 오버헤드 더 적음

데이터 측면:

- 라벨 없는 1024장 calibration만 필요

- QAT처럼 전체 데이터셋 fine-tuning 불필요

결과 :

“QAT급 비용 없이, PTQ 수준 데이터/비용으로 초저비트 성능을 크게 끌어올림”

Model	Method	PTQ	Data Size	Time Cost	Acc.
DeiT-S	LSQ [12]	×	1280 K	~170 h	77.3
	QDrop [46]	✓	1024	47 min	52.6
	APHQ-ViT	✓	1024	62 min	68.8
Swin-S	LSQ [12]	×	1280 K	~450 h	80.6
	QDrop [46]	✓	1024	130 min	74.1
	APHQ-ViT	✓	1024	170 min	76.1

Conclusion

APHQ-ViT 제안: ViT를 위한 PTQ 방법

문제 지적: 기존 Hessian-guided loss는 Hessian 추정이 부정확

해결 1 — APH Loss: Average Perturbation Hessian으로 더 정확/안정적인 중요도 가중 재구성

해결 2 — MR: MLP에서 GELU→ReLU 교체 + activation range 감소로 초저비트 양자화 친화화

효과: 분류/검출/분할 등 다양한 태스크와 ViT 아키텍처에서 유효

핵심 성과: uniform quantizer만으로도 ImageNet 3-bit에서 평균 +7.21% 개선(SOTA 대비)
