

Boosting Cross-spectral Unsupervised Domain Adaptation for Thermal Semantic Segmentation

이미지 처리팀
이찬영 안종식 이진주 최승준 허정원

2025.11.09

Index

1. Introduction

2. Related work

3. Method

4. Experiments

5. Conclusions

1. Introduction

- 자율주행 환경에서의 **Semantic segmentation**
안정적 인식(Robust Perception) 중요 → 인간의 안전과 직결됨
- RGB 이미지 & Thermal 이미지



구분	RGB 이미지	Thermal 이미지
센서 특징	가시광선(Visible Light)을 감지하는 센서 사용	적외선(Infrared Radiation, 열 신호)을 감지하는 센서 사용
주요 정보	색상(Color), 질감(Texture), 밝기(Intensity) 등 시각적 특징	온도(Temperature) 기반의 열 분포
환경 민감도	조명, 악천후, 야간 등 조도 변화에 취약	조도나 날씨 조건에 영향을 거의 받지 않음
이미지 품질	고해상도, 풍부한 세부 정보	상대적으로 저해상도, 질감 정보 부족 (textureless)
주요 한계	어두운 환경에서 성능 급락	세부 객체 구분력 낮고 pseudo-label 품질 불안정

- 하지만, 라벨링 부족이 큰 문제 → 열화상(thermal) 데이터는 픽셀 단위 라벨링이 매우 어렵고 비용이 큼

1. Introduction

최근 연구들은 RGB → Thermal 도메인 적응(UDA) 시도

- 대규모 RGB dataset(Cityscapes)로 학습된 teacher로 thermal student를 학습 → **One-way distillation**



- MS-UDA (Multi-Spectral Unsupervised Domain Adaptation)
 - RGB → RGB : Cityscapes 등 RGB 데이터셋으로 teacher model 학습 (Pseudo-Label generation)
 - RGB → Thermal : pseudo-label을 사용해 thermal student network 학습 (Multi-Spectral Domain Adaptation)
 - Thermal → Thermal : CycleGAN으로 fake night image 생성 → 야간 적응 (Day-to-Night Thermal Image Translation)


1. Introduction

- MS-UDA (Multi-Spectral Unsupervised Domain Adaptation) 한계점
 - RGB → Thermal 단방향 (One-way) 지식 전달로 정보 손실 발생
 - RGB 특징에 치우쳐 Thermal 도메인 특성 반영이 부족
 - 야간 데이터의 pseudo-label 품질 저하 → 성능 급락
 - CycleGAN 기반의 낮 시간 열화상 이미지를 밤 시간 이미지로 합성한 fake night thermal 은 실제 분포를 충분히 반영 못함
- 본 논문의 핵심 : RGB와 Thermal 간 상호보완적 정보를 효율적으로 활용할 수 있을까?
- 본 논문의 제안 방법
 - Masked Mutual Learning (MML) : 불확실한 영역(mask)을 제거하며 RGB & Thermal 간 양방향 지식 교환
 - Cross-spectral Prototypes : 두 스펙트럼의 feature centroid를 공유
 - Prototypical Self-supervised Loss : 야간 이미지에서도 신뢰도 낮은 pseudo-label 대신 prototype 으로 self-learning

1. Introduction

항목	MS-UDA	본 논문 (Ours)
distillation 방식	One-way distillation (RGB -> Thermal)	Two-way distillation (RGB <-> Thermal)
도메인 특성 고려	도메인 특성 무시, 예측값만 distillation	스펙트럼별 특성 고려 & 불확실성 기반 마스킹 (MML) 사용
night 데이터 학습 처리	CycleGAN으로 생성한 가짜 야간 이미지 사용	Prototypical Self-Supervised Loss (PSL) 도입 -> 실제 야간 thermal 이미지 사용, 프로토타입 기반 학습
야간 RGB 의존도	낮은 조도에서 RGB 의존 -> 낮은 성능	Thermal-only PSL 로 야간 성능 개선
손실 함수	Cross-entropy 기반 Segmentation 손실	Cross-entropy + MML + Contrastive + PSL 복합 손실
성능 (MF 기준)	mIOU = 70.4 (Thermal)	mIOU = 76.9 (Thermal)
세부 학습 단계	RGB -> RGB -> Thermal (순차 distillation)	RGB + Thermal 상호 distillation -> 야간 thermal + self-supervision

- 기대
 - 낮/밤 모두 robust한 segmentation
 - label 없는 thermal domain에서도 성능 향상



2. Related work

A. Unsupervised Domain Adaptation

- 정의
 - Supervised → Unsupervised shift : source domain만 label 존재
 - Target domain에는 label이 없지만 성능을 유지해야 함
- 기존 UDA 방식
 - Adversarial Training (GAN) : domain 구분기를 속이도록 feature 분포 정렬 → 불안정한 학습, 세밀한 특성 반영 어려움
 - Self-training : Pseudo-labels을 활용해 반복적으로 개선 → pseudo-labels 오류 누적 위험
- Cross-Spectral UDA의 필요성
 - 대부분의 기존 연구는 동일 모달리티(RGB-RGB) 간 적응
 - 현실에서는 **RGB ↔ Thermal** 간 도메인 전이가 필요함 (ex. 야간 자율주행, 열화상 인식)
- 문제 제기
 - Cross-Spectral은 단순 style gap 이상 : 센서 특성 자체가 다름

2. Related work

MS-UDA (Multi-Spectral Unsupervised Domain Adaptation)

- MS-UDA 소개
 - RGB → Thermal 적응을 3단계 distillation으로 수행
(RGB-RGB adaptation, RGB → Thermal, Thermal → Thermal)
 - 학습된 RGB 기반 모델을 Thermal로 전달하는 teacher-student 방식
- MS-UDA 한계
 - Knowledge distillation이 domain-specific 특성을 고려하지 않음
 - 각 단계에서 성능 저하 발생 (over-simplified transfer)
 - Thermal domain의 특수성 (low-resolution, contrast 부족 등) 무시
- 제안 방향 요약
 - RGB와 Thermal의 상호 보완성(complementary knowledge) 활용
 - Domain-aware filtering : 각 도메인의 약점을 제거하는 지식 정제 구조
 - 목표 : 보다 견고한 feature alignment와 domain generalization

3. Method

A. Overview (Overall Architecture)

- 연구 목표 : 스펙트럼 도메인 간 차이(spectral domain discrepancies) 를 완화하면서 열(thermal) 영상의 semantic segmentation 네트워크를 학습하는 것

→ 이를 위해 저자들은 추론(inference) 시의 효율성을 유지하면서, 훈련(training) 단계에서만 사용되는 여러 가지 향상 기법(enhancements)을 도입





그림 (a)에 제시된 바와 같이, 제안된 방법은 다음 세 부분으로 구성됨

1. 스펙트럼 전용 인코더 (spectral-specific encoder)
2. 가중치 공유 디코더 (weight-shared decoder)
3. 프로토타입 융합 모듈 (prototype-fusion module)

3. Method


- (a) 1단계(Stage 1)에서는, 대규모 RGB 데이터셋에서 사전 학습된 HRNet 이 생성한 의사 라벨 y_{PL} 을 이용하여, RGB 네트워크와 열화상(thermal) 네트워크를 주간(daytime) 데이터로 학습함
- 동시에, 두 student 네트워크 간에 마스킹 기반 상호 학습(Masked Mutual Learning, MML)이 적용되며, 학습 과정 중에 스펙트럼 간 프로토타입 η_{RT} 도 점진적으로 업데이트됨
- (b) 2단계(Stage 2)에서는, (a)에서와 마찬가지로 주간 데이터에 대해 동일한 학습 절차가 수행됨,



회색 실선(gray lines)은 학습 단계에서만 수행되는 과정을 나타내며, 빨간 실선(red lines)은 학습 및 추론 단계 모두에서 수행되는 과정을 나타냄

3. Method

- 구체적으로는, RGB 이미지 x_R 와 열화상 이미지 x_T 가 각각 스펙트럼 전용 인코더 E_θ 에 입력됨 $\rightarrow$ 여기서 $\theta=\{R,T\}$ 는 각각 RGB와 열화상 도메인을 의미
- 인코더 E_θ 는 다중 스케일 특징 맵(multi-scale feature map)을 추출하고, 이후 각 스펙트럼의 특징 맵은 인코더와 디코더 사이에 skip connection을 포함한, 가중치를 공유하는 디코더 D_s 를 통해 전달됨 $\rightarrow$ 이 디코더는 다중 스케일 디코더 특징과 segmentation output 를 생성함
- 그 다음, 우리는 각 스펙트럼 스트림의 예측값 P_θ 과 pseudo-label y_{PL} 간의 크로스 엔트로피 손실 L_{seg} 을 다음과 같이 계산함:



$$L_{seg} = L_R + L_T \quad \text{where}$$

$$L_\theta = -\frac{1}{N} \sum_{p=1}^{H \times W} \sum_{c=1}^C y_{PL}^{(p,c)} \log(P_\theta^{(p,c)}) \quad (1)$$

여기서 H 는 높이(height), W 는 너비(width), N 은 픽셀 수 (number of pixels), C 는 클래스 수(classes)를 나타냄

3. Method

A. Overview (Cross-Spectral Prototypes)

- 먼저, 두 스펙트럼 영역의 잠재 공간을 공유하는 교차 스펙트럼 프로토타입을 생성
- 프로토타입: 특징 임베딩 공간에서 '도로', '하늘', '차량' 과 같은 **각 의미론적 클래스를 대표하는 평균적인 특징 벡터** (feature map의 평균 개념 - $H \times W \times D \rightarrow D$)
- intermediate decoder feature (f_{θ})를 이용해 cross-spectral prototype 인 **n_{RT}** 를 생성

$$\eta_{\theta}^{(c)} = \frac{\sum_{p \in \Omega} f_{\theta}^{(p)} \odot \mathbb{1}[y_{PL}^{(p,c)} = 1]}{\sum_{p \in \Omega} \mathbb{1}[y_{PL}^{(p,c)} = 1]} \quad (2)$$
$$\eta_{RT}^{(c)} = \frac{\eta_R^{(c)} + \eta_T^{(c)}}{2}$$

- 오메가 : confidence가 0.1 보다 높은 pixel의 집합
- dot 연산 : element-wise multiplication
- 1 function : indicator function (if랑 같음)
- $y_{PL}(p,c)$: one hot label
- $n_{\theta}(c)$: class c 에 해당하는 픽셀들의 feature 기대값

3. Method


$$L_{\eta} = L_{\eta_R} + L_{\eta_T} \quad \text{where}$$
$$L_{\eta_{\theta}} = - \sum_{p=1}^{H \times W} \sum_{c=1}^C y_{PL}^{(p,c)} \log \frac{\exp(s(f_{\theta}^{(p)}, \eta_{RT}^{(c)})/\tau)}{\sum_c \exp(s(f_{\theta}^{(p)}, \eta_{RT}^{(c)})/\tau)} \quad (3)$$

- 각 픽셀의 feature가 동일 클래스의 프로토타입으로 끌려가도록 유도하는 동시에 다른 클래스들을 밀어내는 방식을 채택
- s 연산 : consine similarity 구하는 식
- 교차 스펙트럼 프로토타입은 훈련 과정에서 모멘텀 매개변수 0.9를 가진 지수 이동 평균을 사용하여 점진적으로 업데이트되어 더 풍부한 의미적 지식을 포착
- 이 식은 논문에서 제안한 Cross-spectral Prototypical Contrastive Loss를 나타냄

3. Method

B. Boosting Cross-Spectral UDA for Thermal Segmentation (Masked Mutual Learning)

- Thermal Mask가 강하게 나타낸 곳을 RGB Network가 학습
- RGB Mask가 강하게 나타낸 곳을 Thermal Network가 학습



- 사진처럼 사람의 경우는 열화상 카메라가, 자전거의 경우는 RGB 카메라가 더 감지하기 유리함.
- MML(Masked Mutual Learning)의 주된 목표는 두 모델 간에 상호 보완적인 정보만을 공유하고, 각 모델이 자체적으로 불확실하게 예측한 노이즈(오류 지식)의 전파를 차단
- 마스크 두가지 사용 - inter-spectral (다른 이미지끼리), intra-spectral (같은 이미지 내)

3. Method

- inter-spectral mask: uncertainty를 측정하기 위해 $H \times W \times 1$ 의 크기를 가지는 cross-entropy loss map (class 별 확률 loss)을 계산
- 각 student (Thermal), teacher (RGB)에서 각각 생성된 것을 합치고 ($H \times W \times 2$) 이를 softmax로 정규화

$$\mathcal{M}_R^{inter}, \mathcal{M}_T^{inter} = (\text{split} \circ \text{softmax} \circ \text{cat})(-L_R, -L_T). \quad (4)$$

- 상대 spectral보다 더 작은 spectral loss map을 갖고 있다면, 더 많은 weight를 할당하도록
- intra-spectral uncertainty mask : confidence를 계산하여 uncertainty로 사용
- alpha는 2, sigmoid function을 적용해서 신뢰도를 계산
- 다른 spectral이 너무 잘 나오더라도, 부정확한 예측을 filtering 할 수 있음.

$$\mathcal{M}_R^{intra} = \alpha(1 - \sigma(L_R)), \mathcal{M}_T^{intra} = \alpha(1 - \sigma(L_T)) \quad (5)$$

3. Method


$$\begin{aligned} L_{MML} &= L_{KL}(P_R M_T, P_T M_T) \\ &\quad + L_{KL}(P_T M_R, P_R M_R) \\ M_\theta &= \mathcal{M}_\theta^{intra} \odot \mathcal{M}_\theta^{inter}. \end{aligned} \tag{6}$$

- 최종 masked mutual loss는 intra inter spectral uncertainty mask의 KL divergence loss로 구성됨

3. Method

B. Boosting Cross-Spectral UDA for Thermal Segmentation (Prototypical Self-Supervised Learning, PSL)

- 직접 라벨링한 데이터가 없기 때문에, 믿을 수 있는 pseudo-label을 생성하는 것이 중요
- 밤 환경과 같이 빛이 낮은 조건일 때 domain shift로 인한 성능 저하는 student network를 학습시키는데 방해
- MS-UDA는 CycleGAN을 이용해 낮 이미지를 밤으로 전환 → 진짜 밤 이미지의 distribution 을 모델이 학습할 수 없음
- PSL은 segmentation output을 pseudo label로 삼아 prototype이 segmentation output과 비슷하게 나오도록 학습



3. Method

- 이르면 밤의 RGB 이미지와 상관 없이 실제 밤 상황에서의 열화상 이미지 분포를 학습할 수 있음
- 모델이 낮 밤 열화상 이미지 모두 학습 → 다만 낮 이미지는 Stage1과 동일하게 학습
- decoder output을 pseudo label로 삼고, prototype 과의 KL divergence를 loss 로 계산함

$$L_{PSL} = L_{KL}(\tilde{P}_T, P_T) \quad (7)$$

3. Method

C. Training Loss (Stage 1)

- 낮 시간 동안의 데이터를 이용하여 학습
- $\lambda_1 : 0.2, \lambda_2 : 20$ 설정

$$L_{stage1} = L_{seg} + \lambda_1 L_{\eta} + \lambda_2 L_{MML} \quad (8)$$

L_{stage1} 은 낮시간에 대응되는 RGB와 thermal image로 계산

C. Training Loss (Stage 2)

- 믿을만한 pseudo-label의 부재로 밤 시간에는 PSL을 시행
- stage1의 연산도 낮 시간 이미지로 동일하게 수행
- $\lambda_3 : 20$ 설정

$$L_{stage2} = L_{stage1} + \lambda_3 L_{PSL} \quad (9)$$

L_{stage2} 는 밤시간의 thermal image로 계산

4. Experiments

A. Implementation Details (Dataset and Evaluation Metric)

- MS-UDA와 동일한 셋팅으로 Teacher Network를 학습하고, 이를 통해 Pseudo Label을 생성함
 - Teacher Network는 Cityscape (데이터셋) 으로 학습됨
- RGB-T Pair 데이터셋 MF Dataset과 KAIST Multispectral Pedestrian Detection Dataset(KP Dataset)에서 실험 수행
- MF Dataset
 - MF Dataset은 9개의 Class로 구성되어있기 때문에 Cityscape와 중복되는 3개의 Class (자동차, 사람, 자전거)에 대해서는 mIOU를 계산함
 - 이전 방법들은 낮과 밤을 섞은 평가 프로토콜을 사용하지만, MS-UDA는 820개의 주간 이미지를 학습하고, 749개의 야간 이미지를 테스트에 사용함

4. Experiments


A. Implementation Details (Dataset and Evaluation Metric)

- MF Dataset
 - 410개의 주간 이미지를 학습에 사용해 MS-UDA를 재구현 (아래 표기상에 MS-UDA* 임)
 - 모든 Test는 393장의 주간/야간 테스트 이미지에서 수행함
- KP Dataset
 - 도심 주행 장면에서 RGB-T Pair 95,000프레임 (주간 : 62.5K, 야간 32.5K)로 구성된 보행자 탐지용 비디오 데이터셋
 - MS-UDA에서는 세맨틱 세그멘테이션을 위해 Cityscapes와 동일한 19개 클래스로 950장의 이미지를 수동 라벨링 수행
 - MS-UDA 후속논문(CRM)에서 상기 950장을 499장(학습), 140장(검증), 311장(테스트) 로 나누었고, 그 설정 그대로 사용

4. Experiments

A. Implementation Details (Training Details)

- Network 전체 구조 : RTFNet
 - MS-UDA와 동일하게 Encoder-Decoder 구조의 RTFNet을 기본 구조로 채택



- Backbone : ImageNet Pretrained ResNet-50

4. Experiments

A. Implementation Details (Training Details)

- NVIDIA GeForce RTX 3090 GPU 2대, Batch Size 8로 학습 수행
- 1st Stage
 - 초기 학습단계(실험표에서는 "Our w/o Stage 2" 라고 명시됨)에서는 MF Dataset에 대해 120k Iter, KP데이터셋에 대해 500k Iter
 - MS-UDA와 동일하게 학습데이터 Split해서 사용하고, MF Dataset 학습에는 Label이 없는 주간 이미지 410장, KP 데이터셋 학습에는 Label이 없는 주간 이미지 3,283장 사용
 - 추가적으로, CycleGAN으로 생성된 Fake 야간 열영상을 50%확률로 함께 사용함
- 2nd Stage
 - 1단계에서 사용한 Iter의 30% 만큼 추가 학습 수행
 - 추가로 수집한 라벨없는 야간 이미지 374장(MF데이터셋), 3,095장(KP 데이터셋)을 사용하고 CycleGAN 이미지는 사용 안함

4. Experiments

B. Main Results (Quantitative Results on the MF Dataset)

TABLE I

QUANTITATIVE COMPARISON WITH STATE-OF-THE-ART METHODS ON MF DAY-NIGHT EVALUATION SET [4]. (D+N: TRAINING WITH DAYTIME AND NIGHTTIME IMAGES ; R+T: TESTING WITH RGB-T IMAGE PAIRS)

	Method	Train	Test	Car	Person	Bicycle	mIoU↑
Sup.	MFNet [4]	D+N	R+T	65.9	58.9	42.9	55.9
	RTFNet [6]	D+N	R+T	86.3	67.8	58.2	70.7
	MDBFNet [7]	D+N	R+T	85.9	69.2	58.9	71.3
	CENet [5]	D+N	R+T	85.8	70.0	61.4	72.4
	EAEFNet [8]	D+N	R+T	86.8	71.8	62.0	73.5
	CMX [9]	D+N	R+T	<u>90.1</u>	<u>75.2</u>	64.5	76.6
	CRM [10]	D+N	R+T	90.0	75.1	<u>67.0</u>	<u>77.4</u>
UDA	ProCA [11]	D	T	50.8	36.8	14.2	33.9
	DAFormer [12]	D	T	52.0	51.6	38.9	47.5
	MS-UDA* [14]	D	T	82.1	73.4	55.6	70.4
	Ours w/o stage 2	D	T	85.7	78.4	61.0	75.0
	ProCA [11]	D+N	T	48.9	47.1	15.4	37.1
	DAFormer [12]	D+N	T	48.9	55.4	28.9	44.4
	HeatNet [13]	D+N	R+T	56.4	68.8	33.9	53.0
	EKNet [5]	D+N	T	78.6	67.5	51.9	66.0
	Ours	D+N	T	86.2	80.3	64.3	76.9

* We re-implemented MS-UDA with 410 training daytime images

- MF Dataset에 대한 정량적인 결과를 비교하기 위해, HeatNet을 제외한 모든 UDA 방법의 네트워크는 ResNet-50 기반 RTFNet으로 통일함
- 기존 방법과 비교했을 때, 본 논문에서 제시하는 방법이 대부분의 Sup 방법과 모든 UDA방법을 능가함
- 또한, 단일 Thermal Image 입력만 사용하더라도 최신의 Supervised 방법과 유사했음 (CRM)
- ProCA와 DAFormer는 RGB Domain에서는 뛰어난 성능을 보였지만, Cross Spectrum Image에서는 열영상 특성상 성능이 크게 하락함

4. Experiments

B. Main Results (Quantitative Results on the MF Dataset)

TABLE I

QUANTITATIVE COMPARISON WITH STATE-OF-THE-ART METHODS ON MF DAY-NIGHT EVALUATION SET [4]. (D+N: TRAINING WITH DAYTIME AND NIGHTTIME IMAGES ; R+T: TESTING WITH RGB-T IMAGE PAIRS)

	Method	Train	Test	Car	Person	Bicycle	mIoU↑
Sup.	MFNet [4]	D+N	R+T	65.9	58.9	42.9	55.9
	RTFNet [6]	D+N	R+T	86.3	67.8	58.2	70.7
	MDBFNet [7]	D+N	R+T	85.9	69.2	58.9	71.3
	CENet [5]	D+N	R+T	85.8	70.0	61.4	72.4
	EAEFNet [8]	D+N	R+T	86.8	71.8	62.0	73.5
	CMX [9]	D+N	R+T	<u>90.1</u>	<u>75.2</u>	64.5	76.6
	CRM [10]	D+N	R+T	90.0	75.1	<u>67.0</u>	<u>77.4</u>
UDA	ProCA [11]	D	T	50.8	36.8	14.2	33.9
	DAFormer [12]	D	T	52.0	51.6	38.9	47.5
	MS-UDA* [14]	D	T	82.1	73.4	55.6	70.4
	Ours w/o stage 2	D	T	85.7	78.4	61.0	75.0
	ProCA [11]	D+N	T	48.9	47.1	15.4	37.1
	DAFormer [12]	D+N	T	48.9	55.4	28.9	44.4
	HeatNet [13]	D+N	R+T	56.4	68.8	33.9	53.0
	EKNet [5]	D+N	T	78.6	67.5	51.9	66.0
	Ours	D+N	T	86.2	80.3	64.3	76.9

* We re-implemented MS-UDA with 410 training daytime images

- 특히, 자전거에서는 mIOU가 급격히 감소했는데, 열영상 카메라의 낮은 복사율로 인해 객체 감지 한계가 있기 때문임 (금속 프레임)
- 결과에 따르면, RGB-T 간 상호보완적으로 특성을 효과적으로 결합할 수 있는 UDA 전략의 필요성을 시사함
- 추가적으로, Stage 1만 하더라도 SOTA 논문들의 성능을 능가했음 (DayTime 한정)
- 사람이 라벨링하거나, Pretrained Teacher Network 없이도 PSL이 Segmentation 학습을 가능하게 했음을 보여줌

4. Experiments


B. Main Results (Quantitative Results on the KP Dataset)

TABLE II																							
QUANTITATIVE COMPARISON WITH STATE-OF-THE-ART METHODS ON KP DAY-NIGHT EVALUATION SET [3]. (D+N: TRAINING WITH DAYTIME AND NIGHTTIME IMAGES ; R+T: TESTING WITH RGB-T IMAGE PAIRS																							
				Road	Sidewalk	Building	Wall	Fence	Pole	Traffic light	Traffic sign	Vegetation	Terrain	Sky	Person	Rider	Car	Truck	Bus	Train	Motorcycle	Bicycle	mIoU↑
Sup.	MFNet [4]	D+N	R+T	93.5	23.6	75.1	0.0	0.1	9.1	0.0	0.0	69.3	0.2	90.4	24.0	0.0	69.6	0.3	0.3	0.0	0.0	0.6	24.0
	RTFNet [6]	D+N	R+T	94.6	39.4	86.6	0.0	0.6	0.0	0.0	0.0	81.7	3.7	92.8	58.4	0.0	87.7	0.0	0.0	0.0	0.0	0.5	28.7
	CMX [9]	D+N	R+T	97.7	53.8	90.2	0.0	47.1	46.2	10.9	45.1	87.2	34.3	93.5	74.5	0.0	91.6	0.0	59.7	0.0	46.1	0.2	46.2
	CRM [10]	D+N	R+T	99.0	61.9	91.8	0.0	58.7	50.6	39.2	55.3	89.2	23.2	94.3	85.2	2.9	95.3	0.0	80.5	0.0	66.2	54.6	55.2
UDA	DAFormer [12]	D	T	67.5	0.1	0.4	0.0	0.1	1.9	0.0	3.6	22.3	0.4	4.3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	5.3
	ProCA [11]	D	T	71.4	5.0	44.3	0.0	2.0	2.1	0.0	1.3	26.2	2.2	15.6	16.8	0.0	40.8	0.0	0.1	0.0	0.1	0.0	12.0
	MS-UDA [14]	D	T	97.2	25.7	86.3	0.0	31.4	16.5	0.0	28.5	83.1	25.1	92.5	60.8	0.0	85.1	0.0	78.3	0.0	0.0	0.0	37.4
	Ours w/o stage 2	D	T	97.7	33.0	88.7	0.0	35.5	36.4	14.9	46.2	85.6	24.5	94.4	72.2	4.9	88.4	0.0	82.9	0.0	35.3	4.3	44.5
	DAFormer [12]	D+N	T	57.6	0.1	0.0	0.0	0.0	1.0	0.0	4.9	28.8	3.5	19.1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	6.1
	ProCA [11]	D+N	T	74.0	5.3	48.8	0.0	1.4	2.3	0.0	0.3	21.1	2.3	11.6	17.9	0.0	22.5	0.0	0.3	0.0	0.0	0.0	10.9
	Ours	D+N	T	97.8	34.4	88.6	0.0	36.6	35.0	17.9	47.3	85.7	24.5	94.4	71.9	5.5	89.3	0.2	81.7	0.0	56.0	2.6	45.8

- 최신 기법들은 MF데이터셋과 똑같이 Knowledge Distillation 과정에서 Cross Spectrum Mutual Information을 활용하지 않아 성능이 낮음
- 야간의 열영상은 낮보다 Heat Contrast가 낮아 야간에서의 Pseudo Label의 품질저하가 발생하여 일부 Class (Pole, Bus)에서는 다소 낮은 mIOU를 보였지만, PSL을 도입한 2Stage 학습을 통해 대부분의 Class에서 성능 향상 확인

4. Experiments

B. Main Results (Qualitative Results)



- MS-UDA 대비해서 매우 성능 좋음
- 이 결과는 Masked Mutual Learning(MML)이 각 Spectrum의 고유한 한계를 잘 Filtering 하고 효과적으로 상호보완적 Knowledge를 잘 전달했기 때문임.
- 본 논문의 방법은 야간 상황에서 훨씬 더 정확한 예측을 수행했고, 이는 Cross Spectral Prototype과 PSL의 Combination이 RGB 사전학습 모델이 라벨을 생성하기 어려운 어두운 조건에서 효과적임을 보여줌

4. Experiments

C. Ablation Study

ABLATION RESULTS OF COMPONENTS IN OUR PROPOSED FRAMEWORK.

WE REPORT THE MIOU ON MF DATASET [4]

MML	Cross-spectral Prototypes	Stage 2	Thermal			RGB
			Day	Night	All	All
One-way distillation [14]			71.6	67.0	70.4	61.7
Two-way distillation			75.3	67.9	72.8	69.4
✓			76.4	67.4	73.6	69.2
✓	✓		77.2	70.5	75.0	71.1
✓	✓	✓	78.8	73.2	76.9	73.4

MF 데이터셋

- stage 1 (양방향 학습 적용) : One-way를 단순히 Two-way 상호 학습으로 바꾼 것만으로 성능이 72.8%로 크게 향상(양방향 학습이 효과적임을 증명)
- stage 2 (MML 적용) : 이 Two-way 학습에 '불확실한 영역을 거르는' 마스크(MML)를 적용 하자 73.6%로 추가 향상 (MML이 유용함을 증명)
- stage 3 (프로토타입 적용) : 여기에 픽셀 정보를 더 잘 압축하는 '프로토타입' 기술을 더하자 75.0%까지 상승
- stage 4 (PSL 적용) : 마지막으로 '야간 자가 학습'(PSL)을 적용하자, 최종 성능이 76.9%를 달성 (PSL이 야간 성능을 크게 높임을 증명)
- 기준 (기존 SOTA) : 기존 방식(MS-UDA)의 성능은 70.4%

4. Experiments

C. Ablation Study

TABLE V

COMPARISON OF GENERALIZATION PERFORMANCE ACROSS DIVERSE SEGMENTATION NETWORK ARCHITECTURES ON MF DATASET [4]

Network	Method	Car	Person	Bicycle	mIoU↑
RTFNet [6]	MS-UDA* [14]	82.1	73.4	55.6	70.4
	Ours w/o stage 2	85.7	78.4	61.0	75.0
	Ours	86.2	80.3	64.3	76.9
DeepLab-V3 [15]	MS-UDA* [14]	77.4	74.7	46.4	66.2
	Ours w/o stage 2	82.2	75.6	50.1	69.3
	Ours	82.6	75.7	53.0	70.5

* We re-implemented MS-UDA with 410 training daytime images

- Segmentation에서 다양하게 사용되는 DeepLab-V3에서도 제안하는 방법이 MS-UDA이 좋았음
- RTFNet과 DeepLab-V3 architectures에서 둘 다 좋음

5. Conclusions


- 연구 목표
 - RGB와 Thermal 도메인 간의 비지도 도메인 적응(Unsupervised Domain Adaptation, UDA)을 통해 thermal 이미지의 의미 분할(semantic segmentation) 성능을 향상시키는 것이 목표
- 제안 기법: Masked Mutual Learning (MML)
 - RGB Thermal 간의 중요 정보만 선택적으로 공유
 - 각 도메인의 잡음이나 고유한 문제점을 필터링
 - 정보의 효과적인 전이를 유도
- Cross-Spectral Prototypes 도입
 - 픽셀 수준의 의미 정보를 담은 도메인 공통 표현(prototype) 학습
 - RGB와 Thermal 양쪽에서 의미 일관성을 유지하도록 도움

5. Conclusions

- Prototypical Self-Supervised Loss
 - 학습된 prototype을 활용해 자기지도(self-supervised) 학습 수행
 - 야간 조건에서도 AI가 스스로 학습 가능 (PSL)
- 실험 결과
 - 기존 UDA 기법들을 압도적으로 능가하는 성능
 - 최신 감독학습(Supervised) 기법과 유사한 정확도 달성
- 향후 연구 방향
 - 더 정교한 pseudo-label 생성 기법 개발 예정
 - 도메인 적응 과정의 정밀도와 효율성을 더욱 향상시킬 계획



Q & A



Thank you for having listened to me so far.