


BRAIN-IT: IMAGE RECONSTRUCTION FROM FMRI VIA BRAIN-INTERACTION TRANSFORMER

Roman Belyi★, Amit Zalcher★, Jonathan Kogman, Navve
Wasserman, Michal Irani

The Weizmann Institute of Science

이찬영, **최승준**, 허정원

fMRI



fMRI: (기능적 자기공명영상, Functional Magnetic Resonance Imaging)

뇌의 특정 영역이 활성화될 때 해당 부위로 혈류량이 증가하는 것을 측정하여 뇌 활동을 실시간으로 보여주는 기술, 뇌가 특정 과제(예: 생각, 감정, 운동 등)를 수행할 때 어떤 **뇌 부위가 활동하는지 시각화**

fMRI 재구성 작업 (fMRI Reconstruction)

(a) Reconstruction of seen images from fMRI using Brain-IT:



(b) Reconstruction with limited amount of training data:



피험자가 보고 있는 시각적 자극을 시각화하는 기술. 픽셀 단위로 **원본과 유사한 (Pixel-perfect) 이미지**를 복원

- **입력:** 피험자가 이미지를 보는 동안 기록된 fMRI BOLD(Blood-Oxygen-Level Dependent) 신호 - 피에 산소가 포함되었는지 여부
 - 뇌는 3 차원 공간, **입력 데이터는 수만 개의 복셀 (Voxel, 3D Pixel) 단위의 스칼라 값**으로 구성된 1 차원 벡터 형태
 - 특히 시각 피질 영역의 복셀
- **출력:** 피험자가 당시에 보았던 시각적 자극과 동일한 해상도의 2D RGB 이미지

fMRI 재구성 작업 (fMRI Reconstruction)

General Approach

- 딥러닝 모델을 사용하여 뇌 활동 패턴 (fMRI 신호) 을 이미지의 **Latent Space나 feature로 매핑**
- 최근에는 Diffusion 기반의 생성 모델 (Stable Diffusion) 의 조건으로 사용하여 이미지를 생성

기존 SotA(State-of-the-Art) 방법의 한계


- 최근 방법들은 **강력한 Diffusion Model** 을 사용하여 텍스처가 훌륭한 고품질 이미지를 생성
- 생성된 이미지가 그럴싸해 보이지만, **피험자가 본 실제 이미지와 구조적으로 다름.**
 - 시계라는 의미는 맞지만 시계의 위치, 촬영된 방향, 배경의 색상 등이 원본과 다름. 이는 모델이 뇌 신호보다는 생성 모델의 사전 지식 (Prior) 에 지나치게 의존하기 때문




2. Related Works

Image Features Prediction

- semantic CLIP이나 VAE latent embedding image feature를 fMRI로부터 예측, 대부분은 단순한 선형 모델이나 MLP를 사용하며, 일부는 **unCLIP diffusion priors (사전확률)**을 구축하여 사용.
- 한계점:** 이미지 특징을 예측하기 전, fully connected layer를 통해 **모든 복셀을 하나의 global fMRI 임베딩으로 압축**, 시각 정보는 서로 연결되어 있으면서도 구별되는 여러 뇌 영역에 분산, projection 방식은 뇌 분산된 특성을 완전 활용 X
- 최근 연구는 공유된 해부학적 공간 내의 복셀 패치를 사용하는 **공간적 복셀 그룹화 방식을 도입**, 하나의 global image representation을 예측하기 때문에, 국소적인 이미지 정보를 재구성하는 데 어려움.
- 기능적으로 공유되는 복셀 클러스터를 형성**하고 이를 국소적 이미지 특징에 직접 매핑함으로써 이러한 문제를 해결 (구역 별로 나눔), 전역 fMRI 임베딩으로의 투영을 피하고, 더 정확한 이미지 특징 예측을 산출



Mind Tuner (2024)




NeuroPictor (2024)

2. Related Works

Cross-Subject Integration



- 공통점은 정렬 방식이 주로 fMRI 중심, 각 fMRI 스캔을 하나의 단일 개체로 취급하며, 피험자 간에 스캔 전체가 공유하는 임베딩에 의존.
- 스캔 수준에서만 공유된 표현을 활용, 단일 피험자 내에서나 다른 피험자 간의 개별 뇌 복셀들 사이에 존재하는 더 빈번한 유사성은 간과.
→ 기존 방식 : 한 사람의 뇌 스캔 전체를 하나의 덩어리로 취급.
- 이번 연구는 Brain Encoder (2025)의 다중 피험자 Image-to-fMRI 인코더에서 영감을 받아, 피험자 내부 및 피험자 간의 모든 뇌 복셀에 걸쳐 네트워크 가중치를 공유하는 복셀 중심 모델을 채택.
- 대부분의 모델 구성 요소를 공유하고 복셀 수준의 유사성을 활용, 여러 피험자의 데이터를 효과적으로 통합, 데이터가 제한적인 새로운 피험자에게도 효율적으로 적응.
→ 논문 방식 : 뇌 내의 작은 점 하나하나를 개별적으로 다룸



2. Related Works

Low-Level Image Reconstruction

- 기존 방법들은 MLP나 선형 계층을 사용하여 **fMRI로부터 diffusion 모델의 잠재 공간(예: VAE 잠재 공간)으로 직접 회귀 (regress)**, 대안으로 NeuroPictor는 fMRI에서 예측된 특징을 사용하여 **Stable Diffusion의 U-Net 내부 특징 맵을 조작** → 이미지를 너무 심하게 압축해 놓은 것을 맞추려다 보니, 디테일한 구조는 뭉개짐.
- 이번 연구는 상호보완적인 저수준(low-level) 브랜치를 도입, LPIPS에서 영감을 받은 VGG 기반 표현을 예측 (**VGG는 이미지의 윤곽선, 질감 같은 스타일 정보를 아주 잘 잡아냄**) 하고, 이를 **Deep Image Prior (DIP) 프레임워크**를 통해 역변환
- 이러한 설정은 더 믿을만한 low-level prediction 가능, global structure와 저수준 시각 특징을 재구성함 (원본과 훨씬 비슷하게 만들어냄)



3 BRAIN-IT PIPELINE




Image Feature Prediction



- **BIT(Brain Interaction Transformer)**가 fMRI 신호들을 의미있는 visual features에 mapping
- 1st BIT model: adapted CLIP embedding 예측 (**semantic features** - 어떤 물체 인지)
- 2nd BIT model: VGG features 예측 (**low-level** - 자세한 pixel, 위치, 구도)

Image Reconstruction

- VGG feature: Deep Image Prior framework를 통해 **거친 reconstruction. Diffusion model에 초기 노이즈.**
- Semantic feature: **Diffusion model에 condition**으로 주어져서 fMRI와 aligned된 이미지를 생성
- 추론시 DIP로 거친 이미지 생성 → semantic guidance에 의해 refinement

3 BRAIN-IT PIPELINE

3.1 IMAGE FEATURE PREDICTION



- **Voxels-to-Clusters Mapping (V2C)**
 - 기능적으로 비슷한 뇌 부분들을 같은 복셀로 묶고 그것을 **128개의 cluster에 mapping**
 - **Pretrained Brain Encoder**를 통해 얻은 voxel embedding을 이용해 뇌 voxel 간의 기능적 유사성을 결정
 - encoding된 voxel embedding은 기능적 역할들을 맡고 있음.
 - 이미지 내 각 부분에 집중하거나 이미지 전체에 집중하는 등 각 뇌 복셀별로 다름
 - cluster 안에 있는 모든 사람들에 대해 복셀을 매핑하기 위해 **GMM (Gaussian Mixture Model)**을 사용해 128개의 기능적 클러스터를 정의

3 BRAIN-IT PIPELINE

3.1 IMAGE FEATURE PREDICTION






Figure 4: Architecture of the Brain-Interaction-Transformer (BIT). (Sec. 4)

- **Brain Interaction Transformer (BIT)**
 - Brain Activation (40000x1) → Brain token: voxel cluster 안에 있는 voxel 정보들을 요약. Brain Tokenizer
 - 뇌 정보를 통합하기 위해 두 가지 학습 가능한 임베딩을 포함: 각 복셀의 기능을 포착하는 **voxel embedding(40000 x 512)**과 각 클러스터의 전반적인 기능을 포착하는 cluster embedding
 - 복셀 정보가 어떻게 브레인 토큰으로 집계되는지를 결정함으로써 정보 선택의 병목 역할.
 - **self-attention (brain token), cross attention (image feature - brain token)**
 - brain token이 localized image feature를 예측할 수 있도록 함.

3 BRAIN-IT PIPELINE

3.1 IMAGE FEATURE PREDICTION




BrainEncoder (2025)

- **Enriching the Training Data**
 - NSD dataset, fMRI - Image dataset
 - 실험 대상별로 이미지는 한정되어 있기 때문에 외부의 이미지를 이용해 데이터를 키움.
 - COCO dataset 120K 개의 unlabeled dataset 이용
 - **Image to fMRI encoder (Brain Encoder)**를 이용해 외부 이미지를 fMRI 신호로 변환
 - 적은 데이터를 갖고 있는 새로운 대상이 있을 때 training data를 늘리는 과정이 transfer learning에 중요

3 BRAIN-IT PIPELINE


3.2 Image Restoration




- **Semantic Image Generation**
 - adapted-CLIP embeddings (condition) → generate a semantic image를 생성
 - 자연스러운 이미지가 나오는 것이 목표 + 의미적으로 주어진 이미지와 맞아야 함.
 - **BIT가 예측한 adapted CLIP embedding**을 강력한 **prior**로 삼아 생성
 - Feature Alignment: Stable Diffusion XL + 256개의 OpenCLIP ViT-BigG/14 토큰을 예측하도록 BIT 만 학습 - diffusion model 신호와 align
 - fMRI activations - image CLIP embedding L2 Loss로 학습
 - Joint Training: BIT + diffusion 모델을 한꺼번에 diffusion loss로 학습
 - BIT image output이 원래의 CLIP embedding과 같게 생성할 필요가 없음, 목표는 fMRI - image

3 BRAIN-IT PIPELINE

3.2 Image Restoration



Deep Image Prior (2017)



• Low level Image Reconstruction

- 거칠지만 low-level (뭔가가 어디에 있는 정도) 로 reconstruct하는 것

- BIT가 multi-layer VGG feature를 generation 할 수 있도록 훈련 (InfoNCE Loss 사용)

InfoNCE Loss: 정답 쌍(Positive pair)은 가깝게, 오답 쌍(Negative pairs)은 멀게

- CNN의 inductive bias로 인한 강한 이미지 prior를 제공


- 예측된 feature는 **deep image prior (DIP)**를 통해 low-level image 생성

DIP: 학습한 노이즈 이미지보다 더 잘 생성.

- 추론시 예측된 feature와 실제 VGG feature와 가까운 이미지를 DIP가 지속적으로 최적화하여 생성.

3 BRAIN-IT PIPELINE

3.2 Image Restoration



- **Dual-Branch Generation**

- 두개의 branch가 조합되서 **low level image reconstruction → Semantic Image Generation**
- Semantic Embedding으로만 guided되면 의미적으로는 일관되지만 시각적 자극에 구조적으로 충실하지 못하며, 종종 색상이나 구조와 같은 관측된 이미지의 저수준 세부 사항을 보존 X
- 예측된 저수준 이미지의 노이즈가 가미된 버전으로 확산 과정을 초기화하며, 이는 신뢰할 수 있는 구조를 제공.
- 다음은 pretrained SDXL 모델을 사용하여 시각적으로 개선. (**초기 noise: low level image, guidance: semantic feature**)

4 BRAIN INTERACTION TRANSFORMER (BIT)




Figure 4: Architecture of the Brain-Interaction-Transformer (BIT). (Sec. 4)

Brain Interaction Transformer: Brain Tokenizer와 Cross-Transformer module로 이루어짐.

- **Brain Tokenizer:** fMRI activation → Brain Token (40000 복셀 → 128개의 토큰)
- **Cross-Transformer Module:** query token을 이용해 brain token → image feature로 변환
 - 각 query token은 하나의 output image feature로 변환

두 종류의 learnable embedding이 random initialize 되고, 학습하면서 최적화.

- **Voxel Embedding:** 512 차원의 벡터 복셀 (Brain Encoder) - 40000개 x 512 차원 (**Subject Specific**)
 - **Brain Encoder와 유사** image-to-fMRI에 최적화되어 있는 반면, **voxel embedding** (Brain-IT)은 fMRI-to-image에 최적화
 - 각 voxel activation (scalar) 일치하는 voxel embedding을 곱함 → modulated voxel activation
- **Cluster Embedding:** 각 128개의 cluster 별로 512 차원의 벡터로 이루어져 있음.
 - 복셀 정보가 어떻게 집계되는지를 결정함으로써 정보 선택의 병목 역할을 하며, 모든 사람(subject)들이 공유

4 BRAIN INTERACTION TRANSFORMER (BIT)




Figure 4: Architecture of the Brain-Interaction-Transformer (BIT). (Sec. 4)

Brain Tokenizer:

- Brain-Tokenizer는 modulated voxel activation을 이용해서 Brain Token을 형성
- Single-head graph attention layer를 통해 형성
 - Graph Attention:** 그래프 구조에서 연결된(같은 클러스터에 속한) 노드들 사이에서만 Attention을 수행.
V2C(Voxels-to-Cluster) 매핑에 따라 자신에게 할당된 복셀들하고만 attention.
- Voxels to Cluster Mapping에 의해 제한된 voxel - cluster embedding attention 수행 (cluster에 관련된 voxel들만 attention)
 - Query (Q): cluster embeddings
 - Key (K), Value (V): modulate voxel activation
- cluster 하나당 512 차원의 Brain Token

4 BRAIN INTERACTION TRANSFORMER (BIT)




Figure 4: Architecture of the Brain-Interaction-Transformer (BIT). (Sec. 4)

Cross-Transformer

- Brain Token (128 x 512) → image features (semantic(CLIP): 256 x 1280, vgg: 256 x 512)
- query token의 개수는 image feature와 일치, query token은 처음에는 랜덤으로 initialize
- self-attention (brain token), cross attention (image feature - brain token), 8 개의 head
- 마지막 cross attention layer 후에 projection layer가 image feature 차원으로 맞춤

Question?

5 EXPERIMENTAL RESULTS

5.1 EXPERIMENTAL SETTING

Dataset

- Natural Scenes Dataset (NSD) 사용. 7T **fMRI 8명의 대상자에게 COCO 이미지**를 보여줌
- 73000장의 image - fMRI pair set. 한 사람당 9000개의 독립적인 이미지와 1000개의 공유되는 이미지
- 이전 연구들처럼 1000개의 공유된 이미지를 test-set으로 사용
- 40000개까지의 시각 관련 뇌 피질 복셀 선정을 위해 **이전 연구의 후처리 된 버전의 데이터**를 활용

Evaluation Metrics

- **low-level (pixel), high-level (semantic)로 이미지를 평가**
- 다른 연구들과 마찬가지로 NSD Dataset에서 **4명의 피험자들(1,2,5,7)**에 대한 평균 결과를 게재
- **low-level**
 - PixCorr: 원본 이미지와 재구성 이미지 간의 픽셀 단위 상관관계
 - SSIM: 이미지의 밝기, 대비, 구조를 기반으로 한 구조적 유사성 (그레이스케일 기준)
 - Alex(2), Alex(5): AlexNet의 레이어 2와 5에서 추출한 특징
 - color-SSIM: 기존 SSIM을 확장하여 색상 정보까지 포함한 구조적 유사성을 측정.
- **high-level**
 - Incep: Inception Net에서 추출한 특징
 - CLIP: CLIP 모델에서 추출한 이미지 임베딩
 - Eff: EfficientNet-B1 모델
 - SwAV: SwAV 학습 방식이 적용된 ResNet50
 - 1000way-CLIP: 1000개의 후보 이미지 중에서 CLIP 임베딩을 사용하여 정답을 검색할 정확도.
 - LPIPS (Learned Perceptual Image Patch Similarity):

5 EXPERIMENTAL RESULTS

5.2 Reconstruction Results


Method	Low-Level				High-Level			
	PixCorr ↑	SSIM ↑	Alex(2) ↑	Alex(5) ↑	Incep ↑	CLIP ↑	Eff ↓	SwAV ↓
MindEye (Scotti et al., 2023)	0.319	0.360	92.8%	96.9%	94.6%	93.3%	0.648	0.377
Brain-Diffuser (Ozcelik & VanRullen, 2023)	0.273	0.365	94.4%	96.6%	91.3%	90.9%	0.728	0.421
Takagi & Nishimoto (2023)	0.246	0.410	78.9%	85.6%	83.8%	82.1%	0.811	0.504
DREAM (Xia et al., 2024a)	0.274	0.328	93.9%	96.7%	93.4%	94.1%	0.645	0.418
UMBRAE (Xia et al., 2024b)	0.283	0.341	95.5%	97.0%	91.7%	93.5%	0.700	0.393
NeuroVLA (Shen et al., 2024)	0.265	0.357	93.1%	97.1%	96.8%	97.5%	0.633	<u>0.321</u>
MindBridge (Wang et al., 2024a)	0.151	0.263	87.7%	95.5%	92.4%	94.7%	0.712	0.418
NeuroPictor (Huo et al., 2024)	0.229	0.375	<u>96.5%</u>	98.4%	94.5%	93.3%	0.639	0.350
MindEye2 (Scotti et al., 2024)	<u>0.322</u>	<u>0.431</u>	96.1%	98.6%	95.4%	93.0%	0.619	0.344
MindTuner (Gong et al., 2025)	<u>0.322</u>	0.421	95.8%	<u>98.8%</u>	95.6%	93.8%	<u>0.612</u>	0.340
BrainIT (Ours)	<u>0.386</u>	<u>0.486</u>	<u>98.4%</u>	<u>99.5%</u>	<u>97.3%</u>	<u>96.4%</u>	<u>0.564</u>	<u>0.320</u>
Results on 1 hour (out of 40)								
MindEye2 (1 hour)	0.195	0.419	84.2%	90.6%	81.2%	79.2%	0.810	0.468
MindTuner (1 hour)	<u>0.224</u>	<u>0.420</u>	<u>87.8%</u>	<u>93.6%</u>	<u>84.8%</u>	<u>83.5%</u>	<u>0.780</u>	<u>0.440</u>
BrainIT (1 hour)	<u>0.331</u>	<u>0.473</u>	<u>97.1%</u>	<u>98.6%</u>	<u>94.4%</u>	<u>93.0%</u>	<u>0.648</u>	<u>0.370</u>

Method	SSIM-color ↑	1000way-CLIP ↑	LPIPS ↓
NeuroPictor	0.375	0.255	0.628
MindEye2	0.383	0.238	0.624
MindTuner	0.371	0.231	0.638
BrainIT(ours)	0.472	0.393	0.596

- high level metric에서는 하나를 제외하고는 다 1등, low level은 크게 1등

5 EXPERIMENTAL RESULTS


5.2 Reconstruction Results



- **Brain-IT**는 구조적인 배열(도넛, 사람과 말)과 어떤 물체인지에 대한 정보는 seen image와 유사하게 생성.

5 EXPERIMENTAL RESULTS

5.3 Transfer Learning



Method	Low-Level				High-Level			
	PixCorr $\uparrow$	SSIM $\uparrow$	Alex(2) $\uparrow$	Alex(5) $\uparrow$	Incep $\uparrow$	CLIP $\uparrow$	Eff $\downarrow$	SwAV $\downarrow$
<i>BrainIT (15 min)</i>	0.336	0.476	97.6%	98.4%	90.7%	91.3%	0.706	0.404
<i>BrainIT (30 min)</i>	0.378	0.480	99.1%	99.3%	94.3%	93.3%	0.652	0.372
<i>BrainIT (1 hour)</i>	0.396	0.484	99.4%	99.6%	95.9%	94.7%	0.619	0.348

- Brain-IT는 피험자의 **적은 양의 데이터셋으로도 transfer learning**을 할 수 있음.
 - fMRI 데이터를 모으는것은 시간과 비용이 많이 듦.
- BIT라는 모델의 요소들은 모든 피험자들이 공유하지만, **Voxel Embedding**은 제각기 피험자마다 다름.
- 새로운 피험자에 대해서는 **voxel embedding을 최적화**하면 됨.
- 새 피험자의 1시간 데이터를 학습. 훨씬 성능이 좋고, 40시간 학습한 다른 방법들 보다는도 좋았음.
- 30분이나 15분의 새 피험자 데이터로도 학습이 가능함.

5 EXPERIMENTAL RESULTS

5.3 Transfer Learning



Method	Low-Level				High-Level			
	PixCorr ↑	SSIM ↑	Alex(2) ↑	Alex(5) ↑	Incep ↑	CLIP ↑	Eff ↓	SwAV ↓
<i>BrainIT (15 min)</i>	0.336	0.476	97.6%	98.4%	90.7%	91.3%	0.706	0.404
<i>BrainIT (30 min)</i>	0.378	0.480	99.1%	99.3%	94.3%	93.3%	0.652	0.372
<i>BrainIT (1 hour)</i>	0.396	0.484	99.4%	99.6%	95.9%	94.7%	0.619	0.348

- Brain-IT는 피험자의 **적은 양의 데이터셋으로도 transfer learning**을 할 수 있음.
 - fMRI 데이터를 모으는것은 시간과 비용이 많이 듦.
- BIT라는 모델의 요소들은 모든 피험자들이 공유하지만, **Voxel Embedding은 제각기 피험자마다 다름.**
- 새로운 피험자에 대해서는 **voxel embedding을 최적화**하면 됨.
- 새 피험자의 1시간 데이터를 학습. 훨씬 성능이 좋고, 40시간 학습한 다른 방법들 보다는 좋았음.
- 30분이나 15분의 새 피험자 데이터로도 학습이 가능함.

6. ABLATIONS AND ANALYSIS

INFLUENCE OF UNLABELED IMAGES

Method	Low-Level Metrics				High-Level Metrics			
	PixCorr $\uparrow$	SSIM $\uparrow$	Alex(2) $\uparrow$	Alex(5) $\uparrow$	Incep $\uparrow$	CLIP $\uparrow$	Eff $\downarrow$	SwAV $\downarrow$
W/o External Images	0.365	0.494	97.5%	99.1%	96.5%	95.2%	0.592	0.340
With External Images	0.386	0.486	98.4%	99.5%	97.3%	96.4%	0.564	0.320

- External image를 추가로 사용 시 low-level, high-level에서 성능 향상

6. ABLATIONS AND ANALYSIS

FUNCTIONAL VS. ANATOMICAL CLUSTERING

Method	Low-Level				High-Level			
	PixCorr ↑	SSIM ↑	Alex(2) ↑	Alex(5) ↑	Incep ↑	CLIP ↑	Eff ↓	SwAV ↓
Anatomical clustering	0.378	0.491	98.1%	99.3%	96.6%	95.6%	0.589	0.336
Functional clustering	0.386	0.486	98.4%	99.5%	97.3%	96.4%	0.564	0.320

- **Anatomical clustering:** 뇌 안에서의 물리적/공간적 위치(XYZ 좌표)만을 기준으로 묶음
- **Functional clustering:** 각 복셀이 어떤 시각적 자극(색상, 형태, 의미 등)에 반응하는지 나타내는 기능적 임베딩'을 기준으로 묶음
- 기능적(Functional) 클러스터링을 사용했을 때 이미지 재구성의 정확도가 해부학적 방식보다 대체로 높음.
- 해부학적 클러스터링은 뇌의 실제 정보 처리 방식(분산 처리)을 무시하고 단순히 가까운 것끼리 묶음.

6. ABLATIONS AND ANALYSIS


EFFECT OF CLUSTERS NUMBER

# Clusters	Low-Level				High-Level			
	PixCorr ↑	SSIM ↑	Alex(2) ↑	Alex(5) ↑	Incep ↑	CLIP ↑	Eff ↓	SwAV ↓
8	0.379	0.492	97.6%	99.1%	96.6%	95.6%	0.588	0.334
16	0.380	0.491	97.8%	99.3%	96.6%	95.6%	0.582	0.334
32	0.383	0.486	98.2%	99.3%	97.0%	96.0%	0.576	0.325
64	0.385	0.486	98.3%	99.5%	97.2%	96.1%	0.569	0.321
128	0.386	0.486	98.4%	99.5%	97.3%	96.4%	0.564	0.320
256	0.391	0.487	98.6%	99.5%	97.6%	96.3%	0.565	0.321
512	0.392	0.491	98.5%	99.5%	97.4%	96.1%	0.569	0.322

- **클러스터가 적으면** 뇌의 복잡한 시각적 정보를 처리하기에는 적은 토큰만으로 부족.
- **클러스터가 많아지면** 각 클러스터에 할당되는 복셀 수가 너무 적어짐. fMRI 신호 고유의 노이즈를 상쇄(Averaging)하는 효과를 약화

6. ABLATIONS AND ANALYSIS

TWO-BRANCH CONTRIBUTION



Method	Low-Level Metrics		High-Level Metrics	
	SSIM ↑	Alex(5) ↑	Incep ↑	CLIP ↑
Low-level branch	0.505	99.1%	95.9%	85.8%
Semantic branch	0.431	99.4%	96.1%	95.2%
Combined	0.486	99.5%	97.3%	96.4%

- low-level branch의 경우 SSIM 이나 Alex(5)같은 low level metric이 잘 나옴
- semantic은 perceptual한 high level loss에서 잘 나옴.
- 두개를 다쓰면 서로 **상호보완 하는 관계**로 더 성능이 좋아짐.

7. Discussion

- 뇌의 복셀을 해부학적 위치가 아닌 **기능적 유사성**에 기반해 128개의 클러스터로 묶음 - 뇌의 복잡한 신호를 효율적으로 요약
- **DIP를 이용한 구조적 가이드와 SDXL을 이용한 의미적 가이드** - 상호보완
- 대부분의 모델 구성 요소(BIT, 클러스터링 로직 등)를 모든 피험자가 공유 - **적은 피험자 데이터로 학습 가능**
- BIT설계 덕분에 뇌의 각 클러스터 정보가 이미지의 특정 패치(Patch) 위치로 직접 전달 - **물체의 정확한 위치와 레이아웃을 복원**

Limitation & Future Works

- **복잡한 장면의 한계:** 복잡하거나 여러 물체가 엉켜 있는 장면 - 세부적인 묘사 X.
- **동적 뇌 활동:** 현재는 정지된 이미지를 대상, 향후 비디오나 실시간 사고 과정을 복원하는 방향으로 확장.
- **고차원 인지 정보:** 시각적 자극을 넘어 감정이나 기억과 같은 더 고차원적인 뇌 정보와 결합 연구 필요



Thank you!