


Chain-of-Verification Reduces Hallucination in Large Language Models

김세진 (발표자), 자연어 처리팀

Introduction

- Large Language Model (LLM) 은 수십억 개의 텍스트 토큰으로 훈련된 모델
- 모델의 parameter 수가 커질 수록 더 정확한 답변을 생성하는 특징
- 그러나, 때때로 잘못된 정보(환각)를 생성



Problem Statement

- 환각(Hallucination)

- LLM이 사실과 다른 정보를 생성하는 현상

- 발생 원인

- 잘못된 정보로 훈련되었거나, 상대적으로 드문 정보를 포함한 응답을 생성할 때 발생

- 문제점

- 사실적으로는 잘못되었지만 그럴듯한 대체 응답을 생성
- long form task 에서 hallucination 문제 악화

대한민국의 역대 대통령을 나열해줘



대한민국의 역대 대통령은 다음과 같습니다:

1. 이승만 (1948-1960)
2. 윤보선 (1960-1962)
3. 박정희 (1963-1979)
4. 최규하 (1979-1980)
5. 전두환 (1980-1988)
6. 노태우 (1988-1993)
7. 김영삼 (1993-1998)
8. 김대중 (1998-2003)
9. 노무현 (2003-2008)
10. 이명박 (2008-2013)
11. 박근혜 (2013-2017)
12. 문재인 (2017-2022)
13. 윤석열 (2022-현재)

대한민국의 역대 국방부장관을 나열해줘



대한민국의 역대 국방부장관 목록은 상당히 길기 때문에, 여기서는 주요 인물과 최근 몇몇 인물만 간략하게 나열하겠습니다. 보다 상세한 목록이 필요하시다면 말씀해주세요.

1. 신성모 (1948-1950)
2. 장택상 (1950-1951) ✖
3. 백선엽 (1951-1952) ✖
4. 송요찬 (1952-1953)
5. 정일권 (1953-1954) ✖
6. 김관진 (2010-2014)
7. 한민구 (2014-2017)
8. 송영무 (2017-2018)
9. 정경두 (2018-2020)
10. 서욱 (2020-2022)
11. 이종섭 (2022-현재)

Chain-of-Verification (CoVe)

- **LLM이 자체적으로 생성한 응답을 검증하는 방법 제시**
 - LLM 의 reasoning 능력을 활용하고자 함 (Chain-of-Thought, Internal thoughts ..)
- **CoVe의 주요 단계**
 1. Generate Baseline Response (기본 응답 생성)
 2. Plan Verifications (검증 질문 계획)
 3. Execute Verifications (검증 실행)
 4. Generate Final Verified Response (최종 검증된 응답 생성)

Related Works

- **훈련 시 교정 방법**

- 모델 가중치를 조정하여 hallucination 발생 확률을 줄이는 방법
- 예: 강화 학습, 대조 학습 등

- **생성 시 교정 방법**

- LLM 위에 다른 레이어를 추가하여 모델의 신뢰도를 높이는 방법
- 예: 멀티 에이전트 (다중 LLM) 사용, 신뢰도 점수 계산 등

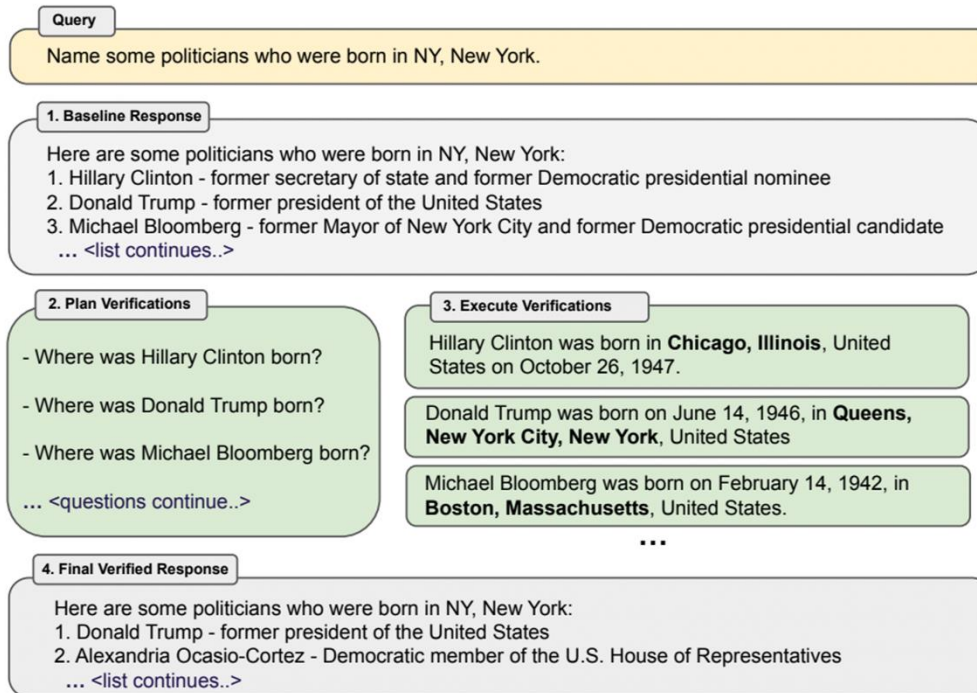
- **Augmentation 방법**

- 다른 외부 도구를 사용하여 hallucination 을 줄이는 방법
- 예: Retrieval-Augmented Generation (RAG) 등

- **CoVe**

- 다른 에이전트 혹은 외부 도구를 사용하지 않고, LLM 의 reasoning 능력을 사용하여 hallucination 을 줄이는 방법론

Structure of CoVe



- **Generate Baseline Response** : 주어진 질문에 대해 초기 응답을 생성
- **Plan Verifications** : 생성된 응답을 검증하기 위한 질문을 계획
- **Execute Verifications** : 계획된 질문에 따라 응답을 검토하고 수정
- **Generate Final Verified Response** : 검토된 결과를 반영하여 최종 응답을 생성.

Key Steps of CoVe - Baseline Response Generation

Query

Name some politicians who were born in NY, New York.

1. Baseline Response

Here are some politicians who were born in NY, New York:

1. Hillary Clinton - former secretary of state and former Democratic presidential nominee
 2. Donald Trump - former president of the United States
 3. Michael Bloomberg - former Mayor of New York City and former Democratic presidential candidate
- ... <list continues..>

- LLM 을 사용하여 입력된 질문에 대한 초기 응답을 생성
- 즉각적인 검토나 수정 없이 생성되므로, hallucination 에 취약할 수 있는 단계
- 예시
 - 질문: "미국-멕시코 전쟁은 언제 일어났습니까?"
 - 출력: "미국-멕시코 전쟁은 1846년부터 1848년까지 일어났습니다."

Key Steps of CoVe - Plan Verifications

Query

Name some politicians who were born in NY, New York.

1. Baseline Response

Here are some politicians who were born in NY, New York:

1. Hillary Clinton - former secretary of state and former Democratic presidential nominee
 2. Donald Trump - former president of the United States
 3. Michael Bloomberg - former Mayor of New York City and former Democratic presidential candidate
- ... <list continues..>

2. Plan Verifications

- Where was Hillary Clinton born?
- Where was Donald Trump born?
- Where was Michael Bloomberg born?

... <questions continue..>

- 모델이 스스로 생성한 응답을 검증하기 위한 질문을 계획하는 단계.
 - 입력: 기존 질문 + 이전 단계에서 생성된 기본 응답
 - "미국-멕시코 전쟁은 1846년부터 1848년까지 일어났습니다"
 - 출력: 기본 응답의 사실성을 검증하기 위한 구체적이고 명확한 질문들
 - "미국-멕시코 전쟁은 언제 시작되고 언제 끝났습니까?"
- 질문 생성의 자유도
 - 모델은 특정한 형식에 구애받지 않고 자유롭게 질문을 작성할 수 있음

Key Steps of CoVe - Execute Verifications

Query

Name some politicians who were born in NY, New York.

1. Baseline Response

Here are some politicians who were born in NY, New York:

1. Hillary Clinton - former secretary of state and former Democratic presidential nominee
 2. Donald Trump - former president of the United States
 3. Michael Bloomberg - former Mayor of New York City and former Democratic presidential candidate
- ... <list continues..>

2. Plan Verifications

- Where was Hillary Clinton born?
 - Where was Donald Trump born?
 - Where was Michael Bloomberg born?
- ... <questions continue..>

3. Execute Verifications

Hillary Clinton was born in **Chicago, Illinois**, United States on October 26, 1947.

Donald Trump was born on June 14, 1946, in **Queens, New York City, New York**, United States

Michael Bloomberg was born on February 14, 1942, in **Boston, Massachusetts**, United States.

- 계획된 검증 질문에 답변하는 단계
 - 입력: 검증 질문
 - "미국-멕시코 전쟁은 언제 시작되고 언제 끝났습니까?"
 - 출력: 사실 여부를 식별할 수 있는 응답
 - "1846년부터 1848년까지"

Key Steps of CoVe - Execute Verifications

- 조인트(Joint) 방식

- 설명

- 검증 질문을 생성하고 해당 질문에 답변하는 과정을 하나의 프롬프트에서 처리
 - 모델은 질문을 생성한 후 바로 그 질문에 답변

- 단점: 모델이 이전 응답에 편향될 수 있어, 동일한 오류가 반복될 가능성



질문 : "미국-멕시코 전쟁은 언제 시작되고 언제 끝났습니까?"
답변 : "1835년부터 1836년까지"

- 2단계(2-Step) 방식

- 설명

- 검증 질문 생성과 답변을 별도의 단계로 분리
 - 첫 번째 단계에서는 검증 질문만 생성하고, 두 번째 단계에서는 질문에 대한 답변을 합니다.

- 장점: 모델이 이전 응답에 영향 받지 않으므로 환각된 정보를 식별하고 수정하는 데 더 효과적



검증 질문 : "미국-멕시코 전쟁은 언제 시작되고 언제 끝났습니까?"



답변 : "1846년부터 1848년까지"

Key Steps of CoVe - Execute Verifications

■ 분리(Factored) 방식

■ 설명

- 각 검증 질문에 대해 별도의 프롬프트를 사용하여 독립적으로 답변
- 질문과 답변 간의 상호 간섭을 최소화

■ **장점:** 모델이 이전 응답이나 다른 질문의 영향을 받지 않음

■ **단점:** 더 많은 계산 자원이 필요할 수 있으나, 병렬 처리를 통해 단점을 보완할 수 있음



검증 질문1 : "미국-멕시코 전쟁은 언제 시작되고 언제 끝났습니까?"



검증 질문2 : "텍사스는 언제 멕시코로부터 분리되었습니까?"



답변 : "1846년부터 1848년까지"

답변 : "1836년"

■ Factored + Revise 방식

■ 설명

- Factored 방식에서, 답변을 원래 응답과 비교하여 일관성이 있는지를 교차 검토하는 과정을 포함

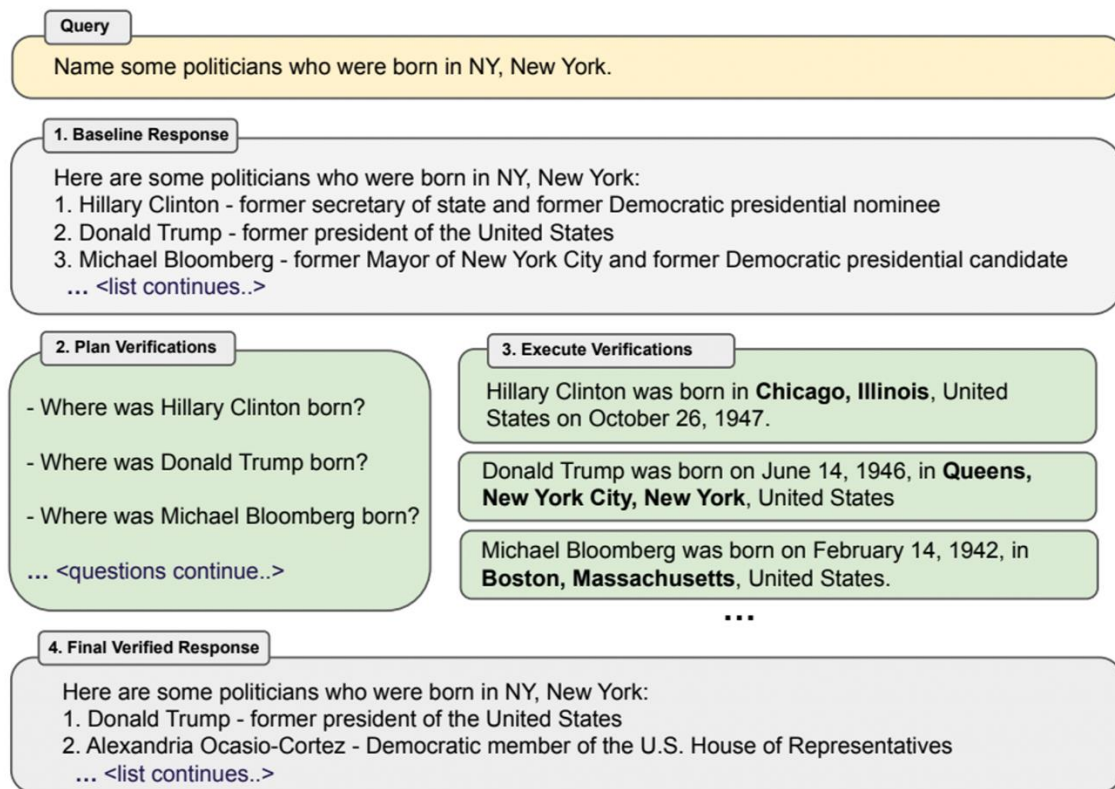
■ 장점



그런 것들 가졌을 때는 일단이 일관성이 있는 수 있음

답변 : Inconsistent. "1846년부터 1848년까지"

Key Steps of CoVe - Generate Final Verified Response



- 검증된 결과를 반영하여 최종 응답을 생성하는 단계
- 이전 추론 단계, baseline response, 검증 질문 및 응답을 고려하여 수정된 응답 생성
- Factor+Revise 를 사용한 경우, 불일치 여부도 제공

Experimental Setup (1/2)

- Tasks

- Wikidata

- 자동 생성된 질문과 엔터티 집합으로 구성
 - Ex> "보스턴에서 태어난 정치인은 누구입니까?"

- Wiki-Category

- Wikipedia 카테고리 목록을 기반으로 한 더 어려운 집합 생성 작업.
 - Ex> "멕시코 애니메이션 공포영화 몇편의 이름을 꼽아보세요"

- MultiSpanQA

- 여러 불연속적인 span 을 답변으로 요구하는 읽기 이해 벤치마크
 - 정답이 되는 문서는 제공하지 않음
 - Ex> "인쇄기를 처음으로 발명한 사람과 연도는 무엇인가요?"

- 장문 생성

- 전기(biography) 생성 작업.
 - Ex> "도널드 트럼프에 대한 biography 를 얘기해줘"

Experimental Setup (2/2)

- 기본 모델

- Llama 65B

- 비교 모델

- Llama 2 (Instruction fine-tuning)
 - Zero shot / Chain-of-Thought 적용
- InstructGPT, ChatGPT 2
- PerplexityAI
 - 실시간 검색 기능 포함

Results Analysis - List-Based Tasks, Closed-Book QA, Longform Generation

		Wikidata (Easier)		
LLM	Method	Prec. (↑)	Pos.	Neg.
Llama 2 70B Chat	Zero-shot	0.12	0.55	3.93
Llama 2 70B Chat	CoT	0.08	0.75	8.92
Llama 65B	Few-shot	0.17	0.59	2.95
Llama 65B	CoVe (joint)	0.29	0.41	0.98
Llama 65B	CoVe (two-step)	0.36	0.38	0.68
Llama 65B	CoVe (factored)	0.32	0.38	0.79

LLM	Method	F1 (↑)	Prec.	Rec.
Llama 2 70B Chat	Zero-shot	0.20	0.13	0.40
Llama 2 70B Chat	CoT	0.17	0.11	0.37
Llama 65B	Few-shot	0.39	0.40	0.38
Llama 65B	CoVe (joint)	0.46	0.50	0.42
Llama 65B	CoVe (factored)	0.48	0.50	0.46

LLM	Method	FACTSCORE. (↑)	Avg. # facts
Llama 65B	Few-shot	55.9	16.6
Llama 65B	CoVe (joint)	60.8	12.8
Llama 65B	CoVe (factored)	63.7	11.7
Llama 65B	CoVe (factor+revise)	71.4	12.3

Wikidata tasks

- 정밀도: 0.17 → 0.36
- 오답 답변 수 감소: 2.95 → 0.68
- 정답 답변 수 감소: 0.59 → 0.38

MultiSpanQA tasks

- F1 성능: 0.39 → 0.48
- Precision & Recall 모두 개선.

Longform tasks

- FACTSCORE: 55.9 → 71.4
- 평균 Fact 수 감소: 16.6 → 12.3

Additional Analysis

■ Instruction based Finetuning 및 Chain-of-Thought(CoT) 의 한계

LLM	Method	FACTSCORE. (↑)	Avg. # facts
Llama 2 70B Chat	Zero-shot	41.3	64.9
Llama 2 70B Chat	CoT	41.1	49.0
Llama 65B	Few-shot	55.9	16.6
Llama 65B	CoVe (joint)	60.8	12.8
Llama 65B	CoVe (factored)	63.7	11.7

- Instruction based 모델이 hallucination 을 더 많이 생성하는 경향
- CoT 는 hallucination 문제에 적합하지 않음

■ 2-Step & Factored CoVe

LLM	Method	Wikidata (Easier)			Wiki-Category list (Harder)		
		Prec. (↑)	Pos.	Neg.	Prec. (↑)	Pos.	Neg.
Llama 65B	CoVe (joint)	0.29	0.41	0.98	0.15	0.30	1.69
Llama 65B	CoVe (two-step)	0.36	0.38	0.68	0.21	0.50	0.52
Llama 65B	CoVe (factored)	0.32	0.38	0.79	0.22	0.52	1.52

- 2-Step & Factored CoVe 접근법이 joint 접근법보다 성능이 더 우수함.

Additional Analysis

- 명시적 추론이 hallucination 제거에 미치는 영향


LLM	Method	FACTSCORE. (↑)	Avg. # facts
Llama 65B	CoVe (joint)	60.8	12.8
Llama 65B	CoVe (factored)	63.7	11.7
Llama 65B	CoVe (factor+revise)	71.4	12.3

- Factored + Revise 방식을 활용하여 명시적 추론을 적용하였을 때 더 정확한 최종 응답을 생성할 수 있었음

Additional Analysis

■ 타 모델과의 비교

LLM	Method	FACTScore. (↑)	Avg. # facts
InstructGPT*	Zero-shot	41.1	26.3
ChatGPT*	Zero-shot	58.7	34.7
PerplexityAI*	Retrieval-based	61.6	40.8
Llama 65B	CoVe (joint)	60.8	12.8
Llama 65B	CoVe (factored)	63.7	11.7
Llama 65B	CoVe (factor+revise)	71.4	12.3



- CoVe 기반 Llama는 InstructGPT, ChatGPT, PerplexityAI보다 뛰어난 성능을 보여주었음
- PerplexityAI 는 retrieval-augment 방법으로 답변을 생성할 때에 사실을 뒷받침해줄 정보를 활용하지만, 기본 언어 모델만을 사용하는 CoVe 가 이를 뛰어 넘었다는 점에서 인상적

Conclusion & Limitations

■ Conclusion

- CoVe(Chain-of-Verification)는 LLM(대규모 언어 모델)의 환각 문제를 줄이는 효과적인 방법으로 입증
- 다양한 실험에서 CoVe는 정밀도, FACTSCORE 등 주요 성능 지표에서 기존 모델 (InstructGPT, ChatGPT, PerplexityAI)을 능가하는 성과를 보여줌

■ Limitations

- 기본 LLM 품질에 대한 의존성
- 계산 비용: 더 많은 계산 자원과 시간을 필요로 함
- 복잡한 시나리오에서의 한계
- 프롬프트 품질에 대한 의존성