

Direct Preference Optimization **: Your Language Model is Secretly a Reward Model**

Arxiv 2023.05

발표자: 차지윤, 펀디멘탈팀

CONTENTS

01 Intro

02 Related Works

03 Methods

04 Experiments

05 Conclusion

Intro

◦ AI Alignment

- 인공지능이 인간의 가치와 목표에 일치하도록 하는 것을 목표로 함
- AI alignment 연구자는 이상 구체화와 실제 AI 행동의 일치를 목표로 설계 구체화를 활용
 - Ideal specification : 인간 관리자가 시스템이 하기 원하는 것
 - Design specification : 실제로 AI 시스템을 구축하는 데에 사용되는 청사진
 - Emergent behavior : AI가 실제로 하게 되는 행동
- AI Alignment 방법
 - Scalable oversight
 - Training by debate : 논쟁
 - Reward modeling and iterated amplification : 인간의 피드백을 모사하는 모델로부터 보상을 받는 강화학습 시스템
 - Inferring human preferences from behavior: 인간의 행동을 기반으로 선호를 최대한으로 실현


◦ RLHF

- 강화 학습 기반 인간 피드백, Reinforcement Learning from Human Feedback
 - 사람의 피드백을 통해 학습한 리워드 모델을 이용하여 생성모델 답변을 긍정, 부정 피드백 정렬
 - OpenAI GPT-3.5, GPT-4, Anthropic(앤트로픽)의 Claude-2(클로드2), Meta의 LLaMA-2-Chat도 이 방법으로 강화학습

Related Works


Human Preference Alignment

- SFT(Supervised Fine-tuning)
 - Unsupervised Learning (Pre-training) 과정이 선행된 후 fine-tuning하는 과정
 - 특정 도메인의 데이터 혹은 클라우드 소싱 등을 통해 구축한 양질의 (Prompt, Response) 데이터를 구축하여 fine-tuning 진행
 - 입력 프롬프트에 대해 사람의 의도에 맞는 원하는 답변 형태(말투, 답변 내용, 지식 등)로 문장을 생성하는 방법 학습
- RLHF (Rank Responses to Align Language Models with Human Feedback without tears)
 - 가장 대표적인 강화 학습 기반의 Alignment 방식으로, 사람의 피드백을 가지고 보상을 계산하여 모델이 강화학습
- RRHF
 - 리워드 모델이 매긴 점수와 각 답변의 문장 확률 정보를 기반으로 학습을 진행, 리워드 모델의 점수를 기반으로 한 랭킹 Loss를 계산 하여 Ranking Loss를 최소화 하는 방식으로 학습
- SLiC-HF
 - 두 답변 후보를 동시에 입력으로 받아서 그 중 어떤 답변이 더 좋은 답변인지를 계산
- DPO (Direct Preference Optimization)
 - 리워드 모델 선호도 학습용 데이터를 모델에 직접 사용하여 positive 답변에 대한 확률은 높아지도록, negative 답변에 대한 확률은 낮아지도록 학습



Methods

◦ RLHF vs DPO



◦ DPO 학습 pipeline

1. π 모델(Base LM)을 SFT로 학습하는 과정 $\rightarrow \pi_{SFT}$
2. π_{SFT} 위에 Preference를 학습하는 과정 $\rightarrow \pi_{DPO}$
 - 보상모델 학습 과정이 없음, 학습할 때 리워드 모델을 사용하지 않고 레퍼런스 모델만 사용
 - Finetune시에 LM에서 데이터 Instruction에 대한 Output sampling을 하지 않음
 - 광범위한 Hparams 튜닝과정이 없어, RLHF 가 LR에 민감한 문제가 없어 보다 안정적으로 학습이 가능

Methods

◦ parameterization

• RLHF

$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(y|x)} [r_{\phi}(x, y)] - \beta \mathbb{D}_{KL}[\pi_{\theta}(y|x) || \pi_{ref}(y|x)]$$

$$\pi_r(y|x) = \frac{1}{Z(x)} \pi_{ref}(y|x) \exp\left(\frac{1}{\beta} r(x, y)\right)$$

- 보상모델 학습 > PPO (proximal policy optimization)
- PPO : policy 모델이 생성한 답에 대해 RM이 매긴 보상 스코어로 policy 모델을 강화학습. PPO의 목적함수에는 보상항 이외에도 KL 제약(KL-divergence constraint)으로 추가로 존재
- DPO는 RLHF의 SFT(supervised finetuning)과, RM(reward model) + PPO과정에서 RM + PPO 과정을 단일한 MLE 기반의 목적함수로 대체하여 한 번에 RLHF를 학습

• DPO policy objective

$$r(x, y) = \beta \log \frac{\pi_r(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x). \quad (5)$$

$$p^*(y_1 \succ y_2 | x) = \frac{\exp(r^*(x, y_1))}{\exp(r^*(x, y_1)) + \exp(r^*(x, y_2))}. \quad (1)$$

$$\begin{aligned} p^*(y_1 \succ y_2 | x) &= \frac{\exp\left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{ref}(y_1|x)} + \beta \log Z(x)\right)}{\exp\left(\beta \log \frac{\pi^*(y_1|x)}{\pi_{ref}(y_1|x)} + \beta \log Z(x)\right) + \exp\left(\beta \log \frac{\pi^*(y_2|x)}{\pi_{ref}(y_2|x)} + \beta \log Z(x)\right)} \\ &= \frac{1}{1 + \exp\left(\beta \log \frac{\pi^*(y_2|x)}{\pi_{ref}(y_2|x)} - \beta \log \frac{\pi^*(y_1|x)}{\pi_{ref}(y_1|x)}\right)} \end{aligned}$$

Implicit Reward

$$\mathcal{L}_{DPO}(\pi_{\theta}; \pi_{ref}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{ref}(y_l|x)} \right) \right]$$

- 리워드 모델 학습에 주로 사용하는 Bradley-Terry 확률 모델을 이용하여, 최종적으로 DPO Loss를 정의



- What does the DPO update do?

- 답변에 대해서 레퍼런스 모델이 계산한 확률 대비 학습하는 모델이 계산한 확률을 리워드 점수로 하여, positive 답변과 negative 답변의 리워드 점수 차이를 강도로 조절

Table 2: Unlikelihood samples from TL;DR prompts sampled at temperature 1.0. In general, we find unlikelihood fails to generate meaningful responses for more complex problems such as summarization and dialogue.


Experiments

- Figure 2: Left. The frontier of expected reward vs KL to the reference policy. DPO provides the highest expected reward for all KL values, demonstrating the quality of the optimization. Right. TL;DR summarization win rates vs. human-written summaries, using GPT-4 as evaluator. DPO exceeds PPO's best-case performance on summarization, while being more robust to changes in the sampling temperature.



Experiments

- Figure 3: Left. Win rates computed by GPT-4 for Anthropic-HH one-step dialogue; DPO is the only method that improves over chosen summaries in the Anthropic-HH test set. Right. Win rates for different sampling temperatures over the course of training. DPO's improvement over the dataset labels is fairly stable over the course of training for different sampling temperatures.



Conclusion

- DPO 가 RLHF를 대체하는 방법으로써 언어모델을 인간에 선호에 맞추어 안전하고 통제가능한 모델로 학습하는 과정을 간소화 하는 새로운 방법을 제시함
- 비교적 컴퓨팅 비용과 자원을 줄이는 동시에 성능을 높이고 안정적이고 구현이 쉽고 효율적인 장점
- 질 좋은 선호도 데이터를 사용하고 이전 단계에서 미세조정(SFT, Supervised Fine-Tuning)에 유의하는 것이 중요