

DreamBooth: Fine Tuning Text-to-Image Diffusion Models for Subject-Driven Generation

Nataniel Ruiz, Yuanzhen Li, Varun Jampani, Yael Pritch, Michael Rubinstein, Kfir Aberman
CVPR 2023

2023. 10. 15

김준철, 안종식, 강인하, 류채은

Contents

- Background
- Introduction
- Method
- Experiments
- Applications
- Conclusion

BackGround


Image Composition

Text-to-Image
Editing and Synthesis

Controllable
Generative Models

Background Image Composition


Given subject new background



물체와 배경의 Copy&Paste 이미지를 자연스럽게 합성하는 연구
한계점 : 입력한 모습으로만 합성가능

3D reconstruction

NeRF



다양한 방향의 이미지를 통해 새로운 방향에서의 물체 인식 연구
한계점 : 많은 이미지 필요, 배경을 생성할 수 없음

Background **Text-to-Image Editing and Synthesis**

GAN based Models

Instruction

Original

VQGAN-CLIP

“Green”




“Red Bus”

VQGAN이 생성한 이미지의 embedding이 CLIP과 닮아가도록 학습


텍스트를 활용해 실제와 유사한 품질의 편집 가능
한계점 : 다양한 객체들이 존재하는 데이터셋에서는 어려움을 보임

Diffusion based Models

• DALL-E2



• Imagen



CLIP의 Text Embedding을 활용하여 이미지 생성

텍스트를 활용해 매우 다양한 데이터셋에 높은 품질의 이미지 생성
한계점 : 정교한 수정이 어렵고 텍스트로만 편집 가능

Background Controllable Generative Models

Text를 활용한 제어




Figure 2: Our method is based on the DDPM model which generates an image from a noise map by iteratively removing noise at each timestep. We control the diffusion generation process by Semantic Diffusion Guidance (SDG) with language and/or a reference image. SDG is iteratively injected at each step of generation process. We only illustrate the guidance at one timestep t in the figure.


Diffusion Network에서는 이미지 제어를 위해서
Semantic 정보를 Text 형태로 입력

- Text Semantic 정보만으로 이미지 수정이 이루어지면 원래 subject들의 특징이 변화됨

Text, Mask를 활용한 제어



"a corgi wearing a bow tie and a birthday hat"



- Mask의 활용은 Mask 내부의 Structure, Content를 고려하지 않는 문제가 발생

Text, Attention Mask를 활용한 제어




- 단어와 매칭되는 attention map을 활용해 작은 부분의 변형이나 전체적인 변형이 가능
- 이미지와 매칭되는 부분에 대해 세밀한 수정 가능

➡ 원래 이미지의 프레임을 유지시킨채로 수정하는 것에 그치는 한계가 있음

Background Controllable Generative Models

Inversion 활용

- DALL-E2



- 특정 latent vector와 유사하게 생성하는 방법
- CLIP 모델을 통해 Text-image Pair Embedding 정보를 활용하여 학습 및 생성

새로운 토큰을 Diffusion에게 인식



- Text-to-Image model 를 Freeze, Text Encoder만 Tuning
- 새로운 토큰을 새로운 물체나 style로 치환하여 적용 가능
- Image variation, Text guided synthesis, Style Transfer가 가능한
한계점 : 생성능력이 freeze 된 네트워크에 한정됨

Introduction

- Definition problem

1. Local, global editing 에 제한됨
2. Object, subject의 특징유지가 어려움
3. Diffusion의 표현력이 한계가 있음
4. 배경을 생성하기 어려움
5. 많은 데이터가 필요함
6. 이미지 기반의 수정이 어려움



Vision-Language Models이 큰 발전이 이루어진 것은 사실이나 원하는 object의 특성을 유지한채 다양화 하는 능력에서는 한계가 존재한다.

- Contributions

1. Personalization 제시

- 특정 원하는 Object와 새롭게 정의한 token sequence를 연결지어 Diffusion Models domain 내에 삽입 (e.g. a [V] dog)

2. 몇 가지의 이미지 샘플과 간단한 Fine-Tuning만을 활용

- Text 설명이 없는 3~5개의 이미지만으로 구현가능

3. 새로운 Loss를 제시하여 Language Drift를 막으면서 특정 Object의 피쳐를 유지한 채 다양한 방식의 생성이 가능하도록 학습

4. 새로운 형태의 Task로 정의하였으며 새로운 Dataset과 Evaluation protocol 제시



Q & A

Methods

- Overview of Architecture
- Text-to-Image Diffusion Models
- Personalization of Text-to-Image Diffusion Models
- Class Specific Prior Preservation Loss

Methods Tasks and Datasets

- Architecture Overview



- 특정 object를 Unique Identifier에 Binding

- Binding된 Unique Identifier를 활용하여 다양한 이미지 생성

Methods Text-to-Image Diffusion Models

- Diffusion Models





Figure 2: The directed graphical model considered in this work.



Diffusion models are probabilistic generative models that are trained to learn a data distribution by the gradual denoising of a variable sampled from a Gaussian distribution. Specifically, we are interested in a pre-trained text-to-image diffusion model $\hat{\mathbf{x}}_\theta$ that, given an initial noise map $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ and a conditioning vector $\mathbf{c} = \Gamma(\mathbf{P})$ generated using a text encoder Γ and a text prompt $\mathbf{P}$, generates an image $\mathbf{x}_{\text{gen}} = \hat{\mathbf{x}}_\theta(\epsilon, \mathbf{c})$. They are trained using a squared error loss to denoise a variably-noised image or latent code $\mathbf{z}_t := \alpha_t \mathbf{x} + \sigma_t \epsilon$ as follows:

$$\mathbb{E}_{\mathbf{x}, \mathbf{c}, \epsilon, t} [w_t \|\hat{\mathbf{x}}_\theta(\alpha_t \mathbf{x} + \sigma_t \epsilon, \mathbf{c}) - \mathbf{x}\|_2^2] \quad (1)$$

where $\mathbf{x}$ is the ground-truth image, $\mathbf{c}$ is a conditioning vector (e.g., obtained from a text prompt), and α_t, σ_t, w_t are terms that control the noise schedule and sample quality, and are functions of the diffusion process time $t \sim \mathcal{U}([0, 1])$. A more detailed description is given in the supplementary material.


- Fine-tuning을 위한 base가 되는 Loss로 probabilistic generative models의 Loss를 그대로 사용

Methods Personalization of Text-to-Image Models

적은 데이터 셋으로만 Fine-Tuning을 할 경우 Overfitting이나 Mode-collapse가 종종 발생하여 Fine-tuning은 섬세하게 진행

Designing Prompts for Few-Shot Personalization

- Goal : **Implant a new (unique identifier, subject) pair into the diffusion model's dictionary**



- 입력 형태는 "a [identifier] [class noun]" (e.g. "a [V] dog")
- Unique identifier 만 사용한 경우 성능이 떨어지고 학습시간이 오래걸리는 현상 발견
- "A [unique identifier] [class noun]"으로 학습한 경우 학습된 특정 instance만 생성하는 language drift 발생

Rare-token Identifiers

- Goal : **Diffusion의 prior를 유지시키면서 원하는 identifier를 Diffusion에 임베딩**
 - 원래 모델이 가진 domain에 re-entangle 해야 하기 때문에 identifier는 weak prior를 가지고 있어야한다.
 - random characters (e.g. "xxy5syt00") 방식은 tokenizer가 분할하여 알고있는 character로 만드는 문제가 있어서 결국 vocab 안에서 rare token lookup을 추출한다.
 - Rare token identifier $f(V)$
 - character sequence to tokens
 - sequence length $k = \{1, \dots, 3\}$ work well
 - T5 : tokenizer range of $\{5000, \dots, 10000\}$ works well
 - Imagen : uniform random sampling of tokens that correspond to 3 or fewer Unicode characters (without spaces)
- (공개된 github의 sks는 9258길이의 vocabulary의 9061번째 index로 rare-token identifier)

Methods Class-specific Prior Preservation Loss

- Unique Identifier, class noun으로만 학습했을 때의 문제점


Language Drift

- NLP에서의 Language Drift
큰 corpus를 학습한 pre-trained NLP모델을
Down-stream task에 적용할 때 기존에 알고있던 semantic 정보와 syntactic 정보를 잃는 문제
- 본 논문에서의 Language Drift
텍스트 프롬프트에는 [identifier]와 [class noun]가 모두 포함되어 있으므로
fine-tuning될 때 동일한 클래스의 객체를 생성하는 방법(클래스별 prior)를
점진적으로 잊어버리고 fine-tuning한 인스턴스만 생성한다.

Reduced output diversity

입력 오브젝트의 특징을 생성할 때 다양성이 크게 줄어듦.
일반적으로 학습을 많이 했을 때 발생 (overfitting과 유사)

w/o prior-preservation loss



해결책

- Autogenous class-specific prior preservation loss**


$$\mathbb{E}_{\mathbf{x}, \mathbf{c}, \epsilon, \epsilon', t} [w_t \|\hat{\mathbf{x}}_{\theta}(\alpha_t \mathbf{x} + \sigma_t \epsilon, \mathbf{c}) - \mathbf{x}\|_2^2 + \lambda w_{t'} \|\hat{\mathbf{x}}_{\theta}(\alpha_{t'} \mathbf{x}_{\text{pr}} + \sigma_{t'} \epsilon', \mathbf{c}_{\text{pr}}) - \mathbf{x}_{\text{pr}}\|_2^2],$$

- 목적 : class의 정보를 잊지 않기 위해 class의 samples만으로 학습한 Loss를 추가
class 에 대한 지식을 유지시킴으로써 Unique Identifier, instance에만 집중해서 학습하는 것을 방지함

Methods Class-specific Prior Preservation Loss

- Autogenous class-specific prior preservation loss

: 모델의 own generated samples를 supervise 로 활용해 Class name으로 이미지를 생성하고 loss 구성



기존의 Diffusion Loss

$$\mathbb{E}_{\mathbf{x}, \mathbf{c}, \epsilon, \epsilon', t} [w_t \|\hat{\mathbf{x}}_{\theta}(\alpha_t \mathbf{x} + \sigma_t \epsilon, \mathbf{c}) - \mathbf{x}\|_2^2 + \lambda w_{t'} \|\hat{\mathbf{x}}_{\theta}(\alpha_{t'} \mathbf{x}_{\text{pr}} + \sigma_{t'} \epsilon', \mathbf{c}_{\text{pr}}) - \mathbf{x}_{\text{pr}}\|_2^2]$$

Autogenous class-specific prior preservation loss


class의 정보를 잊지 않기 위해 class만으로 생성한 이미지를 해당 프롬프트에 학습시키는 Loss를 추가

- Unique Identifier에만 집중하여 학습하지 않고 Class의 정보를 유지시키면서 학습됨
- Class를 잘 인식하므로 diversity도 기존의 모델처럼 생성하고 특정 instance로 치우치는 것을 방지함

Experiments

Experiments **Dataset and Evaluation**

- Datasets



- 30 Images
 - 30개중 21개는 물체 9개는 살아있는 동물
- 25 Evaluation prompt
 - 10 recontextrualization prompt
 - 10 accessorization prompt
 - 5 property modification for live subjects
- Evaluation Protocols
 - 30개의 Subject별로 25 prompt마다 4개씩 생성하여 총 3000개 이미지를 생성하여 평가
 - Metrics : CLIP-I, DINO

Experiments **Comparisons**

Input Images



DreamBooth (Imagen)



DreamBooth (Stable Diffusion)



Textual Inversion (Stable Diffusion)



Model Comparison with metrics

Method	DINO $\uparrow$	CLIP-I $\uparrow$	CLIP-T $\uparrow$
Real Images	0.774	0.885	N/A
DreamBooth (Imagen)	0.696	0.812	0.306
DreamBooth (Stable Diffusion)	0.668	0.803	0.305
Textual Inversion (Stable Diffusion)	0.569	0.780	0.255

Table 1. Subject fidelity (DINO, CLIP-I) and prompt fidelity (CLIP-T, CLIP-T-L) quantitative metric comparison.

- DINO : cosine similarity with ViT-S/16 embedding generated and real
- CLIP-I : average pairwise cosine similarity with CLIP embedding generated and real
- CLIP-T : average cosine similarity between prompt and image CLIP embedding


Model Comparison with user preference

Method	Subject Fidelity $\uparrow$	Prompt Fidelity $\uparrow$
DreamBooth (Stable Diffusion)	68%	81%
Textual Inversion (Stable Diffusion)	22%	12%
Undecided	10%	7%

Table 2. Subject fidelity and prompt fidelity user preference.

Experiments **Ablation Studies**

- Prior Preservation Loss Ablation



Prior Preservation Loss 를 추가해 생성의 다양성 유지

- Class-Prior Ablation

Method	DINO ↑	CLIP-I ↑
Correct Class	0.744	0.853
No Class	0.303	0.607
Wrong Class	0.454	0.728

Table 4. Class name ablation with subject fidelity metrics.

- Prompt text

"A [Identifier] [correct class noun]"

"A [Identifier]"

"A [Identifier] [wrong class noun]"

Subject Fidelity 성능 개선

Applications

Applications **Tasks**

- Recontextualization



Input images



A [V] backpack in the
Grand Canyon



A wet [V] backpack
in water



A [V] backpack in Boston



A [V] backpack with the
night sky



Input images



A [V] teapot floating
in milk



A transparent [V] teapot
with milk inside



A [V] teapot
pouring tea



A [V] teapot floating
in the sea

Applications **Tasks**


- Art Rendition



- Prompts
 1. "A painting of a [V] [class noun] in the style of [famous painter]"
 2. "A statue of a [V] [class noun] in the style of [famous sculptor]"

Applications **Tasks**

- Text-guided View Synthesis



- 학습하지 않은 고양이임에도 불구하고 4장의 입력이미지로부터 위와같은 다양한 방향의 고양이 생성

Applications **Tasks**

- Property Modification

Color modification (“A [color] [V] car”)



Input



purple



red



yellow



blue



pink

Hybrids (“A cross of a [V] dog and a [target species]”)



Input



Bear




Panda



Koala



Lion



Hippo

Applications **Tasks**

- Accessorization

Prompt : “a [V] dog wearing a police/chef/witch outfit”


Input images



Chef Outfit



Witch Outfit



Ironman Outfit



Nurse Outfit



Purple Wizard Outfit



Superman Outfit




Police Outfit



Angel Wings

Applications **Limitations**



- 그림에서 표현된 한계점

- (a) 프롬프트 맥락과 다른 이미지 생성
context에 대해 weak prior이 있을 가능성 혹은
object 유지와 배경생성을 동시에 하는 것의 어려움
- (b) 입력이미지의 특성이 유지되지 않음
- (c) 입력 데이터에 오버피팅되어 비슷한 이미지 생성

- 추가적인 한계점

- 몇몇 대상이 다른 대상에 비해 학습이 빠르다. (dogs and cats)
- 독특한 입력 subject들에 대해서 다양한 생성이 불가능하다.
- 모델 prior에 기반해 생기는 hallucination이 발생

Conclusions

- Authors presented an approach for **synthesizing novel renditions of a subject** using a few images of the subject and the guidance of a text prompt
- Our key idea is to embed a given subject instance in the output domain of a text-to-image diffusion model by **binding the subject to a unique identifier**
- this **fine-tuning process** can work given only 3-5 subject images, making the technique particularly accessible
- We demonstrated a variety of applications with animals and objects in generated photorealistic scenes, in **most cases indistinguishable from real images**

Q & A
