

Your ViT is Secretly an Image Segmentation Model


이미지 처리팀: 안가영(발표자), 안종식, 이진주, 황장훈

Contents

1. Background
2. Method
3. Experiments
4. Conclusion

Vision Transformer

- CV분야에서 Transformer 아키텍처를 적용한 모델
- CNN대신 attention 연산을 통해 이미지 정보를 효과적으로 처리



ViT-Adatper + Mask2Former

- ViT Adapter


ViT 백본의 공간적/다중 해상도 표현 한계를 보완

Mask2Former가 dense prediction에 최적화된 feature를 받을 수 있음

- Mask2Former

Pixel Decoder와 Transformer Decoder(masked attention, multi-scale 처리)를 통해


입력 feature로부터 각 객체의 마스크와 클래스를 효율적이고 정확하게 예측



<기존 segmentaion model 구조>


EoMT (Encoder-only Mask Transformer)

- 사전 학습 규모와 ViT 모델이 커질 수록
구성요소들의 긍정적 효과는 감소, 거의 불필요해질 것이라 가정함
 - 사전 학습 : DINOv2 모델의 경우 MIM을 통한 dense, fine-grained semantic 정보 추출 가능
 - 모델 크기 : 모델이 더 큰 파라미터를 가지면 더 복잡하고 다양한 패턴 학습 가능




< EoMT 구조 >


Removing the adapter



(a) Previous Method (Li et al., ViTDet)



(b) ViT-Adapter (ours)




<ViT-Adapter>

Removing the adapter

- multiscale
 - ViT의 output feature F16 (patch size 16×16)
 - upscaling : F4 and F8
 - Transposed Convolution
 - downscaling : F32
 - Convolution
- 원하는 scale에 달성할 때 까지 다음 연산 반복
 - Transposed 2x2 conv (stride : 2x2)
 - GELU
 - Depth wise Convolution (3x3)
 - Normalization

Removing the Pixel Decoder



<Mask2Former>


Removing the Pixel Decoder

- Adpator가 제거되면서 생성된 Multi Scale Feature가 Backbone에서 나온게 아니므로 별도의 통합 과정 필요 없음
- Pixel Decoder는 필요없으므로 단순화된 Feature Pyramid를 Transformer Decoder에 직접 입력


Removing Multi-scale feature Processing

- multiscale이 아닌 단일 scale을 통한 segmetation 수행
- 결국 ViT의 단일 feature에서 만들어낸 multiscale이기 때문에 multiscale에 대한 필요성에 대한 고민
- mask logits 예측 시에는 High Resolution Output Mask를 생성하기 위해 F4로 upscaling

Encoder-only Mask Transformer





Querying the ViT for masks.




- L1개의 Transformer encoder 블록은 변경 없이 입력 이미지만을 처리
- L1의 output에 k개의 learnable query 추가
- L2개의 개의 Transformer encoder 블록은 patch token과 query를 처리하는 decoder 역할도 함께함

Querying the ViT for masks.




Querying the ViT for masks.



- Mask Module

- Mask2Former 모델과 동일하게 처리
- class logits :
query token을 linear layer를 통해 예측
- mask logits :
MLP 거친 query token과
upscale된 patch token과의 내적연산

Mask annealing during training



- mask annealing
- 학습시 점진적으로 masked attention을 줄여나감
- query마다 mask를 적용할 확률(P_{mask})를 두고 해당 확률값을 1.0에서 0.0으로 점차 줄여감
- 초기에는 Masked attention으로 빠른 수렴 가능 이후 점차 Masked attention 없이도 동작하는 것을 학습
- 추론시에는 intermediate modules이나 modified attention 연산이 필요 없어 최적화된 plain ViT만을 활용하여 효율성 극대화

Experiments

Method	Params	GFLOPs	FPS	PQ
(0) ViT-Adapter + Mask2Former	349M	830	29	57.1
(1) ↳ w/o ViT-Adapter	342M	700	36 ^{↑7}	56.7 ^{↓0.4}
(2) ↳ w/o Pixel decoder	337M	685	61 ^{↑25}	56.9 ^{↑0.2}
(3) ↳ w/o Multi-scale	328M	673	64 ^{↑3}	56.7 ^{↓0.2}
(4) ↳ w/o Transformer decoder	316M	828	61 ^{↓3}	56.2 ^{↓0.5}
(5) ↳ w/o Masking = EoMT	316M	669	128 ^{↑67}	56.0 ^{↓0.2}

Table 1. From ViT-Adapter + Mask2Former to EoMT. Evaluated on COCO *val2017* [43].

모든 task-specific 구성 요소를 제거하고도 속도는 4.4배 향상, 정확도 손실은 1.1 PQ 내외로 매우 작음

Experiments

Model	Pre-train	Params	GFLOPs	FPS	PQ
ViT-Adapter + M2F	DINOv2	349M	830	29	57.1
EoMT w/ Masking		316M	828	61 ^{↑32}	56.2 ^{↓0.9}
EoMT		316M	669	128 ^{↑99}	56.0 ^{↓1.1}
ViT-Adapter + M2F	EVA-02	349M	829	25	56.7
EoMT w/ Masking		316M	826	52 ^{↑27}	56.0 ^{↓0.7}
EoMT		316M	667	77 ^{↑52}	55.5 ^{↓1.2}
ViT-Adapter + M2F	IN21K	349M	830	29	53.9
EoMT w/ Masking		316M	828	61 ^{↑32}	51.0 ^{↓2.9}
EoMT		316M	669	128 ^{↑99}	50.0 ^{↓3.9}
ViT-Adapter + M2F	IN1K	349M	830	29	50.4
EoMT w/ Masking		316M	828	61 ^{↑32}	45.9 ^{↓4.5}
EoMT		316M	669	128 ^{↑99}	44.3 ^{↓6.1}

Table 2. **Pre-training.** EoMT performs significantly better with advanced pre-training, *i.e.*, DINOv2 [51] or EVA-02 [28]. Evaluated on COCO *val2017* [43].

DINOv2, EVA-02 같은 대규모 사전학습이 있을 경우,
task-specific 구성 없이도 높은 성능 달성 가능.

Experiments

Model	Size	Params	GFLOPS	FPS	PQ
ViT-Adapter + M2F	g	1209M	2510	20	57.7
EoMT w/ Masking		1164M	2689	35 ^{↑15}	57.2 ^{↓0.5}
EoMT		1164M	2261	55 ^{↑35}	57.0 ^{↓0.7}
ViT-Adapter + M2F	L	349M	830	29	57.1
EoMT w/ Masking		316M	828	61 ^{↑32}	56.2 ^{↓0.9}
EoMT		316M	669	128 ^{↑99}	56.0 ^{↓1.1}
ViT-Adapter + M2F	B	121M	347	32	54.4
EoMT w/ Masking		93M	286	104 ^{↑72}	51.5 ^{↓2.9}
EoMT		93M	216	261 ^{↑229}	50.6 ^{↓3.8}
ViT-Adapter + M2F	S	47M	165	33	50.5
EoMT w/ Masking		24M	89	108 ^{↑75}	46.1 ^{↓4.4}
EoMT		24M	68	330 ^{↑297}	44.7 ^{↓5.8}

Table 3. **Model size.** EoMT performs significantly better as the ViT [23] model size increases. Evaluated on COCO *val2017* [43].

모델 크기가 클수록 EoMT 성능 향상. 큰 모델일수록 추가 구성 없이 segmentation 잘 수행

Experiments

Method	Backbone	Pre-training	Params	COCO <i>val2017</i> [43]				ADE20K <i>val</i> [70]			
				Input size	GFLOPs	FPS	PQ	Input size	GFLOPs	FPS	PQ
Mask2Former [†] [15]	Swin-L [45]	IN21K	216M	800 ²	868	24	57.8	640 ²	–	33	48.1
kMaX-DeepLab [66]	ConvNext-L [46]	IN21K	232M	1281 ²	–	–	58.0	1281 ²	1302	–	50.9
OneFormer [†] [35]	DiNAT-L [30]	IN21K	223M	800 ²	736	20	58.0	1280 ²	1369	10	51.5
OneFormer [†] [35]	DiNAT-L [30]	IN21K	223M	–	–	–	–	1280 ²	1369	10	53.5 ^c
MaskDINO [†] [40]	Swin-L [45]	IN21K	223M	800 ²	1326	14	58.3	–	–	–	–
Mask2Former [‡] [15]	ViT-Adapter-L [‡] [13]	DINOv2	349M	640 ²	830	29	57.1	640 ²	830	29	51.8 ^c
Mask2Former [‡] [15]	ViT-Adapter-L [‡] [13]	DINOv2	354M	1280 ²	4817	10	59.7	1280 ²	4817	10	53.0 ^c
Mask2Former [‡] [15]	ViT-Adapter-g [‡] [13]	DINOv2	1209M	640 ²	2510	20	57.7	640 ²	2510	20	52.6 ^c
Mask2Former [‡] [15]	ViT-Adapter-g [‡] [13]	DINOv2	1216M	1280 ²	13790	6	59.9	1280 ²	13790	6	54.2 ^c
EoMT (Ours)	ViT-L [23]	DINOv2	316M	640 ²	669	128	56.0	640 ²	669	128	50.6 ^c
EoMT (Ours)	ViT-L [23]	DINOv2	322M	1280 ²	4146	30	58.3	1280 ²	4146	30	51.7 ^c
EoMT (Ours)	ViT-g [51]	DINOv2	1164M	640 ²	2261	55	57.0	640 ²	2261	55	51.3 ^c
EoMT (Ours)	ViT-g [51]	DINOv2	1171M	1280 ²	12712	12	59.2	1280 ²	12712	12	52.8 ^c

Table 4. **EoMT for panoptic segmentation.** [†]During inference, these models resize the shortest side of images to the indicated scale, while preserving the aspect ratio. [‡]Our re-implementation. ^cModels for these ADE20K results are pre-trained for COCO panoptic segmentation.

EoMT는 복잡한 어댑터나 디코더 없이도,
최신 대규모 사전학습(DINOv2)과 대형 ViT 백본만으로 SOTA와 거의 동등한 정확도를
달성

Experiments

Method	Backbone	Pre-training	Params	Cityscapes <i>val</i> [17]				ADE20K <i>val</i> [70]			
				Input size	GFLOPs	FPS	mIoU	Input size	GFLOPs	FPS	mIoU
Mask2Former [†] [15]	Swin-L [45]	IN21K	216M	1024 × 2048	–	14	83.3	640 ²	–	33	56.1
MaskDINO [†] [40]	Swin-L [45]	IN21K	223M	–	–	–	–	640 ²	–	–	56.6
OneFormer [†] [35]	ConvNext-XL [46]	IN21K	373M	1024 × 2048	775	7	83.6	640 ²	607	21	57.4
OneFormer [†] [35]	DiNAT-L [30]	IN21K	223M	1024 × 2048	450	14	83.1	896 ²	678	19	58.1
kMaX-DeepLab [66]	ConvNext-L [46]	IN21K	232M	1025 × 2049	1673	–	83.5	–	–	–	–
Mask2Former [15]	ViT-L [23]	DINOv2 + DA	–	896 × 1792	–	–	84.8	896 ²	–	–	59.4
Mask2Former [‡] [15]	ViT-Adapter-L [‡] [13]	DINOv2	351M	1024 ²	5200	7	84.5	512 ²	910	21	58.9
EoMT (Ours)	ViT-L [23]	DINOv2	319M	1024 ²	4350	25	84.2	512 ²	721	92	58.4

Table 5. **EoMT for semantic segmentation.** [†]On ADE20K, these models resize the shortest side of images to the indicated scale during inference, while preserving the aspect ratio. [‡]Our re-implementation. ViT-Adapter + Mask2Former and EoMT use windowed inference, dividing each image into multiple crops, and the FLOPs and FPS results account for this. DA is Depth Anything [65].

EoMT는 기존 복잡한 구조(어댑터, 디코더 등) 없이도,
SOTA와 거의 동일한 정확도(mIoU)를 보이면서
연산 효율(FPS, GFLOPs)에서 압도적으로 뛰어남

Experiments

Training		Inference	GFLOPs	FPS	PQ
✓	Masking	✓ Masking	828	61	56.2
✓	Masking	✗ w/o Masking	669	128	27.4↓28.8
✗	w/o Masking	✗ w/o Masking	669	128	53.2↓3.0
✓→✗	<i>Mask annealing</i>	✗ w/o Masking	669	128	56.0↓0.2

Table 7. ***Mask annealing***. Effectively removes masked attention during inference. When never masking, intermediate masks are not predicted or supervised. Evaluated on COCO *val2017* [43].

Mask Annealing을 통해 추론 시 마스킹 제거가 가능하면서도 성능 유지 가능
→ 핵심 기여 요소

Experiments

Method	Backbone	Pre-training	mIoU _{ID}	mIoU _{OOD}
M2F [15]	Swin-L [45]	IN21K	83.3	69.4
M2F [‡] [15]	ViT-Adapter-L [‡] [13]	DINOv2	84.5	78.0
EoMT (Ours)	ViT-L [23]	DINOv2	84.2	77.2

Table 8. Out-of-distribution generalization. Despite similar in-distribution performance on Cityscapes *val* (mIoU_{ID}), DINOv2-based models generalize significantly better out-of-distribution (mIoU_{OOD}). Trained on Cityscapes *train* [17], evaluated on BRAVO [58]. [‡]Our re-implementation.

BRAVO 벤치마크에서 DINOv2 + EoMT가 기존 Swin 기반 모델보다
7.8 mIoU 더 높은 OOD 성능을 보임
→ 사전학습 품질이 높은 ViT 모델이 더 강한 일반화 성능을 갖는다는 증거

Conclusion

- 기존의 복잡한 구성요소가 필요 없음
Convolutional Adapter, Pixel Decoder, Transformer Decoder 가 없어도
모델 크기와 사전 학습 규모가 충분히 크다면
task-specific 모듈이 없어도 ViT 자체가 segmentation을 수행할 수 있음
- Encoder-only Mask Transformer (EoMT)
복잡한 decoder 없이도 높은 정확도(PQ, mIoU, AP)와 매우 빠른 속도(FPS) 달성
- 계산 자원을 복잡한 구조에 쓰기보다,
ViT 자체를 키우고 잘 pre-train 하는 것이 더 나음