

From Poses to Identity: Training-Free Person Re-Identification via Feature Centralization

발표자 : 이진주

자료조사 : 최비결, 허정원, 황장훈

Introduction

➡ 연구 배경

Person Re-ID (재식별): 서로 다른 카메라에서 동일 인물을 찾아내는 핵심 과제

문제점:

- 이미지 품질 저하, 모델 한계 → 특징(feature) 노이즈 발생
- 정확도와 검색 성능 저하

Introduction

▶ 제안 방법

1. Training-Free Feature Centralization


- 학습 없이도 특징 노이즈 완화
- 샘플 특징을 **신원 중심**으로 모아 대표성 강화

2. Identity-Guided Pedestrian Generation (IPG)

- 기존 GAN: 효과 제한적, 데이터 증강 수준
- 기존 Diffusion: 고품질 가능하지만 신원 일관성 부족
- 제안: **ReID 신원 특징을 가이드**로 활용해
 - 다양한 자세/상황에서도 동일 인물 고품질 이미지 생성
 - 신원 일관성 확보

3. Neighbor Feature Centralization (NFC)

- 재랭킹 아이디어 활용
- 거리 행렬 기반 숨은 양성 샘플 발굴 → 특징 중앙화



Related Work

➡ Person Re-Identification

주요 접근: **CNN, Vision Transformer(ViT)** 기반 딥러닝

학습 전략:

Feature extraction (특징 추출)

- 사람을 구분할 수 있는 중요한 특징을 뽑아내는 과정(무엇을 볼지?)

Metric learning (거리 학습)

- 추출된 특징 벡터들 간의 거리(distance)를 학습해, 신원을 잘 구분하도록 특징 공간의 구조를 학습 (어떻게 비교할지?)

데이터셋:

Market-1501 - 일반 상황 벤치마크

Occluded-REID - 부분 가려짐 문제 해결

SYSU-MM01 - 가시광선/적외선 매칭 (야간 감시)

Related Work

➡ Feature Enhancement in Re-Identification

목표: 강건한 특징 표현 추출

방법:

1. 데이터 증강 기법 → 다양한 학습 샘플 확보

2. GAN 기반 특징 강화 → 자세 변화 대응

- FD-GAN: 신원과 자세 분리


- Appearance & Structure code 분리 (Zheng et al.)

- 신원 관련/비관련 특징 분리 (Eom et al.)

한계:

GAN → 훈련 불안정, 모드 붕괴 → 신원 일관성 유지 어려움

보완: Re-ranking (예: k-Reciprocal) → 거리 보정으로 정확도 향상



Related Work

➡ Person Generation Models

GAN 활용 → 데이터 증강 & 특징 강화

- Style transfer GAN: 카메라/배경/RGB-IR 도메인 변환
- Pose-transfer GAN: 다양한 자세 합성
- Random generation GAN: 무작위 인물 생성 + LSR 자동 라벨링

한계: 자세 변화 시 identity drift(신원 왜곡) 발생

확산 모델(Diffusion models) → 고품질 인물 생성

- Stable Diffusion 기반 연구를 통해 연구자들은 2D 사람 자세에 조건을 부여해 고품질 인물 이미지를 생성하는 기법 개발
 - ex.ControlNet: 포즈 조건 기반 정밀 제어 가능
-

Method


Method 개요

목표: 특징을 신원 중심(identity center)으로 중앙화

→ 노이즈 제거 & 신원 정보 강화

접근:

1. 특징 분포 분석 (정규분포 근사)
2. 신원-가이드 보행자 생성 (IPG)
3. 이웃 기반 특징 중앙화 (NFC)



Method

► Feature Distribution Analysis

$$f_i = f(x_i), \quad f_i \in \mathbb{R}^d \qquad \mathbf{f}_{i,k} \sim \mathcal{N}(\mu_k, \sigma_k^2) \quad > \quad \mathbf{f}_i \sim \mathcal{N}(\mu, \Sigma)$$

ReID 학습에서 사용하는 전형적 손실함수 :

Cross-Entropy Loss → ID 단위 분류 제약 부여.

Contrastive/Triplet Loss → 같은 ID는 가까이, 다른 ID는 멀리.

Center Loss → 각 ID의 중심을 명시적으로 만들어 제약.

-> 세 Loss 모두 동일 ID 특징을 평균 주위로 집합화 유도

결과: 다변량 정규분포로 근사 가능

이론적 근거: 중심극한정리 (CLT)

(독립이고 동일한 분포를 따르는 확률 변수들을 많이 더하면, 그 분포가 원래 어떤 분포였든 결국 정규분포에 가까워진다)

Method

► Feature Distribution Analysis

Identity Density (ID²) Metric

기존 문제: t-SNE는 일부 ID만 시각화 → 전체 성능 정량화 어려움

$$\text{ID}^2 = \frac{1}{N} \sum_{i=1}^N \frac{1}{n_i} \sum_{j=1}^{n_i} d \left(\frac{f_{ij}}{\|f_{ij}\|_2}, c_i \right) \quad \text{표} \quad c_i = \frac{1}{n_i} \sum_{j=1}^{n_i} \frac{f_{ij}}{\|f_{ij}\|_2}$$

정규화된 임베딩 + 유클리드 거리로 계산

장점: 전 ID에 대해 글로벌 성능 측정 가능

c_i : ID i 의 정규화된 중심

값이 낮을수록 ID별 응집이 잘 됨

Method


➡ Identity-Guided Pedestrian Generation을 통한 특징 중앙화

(1) Feature Centralization

동일 신원 특징은 다변량 정규분포(multivariate normal distribution)를 따르며
샘플을 더 모을수록 신원 중심(Identity Center) 근사 가능

단순 기법: 수평 플립 + 특징 합치기

- 이 방식은 효과가 있지만 너무 단순한 “트릭”이라 기여도가 불명확해질 수 있
- 따라서 논문 실험에서는 **일부러 사용하지 않고** (즉, feature flipping 배제), 제안 방법(IPG, NFC)의 순수 효과를 보여줌.
- 단, 실제로 적용한다면 성능이 더 올라갈 수도 있음을 언급.



Method

➡ Identity-Guided Pedestrian Generation을 통한 특징 중앙화

(2) Identity-Guided Diffusion Process (IPG)

동일 신원의 샘플을 더 확보하기 위해 **IPG 패러다임** 제안

- Stable Diffusion 기반으로, **신원 특징을 조건으로 사용해** 동일 인물의 여러 포즈 이미지를 생성.
- 이렇게 얻은 샘플을 활용하여 feature centralization 수행.

Stable Diffusion 구조를 따르며,


reference UNet을 사용해 기준 이미지의 특징을 확산 과정에 주입하고,
denoising UNet을 통해 최종 타겟 잠재표현을 생성

$$\mathbf{z}_{t-1} = \epsilon_{\theta}(\mathbf{z}_t, t, \mathbf{E}_{\text{pose}}, \mathbf{H}), t \in [0, T]$$

H : 신원 특징(identity feature)

Epose : 포즈 특징

매 시간 스텝마다 Epose와 H가 디노이징 과정을 가이드



Method

➡ Identity-Guided Pedestrian Generation을 통한 특징 중앙화

(2) Identity-Guided Diffusion Process (IPG)

Identity Feature Redistribute (IFR) 모듈 : ID 특징을 단순히 그대로 쓰지 않고, 재분배/저차원 블록화하여 더 효율적으로 사용.

- 목적: 잡음을 줄이고, 생성 모델이 identity 정보를 더 안정적으로 활용하도록 함.
- 결과적으로 생성 이미지에서 ID 일관성이 높아짐.

-주어진 입력에 대해 ReID 모델 f 를 적용하여 얻은 강건한 신원 특징 H 는 attention 모듈의 K, V 로 사용되어, 모델이 신원

$$\mathbf{H} = \text{IFR}(f(\mathbf{x})) = \text{LN}(\text{Linear}(\mathbf{f}))$$

-> ReID에서 추출한 고차원 identity feature $f(x)$ 를 저차원 블록들로 재배치(redistribute)하고 정규화하여, diffusion UNet의 attention에서 K, V 로 사용할 수 있는 안정된 identity 표현 H 로 만드는 모듈

Method

➡ Identity-Guided Pedestrian Generation을 통한 특징 중앙화

(2) Identity-Guided Diffusion Process (IPG)

Pose Encoder

- 구조: CNN 기반, 계층적으로 채널 수 증가(16→32→64→128).
 - 각 블록은 3×3 Conv -> stride-2 Conv -> SiLU 활성화.
 - 최종 출력: Conv를 통해 임베딩 차원 320으로 매핑
 - 출력된 pose feature는 denoising UNet 입력 latent에 더해져, 포즈를 조건으로 반영
-

Method

► Identity-Guided Pedestrian Generation을 통한 특징 중앙화

(2) Identity-Guided Diffusion Process (IPG)

Training Strategy

각 신원 i 에 대해, 참조 이미지 및 타겟 이미지를 무작위로 선택

$$\begin{aligned}x_{i,j}^{ref} &\in S_i^{ref} \\ x_{i,j}^{trg} &\in S_i^{trg}\end{aligned}$$

x_{ref} 는 IFR을 통해 H 로, x_{trg} 는 Pose Encoder를 통해 E_{pose} 로 변환

x_{trg} 는 사전학습된 VAE 인코더를 통해 latent z 로 매핑

$$z = VAE(x_{i,j}^{trg}) + \epsilon$$

학습은 예측된 노이즈와 실제 노이즈 간 MSE 손실로 진행

$$\mathcal{L} = \mathbb{E}_{\mathbf{z}, t, \epsilon} \left[\|\epsilon - \epsilon) \theta(\mathbf{z}_t, t, \mathbf{E}_{pose}, \mathbf{H})\|^2 \right]$$

-> 참조의 신원(H)을 목표 포즈(E_{pose})로 자연스럽게 옮기는 복원 경로를 학습

Method

► Identity-Guided Pedestrian Generation을 통한 특징 중앙화

(3) 대표 포즈 선택 (Selection of Representative Pose)

- 동일 인물이라도 포즈(앞모습, 옆모습, 뒷모습 등)에 따라 feature가 크게 달라짐
 - 예: 어떤 포즈에서는 얼굴·상체 특징이 잘 드러나지만, 다른 포즈에서는 정보가 부족할 수 있음.
 - 따라서 모든 포즈가 ID를 똑같이 잘 나타내지는 않음.
- 이에 따라 대표 포즈(Representative Pose)개념을 도입하였으며, 신원 중심과 가장 가까운 특징을 가진 이미지를 대표 포즈로 선택(모든 샘플 feature의 평균(center))

$$\mathbf{f}_{\text{mean}} = \frac{1}{N} \sum_{i=1}^N \mathbf{f}_i$$

평균과 가장 가까운 샘플을 대표 포즈로 선정.

$$\text{pose} = \arg \min_i d(\mathbf{f}_{\text{mean}}, \mathbf{f}_i)$$

- 실험에서는 대표 포즈들 중 8개 방향을 무작위 선택하여, 신원성을 더 잘 반영하는 이미지를 생성

Method

► Identity-Guided Pedestrian Generation을 통한 특징 중앙화

(4) 특징 중앙화 강화 (Feature Centralization Enhancement)

생성된 다중 포즈 이미지를 통해 추출된 특징을 원본 특징과 결합하여 최종 중앙화 특징을 얻음

IPG로 생성한 feature들을 원본 feature와 합쳐 최종 중앙화 특징을 만드는 단계로 이전단계에서 선택한 대표 포즈들을 바탕으로 새로운 이미지를 생

$$\tilde{\mathbf{f}} = \|\mathbf{f} + \frac{\eta}{M} \sum_{i=1}^M \mathbf{f}_i\|_2$$

η : feature의 품질에 따라 기여도를 조절하는 계수

$\mathbf{f}$: 원본 참조 이미지 특징

$\mathbf{f}_i$: 생성된 M개 이미지의 특징

- 각 생성 이미지에서 feature를 추출한 뒤, 원본 이미지의 feature와 결합해 중앙화된(feature-centralized) 표현을 얻음.
- 마지막에 L2 정규화 수행 → feature 분포를 원래 공간과 일관되게 유지.

즉, 원본 특징에 “생성 이미지들의 평균 특징”을 보정값처럼 더해 강화된 표현을 얻는 과정.

Method

➡ Neighbor Feature Centralization (NFC)

- NFC 목적: 레이블이 없는 상황에서도 feature를 보강.
- 각 샘플의 feature에 상호 최근접 이웃(mutual nearest neighbors)을 찾아 중첩
→ 개별 feature 잡음을 줄이고 ID 구별성을 강화.

Algorithm 1 Neighbor Feature Centralization (NFC)

Require: Feature vectors $\{\mathbf{z}_i\}_{i=1}^N$, parameters k_1, k_2

Ensure: Centralized feature vectors $\{\mathbf{z}_i^{\text{centralized}}\}_{i=1}^N$

```
1: Compute pairwise distance matrix  $\mathbf{D} = [d_{ij}]$ 
2: for  $i = 1$  to  $N$  do
3:   Set  $d_{ii} = C$  ▷ Avoid self-matching
4: end for
5: for  $i = 1$  to  $N$  do
6:    $\mathcal{N}_i \leftarrow$  indices of top  $k_1$  neighbors of  $\mathbf{z}_i$ 
7: end for
8: for  $i = 1$  to  $N$  do
9:    $\mathcal{M}_i \leftarrow \emptyset$ 
10:  for each  $j \in \mathcal{N}_i$  do
11:     $\mathcal{N}_j^{k_2} \leftarrow$  indices of top  $k_2$  neighbors of  $\mathbf{z}_j$ 
12:    if  $i \in \mathcal{N}_j^{k_2}$  then
13:       $\mathcal{M}_i \leftarrow \mathcal{M}_i \cup \{j\}$ 
14:    end if
15:  end for
16: end for
17: for  $i = 1$  to  $N$  do
18:    $\mathbf{z}_i^{\text{centralized}} \leftarrow \mathbf{z}_i + \sum_{j \in \mathcal{M}_i} \mathbf{z}_j$ 
19: end for
```

Experiments

■ Implementation Details

Data Cleaning

효과적인 생성 모델을 학습하기 위해서는 고품질 데이터가 필요

-> 그러나 현재의 ReID 데이터셋에는 많은 저화질 이미지가 포함되어 있으며 이를 제거하여 모델에 대한 저화질 데이터셋의 간섭을 줄여야 했음

기존 문제점 :

극도로 저화질 이미지: 해상도가 너무 낮아 사람 눈으로도 '사람'으로 인식하기 힘든 경우.

자세 추정 실패: 자세 추정 모델이 일부 이미지에서 보행자 자세를 제대로 검출하지 못하는 경우.

해결 : 3.1절의 특징 분포 분석 기반 (Feature Distribution Analysis) 으로 정제

Experiments

■ Implementation Details

신원-가이드 보행자 생성 모델 세부사항(IPG Model)

Reference UNet과 Denoising UNet에 Stable Diffusion v1.5 사전학습 가중치 사용

VAE 인코더·디코더: 공식 가중치로 초기화 후 freeze

ReID 모델: TransReID의 사전 학습 모델을 사용하였으며 , Market1501에서 카메라 정보 없이 학습된 버전을 활용하고 freeze

학습 데이터

Market1501, Mars, MSMT17, SYSU-MM01 학습셋에서 총 1,946명의 ID를 수집

학습 세팅

GPU: L20(48GB) 단일 장비, 반복 횟수: 80,000 iterations, Batch size: 4, 소요 시간: 약 20시간

Optimizer: Adam, 학습률 $1e-5$, weight decay 0.01, 이미지 크기: 512×256

데이터 증강: 참조 이미지에 한해 Random Flip, Random Erasing 적용

Experiments

► Implementation Details

대표 자세 기반 이미지 생성

Market1501에서 8개 대표 포즈 선택

각 테스트 이미지 → 8개 생성 이미지

설정: DDIM 20 steps, guidance=3.5, seed=42

ReID 테스트 설정

오픈소스 사전학습 모델 사용, 카메라 ID 제거 (생성 이미지와 일관성 유지)

이미지 플립 트릭 미적용

실험별 파라미터:

Market1501: $\eta = 2$, $k1 = k2 = 2$

Occluded REID: $\eta = 1$, $k1 = k2 = 1$

SYSU-MM01: $\eta = 1/4$, $k1 = k2 = 2$

Experiments

Improvements on State-of-the-art Method

제안한 중앙화(IPG/NFC)는 모델(CNN/ViT)과 과제(일반/가림/크로스모달리티)에 비
의존적으로 동작하며, re-ranking 없이도 일관된 향상을 보임
재랭킹(re-ranking) 없이도 성능 향상 → 새로운 SOTA 달성
주요 성능 결과:

Market1501 (CLIP-ReID, CNN 기반)

- mAP 94.9%, Rank-1 97.3%

Occluded-ReID (KPR)

- mAP 89.34%, Rank-1 91%

SYSU-MM01 (SAAI)

- All-search: mAP 76.44%, Rank-1 79.33%

- Indoor-search: mAP 86.83%, Rank-1 84.2%

Dataset		Model	Venue	Base	Method	mAP↑	Rank-1↑	ID ² ↓
Market1501		TransReID[16](w/o camid)	ICCV21	ViT	official	79.88	91.48	0.2193
					+ours	90.39(+10.51)	94.74(+3.26)	0.1357
		TransReID[16](w/ camid)			official	89	95.1	0.2759
					+ours	93.01(+4.01)	95.52(+0.42)	0.1967
		CLIP-ReID[31]	AAAI23	ViT	official	89.7	95.4	0.0993
					+ours	94(+4.3)	96.4(+1.0)	0.0624
				CNN	official	89.8	95.7	0.0877
					+ours	94.9(+5.1)	97.3(+1.6)	0.053
Occluded-ReID		KPR[47]	ECCV24	ViT	official	79.05	85.4	0.3124
					+ours	89.34(+10.29)	91(+5.6)	0.1434
		BPBReID[46]	WACV23	ViT	official	70.41	77.2	0.377
					+ours	86.05(+15.64)	89.1(+11.9)	0.1504
SYSU-MM01	All	SAAI[9]	ICCV23	CNN	official	71.81	75.29	0.4817
					+ours	76.44(+4.63)	79.33(+4.04)	0.4072
	Indoor				official	84.6	81.59	0.4424
					+ours	86.83(+2.23)	84.2(+2.61)	0.3694
	All	PMT[38]	AAAI23	ViT	official	66.13	67.7	0.4308
					+ours	75.43(+9.3)	74.81(+7.11)	0.3133
	Indoor				official	77.81	72.95	0.4046
					+ours	84.29(+6.48)	80.29(+7.34)	0.2995

Experiments

► ReID without Training

TransReID → ImageNet 사전학습 ViT 모델 기반, 대조 학습(contrastive learning) 활용(군집화 효과 제공)

제안한 보행자 생성 모델(Pedestrian Generation):

- 높은 신원 일관성(identity consistency) 보장

-> 곧, 생성된 이미지가 동일 라벨의 속성을 유지한다는 것을 의미
동일 ID의 다양한 포즈 이미지 생성 가능


성능 개선:

개별 샘플의 특징이 보행자 매칭 능력이 부족하더라도

(mAP과 Rank-1 값이 각각 3.34%와 11.4%에 불과한 경우에도)

제안 기법 적용 시 → mAP 57.27%, Rank-1 82.39% 으로 향상됨

t-SNE 시각화: 10개 ID의 특징 분포가 뚜렷하게 클러스터링됨



Method	mAP↑	R1↑	R5↑	R10↑	ID ² ↓
w/o training	3.34	11.4	21.88	28	0.5135
+IPG	52.81	78.92	91.21	94.27	0.2158
+IPG+NFC	57.27	82.39	90.17	92.81	0.1890

Experiments

➡ Ablation Study

NFC + IPG 영향

Neighbor Feature Centralization (NFC)와 Identity-Guided Generation을 통한 Feature ID-Centralizing (IPG) 기법의 효과를 검증하기 위해 포괄적인 절제 실험을 수행
-> 큰 성능 향상

Methods	mAP↑	Rank-1↑	ID ² ↓
Base	79.88	91.48	0.2193
+NFC	83.92	91.83	0.1824
+IPG	88.02	94.77	0.1553
+NFC+IPG	90.39	94.74	0.1357

Gallery ^{NFC}	Query ^{NFC}	mAP↑	Rank-1↑
✗	✗	79.88	91.48
✓	✗	81.70	92.04
✗	✓	82.76	91.69
✓	✓	83.92	91.83

Gallery ^{IPG}	Query ^{IPG}	mAP↑	Rank-1↑
✗	✗	79.88	91.48
✓	✗	84.65	92.07
✗	✓	82.18	92.40
✓	✓	88.02	94.77

Experiments


➡ Ablation Study

IFR 모듈 효과

Market1501 데이터셋에서 7개의 이미지를 무작위로 선택,
각 이미지에 대해 5개의 서로 다른 포즈를 선택.

그 후, Identity Feature Redistribute (IFR) 모듈을 적용했을
때와 적용하지 않았을 때의 결과를 시각화

-> ID 특징이 생성된 결과물에 큰 영향을 주는 것을 확인 가능



Experiments

➡ Ablation Study

생성 이미지 수 영향

8개의 대표 포즈에서 생성된 이미지 수를 달리 선택하여
특징 향상 효과를 검증

Section 3.1에서 언급한 이론과 일치하는 결과
즉, 동일한 ID의 더 많은 특징이 집계될수록, 개별
이미지에서 추출된 노이즈가 줄어들고, ID 표현 능력이
강화되어 매칭 성능이 개선

대표 포즈 기반 생성 이미지 수 $\uparrow \rightarrow$ 노이즈 감소 + ID 표현
강화 $\rightarrow$ 매칭 성능 개선 (Tab.6)

N	Gallery ^{IPG}			Query ^{IPG}			Gallery ^{IPG} +Query ^{IPG}		
	mAP $\uparrow$	R1 $\uparrow$	ID ² $\downarrow$	mAP $\uparrow$	R1 $\uparrow$	ID ² $\downarrow$	mAP $\uparrow$	R1 $\uparrow$	ID ² $\downarrow$
0	79.88	91.48	0.2313	79.88	91.48	0.1623	79.88	91.48	0.2193
1	80.96	90.97	0.2087	79.99	90.83	0.1363	82.13	92.01	0.1961
2	82.86	91.45	0.1904	81.17	92.04	0.1156	85.27	93.71	0.1773
3	83.42	91.75	0.1837	81.55	92.25	0.1077	86.16	94.21	0.1704
4	83.81	92.1	0.1795	81.76	92.34	0.1027	86.75	94.24	0.1661
5	84.07	91.83	0.1758	81.85	92.07	0.0984	87.23	94.71	0.1623
6	84.3	91.98	0.1730	81.96	92.52	0.0950	87.52	94.63	0.1593
7	84.49	91.86	0.1707	82.03	92.37	0.0922	87.76	94.60	0.1570
8	84.65	92.07	0.1691	82.18	92.40	0.0902	88.02	94.77	0.1553


Experiments

► Visualizations

동일 포즈, 다른 사람

Market1501, SYSU-MM01, Occluded-ReID

데이터셋에서 8개의 대표 포즈 시각화



Experiments

➡ Visualizations

무작위 사람 & 무작위 포즈

발전된 성능을 입증하기 위해 전체 데이터셋에서 무작위로 샘플을 선택하고 각 샘플마다 무작위 포즈를 선택

이 과정에는 일부 문제가 있는 포즈도 포함되었는데, 이는 모델이 보여줄 수 있는 다양성(diversity)을 충분히 입증하는 사례



Conclusion

Training-Free ReID 프레임워크

- 신원 중심(identity center) 기반의 특징 중앙화(feature centralization)
- 학습 없이 노이즈 감소 및 신원 표현 강화

Identity-Guided Pedestrian Generation (IPG)

- 고품질 다자세 이미지 생성
- 가시광선 / 적외선 / 가림 상황에서도 신원 일관성 유지

Neighbor Feature Centralization (NFC)

- 기존 특징 분포 유지 + 잠재적 양성 샘플 발굴
 - 기존 재랭킹(re-ranking) 기법과 결합 가능
-