

GaussianFormer-2: Probabilistic Gaussian Superposition for Efficient 3D Occupancy Prediction

Yuanhui Huang, Amonnut Thammatatrakoon, Wenzhao Zheng,
Yunpeng Zhang, Dalong Du, Jiwen Lu, Tsinghua University, China
PhiGent Robotics

이찬영, **최승준**, 허정원

Introduction

- 자율주행에서 가장 주요한 센서는 카메라와 라이다
- **가격:** 카메라 (비전) < 라이다
- 카메라는 임의의 장애물을 포착할 수 없기 때문에 주행 안전성과 신뢰성에 문제
- 3D Semantic occupancy prediction (의미론적 점유 추론) 방식은 이러한 한계점을 해결





다수의 이미지



H x W x D x Class

Introduction


- 다수의 이미지 -> **Representation for 3D Scene**
- **Voxel**: 정육면체의 voxel로 이루어진 기본적인 representation
- **Plane**: 평면으로 이루어진 representation, BEV(Bird's Eye View), TPV (Tri-Perspective View)
- 3D 장면에서 빈 공간에 대한 연산 -> **계산 낭비**
- **Object-Centric Sparse Scene**: 물체 중심의 representation, **3D Gaussians**
- **3D Gaussian**: 3차원 공간에서 어떤 물체나 특징의 분포를 확률적(가우시안 분포)으로 표현한 방법 (오비탈)



Related Works

- **3D Semantic Occupancy Prediction**

- 주행 장면을 이해가능하도록 풀어내는 주요 자율주행 모델링
- 각 장면의 각 복셀을 라벨링하는데 목표.
- 라이다: 날씨가 안 좋을 때나 먼 물체를 인식할 때 한계 → 카메라 방식이 각광
- Grid-based representation → Object-centric representation 전환




Tri-Perspective View for Vision-Based 3D Semantic Occupancy Prediction

Related Works


- **Grid-based scene representations**

- **Plane**: 2D 형태로 압축, 경쟁력있는 방식.
- **BEVFormer**는 라이다 방식과 비교해도 될 만큼의 성능.
- BEV feature는 height에 정보를 잃어버려 3d occupancy를 맞히는데 적절하지 X.



Related Works

- Grid-based scene representations
 - TPVformer는 BEV representation 3개를 3D상으로 붙인것.




Tri-Perspective View for Vision-Based 3D Semantic Occupancy Prediction

Related Works

- Grid-based scene representations


- 다른 연구로 **voxel representation**을 이용 연구. → 필요없는 빈공간에 대한 **중복된 연산**



Related Works

- **Object-centric scene representations**

- spatial redundancy(빈공간에 대한 연산 중복)를 해결하기 위해서, 최근 연구에서 sparse representation을 채택.
- 밀집된 그리드를 **자세한 파티션**으로 나누고 비어 있는 것으로 예상되는 영역을 생략
- 실제로는 점유되어 있는데 안되어 있다고 분류되어서 영역을 완전히 없애버리는 것이 한계




(b) 3D and 2D Visualization of Octree Structures

Octreeocc: Efficient and multi-granularity occupancy prediction using octree queries

Related Works

- **Object-centric scene representations**


- spatial redundancy를 해결하기 위해서, 최근 연구에서 **sparse representation**을 채택.
- sampling한 **point representation**을 이용해 refinement process에서 query로 활용
- point는 공간 범위에 대한 정보가 없어 한계



Occupancy as Set of Points

GaussianFormer

- Image to Gaussians: 이미지들을 3D 가우시안으로 변환하는 모델



Gaussian Properties and Queries

- 기우시안의 위치, 크기, 클래스 정보를 담음.
- Gaussian Properties: **mean, scale, rotation, semantic logits, opacity** (gaussian former2)
- mean (3) + scale (3) + rotation (4) + opacity (1) = 11 + |C|

Initial Properties



$$\hat{o}(\mathbf{x}; \mathcal{G}) = \sum_{i=1}^P \mathbf{g}_i(\mathbf{x}; \mathbf{m}_i, \mathbf{s}_i, \mathbf{r}_i, a_i, \mathbf{c}_i),$$

$$\mathbf{g}(\mathbf{x}; \mathbf{G}) = a \cdot \exp\left(-\frac{1}{2}(\mathbf{x} - \mathbf{m})^T \mathbf{\Sigma}^{-1}(\mathbf{x} - \mathbf{m})\right) \mathbf{c},$$


$$\mathbf{\Sigma} = \mathbf{R} \mathbf{S} \mathbf{S}^T \mathbf{R}^T, \quad \mathbf{S} = \text{diag}(\mathbf{s}), \quad \mathbf{R} = \text{q2r}(\mathbf{r}),$$

$$\mathcal{G} = \{\mathbf{G}_i \in \mathbb{R}^{\tilde{d}} | i = 1, \dots, P\} \quad P \text{ 개의 } 11 + |C| \text{ 길이 벡터}$$

Gaussian Properties and Queries

- High dimensional feature vectors
- Gaussian의 feature (ex 이미지 feature pixel 위치 (w,h) - properties, 이미지 feature pixel - queries)
- 3D 정보를 압축하게 하고, refinement module에 수정(rectification)에 대한 가이드를 제공.


Initial Queries



$$\{\mathbf{Q}_i \in \mathbb{R}^m | i = 1, \dots, P\} \quad P \text{ 개의 } m \text{ 길이 벡터}$$

Self-encoding Module

- 이미지의 경우 각 pixel 간의 관계를 encoder를 통해 학습함. -> 가우시안도 마찬가지로 query 간 관계를 학습.
- 보통 voxel, planar에 deformable attention 적용, 하지만 3D sparse gaussian에 적합 X.
- 3D Gaussians interaction -> 3D sparse Convolution: 근처 가우시안 간의 관계를 학습.
- Treat Gaussians means as a point -> voxelize
- $X \times Y \times Z$ voxels $\ggg$ 3D Gaussians P



Sparse Convolution






Image Cross-attention Module

- 시각적 정보를 이미지에서 추출해서, 압축된 가우시안 query와 image feature간 attention 연산
- 가우시안의 중심으로부터 covariance에 따른 일정 간격만큼 R개의 reference point 추출
- 카메라 extrinsics, intrinsics에 따라 reference point -> feature map 에 projection
- Deformable attention을 적용해서 각 가우시안의 reference point에서 feature map 사이의 관계를 학습




$$\text{ICA}(\mathcal{R}, \mathbf{Q}, \mathbf{F}; \mathcal{T}, \mathcal{K}) = \frac{1}{N} \sum_{n=1}^N \sum_{i=1}^R \text{DA}(\mathbf{Q}, \pi(\mathcal{R}; \mathcal{T}, \mathcal{K}), \mathbf{F}_n),$$

- Q: gaussian query
- π : projection
- R: reference points, T: extrinsics, K: intrinsics
- $\mathbf{F}_n$: image features with image number N
- DA: deformable attention

Image Cross-attention Module

- 시각적 정보를 이미지에서 추출해서, 압축된 가우시안 query와 image feature간 attention 연산
- 가우시안의 중심으로부터 covariance에 따른 일정 간격만큼 R개의 reference point 추출
- 카메라 extrinsics, intrinsics에 따라 reference point -> feature map 에 projection
- Deformable attention을 적용해서 각 가우시안의 reference point에서 feature map 사이의 관계를 학습




$$\text{ICA}(\mathcal{R}, \mathbf{Q}, \mathbf{F}; \mathcal{T}, \mathcal{K}) = \frac{1}{N} \sum_{n=1}^N \sum_{i=1}^R \text{DA}(\mathbf{Q}, \pi(\mathcal{R}; \mathcal{T}, \mathcal{K}), \mathbf{F}_n),$$

- $\text{DeformAttn}(\mathbf{z}_q, \mathbf{p}_q, \mathbf{x})$
- $\mathbf{z}_q$ (query_feature): reference point에 해당하는 query
- $\mathbf{p}_q$: reference point 위치 정보
- $\mathbf{x}$: image feature

Refinement Module


- Gaussian Queries -> MLP 적용
- Mean 값을 제외하고 나머지는 residual 하게 추정.
- Mean 값은 gaussian의 위치에 해당 -> 너무 왔다갔다 하는 것을 방지



$$\hat{\mathbf{G}} = (\hat{\mathbf{m}}, \hat{\mathbf{s}}, \hat{\mathbf{r}}, \hat{\mathbf{c}}) = \text{MLP}(\mathbf{Q}), \quad \mathbf{G}_{new} = (\mathbf{m} + \hat{\mathbf{m}}, \hat{\mathbf{s}}, \hat{\mathbf{r}}, \hat{\mathbf{c}}).$$

GaussianFormer




- Image to Gaussians



Gaussian-to-Voxel Splatting

- 가우시안을 semantics occupancy prediction으로 변형하는 과정
- 한 voxel 위치에 대하여 모든 gaussian을 고려하는 것은 오래걸리는 작업 $O(XYZ \times P)$
- tuple형태로 가우시안 번호와 해당되는 복셀을 저장.
- 복셀을 포함하는 가우시안만 모아서 계산

$[(G1,7),(G1,8),(G1,13),$
 $(G2,9),(G2,13),(G2,14),$
 $(G3,22),(G3,23),(G3,24)]$
 $\xrightarrow{\text{Sort}}$
 $[\dots,(G1,13),(G2,13),\dots]$




$$\hat{o}(\mathbf{p}; \mathcal{G}) = \sum_{i \in \mathcal{N}(\mathbf{p})} \mathbf{g}_i(\mathbf{p}; \mathbf{m}_i, \mathbf{s}_i, \mathbf{r}_i, \mathbf{c}_i),$$

$$\mathbf{g}(\mathbf{p}; \mathbf{m}, \mathbf{s}, \mathbf{r}, \mathbf{c}) = \exp\left(-\frac{1}{2}(\mathbf{p} - \mathbf{m})^T \mathbf{\Sigma}^{-1}(\mathbf{p} - \mathbf{m})\right) \mathbf{c},$$

$$\mathbf{\Sigma} = \mathbf{R} \mathbf{S} \mathbf{S}^T \mathbf{R}^T, \quad \mathbf{S} = \text{diag}(\mathbf{s}), \quad \mathbf{R} = \text{q2r}(\mathbf{r}),$$

Any Question?

GaussianFormer 한계점



- voxel에 비해 gaussian 수가 훨씬 적음에도 한계가 존재.

Gaussian 기반 sparse 방식의 중복(Overlapping & Redundancy) 문제


- Gaussian 간에 중복(overlap)이 발생하며, 불필요한 Gaussian이 빈 공간을 설명 하는 비효율성이 여전히 존재한다

Gaussian의 초기화(Initialization) 문제

- 기존에는 Gaussians를 무작위로 초기화해, 의미 있는 위치로 이동하는데 비효율이 컸다.


Probabilistic Gaussian Superposition

- GaussianFormer와 달리, **Geometry prediction**, **Semantics prediction**으로 나뉘서 추정 후 병합
 - **Geometry prediction**: 공간에 뭔가가 존재하는지 여부
 - **Semantics prediction**: 뭔가 존재하면 거기에 있는 것이 무엇인지
- 빈 공간 class 제거



Probabilistic Gaussian Superposition

- Geometry prediction (공간에 뭔가가 존재하는지 여부)



- 점 x 가 점유되어 있는지 없는지만 고려

$$\alpha(\mathbf{x}; \mathbf{G}) = \exp\left(-\frac{1}{2}(\mathbf{x} - \mathbf{m})^T \Sigma^{-1}(\mathbf{x} - \mathbf{m})\right),$$

- 하나의 가우시안에 대하여 점 x 가 점유될 확률. 평균 m 에서의 α 값은 1이 된다. (무조건 존재)

- 각 gaussian들끼리 서로 독립적이라고 가정하면,

$$\alpha(\mathbf{x}) = 1 - \prod_{i=1}^P (1 - \alpha(\mathbf{x}; \mathbf{G}_i)),$$

- 각 gaussian에 속하지 않을 확률들을 곱하면, 모든 gaussian에 속하지 않을 확률 ($1-\alpha$)이 나옴.

- Prob. exclusion은 $1-\alpha$ 를 의미하며, geometry prediction은 α 값을 구하는 것.

- 한 공간에 여러개의 가우시안으로 "점유되었다"고 중복해서 표현하는 것을 줄임.


Probabilistic Gaussian Superposition

- Geometry prediction (공간에 뭔가가 존재하는지 여부)
- 한 공간에 여러개의 가우시안으로 "점유되었다"고 중복해서 표현하는 것을 줄임.

$$\alpha(\mathbf{x}; \mathbf{G}) = \exp\left(-\frac{1}{2}(\mathbf{x} - \mathbf{m})^T \Sigma^{-1}(\mathbf{x} - \mathbf{m})\right),$$

R (1/2 x mahalanobis distance)


$$\alpha(\mathbf{x}) = 1 - \prod_{i=1}^P (1 - \alpha(\mathbf{x}; \mathbf{G}_i)),$$



- $\alpha(\mathbf{x}; \mathbf{G}_1), \alpha(\mathbf{x}; \mathbf{G}_2) = \exp(-r_1), \exp(-r_2) \approx 1$
- $1 - \exp(-r_1), 1 - \exp(-r_2) \approx 0$
- 두개의 가우시안 중 하나라도 들어간다면, $\alpha(\mathbf{x})$ 는 1에 가까워짐.

Probabilistic Gaussian Superposition

- Semantics prediction (공간에 뭔가 존재하면 거기에 있는 것이 무엇인지)



- 빈 공간에 대한 class를 제외-> **geometry**에서 “여기 물체가 있음” or “없음” 을 이미 예측.
- 가우시안 G 집합을 Gaussian Mixture Model로 해석
- Semantic Prediction은 gaussian mixture model이 주어졌을 때, semantics (c_i) 기댓값을 계산
- Opacity a 를 gaussian의 prior($p(G_i)$)라고 한다면 Bayes Theorem 적용.

c_i : softmax로 normalize한 gaussian의 class 확률 logits

$p(\mathbf{G}_i|\mathbf{x})$ Posterior: 점 x 일 때, 가우시안에 속할 확률

$p(\mathbf{x}|\mathbf{G}_i)$ Likelihood: 가우시안 G_i 일 때, 점 x 일 확률

$$e(\mathbf{x}; \mathcal{G}) = \sum_{i=1}^P p(\mathbf{G}_i|\mathbf{x}) \tilde{c}_i = \frac{\sum_{i=1}^P p(\mathbf{x}|\mathbf{G}_i) a_i \tilde{c}_i}{\sum_{j=1}^P p(\mathbf{x}|\mathbf{G}_j) a_j},$$

$$p(\mathbf{x}|\mathbf{G}_i) = \frac{1}{(2\pi)^{\frac{3}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mathbf{m})^T \Sigma^{-1}(\mathbf{x} - \mathbf{m})\right),$$

- 서로 다른 Gaussian간의 contribution에 대해 정규화가 있기 때문에 불필요한 가우시안 겹침을 막음.
- 정규화(합이 1)된 클래스 확률을 바로 구할 수 있음.

Probabilistic Gaussian Superposition

GaussianFormer2

$$\hat{\mathbf{o}}(\mathbf{x}; \mathcal{G}) = [1 - \alpha(\mathbf{x}); \alpha(\mathbf{x}) \cdot \mathbf{e}(\mathbf{x}; \mathcal{G})],$$

- Empty class: 1 - geometry
- 나머지 class: geometry x semantics
- 이미 하나의 가우시안이 높게 점유하고 있다면 다른 가우시안이 기여하는 정도는 덜 중요.
- 빈공간은 alpha 자체를 낮게 예측하니까 1-alpha는 1에 가까움. 비어있다는 표현을 명확하게 전달.
- 각 gaussian의 semantic class에 대한 contribution이 정규화 됨. (합이 1)

GaussianFormer1


$$\hat{\mathbf{o}}(\mathbf{p}; \mathcal{G}) = \sum_{i \in \mathcal{N}(\mathbf{p})} \mathbf{g}_i(\mathbf{p}; \mathbf{m}_i, \mathbf{s}_i, \mathbf{r}_i, \mathbf{c}_i),$$

- 인접한 가우시안 밀도를 단순 합산하여 점유도 결정
- 이미 충분히 점유된 공간에 가우시안을 많이 겹쳐짐.
- 빈 공간에 대해 점유되지 않았다는 정보를 나타내기 위한 가우시안 사용.
- 같은 공간에 gaussian이 중복되어 softmax 결과가 하나의 특정 클래스에 치우치도록 함.
- 각 gaussian의 semantic class에 대한 contribution이 정규화되지 않음.

Distribution-Based initialization module

- 이전 방식의 3D semantic Gaussian 표현은 학습 가능한 초기화(learnable initialization)를 사용함
 - 학습 초기에 가우시안의 속성(예: 위치, 크기 등)을 무작위로 초기화
 - 초기값들을 학습하면서 데이터에 맞춰 최적화
- 최종적으로 개별 샘플(프레임, 장면 등)에 맞게 네트워크가 그 분포를 미세 조정(refinement).
- 가우시안은 지역적인 수용 영역(local receptive field), 자유롭게 이동하거나 멀리 있는 위치로 도달하는 데 한계
- "확률적 가우시안 합성(probabilistic Gaussian superposition)" 에서 가우시안들이 '점유된 영역(occupied regions)'만 표현해야 함.
- -> 학습 이미지와 샘플에 맞춘 **[분포 기반 초기화(distribution-based initialization) 모듈]**을 새로 제안.

Distribution-Based initialization module



전체 idea


- 각 샘플(예: 한 이미지) 마다 더 정확한 가우시안 초기 위치를 만들기 위해 이미지의 각 픽셀로부터 쏘는 광선(ray) 상에 어디가 점유되어 있는지(occupied) 나타내는 분포(distribution)를 학습하는 모델.

과정

- 광선(ray) 설정: 픽셀이 어떤 3D 공간과 연결되는지 알기 위해 카메라 캘리브레이션으로 광선의 시작점 b 와 방향 d 를 결정.
- 광선 위 샘플링: 광선 $b + d * z$ 위에서 고정된 깊이 범위에 걸쳐 R 개의 점을 일정한 간격으로 reference points 샘플링
- 점유 정답 얻기: reference point에 대해 ground truth occupancy map에서 점유 여부를 조회해, R 길이의 binary GT를 얻음
- 학습: Binary GT를 이용해 이미지 백본 B 와 분포 예측기 M 을 학습 $\rightarrow M$ 은 각 픽셀의 이미지 feature를 받아 해당 광선 위의 occupancy distributions을 예측 $\rightarrow$ Binary Cross Entropy Loss로 학습.

$$loss_{init} = BCE(\hat{\mathbf{1}}, \mathbf{1}) = BCE(M(B(\mathcal{I})), \mathbf{1}).$$

Distribution-Based initialization module



Initialization 방법 (추정, 논문에서는 소개 X)

- 다수의 이미지로부터 나오는 image feature pixel 마다의 pixel-aligned occupancy distribution을 종합하면, 3D occupancy 분포를 대략적으로 예측할 수 있음.
- 예측된 분포에서 비어 있지 않는 곳에 가우시안을 초기화 -> 안정적인 초기화

장점

- LiDAR supervision으로 깊이 값을 맞추는 이전 초기화 방식과 달리, **장면의 가시적인 표면뿐만 아니라 전체적인 점유 분포를 학습**
- 추가적인 라벨을 위한 **다른 종류의 데이터** (모달리티) 필요하지 않음

Experiments

Datasets

- The nuScenes Dataset
 - 6개의 이미지 사용
- The KITTI-360 Dataset
 - 1개의 이미지 사용

Metrics

- Intersection-over-Union (IoU)
 - 예측된 voxel과 실제(ground truth) voxel의 겹침 정도를 각 클래스별로 계산.
- Mean IoU (mIoU)
 - 모든 클래스의 IoU의 평균값. semantic segmentation/occupancy에서 가장 널리 쓰임.
- IoU (non-empty)
 - 빈 공간(empty class)은 제외하고, 실질적인 객체(class)만을 대상으로 IoU 측정. **(class 상관 없이 voxel 형상만 비교)**
- 빈 공간에 대한 class는 제외한 mIoU와 IoU를 사용.



Main Results

[Table 1] Surround View 3D Semantic Occupancy Prediction (nuScenes)

Method	IoU	mIoU	barrier	bicycle	bus	car	const. veh.	motorcycle	pedestrian	traffic cone	trailer	truck	drive. suf.	other flat	sidewalk	terrain	manmade	vegetation
MonoScene [3]	23.96	7.31	4.03	0.35	8.00	8.04	2.90	0.28	1.16	0.67	4.01	4.35	27.72	5.20	15.13	11.29	9.03	14.86
Atlas [32]	28.66	15.00	10.64	5.68	19.66	24.94	8.90	8.84	6.47	3.28	10.42	16.21	34.86	15.46	21.89	20.95	11.21	20.54
BEVFormer [23]	30.50	16.75	14.22	6.58	23.46	28.28	8.66	10.77	6.64	4.05	11.20	17.78	37.28	18.00	22.88	22.17	13.80	22.21
TPVFormer [13]	11.51	11.66	16.14	7.17	22.63	17.13	8.83	11.39	10.46	8.23	9.43	17.02	8.07	13.64	13.85	10.34	4.90	7.37
TPVFormer* [13]	30.86	17.10	15.96	5.31	23.86	27.32	9.79	8.74	7.09	5.20	10.97	19.22	38.87	21.25	24.26	23.15	11.73	20.81
OccFormer [51]	31.39	19.03	18.65	10.41	23.92	30.29	10.31	14.19	13.59	10.13	12.49	20.77	38.78	19.79	24.19	22.21	13.48	21.35
SurroundOcc [44]	31.49	20.30	20.59	11.68	28.06	30.86	10.70	15.14	14.09	12.06	14.38	22.26	37.29	23.70	24.49	22.77	14.89	21.86
GaussianFormer [15]	29.83	19.10	19.52	11.26	26.11	29.78	10.47	13.83	12.58	8.67	12.74	21.57	39.63	23.28	24.46	22.99	9.59	19.12
Ours (Ch. = 128)	30.56	20.02	20.15	12.99	27.61	30.23	11.19	15.31	12.64	9.63	13.31	22.26	39.68	23.47	25.62	23.20	12.25	20.73
Ours (Ch. = 192)	31.74	20.82	21.39	13.44	28.49	30.82	10.92	15.84	13.55	10.53	14.04	22.92	40.61	24.36	26.08	24.27	13.83	21.98

- mIoU (192 채널) 기준 논문 방법이 21에 가까운 최고 성능, 기존 GaussianFormer 대비 우수
- 적은 수의 **Gaussian(12800개)**으로도 기존 대비 높은 성능

Main Results

[Table 2] Monocular 3D Semantic Occupancy (KITTI-360)

Method	Input	IoU	mIoU	car	bicycle	motorcycle	truck	other-veh.	person	road	parking	sidewalk	other-grnd	building	fence	vegetation	terrain	pole	traf.-sign	other-struct.	other-object
LMSCNet [34]	L	47.53	13.65	20.91	0	0	0.26	0	0	62.95	13.51	33.51	0.2	43.67	0.33	40.01	26.80	0	0	3.63	0
SSCNet [36]	L	53.58	16.95	31.95	0	0.17	10.29	0.58	0.07	65.7	17.33	41.24	3.22	44.41	6.77	43.72	28.87	0.78	0.75	8.60	0.67
MonoScene [3]	C	37.87	12.31	19.34	0.43	0.58	8.02	2.03	0.86	48.35	11.38	28.13	3.22	32.89	3.53	26.15	16.75	6.92	5.67	4.20	3.09
Voxformer [22]	C	38.76	11.91	17.84	1.16	0.89	4.56	2.06	1.63	47.01	9.67	27.21	2.89	31.18	4.97	28.99	14.69	6.51	6.92	3.79	2.43
TPVFormer [13]	C	40.22	13.64	21.56	1.09	1.37	8.06	2.57	2.38	52.99	11.99	31.07	3.78	34.83	4.80	30.08	17.51	7.46	5.86	5.48	2.70
OccFormer [51]	C	40.27	13.81	22.58	0.66	0.26	9.89	3.82	2.77	54.30	13.44	31.53	3.55	36.42	4.80	31.00	19.51	7.77	8.51	6.95	4.60
GaussianFormer [15]	C	35.38	12.92	18.93	1.02	4.62	18.07	7.59	3.35	45.47	10.89	25.03	5.32	28.44	5.68	29.54	8.62	2.99	2.32	9.51	5.14
Ours	C	38.37	13.90	21.08	2.55	4.21	12.41	5.73	1.59	54.12	11.04	32.31	3.34	32.01	4.98	28.94	17.33	3.57	5.48	5.88	3.54

- Monocular(단일 카메라)에서도 기존 대비 mIoU가 뚜렷하게 개선됨.
- KITTI-360에서 GaussianFormer 대비 약 7.6% mIoU 개선.

Ablation Study

[Table 3] Number of Gaussians

Method	Number of Gaussians	Latency (ms)	Memory (MB)	mIoU	IoU
Gaussian-Former	25600	227	4850	16.00	28.72
	144000	372	6229	19.10	29.83
Ours	6400	<u>313</u> (142)	3026	19.87	<u>30.37</u>
	12800	323 (143)	<u>3041</u>	<u>19.94</u>	<u>30.37</u>
	25600	357 (147)	3063	20.33	31.04

- **Ours(12800) vs. GaussianFormer(144000):**
 - Gaussian 수 1/10 이하로 줄였음에도 비슷하거나 더 좋은 성능.
 - Latency는 initialization 때문에 약간 높지만, 메모리/성능 모두 우수.

Ablation Study

[Table 4] 모델 구성요소별 효과

Probabilistic Modeling	Gaussian Initialization	mIoU	IoU
		16.00	28.72
✓		19.61	30.61
✓	Depth	19.97	30.87
✓	Pointcloud	21.17	34.91
✓	Distribution	<u>20.32</u>	<u>31.04</u>

- **Probabilistic Modeling**만으로도 큰 개선
- **Distribution-based Initialization**까지 도입하면 성능 추가 향상
- (Pointcloud는 실제 포인트 클라우드로 지도, Distr.는 본 논문 방식)

Ablation Study


[Table 5] Gaussian의 위치/중복도/효율

Method	Position		Overlap		mIoU	IoU
	Perc. (%) $\uparrow$	Dist. (m) $\downarrow$	Overall $\downarrow$	Indiv. $\downarrow$		
GaussianFormer [15]	16.41	3.07	10.99	68.43	16.00	28.72
Ours	28.85	1.24	3.91	12.48	20.32	31.04

- Gaussian Former V2의 28.85%가 제대로 된 위치, 중복(overlap)도 1/5 이하로 감소
- 불필요한 Gaussian 할당 및 중복 문제
 - Probabilistic superposition 방식(곱셈정리) + Gaussian mixture로 개별 Gaussian이 빈 공간을 담당하지 않게 하고, 중복도 낮춤
 - 효율적이고 의미 있는 위치 초기화: $\rightarrow$ Distribution-based Initialization으로 학습 초기에 Gaussians를 실제 occupied region에 더 잘 배치
- 메모리/속도: 적은 Gaussian으로 동등/상위 성능 달성, 메모리 효율성 크게 향상


Visualization

[Figure 5] Nuscens dataset GaussianFormer2 결과



Visualization


[Figure 6] GaussianFormer vs GaussianFormer2



- Gaussian Former V2의 가우시안 수가 적기 때문에 상대적으로 빈곳이 많이 보임. (GaussianFormer의 8.8% 가우시안만 사용)
- 사람이나 차에 대한 묘사가 유연하고 정확함.

Visualization



[Figure 6-1] GaussianFormer vs GaussianFormer2



- 사람이나 차에 대한 묘사가 유연하고 정확함.

Visualization

[Figure 7] BEV시점 가우시안 위치 표시



- Distribution-based Initialization 방법으로 처음부터 점유된 곳으로 추정된 곳으로 가우시안이 배치
- 학습이 진행되면서, 물체들에 의해 점유된 곳으로 가우시안이 이동.

Conclusion

변화

- 확률적 가우시안 중첩 모델(probabilistic Gaussian superposition model)을 효율적인 객체 중심 표현(object-centric representation)으로 제안
- 각 가우시안을 인접 영역이 차지될 확률 분포(probability distribution)로 해석, 확률의 곱셈 정리(multiplication theorem of probability)를 적용하여 기하학적 예측을 도출. 가우시안 혼합 모델(Gaussian mixture model) 공식을 활용하여 정규화된 의미론적 예측을 계산
- 분포 기반 초기화 전략(distribution-based initialization strategy)을 설계하여 픽셀 정렬된 점유 분포(pixel-aligned occupancy distribution)에 따라 객체 중심 모델링을 위해 점유 영역 주변의 가우시안을 효과적으로 초기화

성과

- nuScenes 및 KITTI-360 데이터셋에 대해 최신 기술(state-of-the-art) 성능을 달성
- 가우시안 개수, 위치 정확도, 그리고 중첩 비율 측면에서 기존 GaussianFormer보다 향상된 효율성

Discussion

- 가우시안 **regularizer**? 가우시안이 최대한 중복되지 않도록 중복되면 처벌을 주도록 학습.
- initialization module 때문에 **latency 손해**를 많이 봐서 개선이 안됨. - 분포 예측기가 차원상으로 비효율적임 더 빠른 방식 필요
- Refinement process에 **Diffusion**을 사용하는 방법.
- Hierarchial Gaussian? 큰 가우시안안의 작은 가우시안

Thank you!