

GPTQ: ACCURATE POST-TRAINING QUANTIZATION FOR GENERATIVE PRE-TRAINED TRANSFORMERS

작성: 조해창(발표자), 김민아, 조수빈, 황예진

모델 사이즈 증가



- 양자화 필요성
- OPT, BLOOM등의 오픈 소스 모델의 등장으로 양자화 실험이 편리해 짐
- QAT, PTQ
- 본 논문에서는 PTQ를 개선

과거 방법론

- AdaRound: 데이터 의존적인 라운딩
- BitSplit: 오차제곱항 objective를 사용하여 비트 단위로 양자화된 값을 생성
- AdaQuant: 단순 오차값을 사용해 근사
- BRECQ: 피셔 정보(Fisher information)를 목표 함수에 도입, 단일 잔차 블록 내의 층을 공동으로 최적화
- ZeroQuant: Activation과 Weight를 동적 양자화, LKD - 모델을 층별 따로 양자화
- Optimal Brain Quantization (OBQ): 2차 가중치 프루닝 프레임워크인 Optimal Brain Surgeon (OBS)(Hassibi et al., 1993; Singh & Alistarh, 2020; Frantar et al., 2021)를 양자화에 적용



GPTQ

- 성능도 좋고, 기존 방법론에 비해 속도 향상



ZeroQuant

- 언어모델에 기존 양자화가 잘 적용되지 않는 이유 지적
- Activation은 토큰별로, Weight는 행(row)별로 동적 양자화
- 10B 모델 이상에서는 정상적으로 동작 하지 않음



ZeroQuant

Table 3: Result of BERT_{large} on the development set of GLUE benchmark (except WNLI). ⁺We extensively tuned the learning rate for QAT (see Appendix F for more details).


Precision (Method)	CoLA	MNLI-m	MNLI-mm	MRPC	QNLI	QQP	RTE	SST-2	STS-B	Ave.	Ave. Time (s)
W16A16 (Baseline)	63.35	86.65	85.91	87.99/91.62	92.24	91.08/88.08	74.01	93.46	90.34/90.11	85.03	N/A
W8A8 [76] (QAT)	—	—	—	—/90.9	91.74				90.12/—	—	—
W8A8 (QAT) ⁺	59.85	86.65	86.35	85.29/89.43	92.55	91.60/88.60	61.37	93.23	87.55/87.65	82.78	7181
W8A8 (PTQ)	60.57	75.69	76.94	81.13/84.93	88.49	84.04/74.35	46.93	91.74	62.75/55.77	73.54	31
W8A8 (ZeroQuant)	63.38	86.52	85.64	87.75/91.50	92.31	91.09/88.05	72.56	93.35	90.45/90.19	84.81	0
W4/8A16 (PTQ)	0.00	16.85	33.24	68.38/80.89	51.25	63.18/0.00	52.71	52.41	-5.74/-8.51	35.73	31
W4/8A16 (ZeroQuant)	62.99	84.77	84.42	87.50/91.16	91.63	90.03/86.41	48.01	92.16	89.49/89.28	81.23	0
W4/8A16 (ZeroQuant-LKD)	63.72	84.90	84.81	87.99/91.39	91.45	90.34/86.92	51.62	92.43	89.46/89.29	81.85	550
W4/8A8 (ZeroQuant)	62.34	84.62	84.25	87.75/91.38	91.87	89.86/86.09	47.65	91.97	89.39/89.17	81.06	0
W4/8A8 (ZeroQuant-LKD)	63.51	84.70	84.71	88.73/91.99	91.73	90.25/86.74	49.82	92.09	89.34/89.08	81.62	550

Table 4: Post training quantization result of GPT-3_{350M} on 20 zero-shot evaluation datasets. Please see Table H.1 for the results of all 20 tasks.

Precision (Method)	Lambada (↑)	PIQA (↑)	OpenBookQA (↑)	RTE (↑)	ReCoRd (↑)	Ave. 19 Tasks (↑)	Wikitext-2 (↓)	Time Cost
W16A16	49.3	66.3	29.4	53.8	75.1	38.9	21.5	N/A
W8A8 (PTQ)	42.6	64.1	28.0	53.1	67.5	37.8	26.2	7 mins
W8A8 (ZeroQuant)	51.0	66.5	29.2	53.4	74.9	38.7	21.7	0
W4/8A16 (PTQ)	0.00	51.4	30.2	52.7	16.1	28.9	1.76e5	7 mins
W4/8A16 (ZeroQuant)	10.1	58.5	27.2	52.0	56.5	33.5	88.6	0
W4/8A16 (ZeroQuant-LKD)	39.8	63.8	29.4	53.1	70.1	37.0	30.6	1.1 hours
W4/8A8 (ZeroQuant)	10.5	57.7	28.0	52.7	55.3	33.4	92.1	0
W4/8A8 (ZeroQuant-LKD)	37.4	61.8	28.2	53.1	68.5	36.6	31.1	1.1 hours

LLM.Int8()

- 보다 큰 모델에서도 동작하도록 부분적으로 다른 자료형을 쓰도록 적용
- Activation의 이상치를 파악해, 이상치에 대해서는 FP16을 적용



Optimal Brain Quantization

- 기존 Pruning에서 사용되던 OBS(Optimal Brain Surgeon) 기법이 변형된 방법론
- 기본적으로 층별, row별 양자화가 나누어 적용

$$\operatorname{argmin}_{\widehat{\mathbf{W}}} ||\mathbf{W}\mathbf{X} - \widehat{\mathbf{W}}\mathbf{X}||_2^2.$$

Optimal Brain Surgeon

- Weight에서 제거해도 전체 결과에 가장 적은 영향을 미치는 파라미터를 찾는 방법
- q행을 제거했을 경우 전체에 미치는 영향 계산
- 이미 한번 최적화 된 모델을 가져와서 계산하고 있기 때문에, 이미 특정 위치에 수렴한 모델은

$$\delta E = \underbrace{\left(\frac{\partial E}{\partial \mathbf{w}} \right)^T}_{\approx 0} \cdot \delta \mathbf{w} + \frac{1}{2} \delta \mathbf{w}^T \cdot \underbrace{\frac{\partial^2 E}{\partial \mathbf{w}^2}}_{\equiv \mathbf{H}} \cdot \delta \mathbf{w} + \underbrace{O(\|\delta \mathbf{w}\|^3)}_{\approx 0}, \quad (1)$$

$$\delta \mathbf{w} = -\frac{w_q}{[\mathbf{H}^{-1}]_{qq}} \mathbf{H}^{-1} \cdot \mathbf{e}_q \text{ and } L_q = \frac{1}{2} \frac{w_q^2}{[\mathbf{H}^{-1}]_{qq}}. \quad (2)$$

$$\delta f = \underbrace{\frac{\partial f}{\partial w} \cdot \delta w}_{\mathcal{L}_0} + \underbrace{\frac{1}{2} \delta w^T \frac{\partial^2 f}{\partial w^2} \delta w}_{\mathcal{L}_0} + \mathcal{L}_0(\delta w)$$

for $\delta w + w_q = 0$, $\frac{1}{2} \delta w^T H \delta w$ 의 최소값을 도출하는 δw 구하기

라그랑주 함수

$$\mathcal{L}(\delta w, \lambda) = \frac{1}{2} \delta w^T H \delta w + e_q^T \cdot \lambda (\delta w + w_q)$$

$\nabla_{\delta w} \mathcal{L} = 0$ 인 상태에서 해당 값이 극값을 가지게 됨. $\delta w + w_q = 0$ 이기 때문.

$$\nabla_{\delta w} \mathcal{L} = H \delta w + \lambda = 0 \Rightarrow \delta w = -H^{-1} \lambda e_q$$

$$= -H_q^{-1} \lambda$$

$$\mathcal{L}'(\lambda) = \frac{1}{2} e_q^T H^{-1} e_q \lambda^2 + e_q^T \lambda (-H^{-1} \lambda e_q + w_q)$$

$$= -\frac{1}{2} e_q^T H^{-1} e_q \lambda^2 + e_q^T \cdot w_q \lambda$$

$$= -\frac{1}{2} [H^{-1}_{qq}] \lambda^2 + |w_q| \lambda$$

$$= -\frac{1}{2} [H^{-1}_{qq}] \left(\lambda - \frac{|w_q|}{|H^{-1}_{qq}|} \right)^2 + \frac{w_q^2}{2 [H^{-1}_{qq}]}$$

$$\lambda = \frac{|w_q|}{|H^{-1}_{qq}|} \quad \text{if } |w_q| \geq \frac{\sqrt{\frac{1}{2} |H^{-1}_{qq}|}}{\sqrt{2}}, \Rightarrow \delta w^T H^{-1} \delta w = |H^{-1}_{qq}| \lambda^2$$

$$\delta w = -H^{-1}_q \lambda = -\frac{|w_q|}{|H^{-1}_{qq}|} H^{-1}_q$$

$$= \frac{w_q}{|H^{-1}_{qq}|}$$

0.3 Q 2 넘어가면

$$\delta w + w_q = 0$$

$$\Rightarrow \delta w + w_q - \text{quant}(w_q) = 0$$

$$\Rightarrow \delta w = - \frac{|w_q - \text{quant}(w_q)|}{|1 - q_q|} H_q^{-1}$$

$\mathcal{H}(\text{parameter})$
 $\hookrightarrow \frac{d^2}{dw^2} d(t, o) = \frac{d}{dw} \left(\frac{\partial o}{\partial w} \cdot \frac{\partial d}{\partial o} \right)$

$o: x \xrightarrow{w} \hat{t} \quad d(t, o) = (\text{e.g.}) |t - o_{(w, x)}|^2$

$= \frac{\partial^2 o}{\partial w^2} \cdot \frac{\partial d}{\partial o} + \frac{\partial o}{\partial w} \cdot \frac{\partial^2 d}{\partial w \partial o}$

matrix

KL 1224 $\frac{1}{2}$ $\frac{1}{2}$ $\frac{1}{2}$ $\frac{1}{2}$ $O(w, m^k)$

$$X_k \equiv \frac{\partial O}{\partial w}$$

$$a_k \equiv \frac{\partial^2 d}{\partial o^2}$$

e.g. $O(w, x_k) = wx_k$

$$d(t, o) = |t - o|^2$$

$$X_k = x_k$$

$$a_k = 2$$

KL 논문이 Hessian

$$H_F = 2X_F X_F^T$$

Optimal Brain Quantization

- 기존 Pruning에서 사용되던 OBS(Optimal Brain Surgeon) 기법이 변형된 방법론
- 기본적으로 층별, row별 양자화가 나누어 적용

$$\operatorname{argmin}_{\widehat{\mathbf{W}}} \|\mathbf{W}\mathbf{X} - \widehat{\mathbf{W}}\mathbf{X}\|_2^2.$$

$$\mathbf{H}_F = 2\mathbf{X}_F\mathbf{X}_F^\top.$$

$$w_q = \operatorname{argmin}_{w_q} \frac{(\operatorname{quant}(w_q) - w_q)^2}{[\mathbf{H}_F^{-1}]_{qq}}, \quad \delta_F = -\frac{w_q - \operatorname{quant}(w_q)}{[\mathbf{H}_F^{-1}]_{qq}} \cdot (\mathbf{H}_F^{-1})_{:,q}.$$

Arbitrary Order Insight


- 기존 Optimal Brain Surgeon 알고리즘은 loss 변화를 최소화 하면서 weight를 제거하는 방식이었기 때문에 가장 작은 영향을 미치는 weight를 찾아서 순서대로 제거
- 본 상황은 그렇지 않아서, 고정 순서로 양자화 진행

Lazy Batch-Updates

- 각 행별로 순차적으로 연산하는 것은 병렬처리를 심각하게 방해
- 하지만 일부 배치로 묶어서 연산을 해도 성능에 하락을 거의 가져오지 않음
- 배치 처리하여, 양자화 진행

Cholesky Reformulation

- Hessian 행렬의 대칭성에 따라 Cholesky Reformulation이 가능



The Full Algorithm

Algorithm 1 Quantize $\mathbf{W}$ given inverse Hessian $\mathbf{H}^{-1} = (2\mathbf{X}\mathbf{X}^\top + \lambda\mathbf{I})^{-1}$ and blocksize B .

```
 $\mathbf{Q} \leftarrow \mathbf{0}_{d_{\text{row}} \times d_{\text{col}}}$  // quantized output
 $\mathbf{E} \leftarrow \mathbf{0}_{d_{\text{row}} \times B}$  // block quantization errors
 $\mathbf{H}^{-1} \leftarrow \text{Cholesky}(\mathbf{H}^{-1})^\top$  // Hessian inverse information
for  $i = 0, B, 2B, \dots$  do
  for  $j = i, \dots, i + B - 1$  do
     $\mathbf{Q}_{:,j} \leftarrow \text{quant}(\mathbf{W}_{:,j})$  // quantize column
     $\mathbf{E}_{:,j-i} \leftarrow (\mathbf{W}_{:,j} - \mathbf{Q}_{:,j}) / [\mathbf{H}^{-1}]_{jj}$  // quantization error
     $\mathbf{W}_{:,j:(i+B)} \leftarrow \mathbf{W}_{:,j:(i+B)} - \mathbf{E}_{:,j-i} \cdot \mathbf{H}_{j,j:(i+B)}^{-1}$  // update weights in block
  end for
   $\mathbf{W}_{:, (i+B):} \leftarrow \mathbf{W}_{:, (i+B):} - \mathbf{E} \cdot \mathbf{H}_{i:(i+B), (i+B):}^{-1}$  // update all remaining weights
end for
```

감사합니다 😊