

Hallucination of Multimodal Large Language Models : A Survey

Arxiv 2024.04

발표자: 차지윤, 오영화 펀디멘탈팀

CONTENTS

01 Intro

02 Related Works

03 Methods

04 Experiments

05 Conclusion

Intro

- Abstract

- 배경

- 대형 언어 모델(LLMs)의 등장으로 자연어 처리(NLP) 작업에서 언어 이해, 생성, 추론에서 놀라운 성과를 이룸
 - 멀티모달 대형 언어 모델(MLLMs) 또는 대형 비전-언어 모델(LVLMs)도 같이 주목을 받음에 따라 환각 문제도 같이 대두됨

- 개요

- 순수 LLMs의 환각에 대한 여러 조사가 있는 반면, MLLMs의 환각에 대한 조사는 거의 없음
 - 계층적이고 세분화된 환각 분류를 제시 , 다양한 영향 요인에 따라 환각의 원인을 분석, 최근 광범위한 문헌 비교
 - 기본적인 원인, 데이터, 모델, MLLMs의 환각을 평가하기 위한 벤치마크, 다양한 완화 접근방식 설명, 향후 연구 방향 제시
 - MLLMs의 환각 현상에 대한 이해 심화와 추가 발전 촉진을 위한 서베이 논문

Intro


◦ Definitions

• 대형 언어 모델 (LLMs)

- 일반적으로 광범위한 텍스트 데이터셋에서 훈련된 트랜스포머 기반 모델을 포함하여 OpenAI GPT-3.5, GPT-4, PaLM, LLaMA 등
- 훈련 과정 : 사전 훈련 > 지도형 미세 조정(SFT) > 인간 피드백을 통한 강화 학습(RLHF)

• 멀티모달 대형 언어 모델(MLLMs)

- LLMs가 다양한 모달리티 데이터를 인식하고 이해할 수 있게 하는 모델
MLLMs의 목표는 LLMs의 시각적 능력을 활성화하여 이미지를 통해 세계를 '보는' 것
- 강력한 추론 및 언어 생성 능력과 결합하여 이미지/비디오 캡셔닝, 비주얼 질문 응답 등 멀티모달 작업에서 뛰어난 성과를 보임
- MLLMs는 AI 비서, 구현된 에이전트, 로봇 공학 등의 다른 분야에서 응용의 기초를 제공




- 비전+ 언어 통합 방식 :
 1. 인터페이스 기반, 사전 훈련된 단일 모달 모델을 기반으로 구축된 작업, 일반적으로 사전 훈련된 비주얼 인코더와 LLM 간의 학습 가능한 인터페이스를 포함
훈련과정: 사전 훈련 > 지시 조정 (사전 훈련된 시각적 특징을 사전 훈련된 LLM의 입력 공간으로 변환하는 것을 목표로함)
 - 2, 사전 훈련된 단일 모달 모델을 활용하는 대신, 처음부터 끝까지 훈련을 사용, Fuyu-8B 대표 모델

Intro

◦ 환각 현상

• 멀티모달 대형 언어 모델(MLLMs), 또는 대형 비전-언어 모델(LVLMs)의 환각 현상

- MLLM의 환각 현상은 생성된 텍스트 응답이 해당 시각적 콘텐츠와 일치하지 않는 현상을 의미, 그럴듯해 보이지만 사실적으로는 거짓된 내용을 생성
- NLP 커뮤니티에서 LLMs 의 환각 문제는 사실성 환각, 충실성 환각 두 가지 유형으로 나뉘는 것과 달리 MLLMs 최신 연구는 주로 객체 환각에 초점
- 객체 환각 : 비전 및 멀티 모달 맥락에서 중요한 연구 주제 , 크게 세가지 1) 범주 2) 속성 3) 관계 세가지 유형
- 불일치의 일반적 두가지 형태 1. 객체 누락 2. 이미지에 존재하지 않는 객체, 잘못된 설명 생성



• 환각 현상 원인 : 데이터, 모델, 훈련, 추론 네가지 측면

- 데이터 양 : 현재 이미지-텍스트 쌍 데이터셋이 상대적으로 적음, 부족한 데이터는 크로스모달 정렬에 영향을 줌
- 데이터 품질 : 노이즈 데이터, 다양성 부족, 상세한 설명
- 데이터 통계적 편향 : 훈련 데이터셋의 객체 분포는 모델의 행동에 큰 영향, ex) 자주 등장하는 객체, 객체 공존 현상

Model

◦ 모델

- MLLMs의 아키텍처는 여러 구성 요소로 구성되어, 일반적으로 사전 훈련된 비전 모델, 사전 훈련된 LLM 및 정렬 모듈을 포함
각 모듈의 오류가 누적될 수 있고 각 모듈의 문제성 출력이 환각을 초래할 수 있음

◦ 약한 비전모델

- 관련 연구(Rohrbach et al., 2018; Guan et al., 2023; Wang et al., 2023c)에서 언급된 바와 같이
환각의 주요 잠재적 원인은 약한 비전 모델로, 시각적 개념의 오분류 또는 오해석을 초래할 수 있음

◦ 언어모델 우선

- 현재 MLLMs의 아키텍처는 불균형적인 구조로, 일반적으로 언어 모델이 비전 모델보다 훨씬 크고 강력하여 언어 기반 정보를 우선시하는 경향이 있음
- 언어/지식 우선 현상은 모델이 시각적 콘텐츠를 간과하고 환각으로 대답하도록 함
예) 빨간 바나나 > 노란 바나나, "바나나는 노란색이다" 지식 기반

◦ 약한 정렬 인터페이스

- MLLMs에서 두 모달리티 간의 중요한 다리 역할을 하는 인터페이스가 약하면 쉽게 환각을 초래함
- 원인은 데이터 뿐 아니라 인터페이스 구조 자체와 훈련중 손실 설계에도 있어

Training & Inference

◦ 훈련

- MLLMs의 훈련은 기본적으로 LLMs와 동일하며, 자기 회귀 다음 토큰 예측 손실 방식
- 일부 연구에서 복잡한 공간 구조를 가지는 시각 콘텐츠 학습에 기존 언어 모델에서 사용하던 다음 토큰 예측 loss 가 적합하지 않을 수 있다고 제안
- 또 다른 훈련 과정의 관점에서 LLMs 훈련과 달리 MLLMs 훈련 절차에는 RLHF 단계가 없어 환각의 잠재적 원인이 있을 수 있음

◦ 추론

- 자기회귀생성의 잠재적 문제로, 시퀀스 길이가 길어짐에 따라 셀프 어텐션이 이전에 생성된 텍스트 토큰에 더 집중하게 되어 시각적 콘텐츠에 대한 주의가 희석되는 경향
- 생성중 어텐션 맵을 시각화한 결과 생성된 내용이 시각적 콘텐츠 토큰보다 구두점과 같은 이전의 특수 토큰에 더 집중하는 것을 관찰됨
- 이러한 'attention 상실' 문제는 모델의 출력 응답이 시각적 콘텐츠와 관련이 없게 만들 수 있음

Hallucination Metrics and Benchmarks

◦ 주요 매트릭스, 벤치마크

- CHAIR (Rohrbach et al., 2018)
 - 전통적인 이미지 캡셔닝 작업에서 객체 환각을 평가하기 위해 제안
 - 생성된 단어 중 실제 이미지에 존재하는 단어의 비율을 계산
- POPE (Li et al., 2023a)
 - 환각 평가를 이진 분류 작업으로 변환하여 기존 CHAIR의 문제를 해결
 - MLLMs에 간단한 예-아니오 질문(예: "이미지에 차가 있습니까?")을 제시하여 평가
 - POPE는 객체 환각 평가의 기초가 되는 초기 대표적인 작업
- FaithScore (Jing et al., 2023)
 - 인간과 MLLMs 간의 자연스러운 상호작용 형태를 고려하여 자유형 응답을 평가
 - LLM 기반의 전체 평가와 달리, FaithScore는 응답을 분해하고 요소를 상세히 평가하는 자동 파이프라인 설계
 - 최종 FaithScore 계산은 환각된 콘텐츠의 비율, 평가 메트릭은 ~~정확~~정확도, 개수, 색상, 관계, 기타 속성을 포함한 세분화된 객체 환각 범주를 포함
- AMBER (Wang et al., 2023c)
 - POPE는 판별 작업에서 가장 인기있는 평가 도구지만 속성 및 관계와 같은 세분화된 환각 유형이 부족함
 - AMBER는 생성 작업과 판별 작업을 지원하는 LLM-프리 다차원 벤치마크로, 객체 존재 환각, 속성 환각, 관계 환각을 포함
 - AMBER 점수는 생성 작업에서 CHAIR(Rohrbach et al., 2018) 메트릭과 판별 작업에서 F1을 결합하여 형성

Hallucination Metrics and Benchmarks

○ 벤치마크/ 매트릭스 요약

Table 1. Summary of most relevant benchmarks and metrics of object hallucination in MLLMs. The order is based on chronological order on arxiv. In the metric column, Acc/P/R/F1 denotes Accuracy/Precision/Recall/F1-Score.

Benchmark	Venue	Underlying Data Source	Size	Task Type	Metric	Hallucination Type			
						Category	Attribute	Relation	Others
CHAIR [90]	EMNLP'18	MSCOCO [70]	5,000	Gen	CHAIR	✓	✗	✗	✗
POPE [69]	EMNLP'23	MSCOCO [70]	3,000	Dis	Acc/P/R/F1	✓	✗	✗	✗
MME [113]	arXiv'23 Jun	MSCOCO [70]	1457	Dis	Acc/Score	✓	✓	✗	✓
CIEM [42]	NeurIPS-W'23	MSCOCO [70]	78120	Dis	Acc	✓	✗	✗	✗
M-HalDetect [32]	arXiv'23 Aug.	MSCOCO [70]	4,000	Dis	Reward Model Score	✓	✗	✗	✗
MMHal-Bench [96]	arXiv'23 Sep.	Open-Images [61]	96	Gen	LLM Assessment	✓	✗	✗	✓
GAVIE [73]	ICLR'24	Visual-Genome [59]	1,000	Gen	LLM Assessment		Not Explicitly Stated		
NOPE [77]	arXiv'23 Oct.	Open-Images [61]	36,000	Dis	Acc/METEOR [3]	✓	✗	✗	✗
HaELM [104]	arXiv'23 Oct.	MSCOCO [70]	5,000	Gen	LLM Assessment		Not Explicitly Stated		
FaithScore [55]	arXiv'23 Nov.	MSCOCO [70]	2,000	Gen	FaithScore	✓	✓	✓	Obj. Counting
Bingo [21]	arXiv'23 Nov.	Unknown	370	Gen	Human Assessment	✗	✗	✗	Model Bias
AMBER [103]	arXiv'23 Nov.	Web	15,202	Dis & Gen	AMBER Score	✓	✓	✓	✗
RAH-Bench [16]	arXiv'23 Nov.	MSCOCO [70]	3,000	Dis	False Positive Rate	✓	✓	✓	✗
HallusionBench [72]	CVPR'24	Unknown	1,129	Gen	LLM Assessment	✗	✗	✗	Model Diagnose
CCEval [123]	arXiv'23 Dec.	Visual-Genome [59]	100	Gen	LLM-based CHAIR	✓	✗	✗	✗
MERLIM [100]	arXiv'23 Dec.	MSCOCO [70]	31,373	Dis	Accuracy	✓	✗	✓	Obj. Counting
FGHE [105]	arXiv'23 Dec.	MSCOCO [70]	200	Dis	Acc/P/R/F	✓	✓	✓	Obj. Behavior
MOCHa [5]	arXiv'23 Dec.	Synthetic	2,000	Gen	OpenCHAIR [5]	✓	✓	✗	✗
CorrelationQA [35]	arXiv'24 Feb.	Synthetic	7,308	Dis	Acc/AccDrop	✗	✗	✗	Model Bias
VQAv2-IDK [11]	arXiv'24 Feb.	VQAv2 [30]	6,624	Dis	Acc	✗	✗	✗	IK [11]
MHalBench [13]	arXiv'24 Feb.	MSCOCO [70]	1,860	Gen	Acc/P/R/F	✓	✓	✗	T2I
VHTest [46]	arXiv'24 Feb.	MSCOCO [70]	1,200	Dis & Gen	Acc	✓	✓	✗	✓
Hal-Eavl [53]	arXiv'24 Feb.	MSCOCO [70] & LAION [92]	10,000	Dis & Gen	Acc/P/R/F & LLM Assessment	✓	✓	✓	Obj. Event

Hallucination Metrics and Benchmarks

◦ 주요 모델 벤치마크 비교

- 대표적인 벤치마크에서 주요 MLLMs를 비교한 결과, 각 벤치마크마다 평가 차원과 강조점이 달라 성능이 일관되지 않음

Table 2. Comparison of mainstream MLLMs on **generative** benchmarks. The numbers come from the original papers of these benchmarks.

Model	LLM Size	CHAIR (On AMBER) ↓	AMBER Score ↑	HallusionBench All-Acc ↑	FaithScore (LLaVA-1k) ↑	FaithScore (COCO-Cap) ↑	Hal-Eval In-domain Gen. Acc ↑	Hal-Eval Out-of-domain Gen. Acc ↑
mPLUG-Owl [111]	7B	23.1	54.1	43.93	0.7167	0.8546	27.3	29.5
Multimodal-GPT [28]	7B	-	-	-	0.5335	0.5440	-	-
InstructBLIP [22]	7B	10.3	86.2	45.26	0.8091	0.9392	35.5	41.3
GPT-4V [83]	-	4.3	92.7	65.28	-	-	-	-
LLaVA (7B) [75]	7B	13.5	69.3	-	-	-	23.3	26.3
LLaVA (13B) [75]	13B	-	-	-	0.8360	0.8729	-	-
MiniGPT-4 (7B) [138]	7B	-	-	35.78	0.5713	0.6359	61.4	50.1
MiniGPT-4 (13B) [138]	13B	15.9	76.7	-	-	-	-	-
mPLUG-Owl2 [112]	7B	10.6	84.0	47.30	-	-	-	-
LLaVA-1.5 (7B) [74]	7B	8.6	82.9	-	-	-	44.6	46.4
LLaVA-1.5 (13B) [74]	13B	-	-	46.94	0.8566	0.9425	-	-
CogVLM [106]	7B	7.9	86.1	-	-	-	-	-
Qwen-VL-Chat [2]	7B	-	-	39.15	-	-	-	-
Open-Flamingo [1]	9B	-	-	38.44	-	-	-	-
LRV-Instruction [73]	-	-	-	42.78	-	-	-	-

Hallucination Metrics and Benchmarks

◦ 주요 모델 벤치마크 비교

- 대표적인 벤치마크에서 주요 MLLMs를 비교한 결과, 각 벤치마크마다 평가 차원과 강조점이 달라 성능이 일관되지 않음

Table 3. Comparison of mainstream MLLMs on **discriminative** benchmarks. The numbers come from the original papers of these benchmarks.

Model	LLM Size	MME Existence Score ↑	MME Count Score ↑	MME Position Score ↑	MME Color Score ↑	POPE Random F1-Score ↑	POPE Random F1-Score ↑	POPE Adversarial F1-Score ↑	RAH-Bench F1 Score ↑	AMBER Dis. F1-Score ↑	AMBER Score ↑	Hal-Eval In-domain Event. F1 ↑	Hal-Eval Out-of-domain Event. F1 ↑
mPLUG-Owl [111]	7B	120.00	50.00	50.00	55.00	68.06	66.79	66.82	69.3	31.2	54.1	47	46.6
ImageBind-LLM [34]	7B	128.33	60.00	46.67	73.33	-	-	-	-	-	-	-	-
InstructBLIP [22] (7B)	7B	-	-	-	-	-	-	-	89.1	82.6	86.2	66.2	66.6
InstructBLIP [22] (13B)	13B	185.00	143.33	66.67	153.33	89.29	83.45	78.45	84.7	-	-	-	-
VisualGLM-6B [25]	6B	85.00	50.00	48.33	55.00	-	-	-	-	-	-	-	-
Multimodal-GPT [28]	7B	61.67	55.00	58.33	68.33	66.68	66.67	66.67	-	-	-	-	-
PandaGPT [95]	7B	70.00	50.00	50.00	50.00	-	-	-	-	-	-	-	-
LaVIN [78]	13B	185.00	88.33	63.33	75.00	-	-	-	-	-	-	-	-
Cheetor [67]	7B	180.00	96.67	80.00	116.67	-	-	-	-	-	-	-	-
GPT-4V [83]	-	190.00	160.00	95.00	150.00	-	-	-	-	89.6	92.7	-	-
LLaVA [75] (7B)	7B	-	-	-	-	-	-	-	73.3	32.0	69.3	35.1	14.0
LLaVA [75] (13B)	13B	185.00	155.00	133.33	170.00	68.65	67.72	66.98	71.8	-	-	-	-
LRV-Instruction [73]	7B	165.00	111.67	86.67	165.00	-	-	-	-	-	-	-	-
Lynx [122]	7B	195.00	151.67	90.00	170.00	-	-	-	-	-	-	-	-
MMICL [130]	11B	170.00	160.00	81.67	156.67	-	-	-	-	-	-	-	-
Muffin [118]	13B	195.00	163.33	66.67	165.00	-	-	-	-	-	-	-	-
Otter [65]	7B	195.00	88.33	86.67	113.33	-	-	-	-	-	-	-	-
Qwen-VL-Chat [2]	7B	158.33	150.00	128.33	170.00	-	-	-	-	-	-	-	-
SPHINX [71]	13B	195.00	160.00	153.33	160.00	-	-	-	-	-	-	-	-
VPGLTrans [124]	7B	70.00	85.00	63.33	73.33	-	-	-	-	-	-	-	-
BLIVA [43]	11B	180.00	138.33	81.67	180.00	-	-	-	-	-	-	-	-
InfMLLM [135]	13B	195.00	145.00	170.00	195.00	-	-	-	-	-	-	-	-
LLaMA-Adapter V2 [26]	7B	185.00	133.33	56.67	118.33	-	-	-	-	-	-	-	-
MiniGPT-4 [138]	13B	68.33	55.00	43.33	75.00	78.86	72.21	71.37	-	69.3	76.7	48.2	53.0
mPLUG-Owl2 [112]	7B	185.00	155.00	88.33	150.00	-	-	-	-	78.5	84.0	-	-
LLaVA-1.5 [75]	7B	-	-	-	-	-	-	-	-	74.4	82.9	48.9	34.2
CogVLM [106]	7B	195.00	165.00	103.33	160.00	-	-	-	-	80	86.1	-	-

Hallucination Mitigation

◦ 모델

• 해상도 확장

- MLLMs의 인식 능력 향상은 전반적인 성능을 개선하고 환각을 줄이는 데 도움됨
- LLaVA를 LLaVA-1.1.5로 업그레이드할 때 CLIP ViT 비전 인코더를 CLIP-ViT-L-224에서 CLIP-ViT-L-336으로 확장하여 성능을 크게 개선
- Qwen-VL(Bai et al., 2023)은 이미지 해상도를 224×224 에서 448×448 로 점진적으로 확대하는 것이 효과적임을 보여줌
- HallE-Switch(Zhai et al., 2023)는 CCEval 벤치마크에서 비전 인코더 해상도가 환각에 미치는 영향 조사, 세가지 비전 인코더 중 해상도가 높을수록 환각 정도가 낮아지는 경향 확인

• 다재다능한 비전 인코더

- 최근 연구들은 다른 비전 인코더의 시각적 특징을 통합하여 이 정보 손실을 보완 하려고 함 예) CLIP ViT와 DINO ViT의 특징 혼합
- CLIP 이미지 인코더로 인한 정보 손실을 완화하는 것을 목표로 하는 시각 전문가 기반 모델 (He et al., 2024)
- OCR 도구 및 객체 감지기와 같은 시각적 도구를 활용, 분할 마스크 및 깊이 맵과 같은 추가 인식 형식을 사용하는 등 다양한 잠재 시각 정보를 통합 하고 MLLM의 객체 식별 능력을 향상

• 전용 모듈

- 생성이 시각적 콘텐츠 대신 언어 지식에 기반하게 만드는 언어/지식 우선 현상은 LLM에 내재된 파라메트릭 지식은 환각을 유발하는 중요한 요인으로 작용
- 이 문제를 해결하기 위해 (Zhai et al., 2023)은 상세 캡션 내의 파라메트릭 지식의 범위를 제어하는 HallE-Switch라는 전용 "스위치" 모듈을 훈련시키는 방법을 제안

Hallucination Mitigation

◦ 훈련

• 보조감독

- MLLMs의 CrossEntropyLoss 기반 감독은 시각적 콘텐츠에 인코딩된 풍부한 정보를 처리하기에 충분하지 않을 수 있음
- (Chen et al., 2023c)의 연구는 Panoptic Scene Graph (PSG)를 기반으로 추가 주석을 통해 최첨단 비전 모델 SAM(Kirillov et al., 2023)을 사용하여 마스크 예측 손실로 MLLMs를 추가 감독, 중요한 인스턴스를 더 잘 표현할 수 있는 특징을 추출하도록 장려되어 더 정확한 응답을 생성하고 시각적 환각을 완화
- 최근 연구인 HACL(Jiang et al., 2023)은 임베딩 공간 분포의 관점에서 훈련 손실을 분석, HACL은 대조 손실을 통해 시각적 및 텍스트 표현 간의 정렬을 강화하는 것을 제안

• 강화학습

- 강화 학습(RL)은 환각을 완화하기 위해 MLLMs를 훈련하는 데 도입.
- 1) 자동 메트릭 기반 최적화 : 이미지 캡셔닝의 정확성과 관련성을 향상시켜 환각을 줄이는 것을 목표
- 2) AI 피드백을 통한 강화 학습 : HA-DPO (Zhao et al., 2023b), Silkie (Li et al., 2023d), POVID (Zhou et al., 2024)
- 3) 인간 피드백을 통한 강화 학습 :
HalDetect (Gunjal et al., 2023), LLaVA-RLHF (Sun et al., 2023) , RLHF-V (Yu et al., 2023c), ViGoR (Yan et al., 2024)

• Unlearning

- 그라디언트 상승 방법을 통해 모델이 특정 행동이나 데이터를 '잊도록' 유도하는 기술
- LLMs의 개인정보 취약점을 효과적으로 제거하는 데 사용, 최근 연구(Xing et al., 2024)는 환각 문제를 해결하기 위해 효율적인 세부 잊기 프레임워크(EFUF)를 도입
- CLIP 모델을 사용하여 긍정 샘플과 부정(환각) 샘플로 구성된 데이터셋을 구축하고, 문장 하위 수준에서 긍정 및 부정 샘플에 대해 별도로 훈련 손실을 적용

Hallucination Mitigation

◦ 추론

• 생성 개입

- 대조 디코딩 :
왜곡된 시각적 입력이 더 많은 편향과 선호도를 가진 텍스트 응답을 유도한다는 가정하에
원본 및 왜곡된 시각적 입력에서 파생된 출력 분포를 비교하여
통계적 편향과 언어 선호도에 대한 과도한 의존을 효과적으로 줄임
- 안내 디코딩 : MARINE (Zhao et al., 2024), GCD (Deng et al., 2024)
- 시각적 문맥 안내 디코딩 HALC (Chen et al., 2024b)

• 사후 수정

- 사후 수정은 MLLM이 텍스트 응답을 생성한 후 환각 내용을 식별하고 제거하여 환각을 줄이는 방법
- Woodpecker (Yin et al., 2023b) :
생성된 텍스트에서 주요 개념을 추출하고 시각적 콘텐츠를 사용해 이를 검증하고 환각된 객체를 식별하고 수정합니다.
- LURE(Zhou et al., 2023a) :
잠재적으로 환각적인 설명을 정확한 설명으로 변환하는 환각 수정기를 사용
- LogicCheckGPT (Wu et al., 2024) :
최신 자체 수정 기반 환각 완화 방법, 응답의 논리적 일관성에 중점
> 응답이 논리적 닫힌 루프를 형성할 수 있는지가 객체 환각의 지표 (객체의 속성을 묻는, 속성을 기반으로 객체를 묻는)

도전과제 미래방향

- 교차 모달 정렬 및 일관성
 - 생성된 콘텐츠가 입력 모달리티와 일관되고 맥락적으로 관련성을 유지하려면 교차 모달 관계를 포착하고 모델링하는 정교한 기술이 필요
- 모델 아키텍처의 발전
 - LLMs 및 MLLMs의 모델 아키텍처가 최근 발전했음에도 불구하고, 환각에 특화된 효과적인 아키텍처를 설계하는 것은 여전히 도전 과제
 - 복잡한 언어 구조를 포착하고 입력된 시각적 콘텐츠를 기반으로 일관되고 맥락적으로 관련된 출력을 생성할 수 있는 고급 모델 아키텍처를 개발
- 표준화된 벤치마크 수립
 - 표준화된 벤치마크와 평가 메트릭스의 부족은 MLLMs의 환각 정도를 평가하는 데 상당한 어려움을 초래
- 환각을 기능으로 재구성
 - 최근 소셜 미디어(Karpathy, 2023)에서의 논의는 환각을 LLMs 및 MLLMs의 고유한 기능으로 간주할 수 있다고 제안, 환각 기능을 활용하여 사용자 경험을 향상
- 해석 가능성과 신뢰성 향상
 - MLLMs의 생성 과정을 해석하고 설명할 수 있는 기술 개발에 집중해야 함
 - 모델 내부 시각화, 중요한 특징 및 언어 패턴 식별, 입력에서 출력까지의 생성 과정 추적 방법 등이 포함
- 윤리적 관점 탐색
 - 환각의 맥락에서 생성된 응답은 심각한 윤리적 문제를 포함할 수 있으므로 이 문제의 중요성이 더욱 부각됨
 - 잘못된 정보, 편향, 프라이버시, 사회적 영향과 관련된 윤리적 문제를 해결

Conclusion

- 환각 현상은 MLLMs의 실제 응용에 있어 중요한 도전 과제를 제기하며, 안전성, 신뢰성 및 신뢰성에 대한 우려를 야기
- 다중모달 대형 언어 모델 내의 환각에 대해 근본 원인, 평가 메트릭스, 벤치마크 및 완화 방법을 중심으로 철저히 조사
- 환각은 여전히 복잡하고 지속적인 문제로 남아 있으며, 지속적인 연구가 필요, 도전 과제를 고려하여 이 분야에서 여러 유망한 미래 방향을 제시