

Improving Aspect Sentiment Quad Prediction via Template-Order Data Augmentation

Mengting Hu, Yike Wu, Hang Gao, Yinhao Bai, Shiwan Zhao

정강민, 황지현, 황예진, 조해창

목차

The aspect sentiment
quad prediction
(ASQP) task

- 01 Introduction
- 02 Preliminaries on Generative ASQP
- 03 A Pilot Experiment
- 04 Methodology
- 05 Experiments
- 06 Related Work
- 07 Conclusion

01

Introduction

01 Introduction

④ The quadruplet consists of four sentiment elements

- 1) Aspect Category (**ac**) : **The Aspect Class**;
- 2) Aspect Term (**at**) : **The Specific Aspect Description**;
- 3) Opinion Term (**ot**) : **The Opinion Expression** towards the aspect;
- 4) Sentiment Polarity (**sp**) : **The Sentiment Class** of the aspect.

☑ For example

“The service is good and the restaurant is clean.”

Contains two quadruplets

- service general, service, good, positive
- ambience general, restaurant, clean, positive

01 Introduction

Introduction

Original sentence	<i>The restaurant is clean.</i>
Quadruplet (ac, at, ot, sp)	<i>(ambience general, restaurant, clean, positive)</i>
Semantic quadruplet $(x_{ac}, x_{at}, x_{ot}, x_{sp})$	<i>(ambience general, restaurant, clean, great)</i>
Fixed-order template	x_{ac} is x_{sp} because x_{at} is x_{ot}
Target sequence	<i>ambience general is great because restaurant is clean</i>
Free-order template	$O_i([AC] x_{ac}, [AT] x_{at}, [OT] x_{ot}, [SP] x_{sp}); i \in [1, 24]$
Multiple target sequences	$[AC] x_{ac} [AT] x_{at} [OT] x_{ot} [SP] x_{sp}$ $[AT] x_{at} [AC] x_{ac} [OT] x_{ot} [SP] x_{sp}$...

- 고정된 순서의 템플릿을 사용하여 문장을 대상 시퀀스로 바꿈
- 접근법은 특별한 마커를 사용하여 순서에 구애받지 않는 템플릿을 형성하고, 여러 대상 시퀀스를 생성
- O_i 는 네 가지 요소의 i 번째 순서 순열
- Special markers to form free-order templates
- Multiple target sequences

01 Introduction

④ 연구주요내용

- ASQP(Answer Sentence Quadruplet Prediction)에서 템플릿 순서의 효과를 연구
일부 순서가 더 나은 성능을 보임을 확인
- 템플릿 순서 관점에서 ASQP를 조사하는 첫 시도
- 사전 훈련된 언어 모델로 계산된 최소 엔트로피를 사용하여
적절한 템플릿 순서를 선택하는 방법을 제안
- 선택된 순서들은 대체로 그들의 실제 성능과 일관성
- 쿼드렛의 순서-자유 속성에 기반하여,
 - 데이터 증강을 위해 여러 적절한 템플릿을 결합하는 방법을 제안

02

Preliminaries on Generative ASQP

01 Introduction

☑ For example

“The service is good and the restaurant is clean.”

First, map the four elements of (ac, at, ot, sp) into semantic values (xac, xat, xot, xsp)

02 Preliminaries on Generative ASQP

☑ A Pilot Experiment

x_{ac} is x_{sp} because x_{at} is x_{ot}

- Displayed, this template forms a fixed order of four elements

02 Preliminaries on Generative ASQP

☑ Define projection functions

Quadruplet (ac; sp; at; ot) into semantic values $(x_{ac}, x_{at}, x_{ot}, x_{sp})$

- 1) **Aspect category** (ac) is transformed into words,
such as x_{ac} = "service general" for ac = "service#general";
- 2) If **Aspect term** (at) is explicit, $x_{at} = at$, otherwise $x_{at} = \text{"it"}$;
- 3) If **Opinion term** (ot) are explicitly mentioned,
 $x_{ot} = ot$, otherwise it is mapped as "NULL" if being implicitly expressed;
- 4) The **Sentiment polarity** (sp) $\in \{\text{positive, neutral, negative}\}$,
is mapped into words with sentiment semantics {great, ok, bad},

01 Introduction

④ Sequence-to-Sequence Learning

$$p_{\theta}(\mathbf{y}_{t+1} | \mathbf{x}, \mathbf{y}_{<t+1}) = \text{softmax}(W^T \mathbf{y}_t)$$

- 전체 어휘집에 대한 확률 분포를 나타내는 벡터로 매핑

01 Introduction

④ Sequence-to-Sequence Learning

$$\mathcal{L}(\boldsymbol{x}, \boldsymbol{y}) = - \sum_{t=1}^n \log p_{\theta}(\boldsymbol{y}_t | \boldsymbol{x}, \boldsymbol{y}_{<t})$$

- 교차 엔트로피 손실을 최소화하며 Fine tuning

03

A Pilot Experiment

03 A Pilot Experiment

☑ A Pilot Experiment

x_{ac} is x_{sp} because x_{at} is x_{ot}

- The performances of each element are connected to its position

01 Introduction

☑ The four elements have different trends with the positions

Average F1 scores of the six templates of each element at each position

		Position			
		1	2	3	4
Elements	x_{ac}	86.16	85.10	84.01	83.28
	x_{at}	80.15	80.40	80.39	80.52
	x_{ot}	68.41	69.83	70.06	69.05
	x_{sp}	92.45	91.75	90.64	89.44

(a) Results on Rest15

		Position			
		1	2	3	4
Elements	x_{ac}	88.58	88.30	88.48	88.32
	x_{at}	86.12	85.70	86.12	86.25
	x_{ot}	77.27	78.21	78.63	78.52
	x_{sp}	94.20	93.98	93.52	93.06

(b) Results on Rest16

x_{ac} , x_{sp} , x_{at} , x_{ot} 의 성능은 위치에 따라 다르게 나타남

즉, 각 요소가 템플릿 내에서 차지하는 위치에 따라 그 성능이 변화


- x_{ac} 와 x_{sp} 의 F1 점수는 그들이 점차 뒤로 배치될 때 감소하는 경향
두 요소가 앞쪽에 위치할 때 더 좋은 성능을 보인다는 것을 의미
- x_{at} 는 다양한 위치에서 더 안정적인 성능
- x_{ot} 는 첫 번째 위치에서 가장 나쁜 성능
- x_{ac} 와 x_{sp} 는 x_{at} 와 x_{ot} 에 비해 더 높은 F1 점수를 달성
- 네 가지 요소가 각각 다른 난이도를 가지고 있다는 의미

04

Methodology

04 Methodology

Methodology



- 첫 번째 단계에서는 사전 훈련된 T5를 사용하여 템플릿 순서를 선택하는 것을 목표
- 이 단계에서는 각 템플릿 순서를 평가하고, 가장 좋은 성능을 보이는 순서를 선택
- 두 번째 단계에서는 선택된 순서를 사용하여 훈련 샘플을 구성
- T5를 fine-tuning 모델과, 재구성된 데이터를 통해
-> train samples 구성

Template

Template								Rest16		
								Pre	Rec	F1
[AT]	x_{at}	[SP]	x_{sp}	[AC]	x_{ac}	[OT]	x_{ot}	56.36	58.80	57.55
[SP]	x_{sp}	[AC]	x_{ac}	[OT]	x_{ot}	[AT]	x_{at}	57.17	58.97	58.06
[AC]	x_{ac}	[SP]	x_{sp}	[AT]	x_{at}	[OT]	x_{ot}	57.39	58.80	58.08
[AC]	x_{ac}	[SP]	x_{sp}	[OT]	x_{ot}	[AT]	x_{at}	57.07	59.17	58.10
[AC]	x_{ac}	[AT]	x_{at}	[OT]	x_{ot}	[SP]	x_{sp}	57.20	59.32	58.24
[OT]	x_{ot}	[SP]	x_{sp}	[AC]	x_{ac}	[AT]	x_{at}	57.31	59.25	58.26
[AT]	x_{at}	[AC]	x_{ac}	[SP]	x_{sp}	[OT]	x_{ot}	57.30	59.35	58.31
[OT]	x_{ot}	[AT]	x_{at}	[AC]	x_{ac}	[SP]	x_{sp}	57.29	59.42	58.34
[SP]	x_{sp}	[OT]	x_{ot}	[AC]	x_{ac}	[AT]	x_{at}	57.40	59.52	58.44
[SP]	x_{sp}	[AT]	x_{at}	[AC]	x_{ac}	[OT]	x_{ot}	57.77	59.17	58.46
[OT]	x_{ot}	[AT]	x_{at}	[SP]	x_{sp}	[AC]	x_{ac}	57.63	59.82	58.70
[AC]	x_{ac}	[AT]	x_{at}	[SP]	x_{sp}	[OT]	x_{ot}	57.64	59.80	58.70
[SP]	x_{sp}	[OT]	x_{ot}	[AT]	x_{at}	[AC]	x_{ac}	57.81	59.95	58.86
[AC]	x_{ac}	[OT]	x_{ot}	[AT]	x_{at}	[SP]	x_{sp}	58.04	59.82	58.92
[AC]	x_{ac}	[OT]	x_{ot}	[SP]	x_{sp}	[AT]	x_{at}	57.87	60.02	58.93
[SP]	x_{sp}	[AC]	x_{ac}	[AT]	x_{at}	[OT]	x_{ot}	58.29	59.80	59.03
[AT]	x_{at}	[AC]	x_{ac}	[OT]	x_{ot}	[SP]	x_{sp}	58.11	60.02	59.05
[OT]	x_{ot}	[AC]	x_{ac}	[AT]	x_{at}	[SP]	x_{sp}	58.13	60.10	59.10
[AT]	x_{at}	[OT]	x_{ot}	[SP]	x_{sp}	[AC]	x_{ac}	58.25	60.05	59.14
[OT]	x_{ot}	[AC]	x_{ac}	[SP]	x_{sp}	[AT]	x_{at}	57.64	60.85	59.20
[AT]	x_{at}	[OT]	x_{ot}	[AC]	x_{ac}	[SP]	x_{sp}	58.27	60.33	59.28
[AT]	x_{at}	[SP]	x_{sp}	[OT]	x_{ot}	[AC]	x_{ac}	58.03	60.63	59.30
[OT]	x_{ot}	[SP]	x_{sp}	[AT]	x_{at}	[AC]	x_{ac}	58.72	60.45	59.57
[SP]	x_{sp}	[AT]	x_{at}	[OT]	x_{ot}	[AC]	x_{ac}	58.50	60.75	59.60

④ 4.1 Selecting Template Orders

$$O_i(x_{ac}, x_{at}, x_{ot}, x_{sp}) = x_{at} x_{ac} x_{ot} x_{sp}$$

- 사전 훈련된 T5를 사용하여 템플릿 순서를 평가하는 방식으로 진행
- 네 가지 값은 심표와 같은 다른 토큰 없이 단순한 공백으로 연결
- 이 방식을 통해 노이즈 토큰의 영향을 줄이고 순서에 더 집중
- 여러 쿼드렛이 있는 경우 특수 심볼 [SSEP]을 도입
- 템플릿 순서가 주어지면, 입력 x 에 대해 여러 목표 시퀀스 y_{oi} 가 구성

④ 4.1 Dataset-Level Order (DLO)

$$\mathcal{S}_{o_i} = \frac{1}{|\mathcal{T}|} \sum_{\mathcal{T}} \mathcal{E}(\mathbf{y}_{o_i} | \mathbf{x})$$

- 전체 훈련 세트에 대해 각 순서에 대한 점수를 계산하는 것
- 점수는 템플릿 순서에 대한 모든 인스턴스의 평균 엔트로피
- 계산한 점수를 기준으로 템플릿 순서를 순위
- 모델이 더 확실하게 예측하는 순서를 선호한다는 것

04 Methodology

4.1 the average entropy of all instances for the template order O_i

S_{O_i} 는 템플릿 순서 O_i 에 대한 모든 인스턴스의 평균 엔트로피

템플릿 순서 O_i 에 대한 모든 인스턴스의 평균 엔트로피를 계산하는 방법

$$S_{O_i} = \frac{1}{|\mathcal{T}|} \sum_{\mathcal{T}} \mathcal{E}(y_{O_i} | x)$$

교사 강제(teacher forcing) 방식으로 디코더에 입력

- 평균 엔트로피를 기준으로 템플릿 순서를 순위를 매김
- 불확실성이 낮은, 즉 모델이 더 확실하게 예측하는 순서를 선호한다는 것을 의미
- 템플릿 순서에 대한 모든 인스턴스의 평균 엔트로피를 계산하고, 이를 기준으로 템플릿 순서를 선택하는 방법

④ 4.1 the average entropy of all instances for the template order O_i

$$\mathcal{S}_{O_i} = \frac{1}{|\mathcal{T}|} \sum_{\mathcal{T}} \mathcal{E}(\mathbf{y}_{O_i} | \mathbf{x})$$

- 평균 엔트로피를 기준으로 템플릿 순서를 순위를 매김
- 평균 엔트로피 값이 작은 템플릿 순서가 선택됨

④ 4.1 Instance-Level Order (ILO)

- 다른 인스턴스들은 각각 다양한 '컨텍스트'와 '의미'
- 각자 적절한 템플릿 순서를 가짐
- '인스턴스 수준'에서 순서를 선택하는 방법도 설계

$$\mathcal{E}(\mathbf{y}_{o_i} \mid \mathbf{x}) = -\frac{1}{n} \sum_n \sum_{|V|} p_{\theta} \log p_{\theta}$$

- 인스턴스에 가장 적합한 순서를 선택

④ 4.2 Fine-tuning with Selected Orders

$$\begin{aligned} \mathbf{y}_{o_i} &= O_i([AC] x_{ac}, [AT] x_{at}, [OT] x_{ot}, [SP] x_{sp}) \\ &= [AT] x_{at} [AC] x_{ac} [SP] x_{sp} [OT] x_{ot} \end{aligned}$$

- 여러 템플릿 순서를 사용하여 모델을 Fine tuning
- 특수 마커를 사용하여 여러 순서를 함께 훈련
- 추론 과정에서 이 마커를 사용하여 쿼드렛을 복구

05

Experiments

05 Experiments

5.1 Datasets

Methods	Rest15			Rest16		
	Pre	Rec	F1	Pre	Rec	F1
HGCN-BERT+BERT-Linear* (Cai et al., 2020)	24.43	20.25	22.15	25.36	24.03	24.68
HGCN-BERT+BERT-TFM* (Cai et al., 2020)	25.55	22.01	23.65	27.40	26.41	26.90
TASO-BERT-Linear* (Wan et al., 2020)	41.86	26.50	32.46	49.73	40.70	44.77
TASO-BERT-CRF* (Wan et al., 2020)	44.24	28.66	34.78	48.65	39.68	43.71
Extract-Classify-ACOS (Cai et al., 2021)	35.64	37.25	36.42	38.40	50.93	43.77
GAS* (Zhang et al., 2021b)	45.31	46.70	45.98	54.54	57.62	56.04
Paraphrase* (Zhang et al., 2021a)	46.16	47.72	46.93	56.63	59.30	57.93
DLO	47.08	49.33	48.18	57.92	61.80	59.79
ILO	47.78	50.38	49.05	57.58	61.17	59.32

- 정밀도(Precision, Pre), 재현율(Recall, Rec),
- F1 점수(F1 Score, F1)를 Rest15와 Rest16 데이터셋

05 Experiments

5.1 Datasets

Methods	Rest15			Rest16		
	Pre	Rec	F1	Pre	Rec	F1
HGCN-BERT+BERT-Linear* (Cai et al., 2020)	24.43	20.25	22.15	25.36	24.03	24.68
HGCN-BERT+BERT-TFM* (Cai et al., 2020)	25.55	22.01	23.65	27.40	26.41	26.90
TASO-BERT-Linear* (Wan et al., 2020)	41.86	26.50	32.46	49.73	40.70	44.77
TASO-BERT-CRF* (Wan et al., 2020)	44.24	28.66	34.78	48.65	39.68	43.71
Extract-Classify-ACOS (Cai et al., 2021)	35.64	37.25	36.42	38.40	50.93	43.77
GAS* (Zhang et al., 2021b)	45.31	46.70	45.98	54.54	57.62	56.04
Paraphrase* (Zhang et al., 2021a)	46.16	47.72	46.93	56.63	59.30	57.93
DLO	47.08	49.33	48.18	57.92	61.80	59.79
ILO	47.78	50.38	49.05	57.58	61.17	59.32

- 'DLO' 방법은 Rest15에서 정밀도 47.08%, 재현율 49.33%, F1 점수 48.18%를 기록
- Rest16에서는 정밀도 57.92%, 재현율 61.80%, F1 점수 59.79%를 기록

05 Experiments

5.1 Datasets

Methods	Rest15			Rest16		
	Pre	Rec	F1	Pre	Rec	F1
HGCN-BERT+BERT-Linear* (Cai et al., 2020)	24.43	20.25	22.15	25.36	24.03	24.68
HGCN-BERT+BERT-TFM* (Cai et al., 2020)	25.55	22.01	23.65	27.40	26.41	26.90
TASO-BERT-Linear* (Wan et al., 2020)	41.86	26.50	32.46	49.73	40.70	44.77
TASO-BERT-CRF* (Wan et al., 2020)	44.24	28.66	34.78	48.65	39.68	43.71
Extract-Classify-ACOS (Cai et al., 2021)	35.64	37.25	36.42	38.40	50.93	43.77
GAS* (Zhang et al., 2021b)	45.31	46.70	45.98	54.54	57.62	56.04
Paraphrase* (Zhang et al., 2021a)	46.16	47.72	46.93	56.63	59.30	57.93
DLO	47.08	49.33	48.18	57.92	61.80	59.79
ILO	47.78	50.38	49.05	57.58	61.17	59.32

- 'ILO' 방법은 Rest15에서 정밀도 47.78%, 재현율 50.38%, F1 점수 49.05%를 기록
- Rest16에서는 정밀도 57.58%, 재현율 61.17%, F1 점수 59.32%를 기록

5.1 Datasets - 훈련(Train), 검증(Dev), 그리고 테스트(Test)

	Rest15				Rest16			
	#S	#+	#0	#-	#S	#+	#0	#-
Train	834	1005	34	315	1264	1369	62	558
Dev	209	252	14	81	316	341	23	143
Test	537	453	37	305	544	583	40	176

- #S: 문장의 수
- #+: 긍정적인 쿼드릿의 수
- #0: 중립적인 쿼드릿의 수
- #-: 부정적인 쿼드릿의 수

05 Experiments

5.2 Implementation Details

④ 5.2 Implementation Details – T5 (Text-to-Text Transfer Transformer)

- Google의 연구팀에서 개발한 자연어 처리 모델
- T5-base"는 T5 모델의 특정 버전 , base , large , XL
- T5는 텍스트 입력을 받아 텍스트 출력을 생성하는 모든 NLP (자연어 처리) 작업을 "텍스트 생성" 작업으로 간주하는 "텍스트-투-텍스트" 프레임워크를 기반
- 이렇게 하면 모든 NLP 작업을 통일된 방식으로 처리
- T5는 Transformer 아키텍처를 사용하며, 이 아키텍처는 인코더와 디코더를 통해 입력 텍스트를 출력 텍스트로 매핑
- Transformer는 자연어 처리에서 뛰어난 성능을 보이며, 이는 주로 텍스트 내의 다양한 요소 간의 복잡한 관계를 학습할 수 있는 "어텐션(attention)" 메커니즘

④ 5.2 Implementation Details – T5 (Text-to-Text Transfer Transformer)

- T5는 Transformer 아키텍처를 사용하며, 이 아키텍처는 인코더와 디코더를 통해 입력 텍스트를 출력 텍스트로 매핑
- Transformer는 자연어 처리에서 뛰어난 성능을 보이며, 이는 주로 텍스트 내의 다양한 요소 간의 복잡한 관계를 학습할 수 있는 "어텐션(attention)" 메커니즘
- T5는 사전 학습(pretraining) 단계와 미세 조정(finetuning) 단계의 두 단계로 훈련
 - 사전 학습 단계에서는 모델이 대량의 텍스트 데이터로부터 언어의 통계적 구조를 학습
 - 미세 조정 단계에서는 특정 NLP 작업에 대해 모델을 최적화
- T5-base는 총 220M의 파라미터
- T5-large는 770M의 파라미터

④ 5.3 Compared Methods - HGCN-BERT+BERT-Linear

모델의 주요 목표

Aspect categories, ac 와 Sentiment polarity, sp 정보를 공동으로 추출

모델의 작동 원리

- HGCN(Hierarchical Graph Convolutional Networks)
- 첫 번째 단계에서 aspect category와 sentiment polarity를 공동으로 추출
- BERT는 aspect target과 opinion target을 추출(Li 등, 2019).
- 마지막으로, 이들 추출 결과를 모두 사용하여 linear layer를 쌓아(full model) 예측
- 이렇게 모델은 다양한 정보를 추출하고, 이를 결합하여 문장의 관점과 감정을 분석
- 문장의 전반적인 감정과 관점을 보다 정확하게 파악

④ 5.3 Compared Methods - HGCM-BERT+BERT-TFM

HGCM-BERT+BERT-Linear 모델을 변형한 모델
이 모델에서는 최종적으로 쌓여진 레이어를 Transformer 블록으로 변경
"TFM"은 Transformer 의미

이 변경으로 인해 모델은 Transformer의 장점인 입력 데이터 사이의 복잡한 상호 관계를 더 잘 포착하고 처리하는 능력을 활용
이는 감정 분석과 같은 복잡한 작업에 도움이 됩니다.
따라서, 이 변형 모델은 원래의 모델보다 더 높은 성능을 보일 수 있습니다.

④ 5.3 Compared Methods - TASO-BERT-CRF

TASO라는 기법에 CRF(Conditional Random Field) 레이어를 추가한 모델
TASO는 Transformer-based Aspect Sentiment Offsets라는 모델,
리뷰 데이터에서 주제(aspect)와 감성(sentiment) 정보를 함께 추출하는 데 초점

CRF 레이어를 추가

모델은 각각의 데이터 포인트가 서로 연결되어 있는 맥락에서 결과를 추출
이는 특히 감성 분석 같은 과제에서 중요한데, 문장 내의 단어나 구문이 전체 문맥 속에서
어떤 의미를 가지는지를 이해하는 데 도움

TASO-BERT-CRF는 기본 TASO 모델의 성능을 높이는 데 도움
이런 종류의 모델은 리뷰 문장의 감성 분석과 같은 복잡한 자연어 처리 작업에 특히 유용

④ 5.3 Compared Methods - Extract-Classify-ACOS

" Extract-Classify-ACOS "는 두 단계로 이루어진 방법론(Cai 등이 2021년에 제안)

첫 번째 단계에서는 원본 문장에서 'at'와 'ot'를 추출
('at'는 Aspect term을, 'ot'는 Opinion term)

문장에서 주제(aspect)와 그에 대한 의견(opinion)을 먼저 찾아내는 것

'at'와 'ot'를 기반으로 두 번째 단계에서 'ac'와 'sp'를 분류(classification)하여 찾아냅니다.
('ac'는 Aspect category, 'sp'는 Sentiment polarity)

즉, 추출한 주제와 의견을 바탕으로 주제의 카테고리과 감성 극성을 분류하는 것

이런 식으로, 두 단계를 거치며 문장 내 주제와 의견, 그리고 그것들의 카테고리과 감성 극성을 추출합니다. 이렇게 하면 문장의 의미를 더욱 정확하게 이해

④ 5.3 Compared Methods - GAS

"GAS"는 Zhang 등이 2021년에 제안한 방법론
생성 모델을 활용해 감성 분석을 수행하는 첫 번째 작업

감성 사분면(감성 쿼드) 시퀀스를 바로 목표 시퀀스로 처리하도록 수정
(*'Aspect term', 'Opinion term', 'Aspect category', 'Sentiment polarity'*)

GAS는 문장을 입력으로 받아, 그 문장이 표현하는 감성 정보를 '감성 사분면' 시퀀스 형태로 생성해내는 방법론

이 방식은 기존의 분류 기반의 감성 분석과는 다르게, 보다 정교하게 감성 정보를 추출하고 분석하는 것을 가능

④ 5.3 Compared Methods - Paraphrase

Zhang 등이 2021년에 제안한 생성 기반의 방법론

원래의 문장을 다시 표현(paraphrasing)함으로써 문장의 의미론적 지식을 추출
이런 방식은 문장이 표현하는 내용을 다른 방식으로 다시 쓰는 과정에서 얻어진 문맥적인 정보를 활용하여 보다 정확한 감성 분석을 수행하게 도움

즉, 주어진 문장을 다른 말로 바꾸는 과정을 통해, 문장에 내재된 의미를 보다 정교하게 추출하고 분석하는 방식을 사용하는 것
문장이 가진 복잡한 감성 정보를 효과적으로 다루는 데 도움

5.3 ILO(Instance-Level Order) vs DLO(Dataset-Level Order)

Methods	Rest15		
	Pre	Rec	F1
ILO(Entropy Max)	45.68	48.85	47.21
ILO(random)	46.84	50.33	48.52
ILO	47.78	50.38	49.05

Methods	Rest16		
	Pre	Rec	F1
DLO(Entropy Max)	57.09	60.77	58.87
DLO(random)	56.92	60.91	58.85
DLO	57.92	61.80	59.79

06

Related Work

5.4.4 Effects of Special Marker

Template	Rest15			Rest16		
	Pre	Rec	F1	Pre	Rec	F1
T1	48.46	49.46	48.95	58.27	60.33	59.28
T2	47.11	48.30	47.69	57.77	60.40	59.05
T3	47.62	48.60	48.10	57.09	59.57	58.20
T4	46.67	47.87	47.26	57.66	59.97	58.79

Table 6: Evaluation results of special marker.

- **T1:** [AT] x_{at} [OT] x_{ot} [AC] x_{ac} [SP] x_{sp}
- **T2:** aspect term: x_{at} opinion term: x_{ot} aspect category: x_{ac} sentiment polarity: x_{sp}
- **T3:** Aspect Term: x_{at} Opinion Term: x_{ot} Aspect Category: x_{ac} Sentiment Polarity: x_{sp}
- **T4:** $x_{at}, x_{ot}, x_{ac}, x_{sp}$

06 Related Work

👉 Error Analysis

Example 1

Sentence: *Save your money and your time and go somewhere else.*

Gold label: [AT] *it* [OT] *go somewhere else* [AC] *restaurant general* [SP] *bad*

Prediction: [OT] *Save* [AT] *it* [AC] *great* [SP] *restaurant miscellaneous* ❌

Example 2

Sentence: *Terrible, Waste of money .. scammers*

Gold label: [AT] *it* [OT] *Terrible* [AC] *restaurant general* [SP] *bad* [SSEP]

[AT] *it* [OT] *Waste of money* [AC] *restaurant prices* [SP] *bad*

Prediction: [OT] *Terrible* [SP] *bad* [AC] *service general* [AT] *it* ❌

07

Conclusion

👍 Conclusion

- 템플릿 순서 관점에서의 관점 감성 쿼드 예측(ASQP)에 대해 연구
- 다른 순서들이 쿼드럼플릿에 대한 다양한 VIEW를 제공한다는 가설
- 가설에 따라, 가장 적절한 순서를 파악하고, 여러 적절한 템플릿을 데이터 증가를 통해 결합하여 ASQP 작업을 개선하는 간단하지만 효과적인 방법을 제안
- 구체적으로, 사전 훈련된 언어 모델을 사용하여 최소 엔트로피를 가진 순서를 선택
- 템플릿 순서로 사전 훈련된 모델을 Fine-tuning
- 최고의 성능을 달성

06 Related Work

④ Error Analysis

- 요약하자면,
 - 암시적 표현과 여러 측면을 가진 문장들은 대개 어려운 경우
 - 이 관찰은 또한 예비 실험에서의 결과와 일치
 - 그림 2에서 보여지는 것처럼, 측면 용어와 의견 용어의 F1 점수는 다른 두 요소보다

④ Data Augmentation – 유형1

입력 X 를 증가시키는 것

예를 들어, 이미지를 뒤집거나 회전하고 확대/축소하는 것은 모두 X 를 변경하여 성능을 개선하려는 시도

텍스트 작업에서는, 역번역(back-translation) (Sugiyama and Yoshinaga, 2019)이 X 를 증가시키는 방법을 통해 의사 쌍(pseudo pairs)을 생성

- 원본 문장을 다른 언어로 번역한 뒤 다시 원래의 언어로 번역하여 원본 문장과 비슷하지만 약간 다른 새로운 문장을 생성하는 과정
- 원본 문장이 어떤 감정을 나타내는 문장이라면, 역번역을 통해 생성된 새로운 문장 역시 동일한 감정을 나타내는 문장이 될 것

주요 아이디어는 X 를 변경하더라도 그것의 지상 진리 라벨 Y 에는 영향없음

☑ Data Augmentation – 유형2

X와 Y 모두가 증가하는 경우

믹스업(mixup) (Zhang et al., 2018)이라는 유망한 작업

특징 벡터의 선형 보간이 관련 목표의 선형 보간으로 이어져야 한다는 가정

직관적이고 많은 작업에서 효과적임이 입증

📌 Data Augmentation – 유형3

Y를 증가시키는 것


시퀀스-투-시퀀스 학습을 위해 대상 측 데이터 증가로 **가상 시퀀스**를 제안
단어의 순서와 밀접하게 연결된 일반적인 생성 작업을 처리

생성적 ASQP 작업의 특성을 이용
순서 순열(order permutations)은 여전히 지상 진리 라벨을 제공
다른 순서가 다른 관점에서 그림을 보는 것이라는 가정, 즉 다른 뷰

여러 템플릿 순서를 결합하면 모델이 표면적인 패턴에 편향되는 것을 방지하고, 작업의 본질을 종합적으로 이해하는 데 도움

05 Experiments


5.4 Experimental Results – Rest15



(a) Rest15

05 Experiments

5.4 Experimental Results - Rest16



(b) Rest16