

Improving Neural Machine Translation with Soft Template Prediction

박희수(발표자), 조해창, 박산희, 변현정,
김유진, 이기성, 정천감, 이세현

Motivation




Figure 1: An example of template guided translation results. S denotes subject and VP denotes verb phrase.

- 기계 번역 시에 특정한 template 으로 가이드를 주면 성능을 더 높일 수 있지 않을까?

Approach

1. Constituency-based parse tree 를 사용하여 training data 에서 template 을 추출
2. 원문 텍스트가 주어지면 타겟 텍스트의 template 을 맞추는 Transformer 를 학습시킴
3. 2번에서 학습시킨 모델을 사용하여 triple training data 구축 ($D_{X,Y,Y}$)
4. 원문 텍스트와 템플릿을 입력하면 번역을 출력하는 Transformer 학습 (2개의 Encoder와 1개의 Decoder)

Soft Template Prediction


- Target template 을 예측하는 Transformer 모델을 학습

$$P_{\theta_{X \rightarrow T}}(T|X)$$

- **Input:** 원문 텍스트 (예 → 여러 사람들이 달리고 있다.)
- **Output:** Soft template (예 → There are NP VP)
 - Output 문장은 Vocabulary 와 non-terminal token (S_0) 으로 이루어짐


$$S_0 = \{S, NP, VP, EX, VBP, NP, DT, NNS, VBG\}$$

Soft Template Prediction




- Template prediction 모델 학습을 위한 training dataset 구축
 - Training dataset 에서 target 문장을 constituency 기반의 tree 형태로 바꿈
 - Depth 를 고정시키고 depth 이상의 단어들은 pruning 함
 - Depth 가 깊어질 수록 구체적인 template 형태가 나옴
 - Beam search 로 template 결정
- 학습 시킬 때 GT template 이 아닌 학습시킨 모델의 top-1 result 를 사용

Machine Translation via Soft Templates




Machine Translation via Soft Templates



- 기본적인 Transformer Encoder 에 원문 텍스트와 Template 을 각각 넣는다

Machine Translation via Soft Templates



- Source text 와 template 에 대해서 cross attention 을 각각 계산하고 통합한다.

$$Z = \beta Z^{X,Y} + (1 - \beta) Z^{T,Y}$$

$$\beta = \sigma(W_Y Z^{X,Y} + U_T Z^{X,T})$$

Training Strategy

- Soft Template 이 형편 없는 경우를 보완하고자 template 을 사용했을 때와 사용하지 않았을 때의 loss 계산을 따로 함
 - Template 없이 학습할 경우 (이 때, 업데이트 되는 파라미터는 source encoder, target decoder)

$$L_{\theta_{X \rightarrow Y}}(D) = \sum_{X, Y \in D} \log P_{\theta_{X \rightarrow Y}}(Y|X)$$

- Template 과 함께 학습하는 경우 (이 때, 업데이트 되는 파라미터는 source, template encoder, target decoder)

$$L_{\theta_{(X, T) \rightarrow Y}}(D) = \sum_{X, Y \in D} \log P_{\theta_{(X, T) \rightarrow Y}}(Y|X, T)$$

- 실제 학습시에는 두개를 적절히 가중치를 두어 학습

$$L_{\theta}(D) = \alpha L_{\theta_{X \rightarrow Y}}(D) + (1 - \alpha) L_{\theta_{(X, T) \rightarrow Y}}(D)$$

Experiments

- 4개의 Benchmark 를 통해 다양한 도메인과 다양한 언어 페어에 대해 실험을 진행
 1. LDC: Chinese → English, News, 1.2M
 2. WMT14: English → German, News, 4.5M
 3. ASPEC: Japanese → Chinese, Scientific paper, 0.67M
 4. IWSLT14: German → English, TED talk, 16K

Experiments

- LDC: Chinese $\rightarrow$ English, News, 1.2M

Zh $\rightarrow$ En	MT06	MT03	MT05	MT08	MT12	Avg.
ConvS2S (Gehring et al., 2017)	39.98	42.25	41.22	33.43	32.21	37.28
GNMT (Wu et al., 2016)	40.53	42.88	42.73	33.97	32.55	38.03
Transformer (our implementation)	43.60	45.80	44.52	36.62	34.60	40.39
ST-NMT (our proposed)	44.69	46.56	46.04	37.53	35.99	41.53

Table 1: Evaluation results on Zh $\rightarrow$ En translation task with BLEU% metric. The “Avg.” column means the averaged result of all NIST test sets except NIST2006. The result of our model is statistically significant compared to the other baselines ($p < 0.01$).

Experiments

- IWSLT14: German $\rightarrow$ English, TED, 16K

De $\rightarrow$ En	BLEU
GNMT (Wu et al., 2016)	31.44
RNMT+ (Chen et al., 2018)	34.51
ConvS2S (Gehring et al., 2017)	30.41
LightConv (Wu et al., 2019)	34.80
DynamicConv (Wu et al., 2019)	35.20
Rerank-NMT (Liu et al., 2016)	34.82
Transformer (our implementation)	34.43
ST-NMT (our proposed)	35.24

Table 2: BLEU-4 scores (%) on IWSLT14 De $\rightarrow$ En task. The result of our model is statistically significant compared to the other baselines ($p < 0.05$).

Experiments

- WMT14: English → German, News, 4.5M

En → De	BLEU
GNMT (Wu et al., 2016)	24.61
ConvS2S (Gehring et al., 2017)	25.16
Transformer (Vaswani et al., 2017)	28.40
RNMT+ (Chen et al., 2018)	28.49
Rerank-NMT (Liu et al., 2016)	27.81
ABD-NMT (Liu et al., 2016)	28.22
Deliberation Network (Xia et al., 2017)	29.11
SoftPrototype (Wang et al., 2019b)	29.46
SB-NMT (Zhou et al., 2019a)	29.21
SBSG (Zhou et al., 2019b)	27.45
Insertion Transformer (Stern et al., 2019)	27.41
Transformer (our implementation)	29.25
ST-NMT (our proposed)	29.68

Table 3: BLEU-4 scores (%) on WMT14 En→De task. The result of our model is statistically significant compared to the other baselines ($p < 0.05$).

Experiments

- ASPEC: Japanese $\rightarrow$ Chinese, Scientific paper, 0.67M

Ja $\rightarrow$ Zh	BLEU
GNMT (Wu et al., 2016)	49.12
ConvS2S (Gehring et al., 2017)	50.32
Transformer (our implementation)	52.02
ST-NMT (our proposed)	52.84

Table 4: Character-level BLEU-4 scores (%) on ASPEC Ja $\rightarrow$ Zh task. The result of our model is statistically significant compared to the other baselines ($p < 0.01$).

Experiments

- Multiple Template

- Beam search 시에 top-1 만 사용하는 것이 아닌 top-k 를 사용
- Single template 이 가장 효과적임
- 다양한 template 을 사용하는 것은 model 을 robust 하게 만들지만 성능은 떨어뜨릴 수 있음




Figure 4: The effect of the multiple templates. We feed the the top-K results of the beam search as multiple templates and source sentence to generate the target translation.

Experiments

- Balance of Two Objectives
 - 알파가 0.4에서 0.9 일때 가장 최적의 성능을 보임




Figure 5: We use two objective to update our model parameters. One objective only use source sentence and another utilizes source and soft template sentences together to generate the final translation. The hyperparameter α is used to balance the two objectives,

$$L_{\theta}(D) = \alpha L_{\theta_{X \rightarrow Y}}(D) + (1 - \alpha) L_{\theta_{(X, T) \rightarrow Y}}(D)$$

Experiments

- Depth of Parsing Tree
 - 아래 식처럼, 인풋 문장의 길이 L 과 lower bound 와 upper bound 에 의해 결정 된다.
 - 여기서 input 문장 길이의 비율을 조정하면서 실험했을 때, 0.15 를 곱했을 경우 성능이 가장 높음 (LDC dataset 에 대해)

$$d = \min(\max(L \times \lambda, \gamma_1), \gamma_2)$$

λ	MT03	MT05	MT08	MT12
0.10	45.92	45.01	36.55	35.34
0.15	46.56	46.04	37.53	35.99
0.20	46.02	45.20	37.08	35.82
0.25	46.27	44.83	36.88	35.64
0.30	46.08	45.02	36.72	35.54
0.35	46.22	44.92	36.84	35.51
0.40	46.32	45.40	36.94	35.61

Table 5: The results of the different depth on NIST2003, NIST2005, NIST2008 and NIST2012.

Experiments

- Ratio of Overlapping Words
 - Template 이 final translation 결과에 얼마나 영향을 주는지 측정하기 위해, final translation 과 template 사이에 얼마나 중첩되는 단어들이 있는지 측정함
 - 오른쪽 테이블을 보면 template 과 결과 사이에 큰 상관관계가 있는 것을 알 수 있음

λ	MT03	MT05	MT08	MT12
0.15	79.4	81.6	78.6	77.6

Table 6: The ratio(%) of overlapping words between the predicted soft target template and the translation on NIST2003, NIST2005, NIST2008 and NIST2012.

$$ratio = \frac{\sum_{w \in T} \min(Count_y(w), Count_t(w))}{\sum_{w \in T} Count_t(w)}$$

Experiments

- Example Study

Source	另一方面，如果 我们 反应 过度，将 会 被 他们 欺骗 .
Reference	on the other hand , if we overreact , we will be deceived by their trick .
Template	on the other hand , if NP VP , we will VP .
Ours	on the other hand , if we react too much , we will be hit by them .

Table 7: A Chinese-English translation example of our proposed method. VP and NP represent non-terminal nodes in the constituency-based parse tree.

Thank you!