

Natural Posterior Network: Deep Bayesian Uncertainty for Exponential Family Distributions

ICLR 2022

발표자: 박민제, 펀디멘탈 팀

Contents

- 01 Background – Uncertainty Estimation**
- 02 Related Works – Approaches for Deep Learning Uncertainty**
- 03 Methods – Natural Posterior Network**
- 04 Experiments**
- 05 Analysis & Discussion**
- 06 Conclusion**

Background – Uncertainty Estimation

■ Uncertainty Estimation

- 특정 도메인에서는 한 번의 잘못된 예측이 큰 위험을 초래할 수 있다.
 - e.g., 자율 주행, 의료, ...
- **신뢰할 수 있는 모델**을 얻기 위해, 모르는 것을 "모른다"고 말할 수 있게끔 모델을 학습시키자.
 - Anomaly / out-of-distribution (OOD)
 - Covariate shift

■ Decomposition of Uncertainty

- Data uncertainty (a.k.a. *aleatoric uncertainty*)
- Knowledge uncertainty (a.k.a. *epistemic uncertainty*)




Fig 1. Aleatoric uncertainty and epistemic uncertainty.¹ 데이터 자체의 노이즈로 인한 uncertainty와, 학습 데이터가 부족하여 발생하는 uncertainty로 나뉜다.

1. Tuna, Omer Faruk, Ferhat Ozgur, Catak, M Taner, Eski. "Exploiting epistemic uncertainty of the deep learning models to generate adversarial samples". Multimedia Tools and Applications 81. 8(2022): 11479–11500.

Background – Uncertainty Estimation

■ Uncertainty in Deep Learning

- Vanilla deep learning 모델은 자만하는(**overconfident**) 경향이 있다.¹
 - 잘 모르는 데이터(e.g., OOD)에 대해서도 높은 확률 값을 출력하는 경향.²

■ Calibration Error

- **Reliability diagram**³: confidence와 정확도 간의 관계를 보여주는 그래프.
 - Confidence가 0.9 ~ 1.0인 샘플들의 정확도는 정말 90% ~ 100%인가?
 - Confidence > accuracy: overconfident.
- **(Expected) calibration error**¹: confidence와 정확도 사이의 차이.
 - 해당 값이 작을 수록 모델을 신뢰할 수 있다고 본다.




Fig 2. Reliability diagram.¹ ResNet 모델은 높은 confidence에 비해 비교적 낮은 accuracy를 보인다.

1. Guo, Chuan, et al. "On calibration of modern neural networks." International conference on machine learning. PMLR, 2017.

2. Hendrycks, Dan, and Kevin Gimpel. "A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks." International Conference on Learning Representations. 2016.

3. Niculescu-Mizil, Alexandru, and Rich Caruana. "Predicting good probabilities with supervised learning." Proceedings of the 22nd international conference on Machine learning. 2005.

Related Works – Approaches for Deep Learning Uncertainty

▪ Sampling-based Method

- 같은 데이터가 입력되어도 여러 개의 서로 다른 출력 값을 얻게끔 학습.
- 여러 번의 inference를 통해 얻는 출력 값들의 spread를 uncertainty로 활용.
- **방법론 분류:**
 - **Bayesian neural networks**¹: 모델 weight의 분포($= p(w|\mathcal{D})$)를 학습.
 - **Dropout 활용**²: inference 할 때에도 dropout을 활성화.
 - **Ensemble 활용**³: 서로 다른 여러 개의 모델을 학습.
- **한계점:**
 - **메모리 비효율**: vanilla 모델에 비해 더 많은 파라미터를 학습해야 한다.
 - **시간 비효율**: 여러 번의 inference를 수행하므로, vanilla 모델에 비해 N배 더 많은 시간이 소요된다.




Fig 3. Bayesian neural network.¹
각 weight가 특정한 분포를 따르도록 학습시킨다.

1. Blundell, Charles, et al. "Weight uncertainty in neural network." International conference on machine learning. PMLR, 2015.
2. Gal, Yarin, and Zoubin Ghahramani. "Dropout as a bayesian approximation: Representing model uncertainty in deep learning." international conference on machine learning. PMLR, 2016.
3. Lakshminarayanan, Balaji, Alexander Pritzel, and Charles Blundell. "Simple and scalable predictive uncertainty estimation using deep ensembles." Advances in neural information processing systems 30 (2017).

Related Works – Approaches for Deep Learning Uncertainty

▪ Second-Order Predictor / Evidential Deep Learning (EDL)

- Label 분포(Likelihood = $p(y|x; \theta)$)의 모수(= θ)에 대한 분포(Conjugate prior = $Q(\theta|x; \alpha)$)를 학습하는 것.

- Classification: $\mathbf{y} \sim \text{Cat}(\mathbf{y}; \theta), \theta \sim \text{Dir}(\theta; \alpha) = \frac{\Gamma(\sum_{i=1}^K \alpha_i)}{\prod_{i=1}^K \Gamma(\alpha_i)} \prod_{i=1}^K \theta_i^{\alpha_i-1}$

- Regression: $y \sim \mathcal{N}(y; \pi = (\mu, \sigma)), \mu \sim \mathcal{N}(\mu; \mu_0, \frac{\sigma}{\lambda}), \sigma \sim \text{InvGamma}(\sigma; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \sigma^{-\alpha-1} \exp\left(-\frac{\beta}{\sigma}\right)$

- 학습된 모델은 second-order distribution의 모수를 출력.

- 특징:

- 단 한 번의 forward-pass 만으로 uncertainty estimation이 가능하다.

- Closed-form 분포를 가정하고 있으므로, analytic solution(e.g., 분산, entropy, ...) 계산 가능.

- 다른 방법론들(e.g., variational inference, ensemble learning, ...)에 비해 학습 과정이 비교적 수월하다.

- Second-order distribution에 대해 maximum likelihood / maximum a posteriori 추정하는 것 만으로 충분.


- 기존 방법론의 한계:

- 학습데이터와 OOD 데이터가 서로 다른 $Q(\theta|x; \alpha)$ 를 갖도록 학습시키기 위해, 학습 시 OOD example이 필요했다.¹


1. Malinin, Andrey, and Mark Gales. "Predictive uncertainty estimation via prior networks." Advances in neural information processing systems 31 (2018).

Related Works – Approaches for Deep Learning Uncertainty


▪ Second-Order Predictor / Evidential Deep Learning (EDL)



(a) Confident Prediction



(b) Data Uncertainty



(c) Knowledge Uncertainty

Fig 4. Classification 예시.¹

- (a): x 의 evidence가 충분히 쌓여 $Q(\theta|x; \alpha)$ 의 spread가 좁아졌고, 특정 class에 잘 모여있는 모습.
(b): x 의 evidence는 충분히 쌓여 spread는 좁아졌으나, 데이터 자체가 noisy하여 uncertain한 답을 내놓는 모습.
(c): x 의 evidence가 충분히 쌓이지 않아 spread가 넓은 모습.

1. Malinin, Andrey, Bruno Mlodozienec, and Mark Gales. "Ensemble Distribution Distillation." International Conference on Learning Representations. 2019.

Related Works – Approaches for Deep Learning Uncertainty

■ Second-Order Predictor / Evidential Deep Learning (EDL)




Fig 5. Regression 예시.¹

- A: x 의 evidence가 쌓임에 따라 $Q(\theta|x; \alpha)$ 의 spread가 줄어드는 모습.
- B: 중간 정도의 evidence가 쌓인 $Q(\theta|x; \alpha)$ 의 모습.
- C: $Q(\theta|x; \alpha)$ 에서 샘플링 되는 θ 에 의해 결정된 $p(y|x; \theta)$ 들의 모습.

1. Amini, Alexander, et al. "Deep evidential regression." Advances in Neural Information Processing Systems 33 (2020): 14927-14937.

Methods – Natural Posterior Network

▪ Key Contribution

- 특정 task(e.g., classification, regression, ...)에 국한되었던 기존 방법론들을 통합 / 일반화.
- 학습 시 OOD sample이 필요하지 않도록 모델링.

Methods – Natural Posterior Network

▪ Exponential Families

- 아래 수식을 만족하는 분포들을 exponential family라고 일컫는다.
 - Likelihood $p(y; \boldsymbol{\theta}) = h(y) \exp(\boldsymbol{\theta}^T u(y) - A(\boldsymbol{\theta}))$
 - Conjugate prior $Q(\boldsymbol{\theta}; \boldsymbol{\alpha} = (\boldsymbol{\chi}, n)) = \eta(\boldsymbol{\chi}, n) \exp(n\boldsymbol{\theta}^T \boldsymbol{\chi} - nA(\boldsymbol{\theta}))$
 - $\boldsymbol{\chi}$: *Prior parameters*
 - n : *Evidence*
- Bayesian update에 의해, $Q(\boldsymbol{\theta}; \boldsymbol{\alpha})$ 는 다음과 같이 update 된다.
 - $Q^{\text{post}}(\boldsymbol{\theta}; \boldsymbol{\chi}^{\text{post}}, n^{\text{post}}) \propto \prod_{i=1}^N p(y_i; \boldsymbol{\theta}) \times p(\boldsymbol{\theta}; \boldsymbol{\chi}^{\text{prior}}, n^{\text{prior}})$
$$\propto \exp(n^{\text{post}} \boldsymbol{\theta}^T \boldsymbol{\chi}^{\text{post}} - n^{\text{post}} A(\boldsymbol{\theta}))$$
 - $\boldsymbol{\chi}^{\text{post}} = \frac{n^{\text{prior}} \boldsymbol{\chi}^{\text{prior}} + \sum_{i=1}^N u(y_i)}{n^{\text{prior}} + N}, n^{\text{post}} = n^{\text{prior}} + N$
- (Cat, Dir), $(\mathcal{N}, (\mathcal{N}, \text{InvGamma}))$ 은 위 수식을 모두 만족한다 (**Contribution 1**).

Methods – Natural Posterior Network

▪ Input-Dependent Bayesian Update

- $\chi^{\text{post}}(x) = \frac{n^{\text{prior}}\chi^{\text{prior}} + n(x)\chi(x)}{n^{\text{prior}} + n(x)}$, $n^{\text{post}}(x) = n^{\text{prior}} + n(x)$
- n^{prior} 와 χ^{prior} 는 고정된 값으로, 모든 x 가 공유하는 값.
- 두 개의 모델을 통해 각각 $\chi(x)$ 와 $n(x)$ 를 출력하도록 학습.
- **Encoder:** $z = f_{\phi}(x), f_{\phi}: \mathbb{R}^D \rightarrow \mathbb{R}^H$ ($H < D$)
- **Linear decoder for χ :** $\chi(x) = g_{\psi}(z)$
- **Normalized density estimator for n :** $n(x) = N_H p(z|w)$ (N_H : hyperparameter.)
 - 데이터가 많이 관측되는 area에 대해 높은 density를 주도록 학습 (일종의 pseudo-count).
 - Out-of-distribution에선 자연스레 낮은 density를 주게 된다 (**Contribution 2**).
 - 해당 논문에선 Normalizing flow¹를 활용.

1. Papamakarios, George, et al. "Normalizing flows for probabilistic modeling and inference." The Journal of Machine Learning Research 22.1 (2021): 2617-2680.

Methods – Natural Posterior Network

Input-Dependent Bayesian Update




Fig 6. Natural Posterior Network의 overview. OOD인 $x^{(3)}$ 에 대해 낮은 density가 계산되고, 따라서 높은 uncertainty를 출력할 수 있다.

Methods – Natural Posterior Network

■ Optimization

- 아래 수식(a.k.a. Bayesian loss function)을 최적화함으로써 모델 학습.
 - $\mathcal{L}(x, y) = -\mathbb{E}_{\boldsymbol{\theta} \sim Q^{\text{post}}(\cdot | x)} [\log p(y | x; \boldsymbol{\theta})] - \mathbb{H}[Q^{\text{post}}(\cdot | x)]$
 - $\mathbb{H}[Q^{\text{post}}(\cdot | x)]$: Entropy of $Q^{\text{post}}(\cdot | x)$
- 수식적으로 다음과 같이 간단하게 표현 가능.
 - $\mathcal{L}(x, y) \propto \mathbb{E}_{\boldsymbol{\theta} \sim Q^{\text{post}}(\cdot | x)} [\boldsymbol{\theta}]^T u(y) - \mathbb{E}_{\boldsymbol{\theta} \sim Q^{\text{post}}(\cdot | x)} [A(\boldsymbol{\theta})] - \lambda \mathbb{H}[Q^{\text{post}}(\cdot | x)]$
 - 위 값들 모두 analytic form으로 계산된다.
- 하나의 loss function으로 encoder, linear decoder, 그리고 normalized density estimator를 동시에 학습.

Experiments

▪ Questions

- Baseline과 비교하여 비슷하거나 더 높은 예측 정확도를 보이는가?
- Baseline에 비해 더 나은 uncertainty estimation을 보여주는가?
 - Calibration error
 - Estimated uncertainty를 활용한 OOD detection (AUROC)

▪ Benchmark

- Classification: CIFAR-10
- Regression: UCI dataset

Experiments

Results

Tab 1. Classification 성능표.

	Accuracy	Calibration	SVHN Alea.	SVHN Epist.	CelebA Alea.	CelebA Epist.	OODom Alea.	OODom Epist.
Dropout	88.15 ± 0.20	19.59 ± 0.41	80.63 ± 1.59	73.09 ± 1.51	71.84 ± 4.28	71.04 ± 3.92	18.42 ± 1.11	49.69 ± 9.10
Ensemble	* 89.95 ± 0.11	17.33 ± 0.17	85.26 ± 0.84	82.51 ± 0.63	76.20 ± 0.87	74.23 ± 0.78	25.30 ± 4.02	89.21 ± 7.55
EnD ²	84.03 ± 0.25	40.84 ± 0.36	* 86.47 ± 0.66	81.84 ± 0.92	75.54 ± 1.79	75.94 ± 1.82	42.19 ± 8.77	15.79 ± 0.27
PostNet	87.95 ± 0.20	20.19 ± 0.40	82.35 ± 0.68	79.24 ± 1.49	72.96 ± 2.33	75.84 ± 1.61	85.89 ± 4.10	92.30 ± 2.18
NatPN	87.90 ± 0.16	19.99 ± 0.46	82.29 ± 1.11	77.83 ± 1.22	76.01 ± 1.18	76.87 ± 3.38	* 93.67 ± 3.03	94.90 ± 3.09

← OOD detection performances →

Tab 2. Regression 성능표.

	RMSE	Calibration	Energy Alea.	Energy Epist.	Concrete Alea.	Concrete Epist.
Dropout	0.09 ± 0.00	3.13 ± 0.43	90.18 ± 6.00	99.94 ± 0.06	* 100.00 ± 0.00	* 100.00 ± 0.00
Ensemble	* 0.07 ± 0.00	2.69 ± 0.49	* 100.00 ± 0.00	* 100.00 ± 0.00	* 100.00 ± 0.00	* 100.00 ± 0.00
EvReg	0.09 ± 0.00	3.74 ± 0.53	88.06 ± 11.94	88.06 ± 11.94	* 100.00 ± 0.00	86.84 ± 13.16
NatPN	0.08 ± 0.00	* 2.04 ± 0.45	* 100.00 ± 0.00	* 100.00 ± 0.00	* 100.00 ± 0.00	* 100.00 ± 0.00

← OOD detection performances →

Experiments

- Results

Tab 3. Inference 속도 비교.

	CIFAR-10 (batch size 4,096)
Dropout	407.91 ± 5.65
Ensemble	361.61 ± 5.41
R-PriorNet	61.83 ± 2.57
EnD ²	61.83 ± 2.57
PostNet	88.56 ± 0.06
EvReg	—
NatPN	75.64 ± 0.04
NatPE	370.17 ± 0.09

Conclusion

- 기존 방법론들을 통합하면서, 동시에 **Evidential Deep Learning**의 한계점을 극복.
 - Exponential family라는 특성을 활용하여 특정 task에 국한되었던 기존 방법론들을 통합.
 - Posterior update 방식을 활용하여 학습 시 OOD sample이 필요하지 않도록 모델링.
 - 해당 모델이 OOD 데이터에 대해 높은 uncertainty를 출력한다는 것을 이론적으로 보장함.
(Theoretically guaranteed, under the mild assumptions.)

End of Document