


OVSeg

Open-Vocabulary Semantic Segmentation with Mask-adapted CLIP, CVPR 2023


김태수, 강인하, 최승준, 장보아, 안가영



INDEX

OVSeg : Open-Vocabulary Semantic Segmentation with Mask-adapted CLIP

- 01 Introduction
- 02 Related Work
- 03 Method
- 04 Experiments
- 05 Summary & Conclusion



Chapter 01.

Introduction



Where is Saturn V, blossom?



Where is Oculus, Ukulele?



Where is Golden gate, yacht?

- Semantic Segmentation : Semantic 카테고리에 따라 의미 있는 영역으로 픽셀을 그룹화하는 것이 목표인 Task
- 현대의 Semantic segmentation 모델은 사전 정의된 범주에 기반해 주로 학습되기 때문에 미지의 클래스에 대해서는 일반화가 어렵다는 한계를 지님
- 인간은 보통 수천 개의 범주를 가진 개방형 어휘(open-vocabulary) 방식으로 장면을 이해
- 인간 수준의 인식을 추구하기 위해, 텍스트로 설명되는 임의의 범주로 이미지를 세분화하는 open-vocabulary semantic segmentation 을 연구

2-Stage 접근 방식의 두 가지 가정

- 1) The model can generate class-agnostic mask proposals
- 2) Pre-trained CLIP can transfer its classification performance to masked image proposals

위의 두가지 가정 검증

1) “oracle” Mask generator와 Ordinary CLIP classifier를 적용

- Ground truth 마스크를 영역 proposal로 사용하고 사전 학습된 CLIP에 마스킹 된 이미지를 입력하여 분류 수행
- 이 모델의 성능은 ADE20K-150 데이터셋에서 **20.1%의 mIoU**에만 도달

2) 일반적인 마스크 proposal generator(MaskFormer) 와 “oracle” classifier를 적용

- 마스킹 된 영역 proposal을 추출한 다음 각 영역을 실제 객체 마스크와 비교하여 가장 많이 겹치는 객체를 찾아 추출된 영역에 객체 레이블 할당
- 불완전한 영역 proposal에도 불구하고 이 모델은 **66.5%라는 상당히 높은 mIoU**에 도달

두가지 가정의 검증 결과로 CLIP이 2-Stage open-vocabulary segmentation 모델의 성능 병목 현상임을 분명히 보여주었음

- CLIP은 최소한의 data augmentation으로 Natural 이미지에 대해 사전 학습된 반면에 마스크 proposal은 원본 이미지에서 자르고 크기를 조정한 후, 노이즈가 섞여 있는 분할 마스크로 추가 변형되기 때문





Figure 1. (a) CLIP is pre-trained with natural images with little data augmentation. (b) Two-stage open-vocabulary semantic segmentation approaches first generate class-agnostic mask proposals and then leverage pre-trained CLIP to do open-vocabulary classification. The input of the CLIP model is cropped masked images, which have huge domain gap from the natural images. (c) Our analysis reveals that pre-trained CLIP does not work well on masked images.




Chapter 02.


Related Work

Related Work | Pre-trained vision-language models

OpenAI
CLIP



[RegionCLIP]



- OVSeg는 CLIP을 Region Proposal에 맞게 미세 조정하여 객체 탐지를 수행하는 RegionCLIP과 유사

- RegionCLIP과의 차이점

(1) OVSeg는 CLIP을 마스크화 된 이미지를 처리하도록 적응시키는 반면, RegionCLIP은 complete region crops 처리

(2) OVSeg는 마스크화 된 이미지의 빈 영역을 활용하고 Mask prompt tuning을 제안하여 CLIP의 가중치를 변경하지 않고 적응시킴

→ 이는 다중 작업 시나리오에서 CLIP의 가중치를 공유할 수 있게 하며 이는 RegionCLIP에서는 지원되지 않는 기능임




Fig. 1. Overview of our two-stage open-vocabulary semantic segmentation framework. We reformulate and break down the open-vocabulary semantic segmentation into two steps: 1) training a mask proposal generator to generate a set of binary masks; 2) leveraging the pre-trained CLIP to classify each mask proposal.




Figure 2. The pipeline of our proposed ZegFormer for zero-shot semantic segmentation. We first feed N queries and feature maps to a transformer decoder to generate N segment embeddings. We then feed each segment embedding to a mask projection layer and a semantic projection layer to obtain a mask embedding and a semantic embedding. Mask embedding is multiplied with the output of pixel decoder to generate a class-agnostic binary mask, while the semantic embedding is classified by the text embeddings. The text embeddings are generated by putting the class names into a prompt template and then feeding them to a text encoder of a vision-language model. During training, only the seen classes are used to train the segment-level classification head. During inference, both the text embeddings of *seen* and *unseen* classes are used for segment-level classification. We can obtain two segment-level classification scores with semantic segment embeddings and image embeddings. Finally, we fuse these two classification scores as our final class prediction of segments.

- Open-vocabulary segmentation은 텍스트로 설명된 임의의 범주를 이해하는 작업을 목표함
- ZS3Net은 보지 못한 클래스의 단어 임베딩을 통해 픽셀 수준의 특성을 생성하는 생성 모델을 사용
- SPNet은 word2vec와 같은 단어 임베딩을 활용하여 시각적 특성과 의미적 의미를 정렬
- GroupViT은 Text supervision을 통해 Segmentation Mask를 직접 그룹화함
- 최근 연구들은 사전 훈련된 CLIP을 Open-vocabulary segmentation 를 위해 활용할 것을 제안
- ZSSeg 및 ZegFormer(2-Stage Approach) : 먼저 클래스에 구매 받지 않는 마스크 제안을 생성한 다음, 사전 훈련된 CLIP을 활용해 Open vocabulary classification 수행
- 하지만, OVSeg는 마스크화 된 이미지 분류를 위해 기존 CLIP을 직접 사용하는 것이 아니라 성능을 개선하도록 CLIP을 적응시킴

Related Work | Prompt tuning

	Prompt	Accuracy
	a [CLASS].	82.68
	a photo of a [CLASS].	80.81
	a photo of a [CLASS].	86.29
	$[V]_1 [V]_2 \dots [V]_M [CLASS]$.	91.83
(a)		
	Prompt	Accuracy
	a photo of a [CLASS].	60.86
	a flower photo of a [CLASS].	65.81
	a photo of a [CLASS], a type of flower.	66.14
	$[V]_1 [V]_2 \dots [V]_M [CLASS]$.	94.51
(b)		
	Prompt	Accuracy
	a photo of a [CLASS].	39.83
	a photo of a [CLASS] texture.	40.25
	[CLASS] texture.	42.32
	$[V]_1 [V]_2 \dots [V]_M [CLASS]$.	63.58
(c)		
	Prompt	Accuracy
	a photo of a [CLASS].	24.17
	a satellite photo of [CLASS].	37.46
	a centered satellite photo of [CLASS].	37.56
	$[V]_1 [V]_2 \dots [V]_M [CLASS]$.	83.53
(d)		

Fig. 1 Prompt engineering vs Context Optimization (CoOp). The former needs to use a held-out validation set for words tuning, which is inefficient; the latter automates the process and requires only a few labeled images for learning.

[CoOp]




Fig. 2 Overview of Context Optimization (CoOp). The main idea is to model a prompt's context using a set of learnable vectors, which can be optimized through minimizing the classification loss. Two designs are proposed: one is unified context, which shares the same context vectors with all classes; and the other is class-specific context, which learns for each class a specific set of context vectors.

- Prompt tuning은 대규모 Pretrained된 모델을 새로운 작업에 적응시키는 전략
- 자연어 처리에서 시작되었고, 최근에는 컴퓨터 비전으로 확장됨
- CoOp 는 카테고리 단어 앞에 학습 가능한 벡터를 추가하여 CLIP을 여러 인식 작업에 적응시킴
- Text Prompt tuning 은 Open vocabulary Object Detection / Semantic Segmentation 에서도 널리 사용되고 있음
- OVSeg의 Mask Prompt tuning은 이미지 도메인에 학습 가능한 벡터를 적용하는 시각적 도메인의 Prompt tuning과 더 관련이 있음
- Visual Prompt tuning 이 실제 이미지 토큰 앞에 추가 토큰을 삽입하는 것과 달리, OVSeg는 마스크화 된 토큰을 학습 가능한 Prompt 로 대체
- 또한, Mask Prompt tuning은 fully finetuning 후에도 추가적인 성능 향상을 가져오는데 이러한 추가 성능 향상은 이전 연구에서 보고된 바 없음

Chapter 03.

Method

Method | Two-stage models for open-vocabulary semantic segmentation(1)




Figure 2. Two-stage approaches consist of one segmentation model, e.g., MaskFormer, and one CLIP model. Firstly, the modified MaskFormer is trained with CLIP's text embeddings so as to perform open-vocabulary segmentation. (Section 3.1). We then use the pre-trained segmentation model to generate class-agnostic proposals and align proposals with extracted nouns from corresponding captions (Section 3.2). After collecting diverse mask-category pairs, we finetune CLIP with the proposed mask prompt tuning (Section 3.3).

- 마스크 proposal을 생성하는 Segmentation 모델과 open-vocabulary classification 모델로 구성
- pixel 별로 class를 예측하는 segmentation model과는 달리 MaskFormer 모델은 N개의 mask proposal과 대응되는 class prediction을 갖음
- 각 proposal은 대상 객체의 위치를 나타내는 H×W 이진 마스크로 표시되고 Class prediction은 N개의 C dimensional Class embedding로 이루어져 있음. ($v_1 \sim v_N$) (C는 학습 데이터셋의 클래스 개수)
- 기존의 MaskFormer를 수정해서 CLIP에 적용할 수 있도록 C-dimensional proposal embedding을 생성하도록 만들
→ 이 변경을 통해 MaskFormer는 open-vocabulary segmentation을 수행할 수 있게 됨

Method | Two-stage models for open-vocabulary semantic segmentation(2)




Table 4. The effects of class prediction ensemble. The baseline and our OVSeg model are Swin-Base + Vit-L. We report the mIoU on A-150.

	MaskFormer only	CLIP only	Ensemble
baseline	19.6	14.3	21.8
OVSeg (Ours)	19.6	25.1	29.6

- 구체적으로 마스크를 K개의 카테고리 분류하고 싶다고 가정하면 먼저 CLIP 모델의 텍스트 인코더를 사용하여 각 클래스에 대한 K개의 텍스트 임베딩을 $\{t_k | t_k \in R^C\}_{k=1, \dots, K}$ 로 생성(위의 그림에서는 apple, orange, teapot 3개이며 각각 C 차원을 가지는 Text embedding을 생성)
→ no object 에 대한 category를 넣기 위해 learning embedding($\emptyset$)을 추가함
- 다음으로 각 마스크 임베딩 v_i 를 텍스트 임베딩과 비교하고 클래스 k의 확률을 $p_{i,k} = \frac{\exp(\sigma(v_i, t_k)/\tau)}{\sum_k \exp(\sigma(v_i, t_k)/\tau)}$ softmax 로 예측 (여기서 $\sigma(\cdot, \cdot)$ 는 두 임베딩 벡터 간의 코사인 유사도를 나타내며, τ 는 온도 계수)
- Modified MaskFormer를 COCO-stuff dataset 171개의 class에 대해 학습함
- MaskFormer Prediction 외에도 CLIP을 사용하여 parallel prediction branch를 추가함
- MaskFormer는 마스크 proposal $\{M_i | M_i \in \{0, 1\}^{H \times W}\}_{i=1, \dots, N}$ 을 생성하는데 여기서 1과 0은 전경과 배경을 나타내며 각 마스크에 대해 모든 전경 픽셀을 포함하는 bounding box를 선택하고, 이미지를 자르고, 배경을 마스크 처리하고, CLIP 해상도에 맞게 resize 하여 Mask proposal- i 를 CLIP에 공급
- 클래스 k의 확률을 $\hat{p}_{i,k}$ 로 계산 후 두 가지 prediction을 모두 앙상블하여 최종 Prediction을 $p_{i,k}^{(1-\lambda)} \cdot \hat{p}_{i,k}^\lambda$, where $\lambda \in [0, 1]$ 로 계산
- Table4에서 보면, 앙상블 결과가 성능이 훨씬 좋은 모습을 보임

Method | Collecting diverse mask-category pairs from captions




Figure 3. For the given image-caption pair, only "apple" and "orange" are categories in COCO. By extracting nouns from captions, we can also get a novel "teapot" category.

- CLIP이 Masked image를 더 잘 처리할 수 있도록 하기 위해, masked image-text pair 로 구성된 데이터셋에서 CLIP을 fine-tuning하는 방법을 제안
- 첫번째 시도로 COCO-Stuff 와 같이 segmentation dataset의 라벨을 사용하는 것이었는데, 이경우 CLIP의 generalization(class에 없는 경우 classification이 잘 안됨)이 떨어짐
- 제한된 text 단어 때문에, finetune CLIP이 171개의 class에 overfitting 되어서 unseen category에 대한 generalization 성능을 잃는다고 가정함
- Segmentation dataset Label과 비교하여 Image Caption에는 이미지에 대한 훨씬 더 풍부한 정보가 포함되어 있으며 훨씬 더 많은 vocabulary가 포함

- 그림과 같이 이미지가 주어지면 먼저 사전 학습된 MaskFormer를 사용하여 Masked proposal을 추출하며, 해당 이미지 캡션에서 off-the-shelf language parser를 사용하여 모든 명사를 추출하고 이를 잠재적 클래스로 처리한 뒤 CLIP을 사용하여 가장 일치하는 mask-class pair를 구함
- COCO-Captions에서 이미지당 5개의 캡션을 사용하여 2.7만 개의 고유 명사를 포함하는 130만 개의 마스크-카테고리 쌍을 수집하거나, 이미지당 1개의 캡션을 사용하여 1.2만 개의 명사를 포함하는 44만 개의 쌍을 수집
- 실험에 따르면 다양한 mask-category 데이터셋이 수동 segmentation label보다 훨씬 더 나은 성능을 제공하는 것으로 나타남

Method | Mask prompt tuning




Figure 4. The proposed mask prompt tuning can adapt CLIP to masked images without changing its weights. We replace the zero tokens from masked patches with learnable mask prompts.


1. CLIP에 입력 시 마스킹 된 이미지는 텐서 $T \in \mathbb{R}^{N_p \times E}$ 로 토큰화 (N_p 는 패치 수 이고 E 는 토큰 차원)
2. 마스킹 된 이미지에는 압축된 이진 마스크 $M_p \in \{0,1\}^{N_p}$ 함께 제공 (M_p 는 주어진 패치가 유지되는지 또는 마스크 해제되는지 여부)
3. 패치의 모든 픽셀이 완전히 마스킹 된 경우에만 패치가 마스킹 된 토큰으로 처리 (Region classification 할 때 boundary pixel이 중요함 - 주로 masked된 부분)
4. 프롬프트 토큰을 나타내는 학습 가능한 텐서를 $P \in \mathbb{R}^{N_p \times E}$ 로 할당
5. 마지막으로 Transformer에 대한 최종 입력은 $T \otimes M_p + P \otimes (1 - M_p)$ 로 계산

※ $\otimes$: element-wise 곱셈

- Masked image와 Natural 이미지의 가장 큰 차이점은 masked image의 배경 픽셀이 0으로 설정되어 “빈 영역”이 많이 발생한다는 것
- Mask 된 부분은 0으로 token화 되더라도 zero token으로 쓸모없는 값이며, 학습 중에 domain distribution shift가 모델에 일어나서 성능이 떨어짐
- 이를 완화하기 위해 Mask prompt tuning 이라는 기술을 제안(“Visual Prompt tuning” 과 유사)
- Visual prompt tuning의 “deep prompt”를 따라 transformer의 더 깊은 레이어에 이러한 프롬프트 토큰을 추가할 수 있음
- Fully fine-tuning 대비 Mask prompt tuning의 장점
 - 1) 입력 이미지의 일부가 마스킹 되는 segmentation task를 위해 특별히 설계됨
 - 2) 마스크 프롬프트 튜닝의 학습 가능한 파라미터의 양이 훨씬 작아서 학습 효율성이 훨씬 향상됨
 - 3) Foundational model CLIP은 여러 task에 동시에 사용될 수 있으며 CLIP의 가중치를 튜닝하는 것이 허용되지 않을 수도 있는데
Mask prompt tuning에는 CLIP의 가중치 변경이 필요하지 않으므로 이러한 multi-task 시나리오에 적합
 - 4) Mask prompt tuning만으로 상당한 개선이 가능하며 전체 모델 fine-tuning과 함께 적용하면 open-vocabulary segmentation 성능 향상 가능



Q&A



Chapter 04.

Experiments

Experiments | Experimental setup

Training Dataset

- 먼저 COCO-Stuff의 Segmentation Label을 사용하여 수정된 MaskFormer를 Training 시킴
- 그 다음, COCO Captions에서 얻은 마스크-카테고리 데이터셋을 사용하여 CLIP을 fine-tuning
- 데이터셋에는 171개의 유효한 카테고리 주석이 달린 118K개의 훈련 이미지가 포함(별도로 명시되지 않은 경우, Training 중에 모든 171개의 카테고리 사용)

Evaluation Dataset

- 데이터셋에 적응 없이 임의의 데이터셋에서 Zero shot 수행
- 다음 3개의 데이터셋에서 모델 테스트
- ADE20K의 자주 사용되는 150개의 카테고리(A-150)와 다양한 847개의 카테고리(A-847)로 구성된 두 가지 버전을 선택했음
- Pascal VOC의 20개 카테고리(PAS-20)를 포함하는 1.5K개의 검증 이미지에서 평가 진행
- Pascal Context의 자주 사용되는 59개의 카테고리(PC-59)와 전체 459개 카테고리(PC-459)로 구성된 2가지 버전을 선택했음

Implementation Details

[One segmentation model based on MaskFormer]

- backbone: Swin-Base (또는 ResNet-101c)
- backbone 가중치는 ImageNet-21K에서 사전 학습된 모델에서 초기화
- optimizer: AdamW / learning rate : 6×10^{-5} , poly scheduler
- weight decay: 0.01 / batch size: 32 / crop size: 640×640 / iter: 12만

[One mask-adapted CLIP Model]

- Mask Prompt Tuning(MPT), Full fine-tuning(FT), MPT + FT(3가지 방법)
- MPT : CLIP 모델을 초기화하고 학습 가능한 토큰을 무작위로 초기화
 - optimizer: AdamW / learning rate: 2×10^{-2} , cosine annealing scheduler
 - weight decay : 0, 입력 크기 = 224×224, epoch = 5, batch size = 256
- FT : 비슷한 학습 절차를 유지
 - learning rate: 5×10^{-6} / cosine annealing scheduler/ weight decay: 0.2
- MPT + FT
 - 완전히 fine-tuning된 모델로 CLIP을 초기화
 - 그 위에 마스크 프롬프트 튜닝 적용
 - 다른 모든 hyperparameter는 MPT에서만 동일
 - CLIP의 텍스트 인코더는 모든 실험에서 고정

Experiments | Main results on open vocabulary semantic segmentation

OVSeg achieves best performance among open vocabulary models

- 공통적으로 사용되는 ResNet-101 (R-101) 백본을 사용하여 다른 Open vocabulary 모델들과 비교를 수행
- 픽셀당 접근 방식(SPNet, ZS3Net, LSeg, LSeg+)과 비교할 때, Proposal-based 접근 방식(OpenSeg, SimBaseline, ZegFormer, OVSeg)은 더 나은 성능을 보여줌
- 특히, OVSeg R101c 모델은 A-847과 PC-459에서 각각 7.1%와 11.0% mIoU를 달성하며, EfficientNet-B7 기반 OpenSeg 모델보다 더 나은 성능을 보임

Table 1. The mIoU results of open-vocabulary generalist models and supervised specialist models. Results for SPNet and ZS3Net on PAS-20 are reported from [23]. Results for ZegFormer on PAS-20 are recalculated by us. SimBaseline [40], ZegFormer [11] and OpenSeg [16] are using the same COCO images, *i.e.*, the 2017 splits with 118K images, but with different annotations. COCO-Stuff-156/171 denotes using COCO Stuff mask annotations of 156/171 categories. Under the R101c model scale, our model significantly outperforms other open-vocabulary models. Our largest Swin-Base model can match the performance of some supervised specialist models in 2017.

method	backbone	training dataset	A-847	PC-459	A-150	PC-59	PAS-20
<i>Open-vocabulary generalist models</i>							
SPNet [37]	R-101	PASCAL-15	-	-	-	24.3	18.3
ZS3Net [4]	R-101	PASCAL-15	-	-	-	19.4	38.3
LSeg [23]	R-101	PASCAL-15	-	-	-	-	47.4
LSeg+ [16]	R-101	COCO Panoptic	2.5	5.2	13.0	36.0	59.0
SimBaseline [40]	R-101c	COCO-Stuff-156	-	-	15.3	-	74.5
ZegFormer [11]	R-50	COCO-Stuff-156	-	-	16.4	-	80.7
OpenSeg [16]	R-101	COCO Panoptic	4.0	6.5	15.3	36.9	60.0
OVSeg (Ours)	R-101c	COCO-Stuff-156	7.0	10.4	24.0	51.7	89.2
OVSeg (Ours)	R-101c	COCO-Stuff-171	7.1	11.0	24.8	53.3	92.6
LSeg+ [16]	Eff-B7	COCO Panoptic	3.8	7.8	18.0	46.5	-
OpenSeg [16]	Eff-B7	COCO Panoptic	6.3	9.0	21.1	42.1	-
OVSeg (Ours)	Swin-B	COCO-Stuff-171	9.0	12.4	29.6	55.7	94.5
<i>Supervised specialist models</i>							
FCN [29]	FCN-8s	Same as test	-	-	29.4	37.8	-
Deeplab [6]	R-101	Same as test	-	-	-	45.7	77.7
SelfTrain [45]	Eff-L2	Same as test	-	-	-	-	90.0
MaskFormer [9]	R-101c	Same as test	17.4	-	46.0	-	-

Largest OVSeg model sets up new SOTA results on zero-shot benchmarks

- Swin-Base 백본과 CLIP ViT-L/14를 사용하여 A-150과 Pascal PC-59에서 각각 29.6%와 55.5% mIoU를 달성했고 이는 OpenSeg 제로샷 결과보다 각각 +8.5%와 +13.6% 더 높은 결과
- A-847과 PC-459에서는 OVSeg가 9.0%와 12.4% mIoU로 최고의 제로샷 최고 성능을 보임

Open-vocabulary generalist models can match supervised specialist models in 2017

- Supervised specialist models와 비교하여 특정 데이터셋 훈련 없이도 충분히 경쟁력 있는 성능을 보임
- A-150에서 완전히 지도 학습된 FCN-8s와 유사한 성능을 달성했으며, PAS-20에서는 우리의 모델이 94.5% mIoU를 달성하여, SOTA 모델보다 +4.5% 더 높은 결과를 가짐

Experiments | Ablation study

Table 2. Ablation on mask-category pairs. The baseline is MaskFormer Swin-Base with original CLIP ViT-L/14. The masks come from ground-truth (GT) or generated proposals. The category nouns come from ground-truth (GT) classes or captions. We also calculate the statistics (number of pairs and unique nouns) of collected pairs.

Case	Source		Statistics		A-847	A-150	PC-59
	Mask	Category	Pairs	Unique nouns			
Baseline	-	-	-	-	7.3	21.8	51.4
(1)	GT	GT	965K	171	5.3 (-2.0)	23.0 (+1.2)	57.3 (+5.9)
(2)	GT	1 caption	440K	12K	7.9 (+0.6)	24.2 (+2.4)	53.2 (+1.8)
(3)	proposals	1 caption	440K	12K	8.8 (+1.5)	28.8 (+7.0)	55.7 (+4.3)
(4)	proposals	5 captions	1.3M	27K	8.8 (+1.5)	28.6 (+6.8)	55.5 (+4.1)

Collecting mask-category pairs

- Case1) A-847 데이터셋에서 -2.0%의 성능 저하가 관찰되었는데 이는 적응된 CLIP이 171개의 GT 클래스에 과적합 되었기 때문
- 또한, 모델은 COCO-Stuff와 많은 범주가 중복되는 PC-59에서 좋은 결과를 얻었지만, A-847의 더 다양한 개념에서는 성능이 저조했음
- 저자들은 캡션을 활용하여 다양한 마스크-카테고리 쌍을 수집할 것을 제안
- 캡션의 명사를 파싱한 후, 이 명사들을 GT 마스크(Case2) 또는 기본 모델에서 생성된 proposal(Case3)과 매칭
- GT 마스크를 proposal 로 대체함으로써, A-150에서 mIoU가 24.2%에서 28.8%로 크게 개선됨
- Case4) 이미지당 5개의 캡션을 모두 사용하면 A-150과 PC-59에서 -0.2% 성능 저하 발생
- 12K개의 명사가 CLIP의 Open vocabulary 능력을 유지하기에 충분하다고 가정
- 따라서 1개의 캡션만 사용하여 효율성을 높이는 방안을 선택했으며, 이는 5개의 캡션을 사용하는 것보다 훈련 속도가 5배 빠름

Table 3. Ablation on mask prompt tuning (MPT) and full model tuning. The baseline is MaskFormer Swin-Base with CLIP ViT-L/14. We report the zero-shot mIoU on representative ADE-847, ADE-150 and PC-59 datasets. All the improvements are measured upon the baseline model.

case	FT method		A-847	A-150	PC-59
	MPT	full			
Baseline			7.3	21.8	51.4
(a)	✓		8.4 (+1.1)	26.5 (+4.7)	55.4 (+4.0)
(b)		✓	8.8 (+1.5)	28.8 (+7.0)	55.7 (+4.3)
(c)	✓	✓	9.0 (+1.7)	29.6 (+7.8)	55.7 (+4.3)

Mask prompt tuning

- Case a) Mask Prompt tuning
baseline model 대비 ADE-150과 PC-59에서 각각 +4.7% 및 +4.0%의 mIoU 개선
- Case b) Full model fine-tuning
비록 최상의 정확도를 달성했지만, 학습 가능한 매개변수는 훨씬 더 많음
- Case c) Mask Prompt tuning + Full model fine-tuning
제안된 마스크 프롬프트 튜닝은 입력만 수정하며 CLIP의 가중치를 변경하지 않으며, ADE-150에서 29.6% mIoU를 달성하여 Case b보다 +0.8%의 상당한 향상을 이룸



Query: saturn V, blossom

Query: Oculus, Ukulele

Query: golden gate, yacht

Figure 5. Open-vocabulary segmentation with user-defined queries. Our model accurately segments unseen categories, such as the Saturn V rocket, Oculus headset, and Golden Gate bridge.



GT: building Pred: skyscraper

GT: rail Pred: road

Figure 6. Ambiguity of the class definition in open vocabulary segmentation evaluation.

Segmentation with user-defined queries

- OVSeg는 사용자가 임의의 쿼리를 정의하고 이미지에서 해당 쿼리를 검색할 수 있도록 함
- 특정 개념을 학습하도록 모델을 훈련하지 않고도, 해당 이미지에서 Saturn V를 레고 로켓으로, Oculus를 VR 헤드셋으로, Golden Gate를 다리로 식별하고 분할할 수 있음
- 이는 Open vocabulary Semantic segmentation의 강력한 잠재력을 보여줌

Ambiguity of open vocabulary evaluation

- 왼쪽 그림에서는 실제 카테고리가 "건물(building)"인 반면, 모델은 "고층 건물(skyscrapers)"로 예측했음
- "고층 건물"은 합리적인 설명이지만, 표준 A-150 평가 프로토콜에서는 이를 잘 못된 예측으로 간주
- 오른쪽 그림에서도 실제 "레일(rail)"이 "도로(road)"로 인식
- 이는 언어로 정의된 카테고리가 모호하고 서로 겹칠 수 있기 때문
- Open vocabulary segmentation 모델에 대한 더 나은 평가 기준을 설계하는 것은 우리의 미래 연구에서 중요한 주제



Chapter 05.

Summary & Conclusion


Summary & Conclusion

Summary

- ✓ 본 논문은 텍스트로 설명된 임의의 카테고리에 따라 이미지를 세분화하는 Open vocabulary segmentation에 대해 연구 진행
- ✓ 현재의 2-stage 방법의 성능 병목이 사전 훈련된 CLIP에 있다는 것을 확인했는데, 이는 Masked 이미지에서 잘 작동하지 않기 때문
- ✓ 이를 해결하기 위해, 3가지 방법론 제시
 - 1) 마스크 proposal을 생성하는 분할 모델과 open-vocabulary 분류 모델로 구성하고 Masked image를 위해 CLIP을 적응시키는 방법을 제안
 - 2) CLIP의 Open vocabulary 분류 능력을 유지하기 위해, Image-caption 데이터셋에서 다양한 Mask-category 쌍을 추출하여 CLIP을 적응시킴
 - 3) CLIP의 원래 가중치를 변경하지 않고도 CLIP을 적응시킬 수 있는 Mask prompt tuning을 제안

Conclusion

1. OVSeg 모델은 일반적이며, 특정 데이터셋에 대한 적응 없이 임의의 데이터셋에서 zero-shot Segmentation을 수행할 수 있음
2. 처음으로 Open vocabulary 일반 모델이 지도 학습된 전문 모델과 성능을 맞출 수 있음을 보여주었음
3. Open vocabulary segmentation 모델에 대한 더 나은 평가 기준을 설계하는 것은 미래 연구에서 중요한 주제

The background of the slide is a deep space image featuring a bright, colorful nebula or galaxy core in the upper right, with various other celestial structures and stars scattered across the field. The colors range from soft pinks and purples to bright blues and whites.

Thank You