



Parallel Scaling Law for Language Models

Mouxiong Chen, Binyuan Hui, Zeyu Cui, Jiaxi Yang, Dayiheng Liu, Jianling Sun, Junyang Lin, Zhongxin Liu

Zhejiang University, Qwen Team, Alibaba Group

2025.08.03


자연어처리팀 - 이예서(발표자), 정현석, 박민건, 황예진, 박주혜, 김보성, 임다예슬, 김유진, 이웅기, 김기환, 조해창

Contents


- **Introduction**
- **Background and Methodology**
- **Parallel Scaling Law**
- **Scaling Training Data**
- **Discussion and Future Work**
- **Conclusion**

Introduction

- **문제 제기:** 기존 성능 확장 방식인 파라미터 스케일링과 추론 시간 스케일링은 각각 막대한 메모리 및 지연 시간 비용 발생
- **제3의 패러다임 제안:** 병렬 스케일링(PARSCALE)
- **핵심 아이디어:** 모델 파라미터를 재사용하여 병렬 연산을 확장
 - 입력에 P개의 학습 가능한 변환 적용 → 단일 모델에서 P번 병렬 처리 → 결과 동적 집계
- **주요 발견 (병렬 스케일링 법칙):**
 - P개의 병렬 스트림 ≈ 파라미터 수 $O(\log P)$ 배
 - 동일 성능 목표 달성 시 파라미터 확장 대비 메모리 증가 최대 22배, 지연 시간 증가 최대 6배 적음



(1) Illustration of Three Scaling Approaches



Introduction

- 기존 스케일링의 한계:
 - 파라미터 스케일링: 막대한 메모리 비용, 엣지 디바이스 배포 거의 불가능.
 - 추론 시간 스케일링: 높은 지연 시간, 특정 시나리오에 국한, 'overthinking' 문제.
- PARSCALE의 주요 발견:
 - 새로운 스케일링 법칙: 병렬 연산(P)과 파라미터(N)의 정량적 관계($O(\log P)$) 규명
 - 추론 집약적 작업 강점: 코딩, 수학 등에서 효과가 더 커 '연산'이 '추론 능력'과 관련 깊음을 시사
 - 2단계 학습 전략: 전체 데이터의 2%만으로 PARSCALE을 적용해 학습 비용 해결
 - 동적 병렬 스케일링: 추론 시나리오에 따라 P 값을 동적으로 조절 가능

Background and Methodology

- 핵심 가설:


- 영감: CFG(Classifier Free Guidance) 기법 → 성능 향상의 원인은 정교한 규칙보다 '2배의 연산량' 자체일 수 있다
- 가설: 파라미터를 거의 유지하며 병렬 연산을 확장하는 것은 파라미터 확장과 유사한 성능 향상 효과를 낳는다
- CFG의 고정된 규칙을 P개의 스트림을 사용하는 학습 가능하고 확장 가능한 프레임워크로 일반화

$$g_{\theta}(x) = f_{\theta}(x) + w (f_{\theta}(x) - f_{\theta}(x')). \quad (1)$$

$$g_{\theta}(x) = w_1 f_{\theta}(x_1) + w_2 f_{\theta}(x_2) + \cdots + w_P f_{\theta}(x_P), \quad (2)$$

Background and Methodology

- 구현 세부사항:
 - 입력 변환:
 - 목표: 각 병렬 스트림이 입력에 대해 서로 다른 "관점"을 갖도록 유도
 - 채택 방식: **접두사 튜닝(Prefix Tuning)**. 각 스트림에 고유한 접두사를 할당하여 다양한 출력 생성
 - 핵심: 특정 구현 방식보다 '병렬 연산' 원리 자체가 중요
 - 출력 집계:
 - 목표: P개의 출력을 동적으로 통합
 - 채택 방식: MLP 네트워크를 통해 각 스트림의 가중치를 동적으로 계산 후 가중 평균
 - 문제 해결: 학습 초기 '로드 불균형' 현상은 레이블 스무딩(label smoothing)으로 해결



(1) Illustration of Three Scaling Approaches

Parallel Scaling Law

Can PARSCALE Achieve Similar Effects as Parameter Scaling?

- Chinchilla 스케일링 법칙 확장
- 모델 성능은 병렬 스트림 수(P)와 스트림 간의 다양성(DIVERSITY)에 의해 결정

$$\mathcal{L}_i = \left(\frac{A}{N} \right)^\alpha + E, \quad 1 \leq i \leq P,$$

$$\mathcal{L} = \left(\frac{A}{N \cdot P^{1/\alpha} \cdot \text{DIVERSITY}} \right)^\alpha + E.$$



$$\text{DIVERSITY} = [(P - 1)\rho + 1]^{-1/\alpha},$$

Parallel Scaling Law

- **Practical Parallel Scaling Laws:**



- 대규모 실험 결과, P가 증가할수록 손실이 로그 형태로 감소
- **의미:** P개의 병렬 스트림 사용 $\approx$ 유효 파라미터 $(k \log P + 1)$ 배 증가 효과
- **k 값의 의미:** 병렬 연산의 이점 $\rightarrow$ 추론/코딩 데이터(Stack-V2)에서 일반 데이터(Pile)보다 k값이 높다
- **시사점:** 파라미터(N)는 기억력, 병렬 연산(P)은 추론 능력에 더 큰 영향

$$\mathcal{L} = \left(\frac{A}{N \cdot (k \log P + 1)} \right)^\alpha + E,$$



Parallel Scaling Law

- 더 큰 모델일수록 PARSCALE의 효과가 극대화
 - a. 작은 모델 (예: 0.7B): 등고선이 매우 가파름 (Y축(계산)을 조금만 올려도 성능이 크게 향상됨)
 - b. 큰 모델 (예: 4.4B): 등고선이 점점 완만해짐 (Y축을 올릴 때 성능 향상 폭이 훨씬 더 커진다는 것을 의미)
 - c. 같은 P 증가라도 더 큰 모델일 수록 훨씬 더 큰 성능 향상을 가져온다
- 데이터셋에 따른 효과 차이
 - a. Stack-V2-Python (추론): 등고선들이 Y축 방향으로 더 넓게 퍼져 있음 → 계산(P)을 늘리는 것이 성능 향상에 더 큰 기여
 - b. Pile (암기): 등고선들이 상대적으로 더 촘촘함 → 왼쪽 그래프만큼 극적이지는 않음



Parallel Scaling Law

- 표2 (**HumanEval(+)**, **MBPP(+)** 두 가지의 코드 생성 벤치마크 평균 성능)
 - 1.6B ($P=8$) 모델의 성능 (39.1)은 4.4B ($P=1$) 모델의 성능 (39.2)과 거의 동일
 - 추론 능력이 중요한 태스크에서 병렬 계산의 효과가 매우 강력하다
- 표3 (6가지 **lm-evaluation-harness** 일반 상식 태스크 평균 성능)
 - 1.6B ($P=8$) 모델의 성능 (55.7)을 보면, 이 점수는 2.8B ($P=1$) 모델의 성능 (55.2)과 비슷
 - 일반 상식이나 암기가 중요한 태스크에서는 병렬 계산의 효과가 추론 태스크만큼 크지는 않다

Table 2: Average performance (%) on two code generation tasks, HumanEval(+) and MBPP(+), after pre-training on the Stack-V2-Python dataset.


N	0.5B	0.7B	1.1B	1.6B	2.8B	4.4B
$P = 1$	26.7	28.4	31.6	33.9	36.9	39.2
$P = 2$	30.3	32.4	33.6	37.4	39.4	42.6
$P = 4$	30.1	32.5	34.1	37.6	40.7	42.6
$P = 8$	32.3	34.0	37.2	39.1	42.1	45.4

Table 3: Average performance (%) on six general lm-evaluation-harness tasks after pre-training on the Pile dataset.


N	0.5B	0.7B	1.1B	1.6B	2.8B	4.4B
$P = 1$	49.1	50.6	52.1	53.1	55.2	57.2
$P = 2$	49.9	51.0	52.4	54.4	57.0	58.5
$P = 4$	50.6	51.8	53.3	55.0	57.8	59.1
$P = 8$	50.7	51.8	54.2	55.7	58.1	59.6

Parallel Scaling Law


- 추론 비용 분석:
 - 메모리 효율성: 파라미터 재사용으로 메모리 증가 미미
 - 지연 시간 효율성: GPU 친화적 병렬 연산으로 지연 시간 증가 최소화
 - 결론: 동일 성능 달성 시, 파라미터 스케일링 대비 압도적으로 효율적




(a) batch size = 1




(b) batch size = 2




(c) batch size = 4




(d) batch size = 8




(e) batch size = 1



(f) batch size = 2



(g) batch size = 4



(h) batch size = 8

Scaling Training Data

- 대규모 데이터에서도 PARSCALE의 효과는 일관성을 보임

- P가 1에서 8로 증가함에 따라 모든 카테고리에서 성능이 꾸준히 향상

- 추론 시간 스케일링과의 시너지 효과:

GSM8K + CoT

- PARSCALE(P=8) 모델의 GSM8K 점수는 **38.4점**
 - CoT**을 추가로 적용시, 점수가 **43.7점**으로 상승
 - 배타적인 관계가 아닌, 시너지 효과를 낼 수 있음을 시사

	Tokens	Data	Average			General						
			General	Math	Code	MMLU	WinoGrande	Hellaswag	OBQA	PiQA	ARC	
gemma-3-1B	2T	Private	53.4	1.9	14.9	26.4	61.4	63.0	37.8	75.6	56.2	
Llama-3.2-1B	15T	Private	54.8	4.7	30.1	30.8	62.1	65.7	39.2	75.9	55.3	
Qwen2.5-1.5B	18T	Private	63.6	52.3	55.8	61.0	65.6	68.0	42.6	76.6	67.9	
SmolLM-1.7B	1T	Public	57.0	6.0	37.9	29.7	61.8	67.3	42.8	77.3	63.3	
SmolLM2-1.7B	12T	Public	63.3	24.3	41.6	50.1	68.2	73.1	42.6	78.3	67.3	
Baseline ($P = 1$)	1T	Public	56.0	25.5	45.6	28.5	61.9	65.0	40.6	75.2	64.8	
PARSCALE ($P = 2$)	1T	Public	56.2	27.1	47.4	29.0	62.4	64.7	42.0	74.9	64.3	
PARSCALE ($P = 4$)	1T	Public	57.2	30.0	48.6	30.0	63.4	65.9	42.0	75.6	66.3	
PARSCALE ($P = 8$)	1T	Public	58.6	32.8	49.9	35.1	64.9	67.0	42.6	76.1	66.0	

	Tokens	Data	Math			Code							
			GSM8K	GSM8K +CoT	Minerva Math	HumanEval		HumanEval+		MBPP		MBPP+	
						@1	@10	@1	@10	@1	@10	@1	@10
gemma-3-1B	2T	Private	1.8	2.3	1.5	6.7	15.9	6.1	14.6	13.0	29.1	10.8	23.0
Llama-3.2-1B	15T	Private	5.1	7.2	1.8	16.5	27.4	14.0	25.0	33.1	54.5	27.0	43.4
Qwen2.5-1.5B	18T	Private	61.7	67.2	28.1	36.0	62.8	31.1	55.5	61.9	79.6	50.8	68.5
SmolLM-1.7B	1T	Public	6.4	8.3	3.2	20.1	35.4	15.9	32.3	40.7	66.4	34.7	57.4
SmolLM2-1.7B	12T	Public	30.4	30.8	11.8	23.8	44.5	18.9	37.8	45.2	68.5	36.0	57.9
Baseline ($P = 1$)	1T	Public	28.7	35.9	12.0	26.8	44.5	20.7	38.4	51.6	75.9	43.9	62.7
PARSCALE ($P = 2$)	1T	Public	32.6	35.6	13.0	26.2	50.0	20.1	42.1	52.9	77.0	45.0	65.6
PARSCALE ($P = 4$)	1T	Public	34.7	40.8	14.5	27.4	47.6	23.8	43.9	55.3	77.0	47.1	66.7
PARSCALE ($P = 8$)	1T	Public	38.4	43.7	16.4	28.7	50.6	24.4	44.5	56.3	79.1	48.1	67.2

Scaling Training Data

Two-Stage Pretraining

- 2단계 사전 학습 전략:
 - 문제: 학습 시 연산량 P 배 증가로 인한 비용
 - 해결책:
 - 1단계: 대부분의 데이터로 표준 학습($P=1$)
 - 2단계: 소량의 데이터(2%)로 PARSCALE 학습($P>1$)
 - 결과: 매우 효과적. 적은 데이터로도 병렬 추론 능력을 빠르게 학습

	IFEval 0-shot	MMLU 5-shot	GSM8K 4-shot
SmolLM-1.7B-Inst	16.3	28.4	2.0
Baseline-Inst ($P = 1$)	54.1	34.2	50.3
PARSCALE-Inst ($P = 2$)	55.8	35.1	55.3
PARSCALE-Inst ($P = 4$)	58.4	38.2	54.8
PARSCALE-Inst ($P = 8$)	59.5	41.7	56.1

Table 5: Comparison of the performance of different Instruct models, where the few-shot examples are treated as a multi-turn conversation.





Figure 5: Loss for two-stage training, smoothing using an exponential moving average with a weight of 0.95.


Scaling Training Data

Applying to the Off-the-Shelf Pre-Trained Model


- 기존 상용 모델에 적용:
 - 지속적 사전 학습: 이미 잘 학습된 모델(Qwen-2.5)도 성능 향상
 - PEFT: 모델의 핵심 가중치를 고정한 채 PARSCALE 모듈만 미세 조정해도 효과적
 - 가능성: '동적 병렬 스케일링' 패러다임 제시. 하나의 백본 모델로 다양한 성능/비용 요구에 유연하게 대응



(a) Continual Pre-training



(b) Continual Pre-training



(c) Freezing the Model

Discussion and Future Work

- **추론 최적 모델:** 주어진 추론 예산 하에서 최적의 (N,P) 조합을 찾는 연구
- **이론적 심화:** $k\log P$ 관계의 근본 원인 및 성능 상한선 탐구
- **PARSCALE과 MoE 결합:** 메모리 효율적인 PARSCALE과 지연 시간 효율적인 MoE의 장점을 결합한 하이브리드 아키텍처 연구
- **타 도메인 확장:** 컴퓨터 비전, 음성 인식 등 다른 분야로의 적용

Conclusion

- **핵심 요약:** PARSCALE은 기존 파라미터를 재사용하여 병렬 연산을 확장하는 혁신적이고 효율적인 스케일링 패러다임
- **핵심 기여:** 병렬 스케일링 법칙(P 스트림 $\approx O(N \log P)$ 파라미터) 수립 및 검증
- **주요 특징:** 추론 집약적 작업에 강점, 뛰어난 추론 효율성, 2단계 학습 및 동적 스케일링을 통한 실용성 확보
- **미래 가치:** 저자원 및 엣지 디바이스 환경에서 고성능 AI를 구현할 핵심 기술로 부상할 잠재력