

Preference Amplification in Recommender System

Dimitris et al (Harvard, Facebook)

김창연, 김동희, 김지연, 송헌, 이근배, 이재운


목차

1. Introduction
2. Problem Setting
3. Evolution of User Preference
4. Simulations

Introduction

Introduction


- 추천 시스템의 구조
 - 추천을 제공 -> 그에 대한 유저의 피드백 -> 피드백을 통한 fine-tuning
 - Feedback loop -> 유저의 selection에 영향을 줌 -> may be negative experience for users



Introduction

- **Echo Chamber, Filter Bubble**

- 유저 피드백을 기반으로 추천을 하다보면,
 - 해당 유저가 좋아하는 아이템만을 계속 보여주게 됨.
 - 이를 통해 높은 예측도를 얻어 그 방향으로 다시 학습함.
 - 이러한 성향이 점차 **강화됨 (reinforce)**
- 다른 성향, 다른 카테고리의 아이템을 추천받지 못하고, 소비하지 못하는 상황도 발생함.
- 사회적 갈등을 유발하고 추천 품질을 떨어뜨리는 결과 초래.



Introduction

Contribution of this paper

1. Theoretical characterization of interactions btw users and reco system.
2. Evidence of
 1. the divergence of user preferences
 2. the existence of echo chambers in Matrix Factorization
3. Strategy that solve echo chamber in reco system.

Q&A

Problem Setting

Problem Setting

Notation

- 문제를 정의하고 증명하는 데에 있어서 **수학적인 지식이 필요.** (특히 선형대수)
- 수학적인 내용들은 최대한 배제하고, 직관적으로 설명하고자 함 (자세한 사항은 논문 참고)



Problem Setting


Assumption

- 추천할 아이템 갯수는 총 m 개
- At timestamp t ,
 - Reco system presents an item to user.
 - Receives feedback $y \in \{0,1\}$ (like, click, watch, etc...)

Problem Setting

Assumption

- 해당 논문에서는 여러가지 추천 모델 중, **Stochastic Matrix Factorization** 모델에 집중.
- User feedback matrix를 user latent feature matrix ($u \in U$), item latent feature matrix ($x \in X$)로 분해



Problem Setting

Assumption

- 해당 논문에서는 여러가지 추천 모델 중, **Stochastic Matrix Factorization** 모델에 집중.
- Item score $s_x = u^T x$ -> 유저 u 가 아이템 x 를 좋아할 확률 $p_x^t = \sigma(s_x^t)$ 을 예측함.
- **Item feature는 static, user feature는 dynamic 하다고 가정.**
 - Scores of item are **time-varying** -> $s_x^t = u_t^T x$

Problem Setting

Stochastic Recommendation

- **Stochastic Recommendation**

- Top-k Recommendation을 하기 위해서는,
- 각 item score를 prob으로 mapping하는 softmax function 이용. -> 이 값이 큰 K개의 아이템 추천함.

- $x \sim f_t \Rightarrow$ 아이템 x 가 선택될 확률: $f_t(x) = \frac{e^{\beta s_x^t}}{\sum_{x'} e^{\beta s_{x'}^t}}$

- **Sensitivity parameter β**

- $\beta \rightarrow \infty$: f_t exactly top-1 recommendation
- $\beta \rightarrow 0$: more uniform distribution. (All items have similar prob of being presented to users)

Problem Setting

Notation

Table 1: Notation Summary

Symbol	Meaning
m	number of items
$u_t \in \mathbb{R}^d$	inferred user feature vector at time t
$x \in \mathbb{R}^d$	item feature vector (static)
s_x^t	score of item x at time t : $s_x^t = u_t^\top x$
$p_x^t = \sigma(s_x^t)$	predicted probability that the user will like item x
$\pi_t(x)$	true probability that the user will like x at time t
f_t	softmax of item scores at time t
$f_t(x)$	probability of recommending x at time t
$\beta > 0$	system sensitivity, determines the “steepness” of f_t
$\gamma \in (0, 1)$	sensitivity parameter of the user
$\alpha_{t,x}$	rescaling coeff. for item x at time t (see Def. 1)

Q&A

Problem Setting

Stochastic Recommendation

- System Update -> **to learn user preference accurately (CTR, AUC, nDCG 등을 높이하고자 함)**
 - $u_{t+1} = u_t - \eta_t \cdot \mathbb{E}_{x \sim f_t} [\nabla_u \ell(u_t, (x, y))]$ (binary classification 식과 유사)
 - $\ell(x, y) = -y \ln \sigma(u^T x) - (1 - y) \ln(1 - \sigma(u^T x))$ (same as **NLL**)
 - 여기서 중요한 점
 - **Gradient of loss in expectation** $x \sim f_t$ (x is chosen depends on u_t) -> **gradient와 expectation의 순서를 바꿀 수 없음.**
 - Distribution of data dynamically adapting, depends on the parameters at each iteration.

Problem Setting

Fixed points

- 이상적인 추천 시스템이 되기 위해서는 어떻게 되어야 하는가? 업데이트가 더 필요하지 않아야 함.
- Natural solution for recommender system -> **Fixed Point**
 - $u^* = \arg \min_u \mathbb{E}_{x \sim f^*, y} [\ell(u, (x, y))]$ -> **equilibrium btw user and system.**
 - **There are 2 Fixed points with respect to their long term behavior.**
 1. **Stable:** u^* 주변에서 시작하면 모든 t 에 대해서 u^* 주변에서만 맴돈다.
 2. **Attracting:** u^* 주변에서 시작하면 u^* 로 converge.
 3. **Asymptotically stable:** stable + attracting
- 이러한 fixed point가 생기기 위해서는, user preference function (유저가 어떻게 행동하느냐?) 에 대한 추가적인 가정이 필요.

Problem Setting

Fixed Points, echo chambers and filter bubbles

- Notion of a fixed point $\perp$ idea of echo chamber and filter bubbles
 - Echo chamber: user constantly **reinforced** leading to polarization
 - Fixed point: no update on u^* , reinforcement does not occur.


Problem Setting

User Behavior

- Reco system에 대응하는, 유저의 행동 양식(유저가 어떻게 행동하느냐?)은 다음과 같이 가정할 수 있음.
- 유저의 행동은 preference function $\pi_t : \mathbb{R}^d \rightarrow [0,1]$ 로 표현 가능 (시간에 따라 추천 시스템의 영향으로 변화됨)
- 유저의 행동 양식은 2가지의 중요한 가정에 따라 변화됨.

1. 유저가 특정 아이템에 대해서 반응할 likelihood는 해당 아이템의 item score s_x^t 값에 영향을 받는다.

- 유저는 그들의 의견을 동조, 강화하는 방향으로 기울게 된다. (양수면 더욱 양수, 음수면 더욱 음수)
- 이러한 user behavior를 drift function 으로 모델링.
 - $r : \mathbb{R} \rightarrow [-1,1]$, means user's shift in the prob of liking an item with score s_x^t
 - $r(z) = K \cdot z \cdot e^{-z^2}, K \approx 2.33$



Problem Setting



User Behavior

2. 유저가 추천 모델에 의해 받을 수 있는 영향은 한계가 있다.

- Sensitivity γ 도입. (Bound of deviation)
 - true preference function $\pi_t : \mathbb{R}^d \rightarrow [0,1]$ (유저의 실제 반응을 함수화한 것)
 - recommender system's prediction $\sigma(s_x^t)$
 - 둘 사이의 deviation에 대한 bound를 설정.

Problem Setting

User Behavior



DEFINITION 1 (γ -SENSITIVE USER). A user is γ -sensitive with respect to a drift function r , for $\gamma \in (0, 1)$, if for all time steps t and items x the difference between the true user preferences and the perceived preferences by the recommender system is bounded as follows:

$$\pi_t(x) - \sigma(s_x^t) = \gamma \cdot \alpha_{t,x} \cdot r(s_x^t)$$

where:

$$\alpha_{t,x} = \begin{cases} 1 - \sigma(s_x^t) & , \text{ if } s_x^t \geq 0 \\ \sigma(s_x^t) & , \text{ if } s_x^t < 0 \end{cases}$$

is a scaling factor to ensure that $\pi_t(x) \in [0, 1]$ for all items x .

Evolution of User Preferences

Evolution of User Preferences

- Echo Chamber의 존재를 증명하기 위해서는 아래 질문에 대해 답해야 함.

Are there asymptotically stable fixed points in the user-system interaction?

Evolution of User Preferences

- 여기서부터, 이 논문의 주요 이론적인 결과가 나옴.
- 완전 선형대수학적인 부분.
- 자세한 증명은 생략하였고, 논문 및 appendix 참조 바람.

Evolution of User Preferences

Lemma 1

- XX^T 가 full rank라면, $u^* = 0$ 이 유일한 Fixed Point가 된다.

LEMMA 1 (EXISTENCE OF FIXED POINTS.). *Let $X \in \mathbb{R}^{d \times m}$ be the matrix of the items available for recommendation and $XX^T = \sum_x xx^T$ the respective covariance matrix. If $\text{rank}(XX^T) = d$, i.e., the covariance matrix has full rank, then $u^* = 0$ is the unique FP of (2).*

$$u_{t+1} = u_t \Rightarrow \mathbb{E}_{x,y} [\nabla \ell(u_t, (x, y))] = 0$$

$$\sum_x x \cdot \mathbb{P}[x] \cdot \gamma \cdot \alpha_{u_t, x} \cdot (u_t^\top x) \cdot e^{-(u_t^\top x)^2} = 0$$

Evolution of User Preferences

Lemma 2

- XX^T 가 full rank라면, $\|u\|$ 는 시간이 지남에 따라 커진다.

LEMMA 2. *If $\text{rank}(XX^T) = d$ and $u_0 \neq 0$, then $\|u_{t+1}\| > \|u_t\|$ for all t . That is, the norm of the user preferences vector u_t strictly increases in every iteration.*

Evolution of User Preferences

Lemma 3

- Item feature 간의 correlation이 아예 없다면 ($XX^T = I_d$), s_x^0 가 0이 아닐 때, 각 score는 시간이 지남에 따라 절댓값이 더 커진다.

LEMMA 3 (SCORE AMPLIFICATION AND ECHO CHAMBERS). *If $XX^T = I_d$, then and for every item x s.t. $s_x^0 \neq 0$ it holds $|s_x^{t+1}| > |s_x^t|$ and $s_x^{t+1} \cdot s_x^t > 0$. That is, each score gets amplified with time.*

Simulation

Simulation

Metrics

1. Norm of u_t

1. Lemma 2에 따라, 시간이 지날수록 norm이 더욱 커질 것이라 예상.

2. Average prob per item type

1. Item (likable, unlikable) according to s_x^t is positive or negative.
2. Average p_x^t (유저가 t에서 실제로 아이템 x를 좋아할 확률)를 측정.

3. Prob mass on items correlating well with u_0

1. u_0 와 cosine similarity가 가장 큰 top 5% 아이템을 추출.
2. 해당 아이템들이 time t에서 갖는 probability mass (f_t 에 의해 배정된 확률 값)를 확인.

Simulations

Experimental Setup

- **Synthetic Dataset**
 - **Uniform** in the hypercube: $x \sim \text{Uniform}([-1, 1]^d)$
 - **Mixture of two uniforms**
 - 좀 더 실제적인 데이터를 모사하기 위한 방법으로 채택.
 - 낮은 확률로, platform의 정책에 엇나가는 **problematic item (with high feature)**이 등장할 수 있다.
 - With prob $1 - \alpha$, $x \sim \text{Uniform}([-1, b]^d)$
 - With prob α , $x \sim \text{Uniform}([b, 1]^d)$
 - $\alpha = 1\%$, $b = 0.8$

Simulations

Experimental Setup

- Real Dataset
 - MovieLens 10M
 - Yahoo
 - 50 users with highest number of ratings
 - Explicit data -> implicit data
- User preference Vector
 - $u_0 \sim \text{Uniform}([- \epsilon, \epsilon]^d), \epsilon = 0.3$
 - With small $\|u_0\|, f_0 \approx f_{item}$ -> 시작할 때에는 아이템을 거의 랜덤으로 보여주는 것을 목적으로 함.

Simulations

Result

- Fixed Point Never Reached




Figure 3: *Evolution of $\|u_t\|$ with t . In all cases the user preferences diverge as predicted by Lemma 2.*

Simulations

Result

- Likable -> more likable / Unlikable -> more unlikable




Figure 4: *Evolution of the average probability of a likable vs a non-likable item with t .* Solid lines indicate the likable items, whose probability of receiving a positive reaction from the user, p_x^t , is above 0.5, while the dashed lines indicate the non-likable items. The model size is $d = 15$ and $\gamma = 0.5$. The probability of clicking on an item moves towards 1 if its score is positive and towards 0 otherwise.

Simulations

Result

- Small subset of item correlated with u_0 gets more prob mass.




Figure 5: *Total probability mass assigned by f_t to the items with the highest cosine similarity with u_0 . The model size is $d = 15$ and $\gamma = 0.5$. There is a clear tendency to recommend items that the system believes that the user already likes and this tendency becomes more pronounced for higher values of β , making f_t more steep and approximating a Top-1 recommender system.*

Simulations

Effect of β

- Higher $\beta \Rightarrow$ high concentration with high initial score.




Figure 5: Total probability mass assigned by f_t to the items with the highest cosine similarity with u_0 . The model size is $d = 15$ and $\gamma = 0.5$. There is a clear tendency to recommend items that the system believes that the user already likes and this tendency becomes more pronounced for higher values of β , making f_t more steep and approximating a Top-1 recommender system.

Simulations

Effect of γ

- γ 값이 클수록 Echo chamber & Filter bubble에 더 빠르고 강하게 빠진다.




Figure 7: *Effect of user sensitivity γ .* On the left we plot $\|u_t\|$, in the middle the average probability for likable (solid) and non-likable items (dashed) and on the right the probability mass on the items that correlate well with u_0 . The model size is $d = 15$ and $\beta = 1$. More sensitive users experience larger movements in f_t .

Q&A

Simulations

Mitigation Strategies

- Echo Chamber의 존재는 증명하였고, 이를 어떻게 하면 줄일 수 있을까?
 - Global demotion
 - Personalized demotion

Simulations

Mitigation Strategies

- **Global Demotion**

- 앞서 등장한 Mixture distribution에서 출발함.
- *Type1* : $x \sim \text{Uniform}([-1, 0.8]^d)$ with $\alpha = 0.99$
- *Type2* : $x \sim \text{Uniform}([0.8, 1]^d)$ with $\alpha = 0.01$
- $u_0 > 0$
- 유저들은 거의 등장하지는 않지만, Type 2 아이템에 대해서 더 끌리는 것을 표현.
- 다양한 α 에 대해서 **Type2** 아이템이 실제로 노출되는 지 확인.

Simulations

Mitigation strategies

- 어떠한 α (low-prevalence but high feature item)더라도, 유저들은 해당 아이템에 노출될 수밖에 없다.
- 인기가 있을 만한 아이템들은 어떻게든 유저들에게 공급되고, 그 현상이 짙어진다.
- Type-1 item 중 유저의 초기 임베딩과 연관이 있는 아이템 (오른쪽)은 Type2로의 Bridge 역할을 한다.
 - **Borderline problematic items**




Figure 8: On the left we see the total probability that is assigned to the Type-2, low-prevalence items. The different lines correspond to different prevalence of such items in the system ranging from 1% to 0.1%. On the right we plot the probability on the Type-1 items that have high cosine similarity, i.e., they correlate well, with the initial preference vector u_0 . These items act as a “bridge” for the probability to concentrate to the low-prevalence items.

Simulations

Mitigation strategies

- **Personalized Action**

- 유저에 대해 특정 item type에 따라 다른 learning rate를 적용한다.
- 앞서 언급되었던, u_0 와 high correlated된 아이템들에 대해서는 decaying learning schedule을 적용한다.

(1) constant learning rate: $\eta_t = 1$,

(2) decaying learning rate: $1/(1 + t/t_{adj})$

(3) decaying learning rate: $1/(1 + \sqrt{t/t_{adj}})$

(4) feature specific learning rate: In this case the learning rate corresponds to the matrix $\eta_t = \text{diag}[(\frac{1}{(u_t)_i})_{i=1}^d]$, yielding different update for each coordinate. In particular the values for large coordinates are modified at a slower rate.

Simulations

Mitigation strategies

- Personalized Action with different learning rate




Figure 9: Evolution of the user preferences vector u_t and the recommender system for different learning rates. More reluctant updates in the preferences vector u_t mitigate the echo chamber and filter bubble effects.

Simulations

Mitigation in Facebook Recommendations

- 그렇다면 **실제 페이스북에서는 어떻게 적용하였는가?**
 - 페이스북의 비디오 추천 (watch) 에서 실험을 진행함 (multi-task recommendation)
 - 비디오 중 **borderline nudity**를 가지는 아이템에 주목하고자 함.
 - 실제로 nudity를 가지고 있지는 않지만, problematic item의 징검다리 역할을 하는 아이템들
 - 진행 방법
 - 유저들 중에 problematic item에 주 25% 이상 노출되는 케이스들을 수집하여 해당 유저에 대해서 이러한 item들의 노출이 일어나지 않도록 함.
 - **Learning rate**를 유저 별로 적용하는 것은 **production level**에서는 매우 어려우므로, **Borderline problematic item**의 **score**에 대해서 **0.1**을 곱해주는 비교적 심플한 방법 선택.
 - 그 결과 실험군에서, 대조군 대비 명확하게 problematic 아이템 노출이 줄었고, 오히려 유저들의 참여도 (Comment, like 등) 역시 증가함.

Simulations

Mitigations in Facebook Recommendations




Figure 10: The difference in the average impressions of borderline problematic content viewed by treatment and control groups. As time progresses, users that received the treatment see progressively less problematic content.

Simulations

Discussion

- Future work로 mitigation in echo chamber와 user engagement에 대한 추가적인 연구가 필요하다고 언급하고 있음.
 - Echo Chamber에 대한 문제 의식이 조금 다르다.
 - 내가 생각한 것: echo chamber에 빠짐 -> 특정 콘텐츠만 보게 됨 -> 신물 난 유저가 이탈.
 - 이 논문에서 우려하는 점: echo chamber에 빠짐 -> 문제적인 콘텐츠 (선정성, 폭력성) 에 지속적으로 노출됨. -> 유저의 생활에 악영향을 끼치므로 막아야 함.
 - Echo chamber에 빠지는 것이 상황에 따라 다른 처리가 필요한 것이라고 생각함.
- $\|u_t\|$ 가 어느 정도일 때 실제 echo chamber가 생성된다고 볼 수 있는 건 지에 대한 의문.
 - Exact dependence of echo chamber formation on the parameters of the system.
- Static item feature 상황이 아닐 때에는 어떻게 양상이 달라질 것인가? (음악, 기사 등)

감사합니다.