

PUNICA: MULTI-TENANT LORA SERVING

자연어처리팀

황예진(발표자), 김유진, 정천감, 조해창, 황지현

content

- 
1. OVERVIEW
 2. SGMV
 3. EVALUATION
 4. CONCLUSION




overview

Overview

LoRA

Model&Method	# Trainable Parameters	WikiSQL	MNLI-m	SAMSum
		Acc. (%)	Acc. (%)	R1/R2/RL
GPT-3 (FT)	175,255.8M	73.8	89.5	52.0/28.0/44.5
GPT-3 (BitFit)	14.2M	71.3	91.0	51.3/27.4/43.5
GPT-3 (PreEmbed)	3.2M	63.1	88.6	48.3/24.2/40.5
GPT-3 (PreLayer)	20.2M	70.1	89.5	50.8/27.3/43.5
GPT-3 (Adapter ^H)	7.1M	71.9	89.8	53.0/28.9/44.8
GPT-3 (Adapter ^H)	40.1M	73.2	91.5	53.2/29.0/45.1
GPT-3 (LoRA)	4.7M	73.4	91.7	53.8/29.8/45.9
GPT-3 (LoRA)	37.7M	74.0	91.6	53.4/29.2/45.1



LLM을 파인튜닝 하는 효과적인 알고리즘 중 하나이다.


Overview

How serve those LoRA models efficiently?

“어떻게 LoRA 모델들을 효과적으로 서빙할 수 있는가?”


Overview

기존 LLM 서빙 최적화 기법 (1) - kvCache



Overview

기존 LLM 서빙 최적화 기법 (2) - Orca



Overview

기존 LLM 서빙 최적화 기법 (3) - vLLM





Figure 6. Block table translation in vLLM.

Overview

기존 LLM 모델 서빙의 한계



각 LoRA 모델 서빙 시 필요한 GPU 수: k 개

n 개의 LoRA 모델 서빙 시 필요한 GPU 수: $k * n$ 개

Overview

SGMV 제안





Figure 2. The system architecture of Punica.

각 LoRA 모델 서빙 시 필요한 GPU 수: k 개

n 개의 LoRA 모델 서빙 시 필요한 GPU 수: $k * n$ 개

LoRA 모델들끼리 backbone 모델 공유

Overview

SGMV

Segmented Gather Matrix-Vector Multiplication




Figure 3. Semantics of SGMV.


여러 LoRA 모델을 동시에 실행하기 위한 효율적인 CUDA 커널을 제안



SGMV


SGMV

LoRA




$$\vec{y} += \vec{x}AB$$

SGMV Expand



$$\vec{v} += \vec{x}A$$




SGMV Shrink




$$\vec{y} += \vec{v}B$$

SGMV

SGMV
Expand



SGMV



Host memory에서 GPU memory로 LoRA로 학습한 파라미터만 로딩하므로 시간이 적게 든다.



PUNICA
IN
DETAIL

Scheduling new requests

현재 가장 큰 working set이 있는 GPU에 새 요청을 스케줄링 한다.

사용 중인 GPU는 더 많은 요청이 할당되므로 계속 사용 중일 가능성이 높다.

load가 적은 GPU는 요청이 종료될 때 load를 낮출 가능성이 높다.

유휴 GPU는 유휴 상태를 유지할 가능성이 높다.



따라서 GPU 클러스터의 스케일을 키우거나 줄이는 결정을 하기 좋다.

Request migration




Figure 5. Request migration procedure for Request R_3 .

제거와 추가 두 단계로 이루어지며, KvCache를 이동하는 것이 아니라 새로 재계산한다.

Memory layout for KvCache




Figure 6. Block table translation in vLLM.

vLLM의 pagedattention을 사용하여 버려지는 메모리 fragmentation이 적게 만든다.



EVALUATION

EVALUATION




Figure 7. Roofline plot of the SGMV kernel.

- (1) Distinct: 요청마다 다른 LoRA 모델
- (2) Uniform: 모든 LoRA 모델들이 같은 비율
- (3) Skewed: Zipf- α 분포를 따름
- (4) Identical: 같은 LoRA model

vLLM의 pagedattention을 사용하여 버려지는 메모리 fragmentation이 적게 만든다.

EVALUATION

환경

Testbed#1 NVIDIA A100 80GB

Testbed#2 NVIDIA HGX A100 40GB x 8

model: Llama-2 7B, 13B, 70B

LoRA rank: 16

EVALUATION




Figure 10. Transformer Layer Benchmark.




Figure 11. Single GPU text generation comparison

EVALUATION



Figure 12. 70B model text generation comparison.



CONCLUSION

CONCLUSION

- ❑ PUNICA는 GPU 클러스터 내에서 여러 LoRA 모델들을 서빙할 수 있다.
- ❑ 새로운 CUDA 커널은 다른 LoRA 모델들의 GPU operations를 일괄 처리(batching) 할 수 있도록 한다.
- ❑ pre-trained 모델은 하나의 복사본만 필요하다.
- ❑ 12배 더 빠르게 LoRA 모델을 서빙한다.

Q n A