

Published as a conference paper at ICLR 2024 (31 Jan 2024 발표된 논문)

RAPTOR:

Recursive Abstractive Processing For Tree- Organized Retrieval

Parth Sarthi, Salman Abdullah, Aditi Tuli, Shubh Khanna,
Anna Goldie, Christopher D. Manning Stanford University

발표자



권성은, 박주혜, 박산희, 김영민

자연어처리 스터디팀





CONTENTS

1. Introduction		03
2. Related Works		05
3. Methods		06
4. Experiments		10
5. Conclusion		12

01. Introduction



기존 Retrieval 방식

- **Separate Information retrieval system**
: 대규모 텍스트 데이터를 여러 chunk로 나누고, 이를 인덱싱하는 방식
- **Retrieval-augmented approach**
: Retrieval information or domain specific knowledge를 제공하여
해석과 출처 제공(interpretability와 provenance tracking)을 용이하는 방식


문제 제기

- Retrieval-augment는 짧고 인접한 text chunk만을 retrieve하는 한계
- text의 여러 파트에서 지식을 가져와 통합하는 thematic question에는 취약
: ex. 신데렐라는 어떻게 해피 엔딩을 맞이했니?라는 질문에 대답해야 하는 경우

01. Introduction

저자들의 해결 방안

- **Tree structure를 이용한 인덱싱 및 검색 시스템을 제안**
 - : high level과 low level의 자세한 텍스트 정보를 모두 포착 가능
 - : ① 텍스트 chunk들을 클러스터링 → ② 클러스터를 해석하는 text summaries 생성
→ 하나의 tree가 되도록 ① 클러스터링과 ② 클러스터 요약(을 반복 (recursively))



의의

- **다양한 scale로 retrieval augmentation을 하게 한다는 점**
- **긴 문서에서 효과가 크다는 점** (Effective on collections of long documents)

02. Related Works



Why Retrieval?

- [Lie et al. \(2023\), Sun et al. \(2021\)](#)
 - 모델의 긴 컨텍스트 활용도가 낮고, 컨텍스트 길이가 길어지면 성능이 저하되는 경향이 있음.
 - 긴 컨텍스트를 활용하게 되면 사용 비용 높고 속도는 느려져 비효율적

⇒ 따라서, 지식 집약 작업에서는 관련성 높은 정보 선택이 중요하므로
검색 시스템이 필수

02. Related Works



Retrieval Methods

- **Retrieval-augmented Language model의 컴포넌트 개선 연구**
 - **Term-based technics**(TF-IDF, BM25) : Spark Jones(1972), Robertson et al. (1995), 2020)
 - **Deep learning-based strategies** : Karpukhin et al. (2022)
 - **LLM 활용** : Yu et al. (2022), Sun et al. (2022) :
 - **Fusion-in Decoder(FiD)** : Reader component 연구 : Izacard & Grave(2022) :
 - **RETRO** : cross-chunked attention & chunkwise retrieval : Borgeaud et al(2022), Wang et al.(2023)
- **End-to-end 시스템 훈련 연구**
 - **Atlas** : encoder-decoder model 을 the retriever 연계해 파인튜닝 : Izacard & Grave(2022) :
 - **REALM** : Bidirectional, masked LM fine-tuned for open-domain QA : Guu et al. (2020)
 - **RAG** : Lewis et al. (202)
 - **Joint Passage Retrieval** : Tree decoding 알고리즘 : Min et al.(2021), Arivazhgan et al.(2023):
- 대부분의 모델은 corpora chunking 및 BERT 기반 retriever encoding에 의존,
이에 따른 그 한계 지적됨

02. Related Works



Recursive summarization as Context

- Summarization 기법은 문서들을 집약해 주기 때문에 콘텐츠에 더 집중할 수 있게 도와 줌
 - **Summarization/snippet model 소개**: Gao et al. (2023):
정확성을 향상시켰지만 정보 손실 유발 가능성 확인
 - **Recursive-abstractive summarization model 소개**: Wu et al. (2021):
소규모 청크 요약을 모아 더 넓은 맥락에서의 요약문 제공,
broader theme 포착하지만 디테일 누락 가능성 제기
 - **LlamaIndex**: Liu (2022):
소규모 청크 사이 인접 노드를 활용.
디테일 유지하지만 distant interdependencies 간과 가능,

⇒ **RAPTOR**로 개선

03. Methods



Overview

- Idea
 - : 특정 주제의 긴 문서는 하위 주제들로 나뉘어져 있으며 위계 구조를 가짐
 - : Semantic depth and connection은 Recursive tree structure로 표현 가능
 - : node들은 semantic similarity에 따라 그룹화될 수 있음

- Construction



03. Methods



Clustering Algorithm

- Clustering은 text segments 들을 연결된 그룹(cohesive group)으로 조직화
: 관련성 깊은 콘텐츠를 함께 모아서 검색 프로세스를 도와주는 역할

: soft clustering을 실시하여 한 노드가 여러 클러스터에 소속될 수 있게 함

- Clustering 주요 특징

1) GMM 기반 클러스터링 알고리즘 적용

: data point들은 몇 개 가우시안 분포의 Mixture로부터 생성된다고 가정

- N 개의 텍스트 각 세그먼트는 d-dimensional dense vector를 표상

- 한 텍스트 벡터 $\mathbf{x}$ 의 likelihood는 $P(\mathbf{x}|k) = \mathcal{N}(\mathbf{x}; \mu_k, \Sigma_k)$

: GMM 파라미터를 평가하기 위해서는 기댓값 최대화 알고리즘(EM) 적용

2) Two step 클러스터링

: 차원 축소 기법 'UMAP(Uniform Manifold Approximation Projection) 적용

- 텍스트 임베딩 벡터를 그대로 사용하면 차원이 높아지기 때문에 GMM이 성능 저하 문제 발생

- 텍스트 임베딩을 UMAP을 이용하여 차원 축소한 후 클러스터링 실시

: Global cluster를 먼저 규정하고 local cluster를 수행하는 방식이 되어,
Local과 Global 구조를 모두 보존하는 효과 발생

3) Optimal N of cluster 를 정하기 위해 BIC(Bayesian Information Criterion) 적용

4) Soft clustering : 하나의 노드는 복수의 클러스터에 소속 가능


03. Methods




Model-based
Summarization

Querying

- 언어모델을 이용해 Cluster에 속하는 텍스트들을 요약해서 노드를 간략하게 표현
- 이 논문에서는 gpt 3.5 turbo 사용 (4% 정도 할루시네이션 존재)
- Tree traversal and collapsed tree



- 코사인 유사도 기준으로 관련성 높은 top k의 node 선택을 반복
- 모든 텍스트들이 트리 구조로 표현




- 모든 노드를 single layer로 펼쳐 코사인 유사도 기준 query와 node를 비교해 유사 노드 선정
- Tree traversal 기법보다 더 높은 성능을 보임

03. Methods



Comparison of querying methods



04. Experiments




Datasets

- 3 Question-Answering data set: **NarrativeQA**, **QASPER**, **QuALITY**
 - Books, Movie transcripts
 - Comprehensive understanding
 - BLEU (B-1, B-4)
 - 5,049 questions on 1,585 NLP papers
 - Answerable/Unanswerable
 - Standard F1
 - Multiple-choice questions
 - Reasoning over the entire documents for QA task
 - Entire test set vs. Hard subset

Controlled Baseline Comparisons

- The UnifiedQA 3B** as the reader, with SBERT,
- BM25**, and **DPR** as the embedding models **with vs. without Raptor** **트리**



Question1: "What is the central theme of the story?"

Question2: "How did Cinderella find a happy ending?"

04. Experiments



Performance
of
Controlled
Baseline
Comparisons

Table1. NarrativeQA Performance with +without RAPTOR

Model	ROUGE	BLEU-1	BLEU-4	METEOR
SBERT with RAPTOR	30.87%	23.50%	6.42%	19.20%
SBERT without RAPTOR	29.26%	22.56%	5.95%	18.15%
BM25 with RAPTOR	27.93%	21.17%	5.70%	17.03%
BM25 without RAPTOR	23.52%	17.73%	4.65%	13.98%
DPR with RAPTOR	30.94%	23.51%	6.45%	19.05%
DPR without RAPTOR	29.56%	22.84%	6.12%	18.44%

Table2. QuALITY and QASPER Performance with +without RAPTOR

Model	Accuracy (QuALITY)	Answer F1 (QASPER)
SBERT with RAPTOR	56.6%	36.70%
SBERT without RAPTOR	54.9%	36.23%
BM25 with RAPTOR	52.1%	27.00%
BM25 without RAPTOR	49.9%	26.47%
DPR with RAPTOR	54.7%	32.23%
DPR without RAPTOR	53.1%	31.70%

04. Experiments



Performance
of
Controlled
Baseline
Comparisons

Table3. Controlled comparison of F-1 scores on QASPER data set using 3 Language Models (GPT-3, GPT-4, UnifiedQA 3B)

Retriever	GPT-3 F-1 Match	GPT-4 F-1 Match	UnifiedQA F-1 Match
Title + Abstract	25.2	22.2	17.5
BM25	46.6	50.2	26.4
DPR	51.3	53.0	32.1
RAPTOR	53.1	55.7	36.6

Table4. Comparison of accuracies on QuALITY data set for 2 Language Models (GPT-3, UnifiedQA 3B)

Model	GPT-3 Acc.	UnifiedQA Acc.
BM25	57.3	49.9
DPR	60.4	53.9
RAPTOR	62.4	56.6

04. Experiments



Performance
of
Controlled
Baseline
Comparisons

Table5. Results on F-1 Match scores of various models on QASPER data set

Model	F-1 Match
LongT5 XL (Guo et al., 2022)	53.1
CoLT5 XL (Ainslie et al., 2023)	53.9
RAPTOR + GPT-4	55.7

Table6. Performance comparison on the NarrativeQA data set

Model	ROUGE-L	BLEU-1	BLEU-4	METEOR
BiDAF (Kočiský et al., 2018)	6.2	5.7	0.3	3.7
BM25 + BERT (Mou et al., 2020)	15.5	14.5	1.4	5.0
Recursively Summarizing Books (Wu et al., 2021)	21.6	22.3	4.2	10.6
Retriever + Reader (Izacard & Grave, 2022)	32.0	35.3	7.5	11.1
RAPTOR + UnifiedQA	30.8	23.5	6.4	19.1

Table7. Accuracies of the QuALITY data set
on both overall test vs challenging hard subset

Model	Accuracy	
	Test Set	Hard Subset
Longformer-base (Beltagy et al., 2020)	39.5	35.3
DPR and DeBERTaV3-large (Pang et al., 2022)	55.4	46.1
CoLISA (DeBERTaV3-large) (Dong et al., 2023a)	62.3	54.7
RAPTOR + GPT-4	82.6	76.2

04. Experiments



Contribution

- 상위 노드가 thematic, multi-hop query에서 결정적 역할을 하는 것으로 추정
- 상위 노드가 텍스트에 대한 더 넓은 이해를 요구하는 쿼리에서 중요한 역할하기 때문
- Original text와 higher level summary를 모두 이용해서 retrieve


Table8. Performance of RAPTOR when querying different tree layers for Story1 from QuALITY data data set

Layers Queried / Start Layer	Layer 0 (Leaf Nodes)	Layer 1	Layer 2
1 layer	57.9	57.8	57.9
2 layers	-	52.6	63.15
3 layers	-	-	73.68

06. Conclusion



- **트리 기반의 새로운 retrieve system을 제안하여, Tree structure를 효과적으로 개선함.**
- **다양한 수준에서의 추상화에 기반한 contextual information을 통해 LLM의 parametric knowledge를 증강시키는 시스템을 제안**
- **기존 retrieval 방법들보다 효과적이었으며, 몇몇의 QA task에서 벤치마크보다 높은 성능을 보였음**



감사합니다