

ReAct: 언어 모델에서 추론과 행동의 시너지

SYNERGIZING REASONING AND ACTING IN LANGUAGE MODELS

저자: Shunyu Yao et al. | 소속: Princeton University, Google Research | 학회: ICLR 2023


딥러닝논문읽기모임 7기
자연어처리팀
박민건

인간이 문제를 해결하는 과정

인간의 문제 해결 과정 : 요리를 한다면.



“요리“ 문제를 해결하기 위한 과정



인간의 문제 해결 과정의 핵심 : **추론(Reasoning)**과 **행동(Action)**의 긴밀한 협력

외부 정보를 능동적으로 수집
상황에 따라 계획을 동적으로 조정

기존 언어 모델 연구의 한계점

Chain-of-Thought-only (Reasoning)

정적인 추론 중심

환경과의 상호작용 부족

사실 오류(hallucination) 발생

최신 정보 접근 불가


Action-only (Action)

추론 없는 행동

복잡한 계획 수립의 어려움

오류 회복 능력의 부족

맥락 이해의 한계



즉, 인간의 문제해결 과정처럼 추론과 행동을 긴밀하게 협력하여 수행하는 방향으로 발전하지 않고,
Reasoning과 Action으로 나뉘어서 개별적으로 발전

“Reasoning과 Action을 상호 보완적으로 수행하는 새로운 프레임워크가 필요”

ReAct: 추론과 행동의 시너지

행동 공간의 확장 : $\hat{A} = A \cup L$ (Action $\cup$ Language)

기존 행동 공간 A 는 에이전트가 환경에 영향을 미치는 행동들의 집합,
행동공간에서의 행동은 환경을 변화시키고 새로운 관측값 생성에 영향을 줌
언어 공간 L 은 언어를 통한 추론 과정을 나타낸 공간, 언어공간에서의 행동은 외부 환경에 영향을 주지 않음
즉, 행동을 위한 추론은 새로운 가능성을 만들고, 추론을 위한 행동은 추론 과정을 강화함

Thought-Action-Observation Cycle



Reasoning to Act (행동을 위한 추론)

추론을 통해 목표 추적, 행동 계획 수립, 다양한 선택지 처리

Act to Reason (추론을 위한 행동)

추론을 통해 목표 추적, 행동 계획 수립, 다양한 선택지 처리

ReAct에서 추론은 환경(Action에서 필요한 환경)에 영향을 주지 않으며, 내부 Context만 업데이트
행동은 환경을 변화시켜 새로운 관측(observation)을 생성

HotpotQA 기반의 실제 예시

HotpotQA : 영어 위키백과를 기반으로 한 대규모 QA 데이터셋으로 여러 문서에 걸쳐 추론(multi-hop reasoning)이 필요한 질문들로 이뤄져 있음

Question: What is the elevation range for the area that the eastern sector of the Colorado orogeny extends into?

Ko: 콜로라도 조산대의 동부 구역이 확장되는 지역의 고도 범위는 얼마인가요 ?

Thought 1

EN: What is the elevation range for the area that the eastern sector of the Colorado orogeny extends into?

Ko: 콜로라도 조산 운동을 검색하여 동쪽 구역이 확장되는 구역을 찾아줘

⚡ Action (행동)

EN: Search[Colorado orogeny]

Ko: 검색하기[콜로라도 조산 운동]

👁 Observation (관찰)

EN: The Colorado orogeny was an episode of mountain building (an orogeny) in Colorado and surrounding areas

Ko: 콜로라도 조산 운동은 콜로라도와 그 주변 지역에서 산이 형성되는 과정을 뜻함

Thought 2

EN: What is the Eastern Sector ?

Ko: 동부 섹터가 뭐지 ?

⚡ Action (행동)

EN: Search[Eastern Sector]

Ko: 검색하기[동부 섹터]

👁 Observation (관찰)



EN: The eastern sector stretches up to the plateau and is called the Central Plains orogenic movement.

Ko: 동쪽 섹터는 고원 지대까지 뻗어 있고 중앙 평원 조산 운동이라고 불러

🔄 반복하여 Thought-Action-Observation Cycle을 거친 후 🔄

🎯 최종 답변: 1,800~7,000피트 (550~2,130m)

HotpotQA에 대한 4가지 접근 방법 비교



기존의 문제를 해결하고, 향상된 정확도 달성

ReAct 구현 방법론

프롬프팅 기반 접근

Model : PaLM-540B, GPT-4(부록)

프롬프트 구조:

Solve a question answering task with interleaving Thought, Action, Observation steps.

Thought can reason about the current situation

Action can be three types:

- (1) Search[entity], which searches the exact entity on Wikipedia
- (2) Lookup[keyword], which returns the sentences containing keyword
- (3) Finish[answer], which returns the answer and finishes the task

Here are some examples:

[Few-shot examples...]

Question: {question}

Thought 1:

기술 : Langchain + Wikipedia API

즉, Langchain 등으로 Tool들을 사용할 수 있게 구현했지만, 큰 컨셉의 개발은 프롬프트만으로 진행됨

Experiment 1: 지식 기반 추론 테스트(Knowledge-Intensive Reasoning Task)

실험 1의 목표

많은 지식과 복잡한 추론을 필요로 하는 작업에서의 성능 측정

데이터 셋

HotpotQA

다단계 질의응답 구성 데이터
논리적 사고력 평가를 위한 고난이도 QA 벤치
복잡한 추론을 필요함
500개의 예시를 사용

FEVER

사실 검증 기반 데이터
위키피디아 기반 문장을 활용해 사실 검증 모델의
성능을 평가하기 위해 개발된 벤치
증거 기반 판단
500개의 클레임 검증

Action 환경 : Wikipedia API

Search[entity]

Entity 검색 기능
상위 5개 결과를 반환

Lookup[string]

페이지 내 검색
관련 문장 반환



Finish[answer]

답변 완료
최종 답변 제출

Experiment 1: 지식 기반 추론 테스트 성능 결과

HotpotQA & FEVER 성능 비교

방법	HotpotQA (EM %)	FEVER (Acc %)
Standard	28.7	57.1
CoT	29.4	56.3
CoT-SC	33.4	60.4
Act	25.7	58.9
ReAct	27.4	60.9
CoT-SC->ReAct	34.2	64.6
ReAct->CoT-SC	35.1	62.0



💡 결과로 알 수 있는 점

- 기존 도구와의 조합을 하면 더 높은 성능 달성 가능 (CoT-SC -> ReAct가 가장 높은 성능 달성)
- 상호 보완 : ReAct->CoT-SC도 우수한 성능을 달성(FEVER: 64.6%)
- 테스트 특성에 따라 상이 : FEVER에서는 ReAct 단독으로도 CoT 대비 우수

SC : Self-Consistency의 줄임말로, 동일 문제에 대해 여러 다른 추론 경로를 생성하여 가장 많이 다른 답을 선택하는 기법

Experiment 1: 지식 기반 추론 테스트 성능-실패 사례

✓ 성공 사례 분석

정확한 추론

ReAct: 94%

CoT: 86%

환각 추론

ReAct: 6%

CoT: 14%

🎯 핵심 : ReAct는 환각을 제거하여 신뢰성을 크게 향상시킴, 기존 도구와의 조합을 하면 더욱 향상됨

✗ 실패 사례 분석

추론 오류

ReAct: 47%

CoT: 16%

검색 결과 오류

ReAct: 23%

CoT: 0%

환각

ReAct: 0%

CoT: 56%

라벨 모호성

ReAct: 29%

CoT: 28%

Experiment 2: 의사 결정 테스트(Decision Making Tasks)

실험 2의 목표

의사결정(Task Planinng 및 제어) 작업에서의 성능 측정을 통해 환경과의 상호작용이 목표 달성을 위해 얼마나 유용한지 평가

시뮬레이션 (데이터셋을 포함한)



가상 3D 환경에서 로봇이 집안 물건을 조작하고 환경과 상호작용하는걸 테스트하는 시뮬레이션

특성:

- 텍스트 기반 3D 시뮬레이션
- 가정용 로봇 테스트
- 134개의 상호작용 테스트가 존재

태스크 유형(예시):

Pick (물건집기), Clean(청소하기), Heat(가열하기), Pick2 (복잡한 집기)

등

예시 : “차가운 감자를 쓰레기통에 버려:”

-> 냉장고에서 감자찾기 -> 감자 집기 -> 쓰레기통 찾기 -> 버리기



전자가상거래 웹사이트(온라인 쇼핑몰)를 모사한 시뮬레이션
즉, 에이전트가 웹을 탐색하여 상품을 검색, 선택, 구매 등의 쇼핑 과정을 시뮬레이션하는 지표

특성:

- 실제 Amazon 데이터 기반으로 생성됨
- 110만개의 제품이 존재
- 500개의 쇼핑 테스트 시현 가능

태스크 유형(예시):

검색, 필터링, 제품 선택, 장바구니 추가

예시 : “흰색 셔츠 찾기, 사이즈 100, \$100 이하”

-> 검색 -> 필터링 -> 상품 비교 -> 구매

Experiment 2: 의사 결정 테스트(Decision Making Tasks)

Sparse Thought 전략을 추가로 채택

의사결정에서는 모든 단계마다 추론을 하지 않고, 핵심 시점에만 명시적으로 추론을 시행

- ➔ 중요한 순간에만 추론을 시행하는데, 중요한 순간은 전환점을 기준으로 모델이 자유롭게 선택
- ➔ 전환점 : 특정 Task가 끝난 후 다음 목표를 정해야해! 같은 논리적 분기점에 Thought를 시행
- ➔ 즉, Action과 Observation만 반복하다가 필요할 때 다시 Thought를 시행하는 방식

Action: search[lamp]

Observation: [lamp results]

Thought: I need a table lamp with warm light

Action: click[table lamp]

Observation: [table lamp page]

Action: click[add to cart]

Experiment 2: 의사 결정 테스트 성능 결과

ALFWorld 성능

Task	ReAct	Act	Butler
Pick	92%	88%	46%
Clean	58%	42%	39%
Heat	96%	74%	74%
Cool	86%	67%	100%
Look	78%	72%	22%
Pick_2	41%	41%	24%
전체	71%	45%	37%

WebShop 성능

ReAct

Score
66.6

Success Rate
40.0%

Act-only

Score
62.3

Success Rate
30.1%

IL+RL

Score
62.4

Success Rate
28.7%

💡 결과로 알 수 있는 점

- ReAct가 모든 의사결정 테스트에서 우수
- 명시적 추론이 복잡한 환경에서 특히 효과적으로 동작
- 사전 훈련된 기법 대비 상당한 성능 향상

Butler: text 기반 AI 에이전트로, ALFWorld를 기반으로 테스트된 대표적인 Agent

ReAct의 장점



해석가능성

주론 과정을 명확히 관찰
할 수 있어 모델의 결정 과
정을 이해 가능



최신 정보

실시간으로 외부 정보에
접근하여 최신 데이터 활
용 가능



제어가능성

Human-in-the-loop 지원
으로 인간의 개입과 제어
가능



일반성

다양한 태스크와 도메인에
쉽게 적용 가능한 범용성



신뢰성

외부 소스를 기반으로 한
사실 기반 주론으로 높은
신뢰성

ReAct의 한계점 및 향후 연구과제

⚠ 현재 한계점

시퀀스 길이 제한

복잡한 다단계 태스크에서는 긴 시퀀스 처리가 어려움

Context 제약

In-context-learning의 입력 제한으로 인해 성능 저하

비 효율적인 행동

LLM의 자율 의사 결정 중 반복적이고 비생산적 패턴 발생

검색 실패시 회복의 어려움

검색이 실패해버리면, 행동 연결에 어려움을 겪음

🚀 향후 연구 방향

스케일 업

다중 태스크 훈련을 통해 더 강력한 범용 모델 구축

강화 학습 결합

RL과의 결합으로 더 효율적이고 적응적인 에이전트 개발

실세계로의 확장

코드 실행, 도구 사용 등 실세계의 도구 활용

효율성 개선

더 작은 단계로 목표 달성을 통해 효율성 개선

멀티모달 확장

텍스트에 국한되지 않고 다른 모달리티를 지원

ReAct 기여점

1

새로운 패러다임 제시

추론 + 행동을 결합한 언어모델의 새로운 가능성 제시

2

해석 가능한 AI

추론과정을 명시적으로 드러나게해서 해석 가능성과 제어 가능성을 높인 AI 시스템

3

성능 향상 달성

지식 기반 추론과 의사결정 태스크에서 기존 대비 우수한 성능달성

4

인간 중심 접근

인간의 문제 해결 방식을 모방하여 더 직관적이고 자연스러운 AI 접근법 제시

Q & A

Thank you