

SCALING UP MASKED DIFFUSION MODELS ON TEXT

(2025. 02)

딥논워 7기 자연어처리팀

정현석(발표자), 김보성, 박민건, 황예진, 박주혜,
이예서, 임다예슬, 김유진, 이웅기, 김기환, 조해창

Conclusion

장점과 단점이 명확한 논문

MDM Scaling law 최초 제시

창의적인 sampling

ARM limitation 해결


현실적이지 않은 비교 방식

Scaling law of MDM


$$C = 6ND$$

FLOPs = Parameters * Dataset size


$$\log \mathcal{L}^* \approx \alpha \log C + \beta$$




(a) ARMs.



(b) MDMs.



(a) Loss-Flops curve.



(b) Parameters-Flops curve.

Figure 2: **Scaling laws for MDMs.** Compared to ARMs, MDMs demonstrate competitive scalability with comparable scaling rates and similar scaling behavior on utilizing the parameter capacity.

Classifier guidance vs CFG

Sampling step: $\text{score} + w \nabla_{x_t} \log p_{\text{classifier}}(c|x_t)$

추가적으로 따로 학습된 분류기를 사용해,
원하는 클래스(예: 고양이, 강아지)에 더 가까운 이미
지를 뽑아내도록 생성 경로를 교정한다.

$$\tilde{p}_\theta \propto \underbrace{\frac{p_\theta(x_0|c, x_t)^{1+w}}{p_\theta(x_0|x_t)^w}}_{\text{조건부 부스트}} = \underbrace{\frac{p_\theta(x_0|c, x_t)^w}{p_\theta(x_0|x_t)}}_{\text{비율 증폭}} \times p_\theta(x_0|c, x_t)$$

별도의 분류기 없이, "조건을 준 경우"(텍스트 프롬프
트 있음)와 "조건을 주지 않은 경우"(무조건 생성)의
score를 혼합해서, 원하는 조건을 더 강하게 또는 약하
게 반영

CFG vs Unsupervised CFG

$$\tilde{p}_{\theta}(\mathbf{x}_0|\mathbf{c}, \mathbf{x}_t) \propto \frac{p_{\theta}(\mathbf{x}_0|\mathbf{c}, \mathbf{x}_t)^{1+w}}{p_{\theta}(\mathbf{x}_0|\mathbf{x}_t)^w},$$

분자: $p_{\theta}(\mathbf{x}_0 | \text{"빨간 고양이"}, \mathbf{x}_t)$

분모: $p_{\theta}(\mathbf{x}_0 | \mathbf{x}_t)$ ← 이걸 우리 모델이 학습하지 않았음!
← 조건 입력을 받는 방식으로 훈련 안 됨

$$\tilde{p}_{\theta}(\mathbf{x}_0|\mathbf{c}, \mathbf{x}_t) \propto \frac{p_{\theta}(\mathbf{x}_0|\mathbf{c}, \mathbf{x}_t)^{1+w}}{p_{\theta}(\mathbf{x}_0|\mathbf{m}, \mathbf{x}_t)^w},$$

$p_{\theta}(\mathbf{x}_0 | \text{"빨간 고양이"}, \mathbf{x}_t)$

$p_{\theta}(\mathbf{x}_0 | [\text{MASK}], \mathbf{x}_t)$ ← 마스크를 조건으로 받음

필요한 데이터:

("빨간 고양이", 빨간 고양이 사진)	← 정확히 맞아야 함
("파란 강아지", 파란 강아지 사진)	← 쌍 필수
("노란 나비", 노란 나비 사진)	← 가비싸고 구하기 어려움

학습: 매우 정확한 **paired data** 필요 (데이터 수집 비용 ↑)

필요한 데이터:

이미지만: 고양이, 강아지, 나비...	← 라벨 없음, 무료
텍스트만: "빨간", "귀여운", ...	← 텍스트 수집만 하면 됨

Why Unsupervised CFG?

Specifically, in language tasks, both c and x can be viewed as **segments of a whole sequence**, following the same distribution of unsupervised samples for pretraining.

$$\tilde{p}_{\theta}(x_0|c, x_t) \propto \frac{p_{\theta}(x_0|c, x_t)^{1+w}}{p_{\theta}(x_0|m, x_t)^w},$$

마스크 방식 2:

입력: "[MASK] [MASK] [MASK] fox jumps over the lazy dog"

출력: 모델이 앞부분을 "The quick brown"으로 복원

마스크 방식 3:

입력: "The quick brown fox jumps over the [MASK] [MASK]"

출력: 모델이 뒷부분을 "lazy dog"으로 복원

→ 모든 방식에서 `p_data(앞부분, 뒷부분)`을 자동으로 학습!

=> 사전학습과정에서 모델은 분자와 분모의 확률분포를 '이미' 학습한 상태!

Unsupervised CFG for Language Understanding

	FLOPs	ARC-e	BoolQ	Hellaswag	Obqa	PIQA	RACE	SIQA	LAMBADA	GSM8K
GPT-2 (1.5B)	-	51.05	61.77	50.89	32.00	70.51	33.11	40.28	44.61	-
TinyLlama (1.1B)	3.3×10^{21}	52.19	59.39	54.07	33.20	70.29	35.60	39.41	43.22	-
MDM (1.1B)	3.3×10^{21}	48.74	62.17	51.83	33.40	69.53	35.60	41.04	52.73	58.5
Llama-2 (7B)	7.8×10^{22}	74.49	77.68	75.98	44.20	79.00	39.52	46.11	68.00	58.6*

Q: "What is the capital of France?"

- A) Paris
- B) London
- C) Berlin
- D) Madrid

정답: A) Paris

8개 중 4개의 Benchmark에서 ARM보다 우수한 성능을, GSM8K Benchmark에서 훨씬 큰 7B의 ARM모델과 거의 유사한 Mathematical Reasoning 성능을 보였다.

⇒ Pair가 아닌 dataset이므로
“Largely overlooked in prior studies”

Unsupervised CFG for Language Understanding

$$C = 6ND$$




Figure 2: **Scaling laws for MDMs.** Compared to ARMs, MDMs demonstrate competitive scalability with comparable scaling rates and similar scaling behavior on utilizing the parameter capacity.




Figure 3: **Scaling properties of MDMs on language understanding tasks.** The x-axis represents the validation loss, while the y-axis indicates the accuracy.

=> ARM과 유사하게 positive scaling signal을 보인다.
(Scaling할수록 성능이 좋아진다)

Unsupervised CFG for conditional generation

(1) Why conditional generation?

ChatGPT o1 pro mode ▾

H

무엇을 도와드릴까요?

메시지 ChatGPT



🔍 해답 찾기

🎓 조인 구하기

👁 이미지 분석

📄 텍스트 요약

💻 코딩

👁 더 보기

(2) Why MT-Bench rather than Perplexity?

“The of is and the”

⇒ 흔한 단어들의 조합이므로 틀린 문장이지만 Perplexity는 낮을 수 있다

MT-Bench (Zheng et al., 2023):

- "Multi-turn Benchmark"
- GPT-4o를 "심사위원"으로 사용
- 개방형 질문에 대한 모델 답변을 평가

“Conditional generation is more widely applicable in real-world scenarios than unconditional generation.”

Selective Masking for Fine-Tuning Unsupervised CFG

$$\tilde{p}_{\theta}(\mathbf{x}_0|\mathbf{c}, \mathbf{x}_t) \propto \frac{p_{\theta}(\mathbf{x}_0|\mathbf{c}, \mathbf{x}_t)^{1+w}}{p_{\theta}(\mathbf{x}_0|\mathbf{m}, \mathbf{x}_t)^w},$$

입력 데이터:

```
| Prompt: "What is artificial intelligence?" |
| Response: "AI is the simulation of human thinking" |
| Padding: [EOS][EOS][EOS]... |
```

마스킹 적용 (모든 토큰):

```
| [MASK] [MASK] [MASK] [MASK] [MASK] ? |
| [MASK] [MASK] [MASK] [MASK] [MASK] ? |
| [MASK] [MASK] [MASK]... |
```

Table 3: **Ablation of unsupervised CFG.** The symbols * and † indicate the standard CFG and unsupervised CFG respectively. We report the results with the optimal scale searched in {0.4, 0.6, 0.8, 1} for both CFG approaches.

	w/o CFG	w/ CFG*	w/ CFG†
Score ↑	1.32	1.53	1.60

마스킹 적용 (Response와 Padding만):

```
| What is artificial intelligence? | ← 고정! (마스킹 X)
| [MASK] [MASK] [MASK] [MASK] [MASK] | ← 마스크 0
| [MASK] [MASK] [MASK]... | ← 마스크 0
```

=> Conditional과 unconditional distribution을 모두 FT 해야하는 일반적인 CFG보다 효율적이다.

MDM showed Better efficiency quality trade-off compared to ARM

Table 4: **Conditional generation results.**
MDM utilizes 16 times the pre-training time of ARM while ARM utilizes KV-cache.

		MDM		ARM
Score $\uparrow$	1.40	1.56	1.60	1.57
NFEs $\downarrow$	64	128	256	325.94
Time $\downarrow$	204s	396s	780s	555s

NFE = 모델 forward pass 횟수

ARM: 1000 토큰 생성 $\rightarrow$ 1000 NFE

MDM: 50 denoising step $\rightarrow$ 50 NFE

하지만 ARM은 KV-Cache로 가속됨

$\Rightarrow$ NFE보다 실제 Running time이 중요하다

$\Rightarrow$ MDM이 ARM과 비교할 때 1.4배 빨리 샘플링하면서도 비슷한 성능을 내고 있다.

ARM limitation (1): Reverse Curse

ARM 모델이 $A \rightarrow B$ 방향은 잘하지만, $B \rightarrow A$ 방향은 완전히 실패하는 현상

DescriptionToName

“ $\langle \text{description} \rangle$ is $\langle \text{name} \rangle$ ”

(1) A four-legged domestic animal $\rightarrow$ "dog"

(2) An animal that flies $\rightarrow$ "bird"

(3) A striped horse $\rightarrow$ "zebra"

NameToDescription

“ $\langle \text{name} \rangle$ is $\langle \text{description} \rangle$ ”

(1) dog $\rightarrow$ "A four-legged domestic animal"

(2) bird $\rightarrow$ "An animal that flies"

(3) zebra $\rightarrow$ "A striped horse"

Breaking the reverse curse

Table 5: **Results on breaking the reverse curse.** The performance of GPT-3 and Llama-2 is sourced from Berglund et al. (2023) and Lv et al. (2023), respectively. All models are fine-tuned on the same dataset for 10 epochs. For MDM, we use a CFG scale of 0.8. While ARMs and T5 struggle to handle reverse queries, MDMs effectively overcome the reverse curse and maintain performance in the same direction.

	DescriptionToName		NameToDescription			
	Same direction	Reverse direction	Same direction		Reverse direction	
	Acc. ↑	Acc. ↑	Acc. ↑	BLEU ↑	Acc. ↑	BLEU ↑
GPT3 (175B)	97	0	50	-	0	-
Llama-2 (13B)	99	0	-	74	-	19
T5 (3B)	100	0	47	87	0	20
MDM (1.1B)	97	92	49	76	37	67

=> MDM은 Same direction에서 ARM과 유사한 성능을,
Reverse direction에서 압도적인 성능을 보인다

ARM limitation (2): Temporal quality degradation

시간이 지나면서 모델의 성능이 악화되는 현상

Table 6: **Perplexity ($\downarrow$) results on relieving temporal quality degradation.** The symbol * indicates the training dataset. MDM demonstrates superior robustness to temporal shifts than ARM.

	SlimPajama* (before Jun. 2023)	Fineweb (Feb. & Mar. 2024)	Fineweb (Apr. 2024)
ARM	17.34	27.01	26.93
MDM	18.02	24.06	24.01

=> MDM은 ARM에 비해 Temporal quality degradation 정도가 덜하다

Fatal drawback




Figure 2: **Scaling laws for MDMs.** Compared to ARMs, MDMs demonstrate competitive scalability with comparable scaling rates and similar scaling behavior on utilizing the parameter capacity.

Validation loss를 맞추기 위해 16배의 FLOPs를 사용 (16배의 pre-training)

=> 16배 더 훈련하고 겨우 1.4배 빨리 샘플링하는 꼴이지만 논문에서는 강조하지 않는다.

Table 4: **Conditional generation results.** MDM utilizes 16 times the pre-training time of ARM while ARM utilizes KV-cache.

		MDM		ARM
Score $\uparrow$	1.40	1.56	1.60	1.57
NFEs $\downarrow$	64	128	256	325.94
Time $\downarrow$	204s	396s	780s	555s

Table 12: **MT-Bench results of MDM with 10^{20} pre-training FLOPs.**

	CFG = 0.4	CFG = 0.6	CFG = 0.8
Score	1.21	1.22	1.23

Conclusion

장점과 단점이 명확한 논문

MDM Scaling law 최초 제시

창의적인 sampling

ARM limitation 해결

현실적이지 않은 비교 방식

Q&A