

Analyzing the Effects of Supervised Fine-Tuning on Model Knowledge

From Token and Parameter Levels

Authors: Junjie Ye, Shiqiao Huang, Conghui He, Wentao Zhang

발표자: 조해창 **도움 주신 분:** 자연어처리팀

Affiliation: Shanghai Jiao Tong University, Shanghai AI Laboratory

 EMNLP 2025 Main Conference

2025년 11월 16일

연구 배경: Supervised Fine-Tuning의 숨겨진 측면

- ✓ **SFT의 보편적 활용:** LLM 성능 향상을 위한 핵심 기법으로 자리잡음
- 📈 **성능 vs 지식:** 대부분의 연구가 태스크 성능에만 집중, 지식 변화는 미탐구
- ❓ **불분명한 지식 영향:** SFT가 모델의 실제 지식(knowledge)을 어떻게 변화시키는지 미해명
- ⚠️ **핵심 의문:** 더 많은 데이터로 fine-tuning하면 항상 더 좋은 결과를 얻는가?

핵심 연구 질문: 두 가지 분석 수준



Token Level Analysis

- ? SFT 데이터의 특성(양, 품질)이 지식 습득에 어떤 영향을 미치는가?
- ? 지식 마스터리(mastery) 수준의 역할은 무엇인가?
- ? 데이터 양과 지식 향상의 관계는 선형적인가?



Parameter Level Analysis

- ? 파라미터 업데이트가 지식 향상에 기여하는 정도는?
- ? 효율적인 업데이트와 비효율적인 업데이트의 비율은?
- ? 어떤 레이어가 지식 학습에 더 중요한가?

연구 목표: 체계적 SFT 영향 분석

🔗 **체계적 분석 프레임워크 구축:** Token과 Parameter 수준의 동시 분석으로 SFT의 다층적 영향 파악

📊 **정량적 측정 방법론:** Closed-Book QA 기반 지식 평가 체계로 객관적 측정 가능

📋 **다양한 모델 검증:** LLaMA-2 (7B, 13B) 및 LLaMA-3 (8B) 계열에서 일관된 실험

🎯 **실용적 가이드라인 도출:** SFT 데이터 구성 및 학습 전략에 대한 구체적 지침 제공

✂️ **새로운 분석 도구 제안:** Parameter Restoration, Logits Renormalization 기법 개발

실험 설계: Closed-Book Question Answering 기반 평가

📁 모델 선정: LLaMA-2-7B, LLaMA-2-13B, LLaMA-3-8B

📋 태스크 설계: 외부 지식 참조 없이 모델 내재 지식만으로 답변 (CBQA)

📊 데이터 스케일: 240, 480, 960, 1920개 샘플로 단계적 실험

📈 평가 지표: 정확도(Accuracy), In-domain/Out-of-domain 일반화 성능

🎓 지식 마스터리 수준: 모델이 이미 아는 지식 vs 모르는 지식으로 구분하여 분석

💡 핵심 특징: 동일한 데이터셋으로 다양한 크기의 모델을 학습시켜, 모델 크기와 데이터 양의 상호작용을 체계적으로 분석

핵심 발견 #1: 더 많은 데이터가 더 나쁜 성능?

- ⚠ **충격적 결과:** 1,920개 샘플 학습 모델이 240개 샘플보다 **최대 14% 성능 하락**
 - ✖ **전통적 가정 붕괴:** "More Data = Better Performance" 공식이 항상 성립하지 않음
 - 🧠 **과적합 현상:** 과도한 fine-tuning이 오히려 기존 지식을 손상시킴
 - 💎 **데이터 품질 중요성:** 양보다 질, 특히 지식 마스터리 수준이 결정적 요인
- ⚠ **주의:** 무조건적인 데이터 증강은 오히려 역효과를 낼 수 있음. 전략적 데이터 선택이 필수!

데이터 스케일별 성능 변화 (Figure 2)




Figure 2: In-domain ($\text{Acc}_{\text{test}}^{\text{In}}$) and out-of-domain ($\text{Acc}_{\text{test}}^{\text{Out}}$) performance of the LLaMA-3 family models fine-tuned with varying data scales, where 'All' indicates the use of the entire dataset listed in Appendix D.

Figure 2: LLaMA-3 모델군의 데이터 스케일별 In-domain 및 Out-of-domain 성능

↳ 핵심 관찰: 데이터 규모 증가 시 성능 저하의 역설: 특히 OOD 일반화에서 현저한 성능 감소 관찰

핵심 발견 #2: 지식 마스터리의 결정적 역할 (Table 2)

Source	In-Domain						Out-of-Domain					
	$\text{Acc}_{\text{test}=0}^M$	$\text{Acc}_{\text{test}=1}^M$	$\text{Acc}_{\text{test}=2}^M$	$\text{Acc}_{\text{test}=3}^M$	$\text{Acc}_{\text{test}=4}^M$	$\text{Acc}_{\text{test}}^M$	$\text{Acc}_{\text{test}=0}^M$	$\text{Acc}_{\text{test}=1}^M$	$\text{Acc}_{\text{test}=2}^M$	$\text{Acc}_{\text{test}=3}^M$	$\text{Acc}_{\text{test}=4}^M$	$\text{Acc}_{\text{test}}^M$
$M = \text{LLaMA-3-8B}$												
$D_{\text{train}=0}^M$	1.75 _{0.17}	16.07 _{0.67}	55.03 _{1.39}	71.06 _{1.09}	83.46 _{1.23}	45.47 _{0.40}	1.91 _{0.33}	15.89 _{1.20}	59.01 _{0.51}	74.08 _{0.63}	80.33 _{0.98}	46.24 _{0.29}
$D_{\text{train}=1}^M$	0.98 _{0.14}	40.12 _{0.74}	63.93 _{0.55}	74.19 _{0.73}	84.22 _{0.96}	52.69 _{0.88}	1.66 _{0.09}	23.88 _{0.45}	65.03 _{0.77}	79.63 _{0.63}	83.84 _{0.65}	50.80 _{0.45}
$D_{\text{train}=2}^M$	0.78 _{0.03}	36.56 _{0.53}	75.61 _{1.18}	83.98 _{1.37}	90.71 _{1.31}	57.53 _{0.86}	1.45 _{0.35}	25.02 _{0.30}	70.52 _{1.39}	83.66 _{0.67}	87.89 _{0.45}	53.71 _{0.49}
$D_{\text{train}=3}^M$	0.64 _{0.15}	27.20 _{0.69}	70.33 _{1.73}	85.90 _{1.47}	91.66 _{1.57}	55.15 _{1.64}	1.39 _{0.34}	21.66 _{1.13}	63.91 _{2.70}	81.34 _{0.93}	86.87 _{1.85}	51.04 _{1.73}
$D_{\text{train}=4}^M$	0.64 _{0.06}	24.26 _{0.38}	68.28 _{2.00}	83.29 _{1.23}	93.19 _{1.91}	53.93 _{1.56}	0.93 _{0.11}	17.72 _{1.33}	63.64 _{4.39}	80.55 _{2.05}	88.43 _{1.47}	50.25 _{1.83}
$M = \text{LLaMA-3-70B}$												
$D_{\text{train}=0}^M$	3.72 _{0.33}	22.68 _{1.53}	47.28 _{1.26}	57.97 _{2.25}	72.08 _{3.20}	40.75 _{1.31}	3.08 _{0.39}	25.90 _{1.59}	67.04 _{1.63}	82.61 _{0.95}	85.74 _{1.30}	52.87 _{0.79}
$D_{\text{train}=1}^M$	1.94 _{0.11}	43.85 _{0.29}	63.45 _{1.47}	66.22 _{1.66}	79.54 _{0.65}	51.00 _{0.53}	2.61 _{0.45}	31.01 _{0.79}	72.63 _{0.16}	84.69 _{0.30}	86.22 _{0.69}	55.43 _{0.26}
$D_{\text{train}=2}^M$	1.23 _{0.07}	38.17 _{1.78}	71.68 _{0.82}	77.58 _{1.27}	85.89 _{1.44}	54.91 _{0.89}	2.06 _{0.50}	31.26 _{2.10}	74.51 _{1.27}	88.63 _{0.97}	92.01 _{1.19}	57.69 _{1.16}
$D_{\text{train}=3}^M$	1.00 _{0.11}	31.52 _{0.61}	68.32 _{0.30}	81.11 _{0.73}	88.49 _{0.60}	54.09 _{0.45}	1.91 _{0.79}	26.70 _{1.71}	69.60 _{2.77}	89.61 _{1.44}	91.22 _{1.39}	55.81 _{1.47}
$D_{\text{train}=4}^M$	0.90 _{0.05}	26.16 _{1.45}	64.27 _{0.75}	78.00 _{0.43}	89.83 _{0.77}	51.83 _{0.65}	0.81 _{0.35}	21.80 _{1.65}	66.52 _{5.65}	84.85 _{2.57}	92.29 _{2.63}	53.25 _{2.97}

Table 2: Performance of the fine-tuned LLaMA-3 family models on in-domain and out-of-domain test sets, using 1920 data points with varying levels of mastery.

Table 2: 마스터리 수준별 LLaMA-3 모델 성능 비교

💡 핵심 인사이트

- **12% 이상 성능 변동:** 동일 데이터 양이라도 마스터리 수준에 따라 극적 차이 발생
- **최적 조합 존재:** 모델의 현재 지식 상태와 매칭되는 데이터 선택이 핵심
- **맹목적 증강의 한계:** 전략적 데이터 선택이 무조건적 데이터 증강보다 훨씬 효과적

핵심 발견 #3: 파라미터 업데이트의 충격적 비효율성

~90%

지식 향상에 기여하지 않는 파라미터 업데이트 비율

✖ **90% 비기여**: SFT 중 대부분의 파라미터 업데이트가 지식 향상에 기여하지 않음

≡ **형식 학습 편중**: 대부분의 업데이트가 Format Learning에만 사용됨

🔦 **실질 지식 습득 부족**: 실제 지식 강화를 위한 업데이트는 극히 제한적

⚠️ **시사점**: 현재 SFT 방식은 대부분의 컴퓨팅 자원을 형식 학습에 낭비하고 있음. 근본적인 방법론 개선 필요!

분석 방법론 #1: Parameter Restoration 기법




Figure 1: Parameter Restoration 프로세스 일러스트레이션

- 1 기본 개념: Fine-tuned 모델의 파라미터를 원래 값으로 점진적 복원
- 2 분석 목적: 어떤 파라미터 변화가 지식 향상에 기여했는지 식별
- 3 결과 해석: 복원 시 성능 변화를 통해 파라미터별 중요도 측정

Restore	$\mathcal{D}_{\text{train}}^M$ 0	$\mathcal{D}_{\text{train}}^M$ 1	$\mathcal{D}_{\text{train}}^M$ 2	$\mathcal{D}_{\text{train}}^M$ 3	$\mathcal{D}_{\text{train}}^M$ 4
Number of Training Data: 240					
0	55.33	57.96	59.32	59.12	53.97
1%	55.76	58.17	59.62	59.24	54.30
3%	56.64	58.52	59.77	59.40	54.31
5%	57.22	58.68	59.89	59.63	54.44
10%	58.32	59.45	60.40	59.83	54.69
20%	59.07	59.81	59.88	59.91	46.45
40%	59.77	53.40	42.44	11.20	23.83
60%	1.68	2.20	3.65	2.56	1.65
Number of Training Data: 1920					
0	44.96	52.43	58.80	57.70	55.22
1%	46.73	53.72	59.85	58.68	55.88
3%	48.53	55.01	60.56	59.23	56.76
5%	49.85	55.96	61.10	59.65	57.34
10%	52.10	57.14	61.67	60.02	58.24
20%	54.81	58.33	62.21	58.93	58.66
40%	55.44	22.06	59.97	6.92	56.50
60%	1.48	1.12	1.62	0.51	0.60

(a) In-Domain ($\text{Acc}_{\text{test}}^M$)

Restore	$\mathcal{D}_{\text{train}}^M$ 0	$\mathcal{D}_{\text{train}}^M$ 1	$\mathcal{D}_{\text{train}}^M$ 2	$\mathcal{D}_{\text{train}}^M$ 3	$\mathcal{D}_{\text{train}}^M$ 4
Number of Training Data: 240					
0	52.37	51.70	55.35	55.23	50.69
1%	52.62	52.39	56.45	56.17	50.82
3%	53.03	52.82	56.47	56.41	50.74
5%	53.27	53.09	56.80	56.56	50.59
10%	53.44	53.87	56.46	56.72	49.71
20%	54.18	54.36	55.95	55.52	43.13
40%	53.79	20.77	45.49	17.56	31.19
60%	0.20	0.22	0.32	0.20	0.23
Number of Training Data: 1920					
0	49.40	52.38	54.04	53.79	51.70
1%	50.78	54.20	55.17	54.75	52.62
3%	52.03	55.12	56.00	55.52	53.35
5%	52.54	55.12	56.34	55.84	53.77
10%	53.42	55.08	56.68	55.54	54.32
20%	54.50	53.91	57.10	52.23	53.82
40%	53.64	20.51	53.84	9.67	50.17
60%	0.30	0.10	0.27	0.07	0.18

(b) Out-of-Domain ($\text{Acc}_{\text{testOOD}}^M$)

Table 4: Experimental Results

분석 방법론 #2: Logits Renormalization 기법

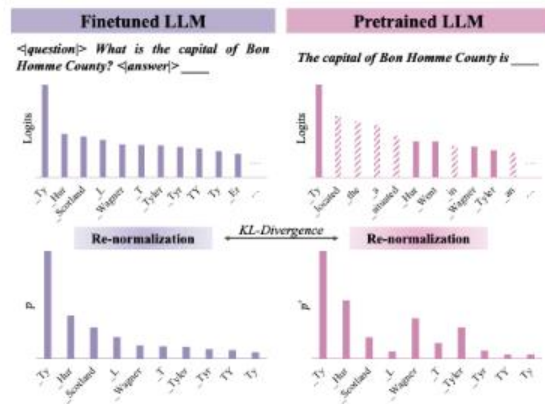


Figure 3: Logits Renormalization 프로세스 일러스트레이션

- 1 기본 개념: Fine-tuned 모델의 logits을 base 모델 기준으로 재정규화
- 2 분석 목적: 형식 학습 효과를 분리하여 순수 지식 변화만 측정
- 3 수학적 접근: Logit space에서 bias 제거를 통한 정확한 지식 평가

Token Level 분석: 데이터 특성과 지식 전이

✱ **질문-답변 복잡도**: 복잡한 QA 쌍이 더 많은 지식 전이를 유발

트 **토큰 빈도 분포**: 답변 토큰의 출현 빈도가 학습 효과에 영향

📖 **지식 중복도**: 기존 지식과의 중복이 높을수록 추가 학습 효과 감소

⚖️ **새로운 지식 vs 강화**: 새로운 지식 추가와 기존 지식 강화 사이의 균형 필요

🔍 **토큰 수준 분석의 가치**: 세밀한 데이터 분석이 SFT 성공의 열쇠

💡 **실용적 시사점**: SFT 데이터를 구성할 때, 단순히 양을 늘리기보다 토큰 수준의 특성을 고려해야 함

Parameter Level 분석: 레이어별 학습 패턴



Early Layers

- 일반적 언어 패턴 조정
- 형식(format) 학습에 집중
- 상대적으로 적은 지식 기여
- 토큰 임베딩 및 기초 표현 학습



Later Layers

- 지식 특화 파라미터 업데이트
- 실질적 지식 향상에 기여
- 선택적 업데이트 가능성
- 고수준 의미 표현 및 추론

⚙️ **전략적 시사점:** 모든 레이어를 동일하게 업데이트하는 대신, 레이어별 역할에 맞춘 선택적 fine-tuning 전략이 더 효율적일 수 있음

결론: 효과적인 SFT를 위한 새로운 패러다임

- ✓ **데이터 양 < 데이터 품질**: 무조건적 데이터 증강의 한계 실증적 입증
 - ✓ **지식 마스터리 고려 필수**: 모델의 현재 지식 상태에 맞는 맞춤형 데이터 선택
 - ✓ **파라미터 효율성 개선 필요**: 90% 비효율 업데이트 제거 전략 개발 시급
 - ✓ **실용적 가이드라인 제공**: SFT 데이터 구성 및 학습 전략에 대한 구체적 지침
 - ✓ **분석 도구 개발**: Parameter Restoration, Logits Renormalization 등 새로운 방법론
- ✓ **핵심 메시지**: "더 많이"가 아닌 "더 똑똑하게" - 지식 인식형(Knowledge-Aware) Fine-Tuning이 미래의 방향

향후 연구 방향: Knowledge-Aware Fine-Tuning

📌 **지식 인식형 데이터 선택**: 모델 상태 기반 동적 데이터 큐레이션 알고리즘

⚙️ **선택적 파라미터 업데이트**: 지식 기여 파라미터만 집중 학습하는 효율적 방법론

📊 **자동화된 마스터리 평가**: 실시간 지식 마스터리 수준 측정 도구 개발

🔗 **다양한 태스크 확장**: CBQA 외 다른 NLP 태스크로 연구 범위 확대

📏 **대규모 모델 검증**: GPT-4, Claude 등 더 큰 모델에서의 검증 필요

💡 **감사합니다**

질문 및 토론 환영합니다