



SSLA: A GENERALIZED ATTRIBUTION METHOD FOR INTERPRETING SELF- SUPERVISED LEARNING WITH- OUT DOWNSTREAM TASK DEPENDENCY

Under review as a conference paper at ICLR, 2025

이미지 처리팀
강인하 장보아 허정원 황장훈

AGENDA

01

INTRODUCTION

02

RELATED WORK

03

METHODS

04

EXPERIMENTS

05

CONCLUSION




01 INTRODUCTION

Self-Supervised Learning

Background

- 빅데이터 시대의 도래로 레이블이 없는 대량의 데이터가 사용 가능해짐
- SSL은 **레이블 없는 데이터에서 의미 있는 특징 표현을 자동으로 추출**하기 위해 제안됨
- SSL은 컴퓨터 비전, 자연어 처리, 음성 인식 등 다양한 분야에서 큰 잠재력을 보여줌
- SSL의 장점과 한계
 - 장점:
 - 레이블 없는 데이터 활용
 - 레이블링 비용 감소
 - 모델 일반화 능력 향상
 - 한계:
 - SSL task의 해석 가능성이 상대적으로 미흡함
 - 인간의 주석이 없어 모델의 학습 과정과 결정 근거가 더 모호할 수 있음



Self-Supervised Learning

Interpretability of SSL

- SSL을 통한 모델 학습 과정은 기존 supervised learning 보다 훨씬 불투명한 측면이 존재
- 라벨 정보 없이 학습되는 과정에서 모델이 어떤 특성을 학습하고, 어떤 근거로 결과를 도출하는지 명확히 파악하기 어렵기 때문
- 이러한 해석력 (interpretability) 부족은 모델 신뢰성, 투명성, 그리고 잠재적 편향성 확인 측면에서 문제가 될 수 있음
- **현재 SSL 해석 방법의 한계**
 - **Downstream Task 의존성:** 기존 SSL 해석 방법은 Downstream Task 정보를 활용하여 모델을 해석하며, 이는 SSL 모델 자체를 해석하지 않고 Downstream Task의 특성을 포함하게 됨
 - **추가 샘플 의존성:** 일부 해석 방법은 현재 샘플 외의 추가 샘플을 필요로 하며, 이는 해석 과정에 불필요한 정보를 도입함
 - **특정 아키텍처 종속성:** 많은 방법이 Transformer 등의 특정 모델 구조에 의존하며, 다른 구조 (CNN 등)에서는 동작하지 않음

Contribution

Proposed Methods

- 본 논문에서는 SSL 과제의 해석가능성 확보를 위해 '**attribution**' 기반 접근을 제안하고, 이는 모델 출력과 입력 특징 사이의 대응 관계를 명확히 해석함으로써, 모델이 unlabeled 데이터에서 어떤 관찰 포인트나 특징에 의존해 의미를 추출하는지를 정교하게 밝히는 방식
- 기존 해석 연구들이 주로 특정 downstream task나 특정 모델 구조에 종속적이었다면, 이 연구는 이러한 제한을 넘어서는 보다 일반화된 해석 방법론을 제안하고자 하였음
- 궁극적으로 SSL이 “**어떤 불변적 특징**”을 포착하는가를 기반으로 해석 방법을 설계함으로써, 다양한 모델 아키텍처나 downstream task 없이도 안정적으로 SSL의 내부 작동 원리를 파악할 수 있음
- 본 논문은 “**label이 없는 방대한 데이터 속에서 모델이 무엇을, 어떻게 학습하고 있는가?**”라는 질문에 답하기 위한 새로운 해석 프레임워크를 제시
- 이는 향후 SSL 연구가 더욱 투명하고 신뢰성 있는 모델 개발로 이어질 수 있는 토대를 제공



02 RELATED WORK


SELF-SUPERVISED LEARNING

자기지도학습 (SSL)의 목적

- 수동 주석 없이 대량의 레이블 없는 데이터에서 표현을 학습
- 학습된 표현을 다운스트림 작업 훈련에 활용

Contrastive Learning (CL)


- 대조 학습은 SSL의 인기 있는 접근 방식으로, 다음과 같은 특징을 가짐
 - 동일 이미지의 다른 증강 뷰 간 거리는 최소화
 - 서로 다른 이미지의 뷰 간 거리는 최대화
- 주요 연구:
 - SimCLR: 특수한 부정 쌍 없이 지도학습에 준하는 성능 달성
 - MoCo-v3: 모멘텀 인코더와 큐를 사용하여 대조 학습 성능 향상
 - BYOL: 부정 쌍 없이 효과적인 표현을 학습하는 자기 증류 기반 방법 도입
 - SimSiam: BYOL 프레임워크를 단순화하고 모델 붕괴 방지를 위한 stop-gradient 연산의 중요성 입증



SELF-SUPERVISED LEARNING

Masked Image Modeling (MIM)

- MIM은 SSL의 또 다른 중요한 분야로, 다음과 같은 특징을 가집니다: 이미지 패치를 무작위로 마스킹하고 누락된 부분을 재구성
 - 주로 Transformer 아키텍처에 의존
 - Masked Autoencoders (MAE)가 대표적인 예시
- 논문의 접근 방식
 - 특정 모델 아키텍처나 매개변수에 의존하지 않는 일반적인 자기지도 방법의 해석 가능성에 초점
 - MAE에 대한 실험 결과도 제시하여 시각적 표현 학습에서의 효과성 입증



INTERPRETABILITY OF TRADITIONAL MODELS

Limitations of traditional models

- Shapley 값 기반 방법 (예: SHAP)
 - 이론적으로는 매력적이나 실제 적용에서 한계 존재
 - 복잡한 모델 (예: 심층 신경망)에서 계산 비용이 높아 실용성 저하
- RISE (Random Input Sampling for Explanation)
 - 입력 특징을 무작위로 마스킹하여 모델 출력 변화 관찰
 - 고차원 입력 (예: 이미지)에서 계산 병목 현상 발생
- SSL 작업 해석의 어려움
 - SSL 훈련의 내재된 무작위성
 - 명시적인 다운스트림 작업 레이블 부재
 - 모델의 표현 능력에 대한 정확한 Attribution 제공의 어려움

INTERPRETABILITY OF TRADITIONAL MODELS

Attribution techniques

- Attribution techniques은 모델의 예측 결과에 input feature들이 어떤 기여를 하는지 파악할 수 있는 기술
- Attribution methods의 중요성
 - Attribution methods은 두 가지 중요한 공리 (**Axioms**)를 따름
 - 민감도 (Sensitivity): baseline과 하나의 feature만 다른 input이 다른 예측 결과를 낳는다면, 그 특징에 non-zero attribution을 할당해야 함
 - 구현 불변성 (Implementation Invariance): 기능적으로 동등한 두 신경망은 구현이 다르더라도 일관된 attribution 결과를 가져야 함
- 기존 Attribution methods의 SSL task 적용 한계
 - 작업 특정성 (Task-specific): 대부분의 방법이 특정 다운스트림 작업(예: 분류)에 맞춰 설계됨
 - SSL의 사전 훈련 단계는 특정 작업 레이블과 독립적이어서 직접 적용이 어려움
 - 무작위성 처리 (Random operations): SSL 훈련 과정의 많은 무작위 연산 (예: 데이터 증강, 대조 학습의 부정 샘플 선택)을 다루는 데 한계 존재
 - 안정적인 귀속 결과 제공이 어려움

INTERPRETABILITY OF SSL

Interpretability of SSL

- SSL 모델의 해석 가능성 연구는 아직 초기 단계에 있음
- 기존 접근 방식과 한계
 - Attribution Guided Factorization (AGF) 방법
 - Gradient와 attribution 정보를 결합하여 지도 학습 및 SSL 모델의 시각적 해석을 달성
 - 한계:
 - 특정 다운스트림 작업의 통합이 필요함
 - 귀속 결과가 특정 작업에 국한되어 SSL 모델이 추출한 일반적인 특징을 반영하지 못함
 - SSL의 목적과 상충됨
 - 계층적 잠재 변수 모델 (Hierarchical latent variable model)
 - MAE의 심층적 해석 가능성 분석에 사용됨
 - 한계:
 - 주로 Transformer 아키텍처에만 적용 가능
 - 현재 non-Transformer SSL 모델의 우수한 성능을 설명하지 못함

Q & A



03 METHODS

PREREQUISITES FOR SELF-SUPERVISED LEARNING ATTRIBUTION

“Prerequisite 1: The interpretation of SSL should not introduce information from downstream tasks.”

- SSL 모델을 해석할 때, 일반적으로 SSL 모델 f_{θ} 에 이어 붙이는 downstream task model g_{ϕ} 나 그 파라미터 ϕ 를 이용하지 않아야 한다는 점을 강조
 - 이는 downstream task에서 얻은 추가적인 정보가 모델 해석 과정에 섞이는 것을 방지하기 위함
- 만약 downstream task 정보가 유입된다면, 결과적으로 해석 대상이 SSL 그 자체의 representation 능력이 아니라 downstream task로 인한 변형을 반영한 모델 상태가 됨
 - 오직 SSL로 학습한 encoder f_{θ} 가 본래의 unlabeled data를 통해 어떤 특징을 추출하고 있는지 “순수하게” 해석하기 위해서는 downstream task 관련 요소를 배제해야 함

PREREQUISITES FOR SELF-SUPERVISED LEARNING ATTRIBUTION

“Prerequisite 2: The interpretation process should not introduce samples other than the current sample.”


- 해석할 때, 현재 분석 대상인 sample x 이외에 추가적인 다른 sample을 도입하지 않아야 함
- 다른 데이터 포인트를 불러와 해석에 활용하면, 그 과정에서 sample 간의 상호작용 정보가 섞여 들어가게 되고, 이는 “모델이 현재 sample을 통해 어떤 특징을 학습했는가”라는 관점보다 “샘플 간 관계”를 반영하는 결과로 이어질 수 있기 때문임
- 따라서 해석은 오직 주어진 single input에만 초점을 맞추고, 그 input이 모델 내에서 어떤 식으로 처리되는지를 밝혀내는 방식으로 진행되어야 함

PREREQUISITES FOR SELF-SUPERVISED LEARNING ATTRIBUTION

“Prerequisite 3: The interpretation process should not be restricted to specific model architectures.”

- SSL 알고리즘은 encoder 구조에 대한 구체적인 제약 없이 적용 가능하다는 점이 하나의 강점이다. 그러므로 해석 기법 또한 특정 모델 아키텍처(예: Transformers, CNN 등)에 종속적이지 않게 설계되어야 함
 - 예를 들어, self-attention 기반 해석 방식만을 사용한다면, CNN 기반 encoder를 사용하는 SSL 모델에서는 해석 불가능하거나 의미가 달라질 수 있음
 - 따라서 SSL을 해석하는 attribution 기법은 모델 구조에 대한 추상화를 유지하며, 다양한 아키텍처에 두루 적용 가능한 일반적인 방법을 제안하는 것이 중요함
- 이 세 가지 Prerequisite는 SSLA 기법을 포함한 SSL 해석 방법이 다운스트림 정보나 추가 샘플에 의존하지 않고, 모델 구조에 종속적이지 않은 형태로 설계될 것을 요구함

SELF-SUPERVISED LEARNING ATTRIBUTION (SSLA)



• SSLA의 핵심 아이디어

- SSL의 본질은 변화 속에서 불변하는 특징을 찾는 것
 - 입력 샘플에 여러 augmentation을 적용하더라도 의미가 유지되는 특징을 추출하기를 기대
 - 즉, "불변적인 특징(invariant features)"을 어떻게 포착하는지를 해석하기 위한 Attribution 방법론
- 코사인 유사도를 사용하여 유사성을 평가: $\cos(f_\theta(\tau_1(x)), f_\theta(\tau_2(x)))$
- 각 feature의 불변적 표현 형성 기여도 정량화

SELF-SUPERVISED LEARNING ATTRIBUTION (SSLA)

SSLA의 핵심 포인트

• 불변성(Invariance) 추출

- 변환 전후 추출된 특징 벡터 간 유사도 관찰
- 높은 유사도 = 모델이 의미 있는 불변적 특징 잘 추출


• SSLA의 평가 함수 $S(x, f_\theta, Z)$

- 코사인 유사도 활용하여 불변적 특징 학습 정도 측정
- $S(x, f_\theta, Z)$ 값이 클수록 모델이 불변적 특징 잘 학습했다고 해석

$$S(x, f_\theta, Z) = E_{z \sim Z} [\cos(f_\theta(x), z)] = \frac{1}{N} \sum_{i=1}^N \cos(f_\theta, z_i)$$

• SSLA의 주요 장점

- 다운스트림 태스크나 추가 샘플 불필요
- 단일 샘플만으로 평가 가능
- 모델 구조와 무관한 평가



SELF-SUPERVISED LEARNING ATTRIBUTION (SSLA)

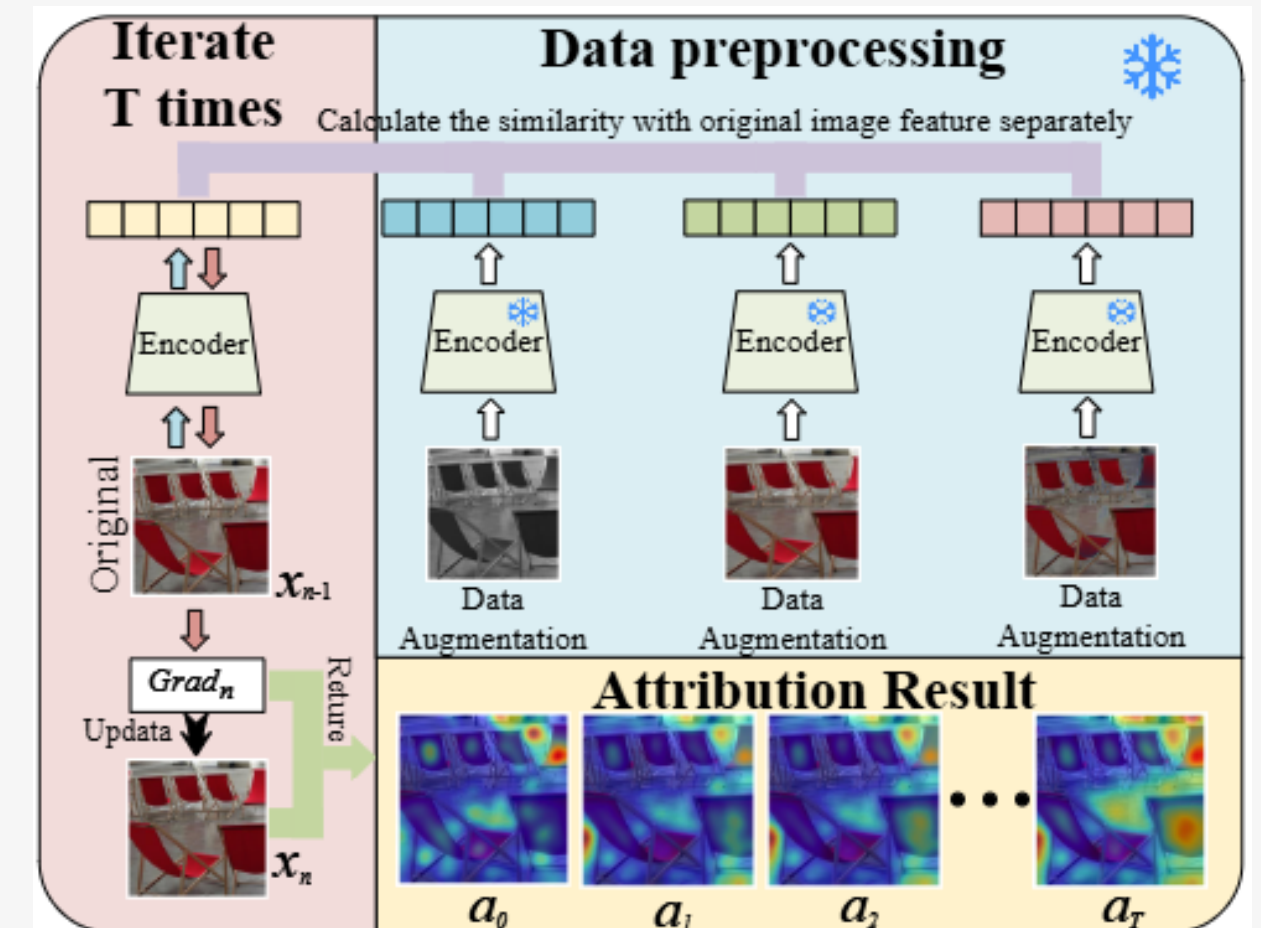
SSLA 설계 원칙과 작동 메커니즘

• SSLA의 설계 원칙 - Attribution 기법의 두 가지 중요한 Axioms을 만족

- a) Sensitivity (민감도)
- b) Implementation Invariance (구현 불변성)

• SSLA의 작동 메커니즘

- 입력 샘플 x 의 각 특징을 미세하게 변화시킨 샘플의 집합 Z 를 준비
- 모델 f_θ 를 사용하여 원본 샘플과 변환된 샘플들의 특징을 추출
- 원본 특징과 변환된 특징들 간의 코사인 유사도를 계산
- 입력 x 의 각 특징에 대해 $S(x, f_\theta, Z)$ 의 Gradient를 계산
- Gradient와 입력의 요소별 곱을 통해 Attribution 값 $A(x)$ 을 획득
- $A(x)$ 의 각 요소 값이 클수록, 해당 입력 특징이 불변적 표현 형성에 더 중요하다고 해석



Algorithm 1 Self-Supervised Learning Attribution (SSLA)

Input: Iterate times T , Data Augmentation Z , model parameter θ

Output: A

- 1: **Initial:** $A = 0, x_0 = x$
- 2: **for** t in range $(1, T)$ **do**
- 3: $A = A + \frac{x}{T} \cdot \left| \frac{\partial S(x_{t-1}, f_\theta, Z)}{\partial x_{t-1}} \right|$
- 4: $x_t = x_{t-1} - \frac{x}{T} \cdot \text{sign} \left(\frac{\partial S(x_{t-1}, f_\theta, Z)}{\partial x_{t-1}} \right)$
- 5: **end for**
- 6: **return** A



04 EXPERIMENTS

EXPERIMENTS

Dataset and Model

- 데이터셋 및 모델
 - ImageNet 이미지 데이터셋 사용
 - ResNet-50 모델을 실험 백본으로 사용
- 다음 5가지 대표적인 SSL 방법들을 SSLA로 평가
 - BYOL: 부트스트래핑 양성 샘플 쌍을 통해 학습
 - SimCLR: 대규모 부정 샘플을 활용한 대조 학습
 - SimSiam: Simsiam 네트워크 구조로 양성 샘플 쌍만으로 학습
 - MoCo-v3: 모멘텀 인코더로 동적 부정 샘플 큐 생성
 - MAE: 마스킹을 통해 전역 문맥 정보 학습

EXPERIMENTS

Evaluation

- 새로운 접근 필요성
 - 기존 방법(Insertion score, Deletion score, INFD score)은 SSL 작업 해석에 부적합
 - SSL의 특성을 고려한 새로운 평가 방법 도입
- Masking 기반 평가 방법
 - 중요 특징과 덜 중요한 특징 마스킹 시 모델 출력 변화 비교
 - 두 가지 시나리오 사용
 - a) Mask Important (MI): 중요 특징 마스킹 → 중요 특징 마스킹 시 모델 출력에 큰 영향
 - b) Mask Unimportant (MU): 덜 중요한 특징 마스킹 → 덜 중요한 특징 마스킹 시 모델 출력에 작은 영향
- 평가 방법의 장점
 - SSL 모델의 특성, 특히 불변성에 초점을 맞춘 평가가 가능
 - 특징의 상대적 중요도를 직접적으로 파악
 - 레이블이 필요 없어 SSL의 본질을 해치지 않음

EXPERIMENTS

Results

- 중요 특징 마스킹 (MI)
 - SSLA가 Random Mask보다 우수한 성능 달성
 - 50% Mask Rate에서 MAE의 경우 SSLA 0.89, Random Mask 0.80의 유사도 점수 기록
- 중요하지 않은 특징 마스킹 (MU)
 - SSLA가 일관되게 더 낮은 유사도 점수 생성
 - MoCo-v3의 경우 50% Mask Rate에서 SSLA 0.65, Random Mask 0.68의 유사도 점수 기록
- 높은 Mask Rate에서의 성능
 - 90% Mask Rate에서 SSLA가 지속적으로 Random Mask보다 우수한 성능 유지

	BYOL			SimCLR			SimSiam			MoCo-v3			MAE		
Mask Rate	Random Mask	SSLA MI	SSLA MU	Random Mask	SSLA MI	SSLA MU	Random Mask	SSLA MI	SSLA MU	Random Mask	SSLA MI	SSLA MU	Random Mask	SSLA MI	SSLA MU
0%	0.62	-	-	0.56	-	-	0.57	-	-	0.53	-	-	0.68	-	-
10%	0.64(±0.0099)	0.66	0.64	0.59(±0.0113)	0.60	0.58	0.59(±0.0077)	0.62	0.59	0.55(±0.014)	0.57	0.54	0.70(±0.0932)	0.74	0.69
20%	0.66(±0.01)	0.70	0.66	0.61(±0.011)	0.64	0.61	0.62(±0.0081)	0.66	0.61	0.57(±0.0134)	0.60	0.56	0.72(±0.0855)	0.78	0.70
30%	0.68(±0.009)	0.73	0.68	0.63(±0.0109)	0.67	0.63	0.65(±0.0073)	0.71	0.63	0.60(±0.0122)	0.64	0.59	0.75(±0.0796)	0.82	0.72
40%	0.71(±0.0084)	0.77	0.70	0.67(±0.0103)	0.72	0.66	0.68(±0.0071)	0.76	0.66	0.64(±0.0116)	0.69	0.62	0.78(±0.071)	0.86	0.74
50%	0.74(±0.0074)	0.81	0.73	0.70(±0.0095)	0.76	0.70	0.72(±0.0063)	0.81	0.69	0.68(±0.0099)	0.73	0.65	0.80(±0.0639)	0.89	0.76
60%	0.78(±0.0065)	0.85	0.76	0.74(±0.0086)	0.82	0.74	0.76(±0.0054)	0.86	0.73	0.72(±0.0085)	0.79	0.70	0.84(±0.0536)	0.92	0.79
70%	0.82(±0.0052)	0.90	0.80	0.79(±0.0076)	0.87	0.79	0.81(±0.0047)	0.90	0.77	0.78(±0.0072)	0.84	0.75	0.87(±0.0418)	0.95	0.83
80%	0.88(±0.004)	0.94	0.85	0.85(±0.006)	0.92	0.85	0.88(±0.0037)	0.95	0.83	0.85(±0.0053)	0.90	0.82	0.91(±0.0292)	0.97	0.87
90%	0.95(±0.0023)	0.98	0.92	0.92(±0.004)	0.97	0.92	0.95(±0.0024)	0.98	0.91	0.93(±0.0031)	0.97	0.90	0.96(±0.014)	0.99	0.92
100%	1.0(±0.0)	1	1	1.0(±0.0)	1	1	1.0(±0.0)	1	1	1.0(±0.0)	1	1	1.0(±0.0)	1	1



05 CONCLUSION

CONCLUSION

- **주요 성과**

- SSLA(Self-Supervised Learning Attribution) 방법 제안
- 다양한 SSL 방법에 대한 광범위한 실험 수행
- SSLA의 강건성과 적용 가능성 입증

- **SSLA의 핵심 특징**

- 효과적인 특징 귀속:모델의 의사 결정 과정에서 중요한 특징과 덜 중요한 특징을 구별
- 랜덤 마스킹 전략 대비 우수한 성능:더 정확하고 안정적인 귀속 제공
- 모델 가이드 능력:의사 결정에 실제로 영향을 미치는 영역에 모델이 집중하도록 유도

Q & A

THANK YOU.