


WHAT DO SELF-SUPERVISED VISION TRANSFORMERS LEARN?

ICLR 2023

이미지처리팀


파트 별 준비 : 최비결

발표자 : 황장훈



Index

1. INTRODUCTION
2. HOW DO SELF-ATTENTIONS BEHAVE?
3. HOW ARE REPRESENTATIONS TRANSFORMED?
4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?
5. ARE THE TWO METHODS COMPLEMENTARY TO EACH OTHER?
6. CONCLUSION

A large, stylized purple number '04' is centered in the background. The '0' is a thick, rounded shape, and the '4' is composed of a thick diagonal stroke and a thick vertical stroke.

INTRODUCTION

1. INTRODUCTION

- 대조 학습(Contrastive Learning, CL)

- CL의 목표는 두 개의 랜덤한 뷰(random views)에 대해 양의 샘플(positive sample)의 표현은 유사하게, 음의 샘플(negative sample)의 표현은 상이하게 만드는 것.
→ 두 뷰가 공유하는 불변 의미(invariant semantics)를 학습하는 것
- 전역적으로 투영된(global projection) 표현들을 서로 대조(contrast)함으로써 학습
→ “이미지 단위(image-level)” 자기 지도 학습 방식






Fig 1. Contrastive Learning Example

- 마스크드 이미지 모델링(Masked Image Modeling, MIM)

- MIM은 입력 이미지의 일부 패치를 마스크(mask)한 뒤, 가려진 패치의 올바른 의미(semantics)를 복원(reconstruct)하도록 ViT를 학습
→ CL과 달리, MIM은 개별 패치 토큰(patch token)의 의미를 학습하므로, 이는 “토큰 단위(token-level)” 자기 지도 학습 방식





1. INTRODUCTION

- MIM은 파인튜닝(fine-tuning) 정확도에서 CL보다 우수한 성능을 보이기 때문에, 언뜻 보기에는 CL보다 더 효과적인 사전 학습(pre-training) 방법처럼 보일 수 있음.

그러나, 흥미롭게도, 선형 프로빙(linear probing) 정확도에서는 CL이 MIM보다 더 우수한 경향을 보임.

→ 그렇다면, ViT의 자기 지도 학습(Self-Supervised Learning)에서는 CL과 MIM 중 어느 방법을 사용해야 할까?

본 논문은 CL과 MIM을 통해 학습된 ViT가 서로 반대되는 성질의 지식(opposite knowledge)을 학습한다는 사실을 보여줌으로써, 두 방법의 본질을 밝힘.

특히, 자기 지도 학습의 원리를 더 깊이 이해하기 위해 몇 가지 핵심 질문을 제기하고, 그에 대한 답을 찾아 향후 방법론의 발전에 영향을 줄 수 있는 통찰을 도출하고자 함.

1. Self-Attention의 동작 방식
2. 표현의 변환 과정
3. 핵심 구성요소의 역할이 중심으로 나타나는 위치

A large, stylized purple smiley face is centered in the background. It consists of two thick, curved lines for eyes and a thick, horizontal line for a mouth, all in a vibrant purple color.

HOW DO SELF-ATTENTIONS BEHAVE?

2. HOW DO SELF-ATTENTIONS BEHAVE?

- CL과 MIM은 모든 과제에 대해 만능이 아님.
 - CL은 선형 프로빙에서 MIM보다 우수한 성능을 보이는 반면,
 - MIM은 파인튜닝 환경에서는 CL보다 더 뛰어난 성능을 보임.
- 하지만 모델의 크기(model size)에 따라 양상이 달라짐.
 - 소형 모델에서는, 파인튜닝 이후에도 CL이 MIM보다 더 나은 성능
 - 대형 모델에서는 MIM이 CL을 능가
- 또한, MIM은 객체 탐지와 같은 고밀도 예측(dense prediction) 과제에서보다 효과적인 표현을 학습하지만, CL은 이러한 과제에서는 한계를 보임.





Figure 1: **CL outperforms MIM in linear probing and small model regimes.** In contrast, MIM excels in fine-tuning, large model regimes, and dense prediction. Red squares (■) denote CL, and blue triangles (▲) denote MIM. By default, we report the performance of ViT-B trained or pre-trained on ImageNet-1K. We use the results from original papers and He et al. (2022) for object detection. Regarding the scaling experiment, we report the results that we reproduced based on official configurations except with 100 epochs, marking them as MoCo[†] and SimMIM[†]. *Left:* CL outperforms MIM in linear probing but underperforms in fine-tuning. *Middle:* CL outperforms MIM in small model regimes (ViT-Ti and ViT-S), and MIM shows superior scalability in large model regimes (ViT-L and ViT-H). *Right:* MIM outperforms CL in the dense prediction downstream tasks, such as object detection with Mask R-CNN (He et al., 2017) on COCO (Lin et al., 2014).



2. HOW DO SELF-ATTENTIONS BEHAVE?

- CL은 주로 전역적(global) 관계를 포착
 - 이를 확인하기 위해, Self-Attention의 범위를 어텐션 거리(attention distance)를 통해 측정

어텐션 거리(Attention Distance)란?

: 각 쿼리 토큰(query token)이 어떤 키 토큰(key token)에 주의를 얼마나 분산시키는지를 고려하여, 그들 사이의 평균 거리(average distance)를 계산한 값

즉, 어텐션 거리는 Self-Attention이 얼마나 멀리 떨어진 토큰까지 정보를 통합하는지를 나타내는 척도

→ 개념적으로 보면 CNN(합성곱 신경망)에서의 수용영역(Receptive Field) 크기와 대응

2. HOW DO SELF-ATTENTIONS BEHAVE?

- CL(MoCo)의 어텐션 거리(attention distance)가 MIM(SimMIM)보다 훨씬 크다는 것을 보여줌.
이 차이는 특히 ViT의 후반부 계층(later layers)에서 두드러지게 나타남.




Figure 3: **Effective receptive fields of CL are global, but those of MIM are local.** This is particularly evident in the later layers.

2. HOW DO SELF-ATTENTIONS BEHAVE?

- CL의 표현이 전역적 패턴(global patterns)과 형태 정보(shape information)를 포함하고 있음을 의미
→ CL은 ViT가 이미지 내 객체를 구분하는데 도움을 줌.
- 반면, MIM의 Self-Attention은 주로 국소적 관계(local relationships)를 포착
→ 전체 객체(whole object)나 그 형태(shape)를 인식하는 데에는 상대적으로 어려움을 겪을 수 있음.




Figure 2: **Self-attentions of CL (MoCo) capture global information, but they collapse into homogeneous attention maps for all query tokens and heads.** Self-attentions of MIM (SimMIM) mainly focus on local areas and similar tokens. We visualize the attention maps for two different query tokens in the beginning through the end layers. We omit the results for self-attention heads, which show mostly consistent results. *Left:* Self-attentions of CL capture global patterns and the shape of an object. However, all attention maps capture the same shape information regardless of the query tokens. *Right:* Self-attentions of MIM capture local patterns and are correlated with queries.

2. HOW DO SELF-ATTENTIONS BEHAVE?

CL의 Self-Attention은 균질화(Homogeneity)로 붕괴(Collapse)됨.

- CL의 Self-Attention은 두 쿼리 토큰이 서로 다른 위치에 있음에도 불구하고 거의 동일한 객체 형태(object shape)를 나타냄.

즉, CL의 Self-Attention이 모든 쿼리 토큰과 어텐션 헤드에 걸쳐 거의 동일한 주의 패턴(attention pattern)으로 수렴하는 것.

이와 달리, MIM의 Self-Attention은 예상대로 각 쿼리 토큰의 위치와 의미에 충실하게 반응하며, 쿼리별로 서로 다른 주의 분포(attention distribution)를 보여줌.




Figure 2: Self-attentions of CL (MoCo) capture global information, but they collapse into homogeneous attention maps for all query tokens and heads. Self-attentions of MIM (SimMIM) mainly focus on local areas and similar tokens. We visualize the attention maps for two different query tokens in the beginning through the end layers. We omit the results for self-attention heads, which show mostly consistent results. *Left*: Self-attentions of CL capture global patterns and the shape of an object. However, all attention maps capture the same shape information regardless of the query tokens. *Right*: Self-attentions of MIM capture local patterns and are correlated with queries.

2. HOW DO SELF-ATTENTIONS BEHAVE?

- 어텐션 붕괴(attention collapse)를 정량적으로 측정하기 위해 정규화 상호 정보량(Normalized Mutual Information, NMI)을 사용

- $p(q)$: 쿼리 토큰(query token)의 분포

→ 각 쿼리 토큰은 서로 다른 공간 좌표(spatial coordinate)에 대응하므로, 쿼리들이 균등하게 분포되어 있다고 가정

따라서, $p(q) = 1/N$

- $p(q, k)$: 쿼리-키(query-key) 쌍의 결합 확률 분포(joint distribution)

이는 Self-Attention 행렬로부터 계산

$$p(q, k) = \pi(k|q), p(q)$$

여기서 $\pi(k|q)$ 는 Self-Attention 행렬의 softmax 정규화된 값으로, 쿼리 토큰 q 가 키 토큰 k 에 주의를 줄 확률

$$NMI = \frac{\sqrt{I(q, k)}}{H(q)H(k)}$$

$I(q, k)$: 상호정보량(Mutual Information) – 쿼리 토큰 q 와 키 토큰 k 사이의 의존성 정도

$H(q), H(k)$: 각각 쿼리와 키의 주변 엔트로피(Marginal Entropy) – 각 확률 분포의 불확실성을 나타냄

NMI가 높다 → 쿼리 토큰과 키 토큰의 관계가 다양함 → Attention 다양성 높음 (MIM)

NMI가 낮다 → 모든 쿼리가 비슷한 키에 주의를 줌 → Attention 붕괴 발생 (CL)

즉, CL에서 Self-Attention의 균질화(homogeneity) 현상이 심할수록 쿼리-키 간의 정보 공유가 줄어들기 때문에 NMI 값이 낮아짐.

2. HOW DO SELF-ATTENTIONS BEHAVE?

- CL의 상호정보량(Mutual Information)은 MIM보다 특히 ViT의 후반부 계층(later layers)에서 현저히 낮게 나타남.
→ CL의 Self-Attention 분포가 균질화(homogeneous)되는 경향이 강하다는 것을 의미

즉, CL의 Self-Attention이 서로 다른 쿼리 토큰에 대해 거의 동일한 형태로 수렴(collapse)한다는 사실을 보여줌.

요약하면,

- NMI ↓ → Attention 다양성 감소 → CL의 후반부 층에서 Attention Collapse 발생
- NMI ↑ → Attention 다양성 유지 → MIM은 쿼리별 독립적 Attention 구조 유지





Figure 4: Self-attentions of CL have little to do with query tokens. Normalized MI of CL is significantly lower than that of MIM in the later layers.



2. HOW DO SELF-ATTENTIONS BEHAVE?

→ 어텐션 붕괴(Attention Collapse)는 표현 다양성(Representational Diversity)을 감소시킴.

Self-Attention이 균질화(homogeneity)로 붕괴되면, 결국 토큰 표현(token representations) 자체도 서로 유사해지는 경향을 보일 것이라고 가정

→ 이 주장을 뒷받침하기 위해, 연구진은 표현 간 코사인 유사도(Cosine Similarity)를 측정

세 가지 유사도(Similarity) 지표

1. Heads (어텐션 헤드 간 유사도)

- 서로 다른 Self-Attention Head들 간의 표현이 얼마나 유사한지를 측정
→ Head 간 기능이 중복되면, 모델의 다중 어텐션 구조가 무의미해짐

2. Depths (계층 간 유사도)

- Self-Attention 층 전후(before vs. after)의 표현이 얼마나 비슷한지를 비교
→ 깊이가 깊어질수록 표현이 변하지 않는다면, 계층 간 표현 변화(representation transformation)가 약화된 것

3. Tokens (토큰 간 유사도)

- 서로 다른 토큰 간 표현 벡터(token representations)의 코사인 유사도 측정
→ 모든 토큰의 표현이 유사해질수록 표현 다양성(representational diversity)이 감소

2. HOW DO SELF-ATTENTIONS BEHAVE?

예상대로, CL의 유사도는 MIM보다 특히 후반부 계층에서 뚜렷하게 더 높게 나타남.

→ 이는 곧 CL의 표현(Representation)이 강한 균질성(homogeneity)을 띤다는 것을 의미

세부 관찰 결과

1. 모델 크기 증가 효과

: 모델 크기를 키워도(CL에서 ViT-B → ViT-L), CL의 Attention 붕괴 문제는 해결되지 않음.

오히려 표현의 중복이 더 심해지는 경향

즉, 깊이를 늘리는 것만으로는(CL의 경우)

새로운 표현 다양성을 만들어내지 못하고, 단지 같은 패턴의

계층을 반복적으로 추가하는 셈




Figure 5: CL lacks representational diversity in the later layers. We measure cosine similarities of representations in the self-attentions between the heads (left), depths (middle), and spatial coordinates (right). All of the results show that the representational similarity of later self-attentions of CL is higher than that of MIM. Increasing heads or depths of CL is not effective in improving the diversity. *Left:* The similarity of representations from two heads in self-attention. *Middle:* The similarity between representations before and after self-attentions transform them. *Right:* The similarities of representations at two spatial coordinates. ViT-{S, L} is trained with 100 epochs.

2. HOW DO SELF-ATTENTIONS BEHAVE?

2. 텐션 헤드 수 증가 효과 (ViT-S → ViT-B, Figure 5a)

: MIM에서는 헤드 수를 늘리면 표현

다양성(representational diversity)이 확연히 향상

그러나 CL에서는 헤드를 늘려도 유사도 감소 효과가 거의 없음.

즉, 여전히 모든 헤드가 비슷한 표현만 학습함.

3. 계층 수 증가 효과 (ViT-B → ViT-L, Figure 5b)

: CL의 깊이를 늘려도, 표현 간 유사도는 거의 변하지 않거나 오히려 증가

→ 불필요한 모듈만 추가되는 결과로 해석됨.




Figure 5: **CL lacks representational diversity in the later layers.** We measure cosine similarities of representations in the self-attentions between the heads (left), depths (middle), and spatial coordinates (right). All of the results show that the representational similarity of later self-attentions of CL is higher than that of MIM. Increasing heads or depths of CL is not effective in improving the diversity. *Left:* The similarity of representations from two heads in self-attention. *Middle:* The similarity between representations before and after self-attentions transform them. *Right:* The similarities of representations at two spatial coordinates. ViT-{S, L} is trained with 100 epochs.

2. HOW DO SELF-ATTENTIONS BEHAVE?

우리가 관찰한 동작(behavior)의 의미

결론적으로, CL의 Self-Attention은 객체의 전역적 패턴과 형태를 효과적으로 포착.

그러나 CL은 Attention 붕괴 문제 즉, Self-Attention이 균질화(homogeneity)되어 토큰 표현의 다양성이 감소하는 문제가 있음.

반면, MIM은 주로 국소적(local) 패턴을 포착하므로, 이러한 Attention 붕괴 문제를 거의 겪지 않음.

Figure 1:

CL: 전역적 특징에 강하므로, 이미지 단위의 구분(예: 분류, 선형 프로빙)에 유리

MIM: 지역적 특징을 풍부하게 학습하므로, 세밀한 구조를 요구하는 파인튜닝 및 고밀도 예측(dense prediction) 과제에서 더 우수한 성능을 보임.





Figure 1: **CL outperforms MIM in linear probing and small model regimes.** In contrast, MIM excels in fine-tuning, large model regimes, and dense prediction. Red squares (■) denote CL, and blue triangles (▲) denote MIM. By default, we report the performance of ViT-B trained or pre-trained on ImageNet-1K. We use the results from original papers and He et al. (2022) for object detection. Regarding the scaling experiment, we report the results that we reproduced based on official configurations except with 100 epochs, marking them as MoCo[†] and SimMIM[†]. *Left:* CL outperforms MIM in linear probing but underperforms in fine-tuning. *Middle:* CL outperforms MIM in small model regimes (ViT-Ti and ViT-S), and MIM shows superior scalability in large model regimes (ViT-L and ViT-H). *Right:* MIM outperforms CL in the dense prediction downstream tasks, such as object detection with Mask R-CNN (He et al., 2017) on COCO (Lin et al., 2014).



2. HOW DO SELF-ATTENTIONS BEHAVE?

1. CL이 선형 프로빙(linear probing)에서 MIM보다 우수한 이유

CL은 객체의 형태를 포착하므로, 객체 인식(object recognition)과 이미지 구분(image discrimination)에 유리

반면 MIM은 질감(texture)과 표현 다양성은 잘 보존하지만, 이러한 정보는 객체의 의미와의 상관성이 형태만큼 강하지 않음.

→ 따라서 CL은 전역적 의미 구조(global semantic structure) 중심의 특징을 학습하기 때문에 클래스 간 선형 구분이 잘 이루어져 linear probing 성능이 높음.

2. CL의 Attention Collapse는 ViT의 활용 효율을 떨어뜨림.

CL에서는 Self-Attention이 균질화(homogeneous)되어, 헤드, 계층, 토큰 간의 표현이 서로 유사해지는 붕괴 현상(attention collapse)이 나타남.

이렇게 되면 각 계층과 헤드가 서로 다른 정보를 학습하지 못하고 중복된 표현만 생산

→ 그 결과, ViT의 네트워크 용량(network capacity) 중 상당 부분이 낭비되고, 큰 모델로 갈수록 CL의 fine-tuning 성능이 MIM보다 크게 뒤처짐.

CL은 전역적 특징 구분은 잘하지만, 내부 표현의 다양성(semantic diversity)을 유지하지 못함.

3. CL은 고밀도 예측(Dense Prediction)에 부적합

CL에서 학습된 토큰 특징은 공간 좌표에 대해 거의 균질한(homogeneous) 형태를 띰.

→ 따라서 각 위치별 세밀한 예측(예: segmentation, detection, depth estimation)에 필요한 공간적 구분 능력이 부족

즉, CL은 픽셀, 패치 수준의 지역적 정보(local detail)를 잘 표현하지 못하므로 dense prediction task에는 부적합

2. HOW DO SELF-ATTENTIONS BEHAVE?

수용영역(receptive field)이 제한된 Self-Attention의 동작을 추가적으로 조사

- Self-Attention의 수용영역을 지역적으로 제한(locally restricted)하면
 - 선형 프로빙 성능은 낮아지지만,
 - 파인튜닝 성능은 오히려 향상되는 경향을 보임.

결론적으로, Self-Attention의 수용영역 범위(receptive field size)는

전역적 구분(linear probing)과 지역적 적응(fine-tuning) 사이의 trade-off를 결정짓는 중요한 요소임을 시사





Figure D.1: **Locality inductive bias harms linear probing but improves fine-tuning.** We report the linear probing and fine-tuning accuracy of MoCo with restricted self-attentions via attention masks.



HOW ARE REPRESENTATIONS TRANSFORMED?



3. HOW ARE REPRESENTATIONS TRANSFORMED?

이 절에서는 CL과 MIM으로 사전학습 된 ViT의 토큰 표현(token representations)을 분석

→ 2장에서 관찰한 Self-Attention의 특성이 표현 학습에 어떤 방식으로 서로 다르게 영향을 미치는지를 보여줌.

본 절에서도 Section 2와 동일하게 ImageNet-1K에서 사전학습된 ViT-B/16 모델을 사용

- ViT-B/16 모델
 - 디코더 모듈 없음.
 - 구조 : [Patch Embedding] → [Transformer Encoder Layers × 12] → [MLP Head]

이 절의 목적은 CL과 MIM의 Self-Attention 구조적 차이가 ViT 내부의 표현 공간(Representation Space)을

어떻게 다르게 형성하는지를 구체적으로 밝히는 것.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

→ CL은 모든 토큰을 동일하게 변환하는 반면, MIM은 각 토큰을 개별적으로 변환

CL과 MIM이 토큰 표현(token representations)을 어떻게 변환하는지를 보여주기 위해, 표현 공간(representation space)에서의 토큰 분포를 시각화

Figure 6 : ImageNet 검증 세트의 한 이미지 샘플에서 Self-Attention 모듈 전후 (before & after)의 196개 토큰 (14×14 패치) 표현을 보여줌.

이를 위해, 각 표현 행렬에 대해 특이값 분해(Singular Value Decomposition, SVD)를 수행

그 중 가장 큰 세 개의 특이벡터(large singular vectors)를 선택하여 시각화 기준 좌표(basis)로 사용

→ "representation이 어떤 방향으로 얼마나 퍼져 있는가"를 측정




Figure 6: **Self-attention layers of CL and MIM transform representations differently.** We visualize 196 spatial representation tokens for an example validation image in a representation space. The blue (●) and red (●) data points denote the tokens before and after the self-attention transformation. *Left:* The self-attentions of CL (e.g., MoCo) translate all the tokens equally, so the distances between the tokens of an image do not increase. *Middle:* However, CL moves the “centers of representations (represented by ×)” away from each other. Therefore, the images are linearly separable. The circle (●) and triangle (△) data represent tokens from different images. *Right:* The self-attentions of MIM (e.g., SimMIM) transform representations differently according to query tokens, thus increasing the distances between tokens. See Figure 7 for quantitative analyses.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

또한, 비교를 명확히 하기 위해

CL(MoCo)의 경우 마지막 계층(last layer)의 표현을,

MIM(SimMIM)의 경우 첫 번째 계층(first layer)의 표현을 각각 표시함.

결과적으로, 이 시각화는 CL이 모든 토큰을 전역적으로 비슷한 방향으로 이동시키는 반면, MIM은 각 토큰을 서로 다른 방향으로 개별 변환시킨다는 점을 직관적으로 보여줌.




Figure 6: **Self-attention layers of CL and MIM transform representations differently.** We visualize 196 spatial representation tokens for an example validation image in a representation space. The blue (●) and red (●) data points denote the tokens before and after the self-attention transformation. *Left:* The self-attentions of CL (e.g., MoCo) translate all the tokens equally, so the distances between the tokens of an image do not increase. *Middle:* However, CL moves the “centers of representations (represented by ×)” away from each other. Therefore, the images are linearly separable. The circle (●) and triangle (△) data represent tokens from different images. *Right:* The self-attentions of MIM (e.g., SimMIM) transform representations differently according to query tokens, thus increasing the distances between tokens. See Figure 7 for quantitative analyses.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 6(a)

CL의 토큰들이 **Self-Attention** 모듈에 의해 변환될 때 발생하는 변화를 시각화한 것.

→ CL의 **Self-Attention**이 모든 토큰을 거의 동일하게 평행 이동시킨다는 사실을 보여줌.

이유는 CL의 **Self-Attention** 맵이 균질(homogeneous)하기 때문

- **Self-Attention**의 가중 분포(attention map)가 공간적 좌표(spatial coordinates)나 쿼리 토큰에 거의 의존하지 않음.
- 결과적으로 모든 토큰에 거의 동일한 가중치가 적용




Figure 6: **Self-attention layers of CL and MIM transform representations differently.** We visualize 196 spatial representation tokens for an example validation image in a representation space. The blue (●) and red (●) data points denote the tokens before and after the self-attention transformation. *Left:* The self-attentions of CL (e.g., MoCo) translate all the tokens equally, so the distances between the tokens of an image do not increase. *Middle:* However, CL moves the “centers of representations (represented by ×)” away from each other. Therefore, the images are linearly separable. The circle (●) and triangle (△) data represent tokens from different images. *Right:* The self-attentions of MIM (e.g., SimMIM) transform representations differently according to query tokens, thus increasing the distances between tokens. See Figure 7 for quantitative analyses.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 6(a)

CL의 토큰들이 **Self-Attention** 모듈에 의해 변환될 때 발생하는 변화를 시각화한 것.

→ CL의 **Self-Attention**이 모든 토큰을 거의 동일하게 평행 이동시킨다는 사실을 보여줌.

이유는 CL의 **Self-Attention** 맵이 균질(homogeneous)하기 때문

- **Self-Attention**의 가중 분포(attention map)가 공간적 좌표(spatial coordinates)나 쿼리 토큰에 거의 의존하지 않음.
- 결과적으로 모든 토큰에 거의 동일한 가중치가 적용

따라서,

- 토큰 간 거리가 증가하지 않고
- 표현 공간의 부피도 확장되지 않음.

→ 이는 곧, CL이 개별 토큰의 세부적 차이에는 상대적으로 관심을 두지 않으며, 대신 이미지 전체의 전역적 특징을 강조한다는 것을 의미




Figure 6: **Self-attention layers of CL and MIM transform representations differently.** We visualize 196 spatial representation tokens for an example validation image in a representation space. The blue (●) and red (●) data points denote the tokens before and after the self-attention transformation. *Left:* The self-attentions of CL (e.g., MoCo) translate all the tokens equally, so the distances between the tokens of an image do not increase. *Middle:* However, CL moves the “centers of representations (represented by ×)” away from each other. Therefore, the images are linearly separable. The circle (●) and triangle (△) data represent tokens from different images. *Right:* The self-attentions of MIM (e.g., SimMIM) transform representations differently according to query tokens, thus increasing the distances between tokens. See Figure 7 for quantitative analyses.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 6(b)

그럼에도 불구하고, Self-Attention은 CL의 판별 능력에 있어 핵심적인 역할을 함.

Self-Attention은 서로 다른 이미지들의 “표현 분포의 중심(centers of the representation distribution)”을 서로 멀리 이동시킴으로써 이미지 간 구분을 가능하게 함.

즉, CL의 Self-Attention은 각 이미지 내부의 토큰 간 차이를 유지하지는 못하지만, 이미지 전체(image-level) 표현들을 선형적으로 분리되게 만듦.




Figure 6: **Self-attention layers of CL and MIM transform representations differently.** We visualize 196 spatial representation tokens for an example validation image in a representation space. The blue (●) and red (●) data points denote the tokens before and after the self-attention transformation. *Left:* The self-attentions of CL (e.g., MoCo) translate all the tokens equally, so the distances between the tokens of an image do not increase. *Middle:* However, CL moves the “centers of representations (represented by ×)” away from each other. Therefore, the images are linearly separable. The circle (●) and triangle (△) data represent tokens from different images. *Right:* The self-attentions of MIM (e.g., SimMIM) transform representations differently according to query tokens, thus increasing the distances between tokens. See Figure 7 for quantitative analyses.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 6(c)

이에 반해, **MIM**은 각 토큰에 서로 다른 변환을 적용함.

→ 각 공간적 토큰에 서로 다른 **Self-Attention**이 할당되기 때문

즉, **MIM**의 **Self-Attention**은 토큰의 공간적 위치나 내용에 따라 각각

다른 방식으로 정보를 통합함.

→ 그 결과, **MIM**은 한 이미지 내의 토큰 간 거리를 변화시키고,

더 나아가 표현 분포의 부피도 확장




Figure 6: **Self-attention layers of CL and MIM transform representations differently.** We visualize 196 spatial representation tokens for an example validation image in a representation space. The blue (●) and red (●) data points denote the tokens before and after the self-attention transformation. *Left:* The self-attentions of CL (e.g., MoCo) translate all the tokens equally, so the distances between the tokens of an image do not increase. *Middle:* However, CL moves the “centers of representations (represented by ×)” away from each other. Therefore, the images are linearly separable. The circle (●) and triangle (△) data represent tokens from different images. *Right:* The self-attentions of MIM (e.g., SimMIM) transform representations differently according to query tokens, thus increasing the distances between tokens. See Figure 7 for quantitative analyses.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

정량적 분석에서도 일관된 결과를 확인

→ 토큰과 이미지 단위의 특이값 스펙트럼(singular value spectrum)을 시각화

특이값 스펙트럼(Singular Value Spectrum)이란?

: 각 계층(layer)의 표현 분포(representation distribution)를 특이값

분해를 통해 얻은 특이값(singular values)들의 분포

→ 표현 공간(representation space)에서 데이터가 차지하는 유효 부

피를

나타냄.

즉,

특이값이 크다 → 표현이 여러 방향으로 넓게 퍼져 있음 (diverse, 고차원 구조 유지)

특이값이 작다 → 표현이 특정 방향으로 압축됨 (collapsed, 다양성 감소)




Figure 7: CL barely changes or even decreases the distribution volume of tokens from a single image, implying that it hardly distinguishes between token. Instead, it significantly increases the distribution volume of images. To demonstrate these properties, we visualize singular value spectra, the singular values of the distribution of representations sorted by the magnitude. The higher a singular value, the larger the volume of a distribution. The right of this figure shows the 64th and 128th highest singular value for depth. *Top*: Singular value spectra of tokens from a single image. CL decreases the singular values of the tokens, but MIM increases. *Bottom*: Singular value spectra of images. CL significantly increases the volumes occupied by images, but MIM hardly does so.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 7(a)

- CL의 계층(layer)에서는 특이값(singular values)이 거의 증가하지 않거나 오히려 감소
→ CL의 Self-Attention이 토큰 간 표현 차이를 거의 만들지 못한다는 의미
즉, CL은 모든 토큰을 거의 동일하게 변환하여 토큰 간 다양성이 낮고, 표현 공간의 부피가 확장되지 않음.
- 반대로, MIM은 특이값이 전반적으로 증가하여 토큰 표현의 부피가 커짐.
→ 결과적으로 토큰 간의 구분 능력이 향상
즉, MIM은 각 토큰이 위치나 주변 맥락에 따라 다르게 변환되므로, 이미지 내부의 세부적(local) 표현 다양성을 강화
- 추가 관찰
MIM의 후반부 몇 개 계층에서는 오히려 특이값이 감소하는 경향
→ 이는 이 계층들이 디코더(decoder)처럼 작동하기 때문
즉, 입력 토큰들을 복원하거나 의미적 통합하는 과정에서 표현이 다시 압축되는 것.




Figure 7: CL barely changes or even decreases the distribution volume of tokens from a single image, implying that it hardly distinguishes between token. Instead, it significantly increases the distribution volume of images. To demonstrate these properties, we visualize singular value spectra, the singular values of the distribution of representations sorted by the magnitude. The higher a singular value, the larger the volume of a distribution. The right of this figure shows the 64th and 128th highest singular value for depth. *Top*: Singular value spectra of tokens from a single image. CL decreases the singular values of the tokens, but MIM increases. *Bottom*: Singular value spectra of images. CL significantly increases the volumes occupied by images, but MIM hardly does so.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 7(b)

과정

1. 한 이미지에 포함된 모든 토큰의 표현(token representations)을 평균(average)내어 하나의 이미지 단위 표현 벡터를 생성
 2. 이후, ImageNet 검증 세트 전체에 대해 이러한 이미지 표현들의 집합을 구성하고, 그 분포에 대해 특이값 분해(SVD)를 수행하여 특이값 스펙트럼을 계산
- CL의 이미지 표현은 MIM보다 특이값이 더 큼.
→ 즉, CL의 표현 분포의 부피가 더 넓음.
이는 곧, CL이 이미지 수준(image-level)에서의 표현을 잘 분리시킨다는 것을 의미
 - 반면, MIM의 경우 특이값 스펙트럼이 더 작고(flat), 전체 표현 공간에서 이미지 간 거리가 상대적으로 좁음.
→ 즉, MIM은 이미지 간 전역적 분리보다는, 개별 이미지 내부의 세밀한(local) 구조 학습에 초점을 맞춤.





Figure 7: CL barely changes or even decreases the distribution volume of tokens from a single image, implying that it hardly distinguishes between token. Instead, it significantly increases the distribution volume of images. To demonstrate these properties, we visualize singular value spectra, the singular values of the distribution of representations sorted by the magnitude. The higher a singular value, the larger the volume of a distribution. The right of this figure shows the 64th and 128th highest singular value for depth. *Top*: Singular value spectra of tokens from a single image. CL decreases the singular values of the tokens, but MIM increases. *Bottom*: Singular value spectra of images. CL significantly increases the volumes occupied by images, but MIM hardly does so.




3. HOW ARE REPRESENTATIONS TRANSFORMED?

➡ CL은 저주파(low-frequency)를, MIM은 고주파(high-frequency)를 활용

기본 가설

- CL은 이미지 수준(image-level)의 자기 지도 학습을 제공하므로, 전역적(global) 패턴을 포착
→ 이는 주로 저주파(low-frequency) 성분에 해당
즉, 형태(shape)나 큰 구조 중심의 정보를 학습
- 반면, MIM은 토큰 수준(token-level)의 자기 지도 학습을 수행하므로, 국소적(local) 세부 정보를 포착
→ 이는 고주파(high-frequency) 성분에 해당
즉, 텍스처(texture)나 세밀한 패턴(detail) 중심의 정보를 학습



3. HOW ARE REPRESENTATIONS TRANSFORMED?

분석 방법 (Fourier Analysis)

1. 각 토큰 표현 또는 이미지 표현을 주파수 영역(**frequency domain**)으로 변환하고,
2. 각 주파수 대역의 진폭(**amplitude**)을 측정

정량 지표 (Relative Log Amplitude)

- 각 표현의 푸리에 스펙트럼에서
가장 높은 주파수(**high frequency**)와 가장 낮은 주파수(**low frequency**) 간의 진폭 차이를 로그 스케일로 계산

이 상대 로그 진폭(**relative log amplitude**) 값이

- 양수(+)이면 → 저주파 성분이 우세 → **CL** 경향
- 음수(-)이면 → 고주파 성분이 우세 → **MIM** 경향

3. HOW ARE REPRESENTATIONS TRANSFORMED?

CL의 고주파 성분 진폭은 MIM보다 현저히 작음.

→ 이는 CL이 주로 저주파 공간 정보를 사용한다는 것을 의미

→ 다시 말해, CL은 전역적 구조(global structures)나 형태(shape) 같은 큰 스케일의 정보를 중심으로 학습

반대로, MIM의 고주파 성분 진폭은 CL보다 훨씬 큼.

→ 즉, MIM은 세밀한(local) 구조, 얇은 윤곽선(narrow structures), 질감(fine textures) 등 고주파 공간 정보를 적극적으로 활용




Figure 9: **CL exploits low-frequency, but MIM exploits high-frequency.** Moreover, a few last layers of CL reduce high-frequency by capturing global patterns. MIM also reduces it even though they capture local patterns, because the later layers behave like decoders. See also Figure 11.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

흥미로운 추가 발견

: MIM의 마지막 몇 개 계층은 비록 국소 영역에 집중함에도 불구하고, 고주파 성분을 감소시키는 경향을 보임.

해석

: MIM은 ViT를 암묵적으로(implicitly) 인코더-디코더(encoder-decoder) 구조로 분리함.

- 초중반부 계층(encoder 부분)

: 마스크된 입력 패치를 복원하기 위한 국소적(local), 세밀한(high-frequency) 정보에 집중

→ 세부 질감(texture)과 구조(detail)를 학습

- 후반부 계층(decoder 부분)

: 복원 과정에서 전체 의미를 통합 하며 고주파 정보를 줄이고, 저주파 중심의 표현으로 압축

→ 완성된 이미지 수준의 의미를 만드는 역할 수행





Figure 9: **CL exploits low-frequency, but MIM exploits high-frequency.** Moreover, a few last layers of CL reduce high-frequency by capturing global patterns. MIM also reduces it even though they capture local patterns, because the later layers behave like decoders. See also Figure 11.



3. HOW ARE REPRESENTATIONS TRANSFORMED?

➡ CL은 형태(shape) 편향적이고, MIM은 질감(texture) 편향적

앞서 수행한 푸리에 분석(Fourier analysis) 결과를 바탕으로, CL과 MIM이 각각 형태와 질감 정보에 대해 서로 다른 편향을 가진다고 가정

- CL → 저주파(low-frequency) 중심 → 형태(shape) 위주로 학습
- MIM → 고주파(high-frequency) 중심 → 질감(texture) 위주로 학습

이 가설을 검증하기 위해, Stylized ImageNet 데이터셋을 사용

: Stylized ImageNet은 원본 ImageNet 이미지의 질감을 변형하여 형태는 유지하되 질감은 완전히 바꾼 버전

즉, 이 데이터셋에서는

“형태(shape) 정보만으로 인식할 수 있는가?” vs “질감(texture)에 의존하는가?”를 구분할 수 있음.

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 8(a)

선형 프로빙으로 평가한 결과, CL로 사전학습된 모델은 형태(shape)에 더 의존하는 경향을 보임.

→ 즉, 질감이 바뀌어도 여전히 이미지를 잘 분류할 수 있음.

→ texture 변화에 강인(robust)함.

반대로, MIM으로 사전학습된 모델은 질감(texture)에 더 의존함.

→ 즉, 질감이 바뀌면 분류 성능이 크게 저하됨.

→ texture 변화에 취약

비교 기준

: 감독학습으로 학습된 모델은 CL보다 형태 정보 활용이 약하고, MIM보다는 균형 잡힌 경향




Figure 8: **CL is biased toward shape, whereas MIM is biased toward texture.** We report the predictive results of models for linear probing tasks. However, we observe consistent results in fine-tuned models (See Figure F.2). *Left:* Result of classification on Stylized ImageNet. It shows that CL is more shape-biased than MIM and even than the supervised pre-trained model. Vertical lines represent averaged results for the shape categories. We also report the results of supervised ViT with ImageNet-1K class labels for comparison. *Right:* Accuracy drops on images with frequency-based random noises. MIM shows a more significant amount of accuracy drop than CL with high-frequency noises, demonstrating MIM's texture-biased property. The frequency window size of the frequency-based noise is 0.1π .

3. HOW ARE REPRESENTATIONS TRANSFORMED?

Figure 8(b)

ImageNet 데이터셋에 주파수 기반의 랜덤 노이즈를 추가하고 이에 따른 정확도 감소(decrease in accuracy)를 측정

즉, 원본 이미지에

고주파(high-frequency) 노이즈 → 세부 질감(texture) 영역 교란

저주파(low-frequency) 노이즈 → 전역 구조(global shape) 교란

등을 각각 추가해 보며, 모델이 어느 쪽에 더 민감한지를 관찰

- **CL** : 고주파 노이즈(high-frequency noise)에 대해 매우 강인(robust)함.
즉, 세부 질감이 흐트러지거나 텍스처가 왜곡되어도, 이미지의 전역적 형태(shape)를 기반으로 인식할 수 있음.
- **MIM** : 고주파 노이즈에 훨씬 더 취약(vulnerable)함.
세부 질감(texture) 정보가 깨지면 이미지의 의미적 구조를 유지하기 어려워, 분류 성능이 크게 하락





Figure 8: **CL is biased toward shape, whereas MIM is biased toward texture.** We report the predictive results of models for linear probing tasks. However, we observe consistent results in fine-tuned models (See Figure F.2). *Left*: Result of classification on Stylized ImageNet. It shows that CL is more shape-biased than MIM and even than the supervised pre-trained model. Vertical lines represent averaged results for the shape categories. We also report the results of supervised ViT with ImageNet-1K class labels for comparison. *Right*: Accuracy drops on images with frequency-based random noises. MIM shows a more significant amount of accuracy drop than CL with high-frequency noises, demonstrating MIM's texture-biased property. The frequency window size of the frequency-based noise is 0.1π .



WHICH COMPONENTS PLAY AN IMPORTANT ROLE?



4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

앞선 여러 실험과 분석 결과를 통해,

- CL은 이미지 수준의 전역적 패턴(global patterns)을 활용하고,
- MIM은 토큰 수준(token-level)의 국소적 패턴(local patterns)을 학습한다는 사실이 일관되게 드러남.

이번 절에서는 이러한 차이를 모델 구조적 관점(architectural perspective)에서 분석

즉, 사전학습된 ViT의 내부를 자세히 살펴봄으로써,

CL과 MIM에서 어떤 계층(layers)이나 구성요소(modules)가 핵심적인 역할을 담당하는지를 규명

4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

→ CL의 후반부 계층(later layers)과 MIM의 초반부 계층(early layers)이 중요한 역할을 함.

- 초반부 계층 (early layers)
: 저수준(low-level) 정보 : 국소적 패턴(local patterns), 질감(texture), 경계(edge) 등
- 후반부 계층 (later layers)
: 고수준(high-level) 정보 : 전역적 패턴(global patterns), 형태(shape), 의미적 구조(semantic structure) 등

Figure 11 : 각 계층의 중요도를 평가하기 위한 실험

1. 첫번째 관찰

- early layer에서 MIM 이 CL보다 높음.
- later layer에서 CL이 MIM 보다 높음.

→ CL은 후반부 계층에서, MIM은 초반부 계층에서 선형적으로 분리 가능한(linearly separable) 표현을 형성




Figure 11: **Later layers of CL and early layers of MIM play a key role.** We report linear probing accuracies by using the representations of the intermediate layers. CL outperforms MIM in later layers, and MIM outperforms CL in early layers.

4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

2. 두번째 관찰

- CL의 정확도는 예상대로 계층의 깊이가 증가할수록 상승
- MIM의 정확도는 모델의 끝부분에서 오히려 감소

→ 즉, MIM의 후반부 계층은 표현을 선형적으로 분리하는 데 크게 도움이 되지 않음.

WHY?

: SimMIM처럼 예측 헤드가 얇은 MIM 방법들이 백본의 후반부 계층을 디코더처럼 사용하기 때문에 발생

디코더처럼?

: 마스크된 픽셀을 복원하는 데 필요한 **low-frequency** 정보를 재구성하기 위해 토큰 정보를 다시 압축(compact)하는 과정으로 동작

→ 즉, 픽셀 복원을 위한 압축이지 이미지를 구분하기 위한 전역 정보 통합이 아님.




Figure 11: Later layers of CL and early layers of MIM play a key role. We report linear probing accuracies by using the representations of the intermediate layers. CL outperforms MIM in later layers, and MIM outperforms CL in early layers.

4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

MIM의 후반부 계층이 디코더처럼 동작

: 정보를 **semantic**하게 통합하는 것이 아니라,

복원을 위해 **smoothing & compacting**하는 단계

즉,

- **global semantic structure**는 강화되지 않고
- **token variance**(고주파 성분, Figure 9)가 줄고
- **singular value**(표현 분포의 부피, Figure 7)가 감소하기 때문에

→ linear probing 성능이 낮아짐.




Figure 9: **CL exploits low-frequency, but MIM exploits high-frequency.** Moreover, a few last layers of CL reduce high-frequency by capturing global patterns. MIM also reduces it even though they capture local patterns, because the later layers behave like decoders. See also Figure 11.




Figure 7: **CL barely changes or even decreases the distribution volume of tokens from a single image**, implying that it hardly distinguishes between token. Instead, it significantly increases the distribution volume of images. To demonstrate these properties, we visualize singular value spectra, the singular values of the distribution of representations sorted by the magnitude. The higher a singular value, the larger the volume of a distribution. The right of this figure shows the 64th and 128th highest singular value for depth. *Top*: Singular value spectra of tokens from a single image. CL decreases the singular values of the tokens, but MIM increases. *Bottom*: Singular value spectra of images. CL significantly increases the volumes occupied by images, but MIM hardly does so.

4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

→ MAE처럼 깊은 **self-attention** 디코더를 갖춘 **MIM** 방식은 선형 프로빙 성능을 높이는 데 유용할 수 있음.

3. 세번째 관찰

MIM의 선형 프로빙 정확도 중 가장 높은 값조차도 CL보다는 낮음.




Figure 11: **Later layers of CL and early layers of MIM play a key role.** We report linear probing accuracies by using the representations of the intermediate layers. CL outperforms MIM in later layers, and MIM outperforms CL in early layers.

4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

→ 명시적인 디코더(explicit decoder)는 ViT가 MIM의 장점을 더욱 효과적으로 활용하도록 도움.

디코더의 특성을 더 깊이 이해하기 위해 MAE를 분석

Figure 10(a)

MAE의 인코더 후반부 계층에서의 상호정보량(mutual information)은 SimMIM보다 낮지만, 디코더에서는 SimMIM보다 높음.

→ MAE의 디코더가 주변 토큰(neighborhood tokens)에 기반하여 마스크된 토큰을 복원함을 의미




Figure 10: **The explicit decoder architecture of MAE helps ViTs effectively leverage the advantages of MIM.** We analyze the encoder and decoder of a pre-trained model with a masking ratio of zero. The left side of each figure represents the encoder and the right side the decoder. *Left:* The mutual information of MAE is lower than that of SimMIM in the encoder but higher in the decoder. *Right:* The decoder of MAE captures low-frequencies, while the encoder captures high-frequencies. As a result, the decoder predicts blurred images. Moreover, the later layers (excluding the last layer) of the encoder do not reduce high-frequency information, while those of SimMIM do.

4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

Figure 10 (b)

- SimMIM의 마지막 네 개 계층은 고주파(high-frequency) 성분을 감소
 - 반면 MAE의 후반부 계층(마지막 계층 제외)은 고주파 성분을 감소시키지 않음.
 - 대신 MAE의 디코더는 인코더보다 저주파(low-frequency) 정보를 우선적으로 처리
- 이를 통해 백본(backbone)이 고주파 정보를 효율적으로 활용할 수 있도록 함.




Figure 10: **The explicit decoder architecture of MAE helps ViTs effectively leverage the advantages of MIM.** We analyze the encoder and decoder of a pre-trained model with a masking ratio of zero. The left side of each figure represents the encoder and the right side the decoder. *Left:* The mutual information of MAE is lower than that of SimMIM in the encoder but higher in the decoder. *Right:* The decoder of MAE captures low-frequencies, while the encoder captures high-frequencies. As a result, the decoder predicts blurred images. Moreover, the later layers (excluding the last layer) of the encoder do not reduce high-frequency information, while those of SimMIM do.

4. WHICH COMPONENTS PLAY AN IMPORTANT ROLE?

예를 들어, 고양이 얼굴 이미지에서 눈 주변 일부 패치가 **mask** 되었다고 가정.

디코더는 다음을 해야 함.

✓ **Step 1:** 복원을 위해 주변 토큰에 집중

“눈 근처 패치로부터 정보를 가져와야” 하므로

attention이 **query-specific**하게 변함 → **MI** 증가

✓ **Step 2:** 복원된 패치는 매우 **smooth**한 **low-frequency** 형태

노이즈나 **texture** 디테일을 복원하지 않음. → **Low frequency** 증가

token representation이 단조롭게(smooth) 됨 → **SVD** 감소

→ 즉, 복원을 잘하기 위해 **MI**는 올라가지만, 결과 **representation**은 더 **compact**해져 **SVD**는 떨어지는 것.




Figure 10: **The explicit decoder architecture of MAE helps ViTs effectively leverage the advantages of MIM.** We analyze the encoder and decoder of a pre-trained model with a masking ratio of zero. The left side of each figure represents the encoder and the right side the decoder. *Left:* The mutual information of MAE is lower than that of SimMIM in the encoder but higher in the decoder. *Right:* The decoder of MAE captures low-frequencies, while the encoder captures high-frequencies. As a result, the decoder predicts blurred images. Moreover, the later layers (excluding the last layer) of the encoder do not reduce high-frequency information, while those of SimMIM do.



ARE THE TWO METHODS COMPLEMENTARY TO EACH OTHER?

5. ARE THE TWO METHODS COMPLEMENTARY TO EACH OTHER?

Figure 12(a)

- 놀랍게도, 이 하이브리드 모델은 두 측면 모두에서 $\text{MIM}(\lambda = 0)$ 과 $\text{CL}(\lambda = 1)$ 보다 더 높은 성능을 보임.

Figure 12(b), 12(c)

- $\lambda = 0.2$ 인 모델을 각각 2장에서의 Self-Attention 분석, 3장에서의 푸리에 분석 관점에서 살펴봄.

→ 두 결과 모두, 하이브리드 모델이 초반 계층에서는 MIM의 특성을, 후반 계층에서는 CL의 특성을 활용함.

- 초반 계층의 Self-Attention은 쿼리 토큰에 따라 달라지지만, 후반 계층에서는 그렇지 않음을 나타냄.
- 초반 계층은 고주파(high-frequency) 정보를 활용하는 반면, 후반 계층은 저주파(low-frequency) 정보를 활용




Figure 12: **The simple linear combination of CL (MoCo) and MIM (SimMIM) objectives outperforms the vanilla CL and MIM.** λ is the importance weight of CL, so $\lambda = 0$ means SimMIM and $\lambda = 1$ means MoCo. *Left:* “CL + MIM” outperforms CL and MIM in both linear probing and fine-tuning accuracy. *Middle:* Mutual information of “CL + MIM” decreases at the end of the model, suggesting that the self-attentions of later layers collapse into homogeneity and capture the same object shape information. *Right:* Fourier analysis shows that “CL + MIM” amplifies high frequencies at the beginning and reduces them at the end. It implies that “CL + MIM” exploits high-frequency information at the beginning and low-frequency information at the end.

A stylized purple logo consisting of the letters 'O' and 'C' intertwined. The 'O' is a simple circle, and the 'C' is a thick, curved line that starts from the right side of the 'O' and curves upwards and then downwards, ending on the right side.

CONCLUSION



6. CONCLUSION

Vision Transformer를 위한 두 가지 널리 사용되는 자기지도 학습 방법, 즉 대조 학습(CL)과 마스크드 이미지 모델링(MIM)의 다양한 측면을 강조하는 비교 연구를 수행

본 연구는 두 방법의 여러 상반된 특성을 보여줌.

향후 연구 방향

: CL과 MIM의 목표 함수를 단순히 선형 결합하는 것보다 더 나은 방법이 존재할 것이라 믿음.

- 예를 들어, 후반부 계층에는 CL을, 초반부 계층에는 MIM을 적용하는 새로운 형태의 자기지도 학습 접근법을 고려할 수 있음.
- Swin과 같은 다단계 ViT 구조에서의 자기지도 학습으로 본 연구의 발견을 확장할 수도 있음.
- CL과 MIM 각각의 특성을 강화하는 것. 즉, CL이 형태(shape)를, MIM이 질감(texture)을 더 잘 학습하도록 돕는 기술들이 성능 향상에 기여할 수 있음.

Thank you for Listening!