

Object detection

경희대학교 치과병원

주창민

Yolo

You Only Look Once: Unified, Real-Time Object Detection

Joseph Redmon*, Santosh Divvala*[†], Ross Girshick[¶], Ali Farhadi*[†]

University of Washington*, Allen Institute for AI[†], Facebook AI Research[¶]

<http://pjreddie.com/yolo/>




Figure 1: The YOLO Detection System. Processing images with YOLO is simple and straightforward. Our system (1) resizes the input image to 448×448 , (2) runs a single convolutional network on the image, and (3) thresholds the resulting detections by the model's confidence.

Yolo의 장점

- 장점
- 간단한 처리과정으로 속도가 매우 빠르다. 또한 기존의 다른 real-time detection system들과 비교할 때, 2배 정도 높은 mAP를 보인다.
- Image 전체를 한 번에 바라보는 방식으로 class에 대한 맥락적 이해도가 높다. 이로 인해 낮은 background error(False-Positive)를 보인다.
- Object에 대한 좀 더 일반화된 특징을 학습한다. 가령 natural image로 학습하고 이를 artwork에 테스트 했을때, 다른 Detection System들에 비해 훨씬 높은 성능을 보여준다.

Yolo v2




Figure 4: Accuracy and speed on VOC 2007.

- Yolo 는 실시간 object detector로서 영상에서 object의 경계 박스를 표시함과 동시에 클래스를 분류한다.
- Yolo의 다음버전인 Yolov2는 성능과 속도를 모두 개선시켜서 SSD(Single Shot MultiBox Detector)보다 뛰어나다.
- Yolov2는 네트워크의 크기를 조절하여 FPS와 MAP를 균형있게 조절할 수 있다.

Yolov2

	YOLO								YOLOv2
batch norm?		✓	✓	✓	✓	✓	✓	✓	✓
hi-res classifier?			✓	✓	✓	✓	✓	✓	✓
convolutional?				✓	✓	✓	✓	✓	✓
anchor boxes?				✓	✓				
new network?					✓	✓	✓	✓	✓
dimension priors?						✓	✓	✓	✓
location prediction?						✓	✓	✓	✓
passthrough?							✓	✓	✓
multi-scale?								✓	✓
hi-res detector?									✓
VOC2007 mAP	63.4	65.8	69.5	69.2	69.6	74.4	75.4	76.8	78.6

Table 2: The path from YOLO to YOLOv2. Most of the listed design decisions lead to significant increases in mAP. Two exceptions are switching to a fully convolutional network with anchor boxes and using the new network. Switching to the anchor box style approach increased recall without changing mAP while using the new network cut computation by 33%.

- 성능향상의 요인


1. Batch normalization

- YOLOv2 에서는 모든 컨볼루션 레이어에 배치 정규화를 추가하여 mAP 2% 향상시켰다.
- 기존에 사용하던 dropout은 제거하였는데 이에 따른 오버피팅은 발생하지 않았다.

2. High Resolution Classifier


- 학습과정은 2단계로 나뉜다.
- 기존 yolo는 224×224 이미지로 classifier를 학습한 후 detection을 위해 해상도를 448×448 로 올린다.
- YOLOv2는 처음부터 448×448 이미지로 학습시킨다.
- 이는 mAP를 4% 올린다.

3. Convolutional with anchor boxes



- YOLOv2 : 기존 yolo의 FC를 convolution으로 대체
- 네트워크의 입력 이미지 크기를 448*448에서 416*416 으로 축소 □ 최종 특징맵의 크기를 홀수*홀수로 만들기 위함
- 최종 특징맵의 크기가 홀수 □ 그리드셀이 특징맵의 중앙 부분에 위치할 수 있다.

4. Dimension Clusters



- 기존의 앵커 박스는 종횡비가 1, $\frac{1}{2}$, 2 인 직사각형 사용.
- YOLOv2는 VOC와 COCO 데이터셋에 있는 오브젝트의 경계 박스를 클러스터링해서 앵커 박스의 종횡비와 크기를 결정했다.
- 클러스터링 개수를 늘릴수록 IOU가 증가한다.
- 그러나 클러스터링 개수가 커지면 복잡도가 상승하는 트레이드 오프 관계가 있기 때문에 YOLOv2는 5를 선택.

4. Dimension Clusters

Box Generation	#	Avg IOU
Cluster SSE	5	58.7
Cluster IOU	5	61.0
Anchor Boxes [15]	9	60.9
Cluster IOU	9	67.2

- 클러스터링을 통해 선택한 경계박스 5개의 평균 IOU가 61.0으로 일반적으로 사용하는 앵커박스를 9개 선택했을때 보다 높다.

5. Direct location prediction




Figure 3: Bounding boxes with dimension priors and location prediction. We predict the width and height of the box as offsets from cluster centroids. We predict the center coordinates of the box relative to the location of filter application using a sigmoid function.

- 학습 불안정의 주요 원인은 학습 초기에 박스의 x, y 위치가 너무 랜덤하게 예측되기 때문이다.
- Yolo는 이전 버전부터 x, y 위치를 그리드셀 내부에만 있도록 제약을 두었기 때문에 x, y 의 Ground truth(정답)은 항상 0과 1 사이의 값이 된다.
- 예측할 때는 시그모이드 함수를 사용하여 0~1이 되도록 했다.
- 위치 예측 파라미터에 시그모이드 함수, 경계박스의 중심이 그리드셀 안에 있어야 한다는 제약이 있어서 네트워크의 학습이 보다 안정적이다.
- 앵커박스 없이 직접 예측할 때 보다 mAP가 5% 상승한다.

6. New network

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64	conv3-64	conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128	conv3-128	conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

그림) VGG 와 Darknet-19 의 네트워크 비교.

Type	Filters	Size/Stride	Output
Convolutional	32	3 × 3	224 × 224
Maxpool		2 × 2/2	112 × 112
Convolutional	64	3 × 3	112 × 112
Maxpool		2 × 2/2	56 × 56
Convolutional	128	3 × 3	56 × 56
Convolutional	64	1 × 1	56 × 56
Convolutional	128	3 × 3	56 × 56
Maxpool		2 × 2/2	28 × 28
Convolutional	256	3 × 3	28 × 28
Convolutional	128	1 × 1	28 × 28
Convolutional	256	3 × 3	28 × 28
Maxpool		2 × 2/2	14 × 14
Convolutional	512	3 × 3	14 × 14
Convolutional	256	1 × 1	14 × 14
Convolutional	512	3 × 3	14 × 14
Convolutional	256	1 × 1	14 × 14
Convolutional	512	3 × 3	14 × 14
Maxpool		2 × 2/2	7 × 7
Convolutional	1024	3 × 3	7 × 7
Convolutional	512	1 × 1	7 × 7
Convolutional	1024	3 × 3	7 × 7
Convolutional	512	1 × 1	7 × 7
Convolutional	1024	3 × 3	7 × 7
Convolutional	1000	1 × 1	7 × 7
Avgpool		Global	1000
Softmax			

Table 6: Darknet-19.

- Darknet-19를 특징 추출기로 사용
- VGG-19 와 유사하지만 연산량이 훨씬 적다.
- Darknet은 Maxpool이 굉장히 빠르게 시작되며 중간중간에 1×1 컨볼루션을 통해서 특징맵의 채널 수를 절반으로 줄인다.


7. Multi-Scale Training

Detection Frameworks	Train	mAP	FPS
Fast R-CNN [5]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[15]	2007+2012	73.2	7
Faster R-CNN ResNet[6]	2007+2012	76.4	5
YOLO [14]	2007+2012	63.4	45
SSD300 [11]	2007+2012	74.3	46
SSD500 [11]	2007+2012	76.8	19
YOLOv2 288 × 288	2007+2012	69.0	91
YOLOv2 352 × 352	2007+2012	73.7	81
YOLOv2 416 × 416	2007+2012	76.8	67
YOLOv2 480 × 480	2007+2012	77.8	59
YOLOv2 544 × 544	2007+2012	78.6	40


- YOLOv2 는 FCNN(Fully Convolutional Neural Network)이기 때문에 입력 이미지의 해상도를 변경시킬 수 있다.
- 네트워크는 이미지를 1/32로 줄이므로 입력이미지의 해상도는 32의 배수이다.
- 기존의 detection method 보다 빠르고 더 정확하다.

8. Fine-Grained Features

- 최종 특징 레이어가 7×7 에서 13×13 으로 커졌다.
- 기존 Yolo에서는 그리드 셀이 7×7 이고 각 그리드 셀은 2개의 경계박스를 제안했다.
- 또한 2개의 경계박스들은 경계 박스 안에 있는 오브젝트에 대한 클래스 확률을 공유했다.
- Yolo v2는 각 그리드 셀에서 5개의 경계박스 후보와 각 경계박스의 클래스 확률을 독립적으로 제안한다.



- Yolo : $7 * 7 * (5 + 5 + n_classes)$
- YOLOv2 : $13 * 13 * (5 * (5 + n_classes))$
- 최종 출력 : $13 * 13$ 크기의 125채널 특징맵



Detection data 와 분류 데이터 조합한 학습

- Detection data(경계 박스)는 모델을 완전히 back propagation 하고, classification data는 classifier 부분만 back propagation 한다.
- Detection dataset은 “개“, “사람” 처럼 그 수가 적다.
- Classification 데이터 셋은 개의 종류만 해도 수백 종류가 있다.
- 그러므로 두 종류의 데이터 셋을 같이 사용하기 위해서는 라벨을 일관성 있게 통합해야만 한다.
- Softmax는 모든 클래스가 상호배타적이라고 생각하기 때문에 멀티-라벨 모델을 사용한다.

Hierarchical classification





Figure 5: Prediction on ImageNet vs WordTree. Most ImageNet models use one large softmax to predict a probability distribution. Using WordTree we perform multiple softmax operations over co-hyponyms.

- Imagenet의 label의 언어구조는 wordnet에서 가져왔다.
- WordNet은 단어 간 서로 포함되는 관계를 방향 그래프로 그린 것이다.
- (“노퍽 테리어” → “테리어” → “사냥개” → “개”)
- 만약 label이 “노퍽 테리어” 라면 WordTree 를 거슬러 올라가서 더 상위 카테고리 알 수 있다.
- Detection의 경우 내려오며 예측한다.

Dataset combination with WordTree



- 코코 데이터셋과 이미지넷의 데이터셋을 합쳐서 계층적 워드 트리를 만들었다.

Conclusion

Method	data	mAP	aero	bike	bird	boat	bottle	bus	car	cat	chair	cow	table	dog	horse	mbike	person	plant	sheep	sofa	train	tv
Fast R-CNN [5]	07++12	68.4	82.3	78.4	70.8	52.3	38.7	77.8	71.6	89.3	44.2	73.0	55.0	87.5	80.5	80.8	72.0	35.1	68.3	65.7	80.4	64.2
Faster R-CNN [15]	07++12	70.4	84.9	79.8	74.3	53.9	49.8	77.5	75.9	88.5	45.6	77.1	55.3	86.9	81.7	80.9	79.6	40.1	72.6	60.9	81.2	61.5
YOLO [14]	07++12	57.9	77.0	67.2	57.7	38.3	22.7	68.3	55.9	81.4	36.2	60.8	48.5	77.2	72.3	71.3	63.5	28.9	52.2	54.8	73.9	50.8
SSD300 [11]	07++12	72.4	85.6	80.1	70.5	57.6	46.2	79.4	76.1	89.2	53.0	77.0	60.8	87.0	83.1	82.3	79.4	45.9	75.9	69.5	81.9	67.5
SSD512 [11]	07++12	74.9	87.4	82.3	75.8	59.0	52.6	81.7	81.5	90.0	55.4	79.0	59.8	88.4	84.3	84.7	83.3	50.2	78.0	66.3	86.3	72.0
ResNet [6]	07++12	73.8	86.5	81.6	77.2	58.0	51.0	78.6	76.6	93.2	48.6	80.4	59.0	92.1	85.3	84.8	80.7	48.1	77.3	66.5	84.7	65.6
YOLOv2 544	07++12	73.4	86.3	82.0	74.8	59.2	51.8	79.8	76.5	90.6	52.1	78.2	58.5	89.3	82.5	83.4	81.3	49.1	77.2	62.4	83.8	68.7

Table 4: PASCAL VOC2012 test detection results. YOLOv2 performs on par with state-of-the-art detectors like Faster R-CNN with ResNet and SSD512 and is 2 – 10× faster.

- YOLOv2의 mAP가 특별히 높지는 않다.
- SSD300과 SSD512의 중간 정도의 성능을 보인다.
- 장점은 2~10배 빠르다는 것이다.

Conclusion

- YOLOv2는 최고 성능의 빠른 검출 시스템으로, 이미지 사이즈에 따라 속도와 정확도 간의 트레이드 오프를 컨트롤 할 수 있다.
- 학습 중에 동적으로 입력데이터의 크기를 바꾸는 기술은 영상 처리 분야에 도움이 될 것이다.