

Learning to Generalize to More: Continuous Semantic Augmentation for Neural Machine Translation

자연어처리 2팀

김수빈, 신문종, 박희수, 진명훈, 황경진, 조진욱(발표자)

Paper Summary

번역 모델의 성능 향상을 위한 새로운 데이터 증강 방법 제안

➔ Continuous Semantic Augmentation (CSANMT)을 제안함

<기존 연구>

이전 연구들은 대부분 discrete space 에서의 변화를 통해 데이터를 증강함

- 그러나 이러한 discrete manipulation 은 **1. lack of diversity, 2. semantic deviation** 의 문제가 있음
- 이를 해결하기 위해 continuous space 에서 새로운 데이터를 sampling 하는 방식을 제안

<제안하는 방법론>

1. **Tangential Contrastive Learning**: source-target 언어를 한 공간에 맵핑하는 semantic encoder를 contrastive learning을 이용하여 학습. 학습된 semantic encoder 로 특정 데이터에 대해 “**의미적으로 동일한 영역(adjacency semantic region)**”을 구함
2. **Mixed Gaussian Recurrent Chain**: 의미적으로 동일한 영역에서 **새로운 훈련 데이터를 하는 다양하게 sampling** 하는 알고리즘

<실험>

다양한 환경에서의 실험과 Ablation Study, Analysis를 통해 1) 기존 연구의 문제를 해결했는지
2) 제안하는 방법이 왜 좋은 성능이 나오는지 상세히 분석함

Neural Machine Translation

기계 번역이란?

- Source 언어 문장에 의미적으로 맞는 Target 언어 문장을 생성하는 과제

기계 번역에서의 일반화

- 기계 번역을 일반 데이터와 달리 두 언어에 대한 병렬 데이터가 필요함
- 현재 Neural Machine Translation 기술은 대용량 병렬 데이터를 가지고 학습하면 한번도 보지 않은 문장들에 대해서도 뛰어난 번역 성능을 보임
- 그러나 많은 언어쌍은 병렬 데이터를 많이 구축하지 못하고 있음
- 따라서 데이터 증강 방법을 통해 부족한 일반화 성능을 개선하는 연구가 그동안 진행되어 옴

Data Augmentation

NLP 연구에선 부족한 훈련 데이터를 데이터 증강 기법을 통해 늘리는 다양한 시도가 있어옴


기존 연구

- Back-Translation (Sennrich et al., 2016; Ott et al., 2018)
- Self-Supervised Learning (Cheng et al., 2016)
- SwitchOut (Wang et al., 2018)
- Soft Contextual Data Augmentation (Gao et al., 2019)
- Robust NMT (Cheng et al., 2018, 2019, 2020)
- Data Diversification (Nguyen et al., 2020)
- 그 외 다수

크게 1. Back Translation 2. Adversarial Example 로 나눔

기존 연구1: Back Translation (BT)

기계 번역 분야에서 Back Translation 이란, Target 언어의 mono-lingual 데이터를 이용하여 새로운 pseudo 병렬 데이터를 만드는 방법이다.



기존 연구2: Adversarial Examples

기존 병렬 데이터를 수정해서 새로운 데이터를 만드는 모든 방법을 Adversarial Example 이라고 통칭한다

Synonym replacement

X: 我喜欢唱歌跳舞
Y: I **like** singing and dancing



X: 我喜欢唱歌跳舞
Y: I **enjoy** singing and dancing

Reorder


X: 我**喜欢**唱歌跳舞
Y: I like **singing and** dancing



X: 我**唱歌喜欢**跳舞
Y: I enjoy **and singing** dancing

Drop

X: 我喜欢唱歌**跳舞**
Y: I like **singing** and dancing



X: 我喜欢唱歌**跳舞**
Y: I enjoy **singing** and dancing

Random Replacement

X: 我**喜欢**唱歌跳舞
Y: I like singing and **dancing**



X: 我**支持**唱歌跳舞
Y: I enjoy singing and **walking**

기존 연구의 한계

이러한 방법들은 번역 성능을 올려주는 것은 하나, 이렇게 discrete space 에서 증강하는 방식은 두 가지 문제가 있다.

1. lack of diversity

- 디코딩 방법(greedy, beam) 때문
- 그게 아니더라도 같은 의미를 가지면서 다른 variants 를 다 커버하기엔 어려움

2. semantic deviation

- 약간의 manipulation 을 하더라도 그게 기존 문장과 동일하다고 보기 어려워짐

➔ Discrete manipulation 이 아닌 continuous space 에서 새로운 훈련 데이터를 얻는 방법이 필요함

➔ Continuous Semantic Augmentation (CSANMT)을 제안

문제 정의

데이터

같은 의미를 가진 한 쌍의 병렬 문장 데이터 $(\mathbf{x}, \mathbf{y}) \in (\mathcal{X}, \mathcal{Y})$

훈련하고자 하는 기계 번역 모델


$$\mathcal{X} \mapsto \mathcal{Y} : f(\mathbf{y}|\mathbf{x}; \Theta)$$

NMT 모델의 훈련 목표: Maximum Likelihood Estimation

Maximum Likelihood Estimation

training corpora parameters


$$J_{mle}(\Theta) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \mathcal{C}} (\log P(\mathbf{y}|\mathbf{x}; \Theta))$$



decomposed to

$$J_{mle}(\Theta) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \mathcal{C}} \left[\sum_{t=1}^{T'} \log P(y_t | \mathbf{y}_{<t}, \mathbf{x}; \Theta) \right]$$

Continuous Semantic Augmentation (CSANMT)

CSANMT 는 source, target 언어가 같이 맵핑되는 continuous space 에서 기존 훈련 데이터에 "의미적으로 동일한" 영역을 정의하고 새로운 데이터를 sampling 하는 것을 목표로 한다.

의미적으로 동일함(Semantic Vicinity)

- 같은 의미를 가졌으나 literal expression 만 다른 variants

Semantic Vicinity 가 성립하는 "의미적으로 동일한" 영역 = Adjacency semantic region

- 해당 공간에서 sampling 된 데이터는 의미적으로 같으나, 완전히 똑같은 데이터는 아님.
- 즉 (x, y) 로부터 이 영역을 구하면 여러 (x', y) 를 만들어 낼 수 있음

CSANMT 문제 정의

NMT 모델의 훈련 목표: Maximum Likelihood Estimation

Maximum Likelihood Estimation

training corpora

parameters

$$J_{mle}(\Theta) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \mathcal{C}} (\log P(\mathbf{y} | \mathbf{x}; \Theta))$$

$$J_{mle}(\Theta) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \mathcal{C}} \left[\sum_{t=1}^{T'} \log P(y_t | \mathbf{y}_{<t}, \mathbf{x}; \Theta) \right]$$

decomposed to

CSANMT 모델의 훈련 목표: Maximum Likelihood Estimation with Vicinities

Maximum Likelihood Estimation with Vicinities

$$J_{mle}(\Theta) = \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim \mathcal{C}, \hat{r}^{(k)} \in \mathcal{R}} (\log P(\mathbf{y} | \mathbf{x}, \hat{r}^{(k)}; \Theta))$$

$$\mathcal{R} = \{\hat{r}^{(1)}, \hat{r}^{(2)}, \dots, \hat{r}^{(K)}\}$$
$$\hat{r}^{(k)} \sim \nu(r_x, r_y)$$

a series of examples
sampled from the vicinity

CSANMT 의 구조

Vanilla Transformer와 의 차이점

1. Semantic Encoder

- Source sentence X 또는 Target sentence Y 에 대해 semantic representation 을 학습하는 encoder

$$r_x = \psi(\mathbf{x}; \Theta') \quad r_y = \psi(\mathbf{y}; \Theta')$$

- Source 와 Target 을 같은 한 공간에서 맵핑하기 때문에, 이론적으로는 $r_x = r_y$ 가 성립해야 함 (같은 의미를 가졌으나 두 언어로 표현된 문장 x, y)
(그러나 ψ 는 deterministic 하며, x 와 y는 각기 다른 input token sequence 이므로 두 값은 같을 수 없음)

2. Broadcasting Integration

- Semantic encoder 는 r_x, r_y 를 이용하여 새로운 데이터 $\hat{r}^{(i)}$ 를 K 개 sampling함 (data augmentation)
- 생성된 $\hat{r}^{(i)}$ 는 broadcasting integration 네트워크를 통해 time step t 에서의 출력과 통합됨




Figure 1: The framework of the CSANMT.

Semantic Encoder

Definition 1. There is a universal semantic space among the source and the target languages for neural machine translation, which is established by a semantic encoder. It defines a forward function $\underline{\psi(\cdot; \Theta')}$ to map discrete sentences into continuous vectors, that satisfies: $\underline{\forall(\mathbf{x}, \mathbf{y}) \in (\mathcal{X}, \mathcal{Y}) : r_x = r_y}$. Besides, an adjacency semantic region $\underline{\nu(r_x, r_y)}$ in the semantic space describes adequate variants of literal expression centered around each observed sentence pair $(\mathbf{x}, \mathbf{y})$.

Semantic Encoder

Definition 1. There is a universal semantic space among the source and the target languages for neural machine translation, which is established by a semantic encoder. It defines a forward function $\underline{\psi(\cdot; \Theta')}$ to map discrete sentences into continuous vectors, that satisfies: $\underline{\forall(\mathbf{x}, \mathbf{y}) \in (\mathcal{X}, \mathcal{Y}) : r_x = r_y}$. Besides, an adjacency semantic region $\nu(r_x, r_y)$ in the semantic space describes adequate variants of literal expression centered around each observed sentence pair $(\mathbf{x}, \mathbf{y})$.

- How to optimize the extra semantic encoder $\underline{\psi(\cdot; \Theta')}$ so that it produces a meaningful vicinity $\nu(r_x, r_y)$ for each training instance?
- How to obtain samples from the adjacency semantic region in an efficient and effective way?

Tangential Contrastive Learning


Positive pairs: 한 쌍의 병렬 데이터 (x, y) 의 임베딩 $\mathbf{r}_x^{(i)}, \mathbf{r}_y^{(i)}$

Negative pairs: 같은 배치 내 다른 병렬 데이터에 대한 (interpolated) 임베딩 $\mathbf{r}_{x'}^{(i)}, \mathbf{r}_{y'}^{(i)}$

- in-batch negatives 와 유사한 개념이나, $\mathbf{r}_x^{(i)}, \mathbf{r}_y^{(i)}$ 를 그대로 사용하지 않고 $\mathbf{r}_x^{(i)}, \mathbf{r}_y^{(i)}$ 와 interpolated 된 임베딩을 사용함

- Interpolation 을 통한 contrastive learning 이 더 효과적임을 이전 연구에서 보임


- Key idea: 단순한 in-batch negatives 는 너무 다른 존재라서 모델이 구분하기 너무 쉽고, 때문에 학습이 일정 수준 이상으로 안된다. 특정 instance 와 좀 더 유사한 pseudo negative sample 을 만들자



Tangential Contrastive Learning

Positive pairs: 한 쌍의 병렬 데이터 (x, y)의 임베딩

Negative pairs: 같은 배치 내 다른 병렬 데이터에 대한 (interpolated) 임베딩 (in-batch negatives)



- i and j are two instances randomly sampled from the training corpora.

$$r_{x'(j)} = r_{x^{(i)}} + \lambda_x (r_{x^{(j)}} - r_{x^{(i)}}), \lambda_x \in (\frac{d}{d'_x}, 1]$$


$$r_{y^{(j)}} = r_{y^{(i)}} + \lambda_y(r_{y^{(j)}} - r_{y^{(i)}}), \lambda_y \in (\frac{d}{d_y'}, 1]$$

$\nu(\mathbf{r}_x, \mathbf{r}_y)$: the union of two closed balls that are centered around r_x and r_y , the radius is $d = \|r_x - r_y\|_2$

Tangential Contrastive Learning

Positive pairs: 한 쌍의 병렬 데이터 (x, y)의 임베딩

Negative pairs: 같은 배치 내 다른 병렬 데이터에 대한 (interpolated) 임베딩 (in-batch negatives)



$\nu(\mathbf{r}_x, \mathbf{r}_y)$: the union of two closed balls that are centered around r_x and r_y , the radius is $d = \|\mathbf{r}_x - \mathbf{r}_y\|_2$

- i and j are two instances randomly sampled from the training corpora.

$$r_{x'(j)} = r_{x(i)} + \lambda_x (r_{x(j)} - r_{x(i)}), \lambda_x \in \left(\frac{d}{d'_x}, 1\right]$$

$$r_{y'(j)} = r_{y(i)} + \lambda_y (r_{y(j)} - r_{y(i)}), \lambda_y \in \left(\frac{d}{d'_y}, 1\right]$$


Adaptively adjusted factors during training

Reasonable Negatives are walking between tangent points and in-batch ones


Tangential Contrastive Learning

Positive pairs: 한 쌍의 병렬 데이터 (x, y)의 임베딩

Negative pairs: 같은 배치 내 다른 병렬 데이터에 대한 (interpolated) 임베딩 (in-batch negatives)





A training batch



Tangential Contrastive Learning

Positive pairs: 한 쌍의 병렬 데이터 (x, y)의 임베딩



Negative pairs: 같은 배치 내 다른 병렬 데이터에 대한 (interpolated) 임베딩 (in-batch negatives)



Tangential Contrastive Learning

Positive pairs: 한 쌍의 병렬 데이터 (x, y)의 임베딩


Negative pairs: 같은 배치 내 다른 병렬 데이터에 대한 (interpolated) 임베딩 (in-batch negatives)



Tangential Contrastive Learning

Positive pairs: 한 쌍의 병렬 데이터 (x, y)의 임베딩

Negative pairs: 같은 배치 내 다른 병렬 데이터에 대한 (interpolated) 임베딩 (in-batch negatives)



Parallel sentence pairs

$$J_{ctl}(\Theta') = \mathbb{E}_{(x^{(i)}, y^{(i)}) \sim \mathcal{B}} \left(\log \frac{e^{s(r_{x^{(i)}})}, r_{y^{(i)}})} }{e^{s(r_{x^{(i)}})}, r_{y^{(i)}}} + \xi} \right)$$

$$\xi = \sum_{j \& j \neq i}^{|B|} \left(e^{s(r_{y^{(i)}}), r_{y'^{(j)}})} + e^{s(r_{x^{(i)}}), r_{x'^{(j)}})} \right)$$

Interpolated in-batch negatives

Sampling with Mixed Gaussian Recurrent Chain

CSANMT 는 source, target 언어가 같이 맵핑되는 continuous space 에서 기존 훈련 데이터에 "의미적으로 동일한" 영역을 정의하고 새로운 데이터를 sampling 하는 것을 목표로 한다.


➔ "의미적으로 동일한" 영역에서 어떻게 샘플링 해야 할까?

Sampling with Mixed Gaussian Recurrent Chain

CSANMT 는 source, target 언어가 같이 맵핑되는 continuous space 에서 기존 훈련 데이터에 "의미적으로 동일한" 영역을 정의하고 새로운 데이터를 sampling 하는 것을 목표로 한다.

➔ "의미적으로 동일한" 영역에서 어떻게 샘플링 해야 할까?

A possible solution with vector transform




Sampling with Mixed Gaussian Recurrent Chain

CSANMT 는 source, target 언어가 같이 맵핑되는 continuous space 에서 기존 훈련 데이터에 "의미적으로 동일한" 영역을 정의하고 새로운 데이터를 sampling 하는 것을 목표로 한다.

➔ "의미적으로 동일한" 영역에서 어떻게 샘플링 해야 할까?

A possible solution with vector transform




Compute the bias vector
between the embeddings of
two parallel sentences

Sampling with Mixed Gaussian Recurrent Chain

CSANMT 는 source, target 언어가 같이 맵핑되는 continuous space 에서 기존 훈련 데이터에 "의미적으로 동일한" 영역을 정의하고 새로운 데이터를 sampling 하는 것을 목표로 한다.

➔ "의미적으로 동일한" 영역에서 어떻게 샘플링 해야 할까?

A possible solution with vector transform



Compute the bias vector
between the embeddings of
two parallel sentences


Transform the norm or the
direction of the bias vector

Sampling with Mixed Gaussian Recurrent Chain

CSANMT 는 source, target 언어가 같이 맵핑되는 continuous space 에서 기존 훈련 데이터에 "의미적으로 동일한" 영역을 정의하고 새로운 데이터를 sampling 하는 것을 목표로 한다.


➔ "의미적으로 동일한" 영역에서 어떻게 샘플링 해야 할까?

A possible solution with vector transform



Sampling with Mixed Gaussian Recurrent Chain

A possible solution with vector transform



Vector transform 으로 새로운 데이터를 sampling 하되,
K 개의 샘플링을 해야함으로 이에 대한 적절한 알고리즘이 필요하다

$$\omega \in \{\omega^{(1)}, \omega^{(2)}, \dots, \omega^{(K)}\}$$

Sampling with Mixed Gaussian Recurrent Chain

MGRC Sampling Algorithm

Input: The representations of the training instance $(\mathbf{x}, \mathbf{y})$,
i.e. r_x and r_y .

Output: A set of augmented samples $\mathcal{R} = \{\hat{r}^{(1)}, \hat{r}^{(2)}, \dots, \hat{r}^{(K)}\}$

- 1: Normalizing the importance of each element in $\tilde{r} = r_y - r_x$: $\mathcal{W}_r = \frac{|\tilde{r}| - \min(|\tilde{r}|)}{\max(|\tilde{r}|) - \min(|\tilde{r}|)}$
- 2: Set $k = 1$, $\omega^{(1)} \sim \mathcal{N}(\mathbf{0}, \text{diag}(\mathcal{W}_r^2))$, $\hat{r}^{(1)} = r + \omega^{(1)} \odot (r_y - r_x)$
- 3: Initialize the set of samples as $\mathcal{R} = \{\hat{r}^{(1)}\}$.
- 4: **while** $k \leq (K - 1)$ **do**
- 5: $k \leftarrow k + 1$
- 6: Calculate the current scale vector: $\omega^{(k)} \sim p(\omega | \omega^{(1)}, \omega^{(2)}, \dots, \omega^{(k-1)})$ according to Eq. (6).
- 7: Calculate the current sample: $\hat{r}^{(k)} = r + \omega^{(k)} \odot (r_y - r_x)$.
- 8: $\mathcal{R} \leftarrow \mathcal{R} \cup \{\hat{r}^{(k)}\}$.
- 9: **end while**


Sampling with Mixed Gaussian Recurrent Chain

MGRC Sampling Algorithm

Input: The representations of the training instance $(\mathbf{x}, \mathbf{y})$,
i.e. r_x and r_y .

Output: A set of augmented samples $\mathcal{R} = \{\hat{r}^{(1)}, \hat{r}^{(2)}, \dots, \hat{r}^{(K)}\}$

- 1: Normalizing the importance of each element in $\tilde{r} = r_y - r_x$: $\mathcal{W}_r = \frac{|\tilde{r}| - \min(|\tilde{r}|)}{\max(|\tilde{r}|) - \min(|\tilde{r}|)}$
- 2: Set $k = 1$, $\omega^{(1)} \sim \mathcal{N}(\mathbf{0}, \text{diag}(\mathcal{W}_r^2))$, $\hat{r}^{(1)} = r + \omega^{(1)} \odot (r_y - r_x)$
- 3: Initialize the set of samples as $\mathcal{R} = \{\hat{r}^{(1)}\}$.
- 4: **while** $k \leq (K - 1)$ **do**
- 5: $k \leftarrow k + 1$
- 6: Calculate the current scale vector: $\omega^{(k)} \sim p(\omega | \omega^{(1)}, \omega^{(2)}, \dots, \omega^{(k-1)})$ according to Eq. (6).
- 7: Calculate the current sample: $\hat{r}^{(k)} = r + \omega^{(k)} \odot (r_y - r_x)$.
- 8: $\mathcal{R} \leftarrow \mathcal{R} \cup \{\hat{r}^{(k)}\}$.
- 9: **end while**



Sampling with Mixed Gaussian Recurrent Chain

MGRC Sampling Algorithm

Input: The representations of the training instance $(\mathbf{x}, \mathbf{y})$,
i.e. r_x and r_y .

Output: A set of augmented samples $\mathcal{R} = \{\hat{r}^{(1)}, \hat{r}^{(2)}, \dots, \hat{r}^{(K)}\}$

1: Normalizing the importance of each element in $\tilde{r} = r_y - r_x$: $\mathcal{W}_r = \frac{|\tilde{r}| - \min(|\tilde{r}|)}{\max(|\tilde{r}|) - \min(|\tilde{r}|)}$

2: Set $k = 1$, $\omega^{(1)} \sim \mathcal{N}(\mathbf{0}, \text{diag}(\mathcal{W}_r^2))$, $\hat{r}^{(1)} = r + \omega^{(1)} \odot (r_y - r_x)$

3: Initialize the set of samples as $\mathcal{R} = \{\hat{r}^{(1)}\}$.

4: **while** $k \leq (K - 1)$ **do**

5: $k \leftarrow k + 1$

6: Calculate the current scale vector: $\omega^{(k)} \sim p(\omega | \omega^{(1)}, \omega^{(2)}, \dots, \omega^{(k-1)})$ according to Eq. (6).

7: Calculate the current sample: $\hat{r}^{(k)} = r + \omega^{(k)} \odot (r_y - r_x)$.

8: $\mathcal{R} \leftarrow \mathcal{R} \cup \{\hat{r}^{(k)}\}$.

9: **end while**

Limits the range of sampling to a subspace of the vicinity, and rejects to conduct sampling from the uninformative dimensions


$$p = \eta \mathcal{N}(\mathbf{0}, \text{diag}(\mathcal{W}_r^2)) + (1.0 - \eta) \mathcal{N}\left(\frac{1}{k-1} \sum_{i=1}^{k-1} \omega^{(i)}, \mathbf{1}\right)$$




Describes the fact that the diversity of each training instance is not infinite

CSANMT 의 훈련 과정 정리

1. Tangential contrastive learning 을 이용하여 semantic encoder 을 학습시킴

$$\Theta'^* = \operatorname{argmax}_{\Theta'} J_{ctl}(\Theta')$$



CSANMT 의 훈련 과정 정리

1. Tangential contrastive learning 을 이용하여 semantic encoder 을 학습시킴

$$\Theta'^* = \operatorname{argmax}_{\Theta'} J_{ctl}(\Theta')$$

2. MGRC sampling algorithm 을 통해 증강되는 데이터를 Maximum likelihood estimation with vicinities 를 훈련 목표로 하여 기계 번역 모델 학습

$$\Theta^* = \operatorname{argmax}_{\Theta} J_{mle}(\Theta)$$




Figure 1: The framework of the CSANMT.

CSANMT 의 훈련 과정 정리

1. Tangential contrastive learning 을 이용하여 semantic encoder 을 학습시킴

$$\Theta'^* = \operatorname{argmax}_{\Theta'} J_{ctl}(\Theta')$$

2. MGRC sampling algorithm 을 통해 증강되는 데이터를 Maximum likelihood estimation with vicinities 를 훈련 목표로 하여 기계 번역 모델 학습

$$\Theta^* = \operatorname{argmax}_{\Theta} J_{mle}(\Theta)$$

- 2번을 수행하면서 semantic encoder 또한 추가로 같이 학습 (매우 작은 learning rate)

$$\Theta' = \Theta' - \alpha_{ctl} \cdot \nabla_{\Theta'} J_{ctl}(\Theta')$$

CSANMT 의 추론 과정

일반적인 추론과의 차이점

1. Semantic Encoder 에서 추가 정보 제공

- 다만 추론에서는 sampling 없이, semantic encoder 가 임베딩한 정보를 그대로 decoder 에 제공함

$$r_x = \psi(\mathbf{x}; \Theta')$$

- 따라서 생성 과정은 다음과 같이 나타낼 수 있음

$$y_t^* = \operatorname{argmax}_{y_t} P(\cdot | \mathbf{y}_{<t}, \mathbf{x}, r_x; \Theta)$$




Figure 1: The framework of the CSANMT.

실험 설정

1. 대용량 데이터에서 기존 데이터 증강기법과의 비교 실험

- Chinese(Zh) to English(En), NIST
- English(En) to German(De), WMT14
- English(En) to French(Fr), WMT14


2. 소량의 데이터에서 기존 데이터 증강기법과의 비교 실험

- English(En) to German(De), IWSLT14
- English(En) to French(Fr), IWSLT17

3. Semantic Encoder 을 제외한 나머지 세팅은 Transformer(Vaswani et al., 2017)을 따름

실험 결과: Zh-En, NIST

NIST Chinese-to-English, LDC corpus (1.25M) for training, MT06 (valid), MT02-05&08 (test)



4.2 BLEU higher than Transformer

3.1 BLEU higher than Back-Translation

1.0 BLEU higher than AdvAug

실험 결과: En-De, En-Fr, WMT14

Model	WMT 2014 En→De			WMT 2014 En→Fr		
	#Params.	BLEU	SacreBLEU	#Params.	BLEU	SacreBLEU
Transformer, base (<i>our implementation</i>)	62M	27.67	26.8	67M	40.53	38.5
Transformer, big (<i>our implementation</i>)	213M	28.79	27.7	222M	42.36	40.3
Back-Translation (Sennrich et al., 2016a)*	213M	29.25	28.2	222M	41.73	39.7
SwitchOut (Wang et al., 2018)*	213M	29.18	28.1	222M	41.62	39.6
SemAug (Wei et al., 2020a)	221M	30.29	-	230M	42.92	-
AdvAug (Cheng et al., 2020)	†65M	29.57	-	-	-	-
Data Diversification (Nguyen et al., 2020)	†1260M	30.70	-	†1332M	43.70	-
CSANMT, base	74M	30.16	29.2	80M	42.40	40.3
CSANMT, big	265M	30.94	29.8	274M	43.68	41.6

Table 2: BLEU scores [%] on the WMT14 En→De and En→Fr tasks. “*” indicates the results obtained by our implementation, which is the same in Table 1. “†” denote estimate values. We further compare against the baselines with increased amounts of parameters, and investigate the performance of CSANMT equipped with much stronger baselines (e.g. deep and scale Transformers (Ott et al., 2018; Wang et al., 2019; Wei et al., 2020b)) in Sec. 3.3.


실험 결과: En-De, En-Fr, IWSLT

- Low resource setting 에서도 잘 작동함
 - Vanilla transformer 보다 2.7점 상승
 - Back-Translation 에 비해 성능 향상의 폭이 더 큼

Model	English-German	English-French
Transformer	28.64	35.8
Back-translation	29.45	36.3
CSANMT	31.29	38.6

Table 7: BLEU scores [%] on the IWSLT tasks. For fairer comparison, all the models are implemented by ourselves using the same backbone, and the extra monolingual corpora is not introduced into back-translation.

실험 분석: Data utilization & training efficiency



- CSANMT 는 low-resource 환경에서 더 나은 data utilization & training efficiency 를 보인다
 - 25%의 데이터만 사용해도 이미 baseline(vanilla transformer)의 최고 성능을 달성함
 - Back translation 의 경우 추가적으로 2M(전체 데이터의 약 50%)의 mono-lingual 데이터를 사용하더라도 CSANMT 보다 떨어지는 성능을 보인다

실험 분석: Semantic Encoder 의 성능

Model	BLEU	Dec. speed
Transformer-base	27.67	reference
Default 4-layer semantic encoder	30.16	0.95×
Remove the extra semantic encoder	28.71	1.0×
Take PTMs as the semantic encoder	31.10	0.62×

Table 3: Effect of the semantic encoder variants.

- Large Scale pretrained model, PTM 을 사용하였더니 (여기서는 XLM-R) 번역 성능이 올라갔다
 - 기존의 semantic encoder 는 Transformer base 모델의 16% 정도 밖에 안되는 적은 파라미터를 가지고 있음
 - 잘 학습된 대용량 사전학습 모델로 semantic encoder 을 사용하면 더 높은 번역 성능을 기대할 수 있다
- Semantic encoder 이 없어도 transformer base 보다 jointly 하게 학습된 transformer 의 성능이 더 좋다
 - 따라서 데이터 증강기법을 통해 transformer 모델의 가중치 또한 well trained 하게 되었다

실험 분석: tangential CTL 과 MGRC 의 성능

#	Objective	Sampling	BLEU
1	Default tangential CTL	Default MGRC	30.16
2	Default tangential CTL	MGRC w/o recurrent chain	29.64
3	Default tangential CTL	MGRC w/ uniform dist.	29.78
4	Variational Inference	Gaussian sampling	28.07
5	Cosine similarity	Default MGRC	28.19

Table 5: Effect of MGRC sampling and tangential contrastive learning on En→De validation set.

- semantic encoder 을 학습할 수 있는 방법, sampling 하는 방법은 실제로 다양하다
 - 그러나 tangential contrastive learning 을 통해 semantic encoder 을 학습하는 것이 효과적이다
- Sampling 방식 또한 MGRC 방식이 가장 효과적이다
 - Gaussian dist. 를 이용하는 것이나 recurrent 하게 sampling 을 하는 것 모두 중요한 요소이다

Paper Summary

번역 모델의 성능 향상을 위한 새로운 데이터 증강 방법 제안

➔ Continuous Semantic Augmentation (CSANMT)을 제안함

<기존 연구>

이전 연구들은 대부분 discrete space에서의 변화를 통해 데이터를 생성함

- 그러나 이러한 discrete manipulation 은 1. lack of diversity, 2. semantic deviation 의 문제가 있음
- 이를 해결하기 위해 continuous space 에서 새로운 데이터를 sampling 하는 방식을 제안

<방법론>

1. **Tangential Contrastive Learning**: source-target 언어를 한 공간에 맵핑하는 semantic encoder를 contrastive learning을 이용하여 학습. 학습된 semantic encoder 로 특정 데이터에 대해 “의미적으로 동일한 영역(adjacency semantic region)”을 구함
2. **Mixed Gaussian Recurrent Chain**: 의미적으로 동일한 영역에서 새로운 훈련 데이터를 하는 다양하게 sampling 할 수 있는

알고리즘을 제시

<실험>

다양한 환경에서의 실험과 Ablation Study, Analysis를 통해 1) 기존 연구의 문제를 해결했는지

2) 제안하는 방법이 왜 잘되는지를 상세히 분석함

감사합니다.