

# GTRANS- Grouping and Fusing Transformer Layers for Neural Machine Translation

---

자연어처리 2팀

김수빈, 신문종, 박희수, 진명훈, 황경진, 조진욱(발표자)

# Paper Summary

---

## 트랜스포머 모델의 multi-level layer 들을 활용하여 성능을 향상시키는 방법 제안

➔ Multi-level layer features 를 encoder, decoder 단에서 잘 활용하는 fusion 방식을 제안.

### <기존 연구>

Transformer 모델은 top-level representation 만을 사용하기 때문에 lower-level layer 들의 정보가 잘 활용되지 못함.

이를 해결하기 위해 이전 연구들은 1) low level layer 정보에 더 집중 2) 전체 encoder layer 정보 모두 활용하는 연구 있었음

- 그러나 기존 연구는 decoder의 multi-layer features 를 충분히 활용하지 못함

- 그리고 shallow 한 모델에서의 성능 향상이 거의 없었음

### <방법론>

전체 레이어를 그룹으로 나누어, 각 그룹마다 가중치를 두어 정보를 취합하는 Encoder fusion, Decoder fusion 방식을 제안함

### <실험>

다양한 언어쌍 / bilingual & multilingual / high-med-low 크기 데이터셋 에서 기존 연구들보다 일관되게 뛰어난 성능을 보임

자세한 분석을 통해 multi layer feature 을 활용하는 것이 deep 한 모델, longer sentence 에서 매우 중요함을 보임.

# 배경 – Deepening the Transformer model

---

기계번역 과제에선 Transformer(Vaswani et al, 2017) 의 사용으로 인해 큰 성능 향상이 있음

- Sequence-to-Sequence
- Encoder-Decoder

Transformer 의 레이어 수를 더 키우는 것(deepening)은 일반적으로 성능의 향상을 발생함.

- 특히 multilingual translation 에서는 풍부한 표현을 담아낼 수 있는 deep model 이 중요함
- 그러나 깊게 만들 수록 수렴하기 어려워지며, 성능이 오히려 떨어지는 경우도 있음
  - low resource 에선 deep 한 모델이 성능 떨어짐
- Vaswani 의 Transformer 을 deep 하게 만들면 훈련 자체가 안되는 경우도 발생함
  - higher risk of gradient vanishing or exploding

# 배경 – Deepening the Transformer model

Transformer vanilla 는 뒤에서 layer normalization 을 수행하는 post-norm 방식.

- 기존 연구에서 pre-norm 방식으로 deep Transformer 를 학습하는데 성공함





Figure 1: Examples of pre-norm residual unit and post-norm residual unit.  $\mathcal{F}$  = sub-layer, and LN = layer normalization.

Post-Norm is defined as:

$$x_{l+1} = \text{LN}(x_l + \mathcal{F}(x_l; \theta_l)) \quad (3)$$

**Pre-Norm**

Pre-Norm is defined as:

$$x_{l+1} = x_l + \mathcal{F}(\text{LN}(x_l); \theta_l) \quad (4)$$

# 배경 – Deepening the Transformer model

---

그러나 pre-norm 방식은 shallow 한 경우 post-norm 보다 오히려 성능이 낮음.

즉,

- 1) post-norm(Vaswani, 2017): Deep Model 훈련 실패
- 2) pre-norm(Wang, 2019): Deep 하게 가능은 하지만 shallow 기준으로는 post-norm 보다 성능 낮음

➔ post-norm 방식을 deep 하게 만드는 방법은 없을까?

# 배경 – Utilizing multi-level representation

---

Transformer vanilla 는 encoder, decoder 모두 top layer representation 만 사용함

- Encoder: last encoder layer representation 만 각 decoder layer 에서 enc-dec attention 으로 활용됨

- Decoder: 최종 output 을 계산할 때 last decoder layer representation 만 사용함

최근 많은 연구들이 다양한 과제에서 different level representation 을 사용하는 것이 도움이 된다고 주장함.

➔ how to fully utilize the multi-layer features to ameliorate the translation quality?

Q. Wang, F. Li, T. Xiao, Y. Li, Y. Li, and J. Zhu, “Multi-layer representation fusion for neural machine translation,” in COLING 2018. Association for Computational Linguistics, 2018, pp. 3015–3026.

G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in CVPR2017, 2017, pp. 2261–2269.

H. Guo, R. Pasunuru, and M. Bansal, “Soft layer-specific multi-task summarization with entailment and question generation,” in ACL 2018, 2018, pp. 687–697.

# 기존 연구와 한계점

---

## 1. Deepen the Transformer

- Pre-norm residual unit & Linear Combination(Wang, 2019)

## 2. Utilize the multi-level representation

- MLRF(Wang, 2018), TA(Bapna, 2018), Rezero(Bachlechner, 2020),

### 기존 연구들의 한계

- 1) pre-norm 방식은 같은 레이어 수에서 post-norm 보다 성능이 떨어짐

- 2) decoder 의 multi-layer feature 을 같이 활용하는 연구 거의 없음

- MLRF 는 encoder decoder 모두 사용하나 shallow 한 depth 에서는 성능 향상이 없음

➔ Bi & multi-lingual 환경에서 모두 잘 작동하며, deep & shallow 모델 모두 가능한 multi-layer fusion 방식 제안함

# 방법론 – Multi-layer Representation Fusion




Fig. 1. Comparison between (a) the single-layer feature and (b) multi-layer feature fusion. (a) is the network only using representation of the last layer, and (b) is the network with the multi-layer feature incorporation, where all layers are divided into different groups.

- 그룹 수에 따라 sequential 한 layer stack 을 인접한 레이어들로 묶어 그룹을 만들었음
- 각 그룹에 대한 representation 을 합쳐서 multi-layer representation 만들 수 있음




# 방법론 - Group Transformer (Gtrans)

1) Encoder Representation Fusion

2) Decoder Representation Fusion

- 둘 다 전체 레이어를 1)그룹화 2)가중합(fusion) 한다는 점은 같으나, 세부 방식에서 차이 존재함



# 방법론 – Encoder Representation Fusion

---

## Notation

- 먼저  $L_e$  개 레이어를 가지는 인코더가  $H_e$  라는 stacked hidden states 를 가지고 있다고 정의

$$H_e = \{h_1^e, \dots, h_{L_e}^e\}$$

- 여기서  $\Phi_e(\cdot)$  은  $H_e$  를 fuse, 합쳐서 하나의 fused representation  $h_e^f$  로 만드는 fusion function 임.

$$h_e^f = \Phi_e(H_e) = \Phi(h_1^e, \dots, h_{L_e}^e)$$

# 방법론 – Encoder Representation Fusion

---

## Fusion function

$$\Phi_e(H_e) = LN(\frac{1}{M} \sum_{i=1}^M \sigma(w_i^e) h_{\alpha_i}^e)$$

- $T_e$  는 인코더의 각 그룹 크기를 얼마로 할 지임.  $M = \lceil \frac{L_e}{T_e} \rceil$  이며, 즉 인코더 그룹의 수 를 말함.
- $\alpha_i = \min(iT_e, L_e)$  이는 특정 레이어를 선택할 때 전체 레이어의 수 와 i 번째 그룹의 크기와 둘 중 작은 걸 선택하게 됨
  - 즉 가중치를 받을 h 라는 repr. 을 고를 때 그룹 내에서 가장 마지막 레이어를 선택하겠다는 말임
- $LN$  은 레이어 놔,  $\sigma$  는 시그모이드 활성화 함수를 말함

# 방법론 – Decoder Representation Fusion

---

- 각 디코더 레이어는 enc-dec attention 을 fused encoder representation  $h_e^f$  와 진행함
- 디코더도 인코더 처럼 각 레이어 마다의 hidden states 를 시퀀스 처럼 표현가능

$$H_d = \{h_1^d, \dots, h_{L_d}^d\}$$

- 디코더는 인코더와 다르게 각 그룹마다 레이어에 대한 weighted representation 을 먼저 계산함

$$h_k^{d_f} = \sum_{i=(k-1)T_d+1}^{\min(kT_d, L_d)} \sigma(w_i^{d_r}) h_i^d$$

$$\Phi_{d_r}(H_d) = [h_1^{d_f}, \dots, h_k^{d_f}, \dots, h_N^{d_f}]$$

# 방법론 – Decoder Representation Fusion

- 그 뒤 각 디코더 그룹의 representation  $h_k^{df}$  를 합치는 probability fusion function 을 통해 최종 확률을 구함

$$\begin{aligned} P(y|x) &= \Phi_{d_p} (\Phi_{d_r} (H_d)) \\ &= \sum_{i=1}^N \psi(w_i^{d_p}) P_i(y|x) \\ &= \sum_{i=1}^N \psi(w_i^{d_p}) \text{softmax}(h_i^{df} W_o) \end{aligned}$$

- 여기서  $\psi(w_i^{d_p})$  는 확률로 구하기 위해 normalize 하는 가중치임

$$\psi(w_i^{d_p}) = \frac{e^{\frac{w_i^{d_p}}{\tau}}}{\sum_{j=1}^N e^{\frac{w_j^{d_p}}{\tau}}}$$

# 방법론 – Multi Level Training

- 기계번역 데이터 쌍  $(x, y)$  는 일반적인 훈련 방식과 동일하게 훈련되나, 각 그룹 마다 parametrized 된 loss weight 을 고려하여 gradient propagation 이 일어남

$$\mathcal{L}_{MT} = - \sum_{(x,y) \in \mathcal{D}} \sum_{i=1}^N \psi(w_i^{d_p}) \log P_i(y|x; \theta)$$

- 실제 훈련 코드

```
# T x B x C -> layers x T x B x C -> groups x group_layers x T x B x C
decoder_fusion_weight = torch.sigmoid(
    self.decoder_fusion_weight.unsqueeze(1)
    .unsqueeze(2).unsqueeze(3))
x = torch.stack(inner_states, dim=0) * decoder_fusion_weight
x = x.view(self.decoder_group_number, self.decoder_group_layers,
           x.size(1), x.size(2), x.size(3))
x = x.mean(dim=1) # G x T x B x C
loss_weight = self.loss_weight
loss_weight = utils.softmax(loss_weight / self.softmax_temperature, dim=-1)
```

# 방법론 정리

---

## 1) Encoder Representation Fusion

- Transformer vanilla 와 달리, 인코더의 그룹 정보가 디코더 각 레이어에서 활용됨
  - 모든 인코더 정보가 다 들어가는 것은 아니고, 인코더 각 그룹마다 마지막 레이어의 정보임
  - 각 그룹마다 얼마나 정보를 활용할지(가중치) 를 훈련하면서 알아감

## 2) Decoder Representation Fusion

- Transformer vanilla 와 달리, 디코더 최종 아웃풋은 각 디코더 그룹에서 나온 정보를 잘 취합해서 만들어짐
  - 각 그룹에서 나온 정보는 해당 그룹의 모든 레이어 정보가 다 들어가 있음
  - 각 그룹마다 얼마나 정보를 활용할지(가중치)를 훈련하면서 알아감
  - 하나의 그룹에서 각 레이어 마다 얼마나 정보를 활용할지(가중치)를 훈련하면서 알아감

# 실험 세팅

---

## 1. 데이터셋

- Bilingual & Multilingual, High-Med-Low resource setting 전부 실험해 봄

### 1) Bilingual

- IWSLT14 German English: 16k 작은 데이터셋
- LDC Chinese English: 1.25 M 소규모
- WMT14 English German: 4 M 중규모

### 2) Multilingual

- IWSLT17: English (En), German (De), Italian (It), Dutch (Nl), and Romanian (Ro)
- OPUS-100: massively multilingual machine translation, 94 개 언어쌍 사용



# 실험 세팅

---

## 2. 비교 모델

- PreNorm, PostNorm, TA, DLCL, Rezero, MLRF

- 기존 연구들을 비교

  - 최근 연구가 부족함

- 각 데이터셋마다 적절한 Depth 를 선정해서 실험함

  - 1: LDC Zh En, 6-6, transformer\_base,

  - 2: IWSLT14 DeEn & WMT14 EnDe, 6-6, transformer\_small & transformer\_big

  - 3: IWSLT14 DeEn, 12-12, transformer\_base

  - 4: IWSLT17 Multi, both direction, 6-6, transformer\_base

  - 5: OPUS Multi, many-to-many, high-med-low resource, 12-6

# 실험 결과

TABLE I

EVALUATION RESULTS ON THE ZH  $\rightarrow$  EN TRANSLATION TASK WITH BLEU% METRIC. THE "AVG." COLUMN MEANS THE AVERAGED RESULT OF ALL NIST TEST SETS EXCEPT NIST2006. ALL MODELS CONSIST OF 6 ENCODER AND DECODER LAYERS.

| Zh $\rightarrow$ En        | MT06         | MT02         | MT03         | MT05         | MT08         | MT12         | Avg.         |
|----------------------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
| Pre-norm Transformer [5]   | 43.03        | 42.97        | 43.86        | 44.05        | 36.07        | 34.73        | 40.34        |
| Post-norm Transformer [5]  | 43.52        | 43.17        | 44.06        | 44.45        | 36.27        | 35.07        | 40.60        |
| TA [14]                    | 44.02        | 43.40        | 44.22        | 44.66        | 36.33        | 35.22        | 41.30        |
| MLRF [17]                  | 44.94        | 43.88        | 45.70        | 45.25        | 37.54        | 35.80        | 41.63        |
| DLCL [8]                   | 44.02        | 43.84        | 44.98        | 44.62        | 36.77        | 34.89        | 41.02        |
| ReZero [9]                 | 43.22        | 43.02        | 45.59        | 43.89        | 35.94        | 34.17        | 40.52        |
| <b>GTRANS (our method)</b> | <b>44.48</b> | <b>44.02</b> | <b>46.54</b> | <b>46.33</b> | <b>38.22</b> | <b>36.42</b> | <b>42.31</b> |

TABLE II

BLEU-4 SCORES (%) ON THE IWSLT-2014 DE $\rightarrow$ EN TASK AND WMT-2014 EN $\rightarrow$ DE TRANSLATION TASK. ALL MODELS CONSIST OF 6 ENCODER AND DECODER LAYERS.

| Model                      | De $\rightarrow$ En | En $\rightarrow$ De |
|----------------------------|---------------------|---------------------|
| Pre-norm Transformer [5]   | 34.07               | 28.82               |
| Post-norm Transformer [5]  | 34.27               | 29.22               |
| TA [14]                    | 34.54               | 28.64               |
| MLRF [17]                  | 34.83               | 29.42               |
| DLCL [8]                   | 34.40               | 29.42               |
| ReZero [9]                 | 33.67               | 28.22               |
| <b>GTRANS (our method)</b> | <b>35.32</b>        | <b>30.01</b>        |

TABLE III

BLEU-4 SCORES (%) ON THE IWSLT-2014 DE $\rightarrow$ EN TASK. ALL DEEP MODEL CONSIST OF 12 ENCODER LAYERS AND 12 DECODER LAYERS.

| De $\rightarrow$ En        | BLEU         |
|----------------------------|--------------|
| Pre-norm Transformer [5]   | 34.88        |
| Post-norm Transformer [5]  | 35.12        |
| TA [14]                    | 34.80        |
| MLRF [17]                  | 35.10        |
| DLCL [8]                   | 34.82        |
| ReZero [9]                 | 34.04        |
| <b>GTRANS (our method)</b> | <b>35.68</b> |

TABLE IV  
EVALUATION RESULTS ON THE IWSLT-2017 MULTILINGUAL TRANSLATION TASK WITH BLEU-4 SCORES (%). ALL MODELS CONSIST OF 6 ENCODER AND DECODER LAYERS.

| IWSLT-2017 De,It,Nl,Ro $\leftrightarrow$ En multilingual Translation |              |               |              |               |              |               |              |               |              |
|----------------------------------------------------------------------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|---------------|--------------|
| Model                                                                | En-De        |               | En-It        |               | En-Nl        |               | En-Ro        |               | Avg.         |
|                                                                      | $\leftarrow$ | $\rightarrow$ | $\leftarrow$ | $\rightarrow$ | $\leftarrow$ | $\rightarrow$ | $\leftarrow$ | $\rightarrow$ |              |
| Pret-norm Transformer [5]                                            | 27.44        | 22.63         | 36.87        | 30.28         | 31.54        | 28.86         | 30.45        | 24.14         | 29.03        |
| Post-norm Transformer [5]                                            | 27.78        | 22.93         | 37.07        | 30.68         | 31.86        | 29.16         | 31.02        | 24.69         | 29.39        |
| TA [14]                                                              | 27.35        | 24.39         | 36.70        | 32.35         | 32.33        | 30.63         | 32.44        | 26.00         | 30.27        |
| MLRF [17]                                                            | 28.62        | 24.11         | 37.62        | 32.65         | 33.14        | 31.10         | 33.09        | 26.93         | 30.91        |
| DLCL [8]                                                             | 27.29        | 22.66         | 37.04        | 31.53         | 32.57        | 29.39         | 31.45        | 25.13         | 29.63        |
| ReZero [9]                                                           | 27.00        | 21.83         | 36.24        | 31.01         | 31.18        | 29.32         | 30.85        | 23.99         | 29.39        |
| <b>GTRANS (our method)</b>                                           | <b>29.61</b> | <b>24.94</b>  | <b>38.99</b> | <b>33.37</b>  | <b>33.63</b> | <b>30.96</b>  | <b>33.35</b> | <b>26.57</b>  | <b>31.43</b> |

TABLE V  
X $\rightarrow$ EN AND EN $\rightarrow$ X TEST BLEU FOR HIGH/MEDIUM/LOW RESOURCE LANGUAGE PAIRS IN MANY-TO-MANY SETTING ON OPUS-100 TEST SETS. THE BLEU SCORES ARE AVERAGE ACROSS ALL LANGUAGE PAIRS IN THE RESPECTIVE GROUPS. “WR”: WIN RATIO (%) COMPARED TO *ref* (MNMT).

| Models (N $\rightarrow$ N) | #Params | X $\rightarrow$ En |                   |                   |                   |            | En $\rightarrow$ X |                   |                   |                   |            |
|----------------------------|---------|--------------------|-------------------|-------------------|-------------------|------------|--------------------|-------------------|-------------------|-------------------|------------|
|                            |         | High <sub>45</sub> | Med <sub>21</sub> | Low <sub>28</sub> | Avg <sub>94</sub> | WR         | High <sub>45</sub> | Med <sub>21</sub> | Low <sub>28</sub> | Avg <sub>94</sub> | WR         |
| Previous Best System [18]  | 254M    | 30.3               | 32.6              | 31.9              | 31.4              | -          | 23.7               | 25.6              | 22.2              | 24.0              | -          |
| MNMT [19]                  | 362M    | 32.3               | 35.1              | 35.8              | 33.9              | <i>ref</i> | 26.3               | 31.4              | 31.2              | 28.9              | <i>ref</i> |
| XLMT-R [20]                | 362M    | 33.1               | 35.7              | 36.1              | 34.6              | -          | 26.9               | 31.9              | 31.7              | 29.4              | -          |
| <b>GTRANS (Our method)</b> | 362M    | <b>33.8</b>        | <b>36.2</b>       | <b>36.4</b>       | <b>35.5</b>       | 74.5       | <b>27.8</b>        | <b>32.6</b>       | <b>32.1</b>       | <b>30.2</b>       | 78.5       |

# 실험 결과

---

## 1. Bilingual

- 일관되게 모든 환경에서 BLEU 1 이상 증가
  - multi layer 정보를 잘 활용하는 것을 알 수 있음
- 12-12 로 더 깊게 만든 모델에서도 잘함
- Low-Med resource 에서도 잘함

## 2. Multilingual

- multilingual 은 bi 에 비해 각 레이어 마다 더 풍부한 정보가 있어 이러한 group&fuse 방식이 더 효과 있음
  - worst 대비 BLEU 2 이상 증가
- 특히 opus 같은 엄청나게 많은 언어를 다룰 때 더 효과를 발휘함
  - BLEU 최소 3이상 증가
  - Low resouce 일 수록 더 BLEU 증가폭 큼.
  - En → X 의 경우 Low 에서 10 가까이 증가
  - XLM-R 이 이미 잘하는 모델인데도 이만한 성능 차 나옴
    - 즉 low res 에서 얻기 힘든 high level 도 잘 얻어냄

# 실험 추가 분석

## 1. Effect of Different Model Layers

### 1) IWSLT14 - low resource, T = 3

- 인코더 올리든 디코더 올리든 성능 향상
- 성능 차이는 얼마 없음. 0.4 정도

### 2) WMT14 - med resource, T = 6

- 항상 Transformer vanilla 보단 1점 이상 좋음
- 레이어 수 늘리면 성능 증가 폭 강함. 두 방향 모두 거의 1.5 정도




Fig. 3. Effect of the number of the encoder layers with the fixed 12 decoder layers (a) and the number of the encoder layers with the fixed 12 encoder layers (b) on the IWSLT-2014 De→En translation task.




Fig. 4. Effect of the number of the encoder layers with the fixed 12 decoder layers (a) and the number of the encoder layers with the fixed 12 encoder layers (b) on the WMT-2014 En→De translation task.

# 실험 추가 분석

## 2. Effect of Group size

### 1) Encoder Group size

- 인코더 그룹을 1개(즉 하나 그룹에 60개 레이어, 트랜스포머 바닐라)로 하면 학습 실패
- 최소한 4개 그룹(하나당 15개 레이어)은 되어 학습 성공.
- 너무 많은 그룹(그룹 60개, 하나당 1개 레이어)는 오히려 성능이 살짝 하락
  - low level feature 을 너무 많이 봐서

### 2) Decoder Group size

- 디코더 그룹 수를 늘릴 수록(세분화) 성능 향상.
- 그룹 늘릴 수록 성능 차이 1.2 정도로 많이 남
  - 즉 디코더는 세분화해야 multi layer feature 을 다 활용 가능




Fig. 5. Results of our model (60L-6L) with the different numbers of the encoder groups.




Fig. 6. Results of our model (12L-12L) with the different numbers of the decoder groups.

## 3. Effect of Long Sentences




Fig. 12. Comparison between the Transformer baseline and our method in different length intervals.

- 테스트셋의 문장을 길이 별로 나누어 점수를 평가함 (4.1K, 2.1K, 0.4K, and 0.1K)
- 길이가 더 긴 문장일 수록 Gtrans 와 Transformer Vanilla 의 성능 차이가 심해지는 것을 확인 (성능 차이 최대 1.4)

# 실험 추가 분석

---

## 4. Effect of Encoder Multi-layer Features (Figure 7)

- Encoder 은 그룹 내 마지막 레이어만 선택하게 되는데, 이러한 방식(sparse fusion)이 Encoder 에서는 맞는 방식임을 보임
- 또한 encoder 의 경우 마지막 레이어 몇 개를 잘라내도 deep 한 경우 성능의 큰 차이가 없음을 보임

## 5. Effect of Decoder Multi-layer Features (Table 6)

- 디코더는 각 그룹 내 모든 레이어를 다 선택하기 때문에, 인코더에서 발생하는 문제가 없음
- 단지 그룹마다, high-low level layer 의 성능 차를 보고자 함
- 그룹 별로 해당 그룹 정보만 활용했을 때 성능을 보면 마지막으로 갈 수록 성능이 오름. 학습된 가중치를 봐도 마지막 그룹에 가중치가 쏠림
- 그리고 1-6 그룹 을 모두 활용하는 결과와 상위 그룹만 활용하는 결과가 성능 차이가 그렇게 크지 않음(0.4 블루). 즉 디코더의 경우 만약 inference 에서 속도가 중요한 문제라면 low level 을 활용안해도 된다는 것을 의미



## 6. Visualization of Decoder Fusion (Figure 8, 9)

- Decoder 레이어 별, 그룹 별 학습 가중치가 학습이 진행되는 동안 어떻게 달라지는 지 보임
- 하위 가중치는 그다지 높지 않으며, 상위 레이어로 갈 수록 가중치가 커짐
- 그러나 가장 마지막 레이어가 아니라 중상위 레이어들의 가중치가 가장 높음을 보임. 따라서 기존에 마지막 디코더 레이어만을 사용하는 방식이 항상 좋지는 않다는 것을 보임

## 7. Comparison with Ensemble System (Figure 10)

- Ensemble 시스템 보다 비슷한 파라미터에서 더 나은 성능을 보임

## 8. Inference Speed (Table 7)

- 같은 파라미터에서 성능은 증가하나 속도 하락은 미약함을 보임

## 9. Gradient Propagation (Figure 11)

- Gtrans 는 하위 레이어에게 gradient propagation 을 더 잘 해줌
- 따라서 레이어마다 gradient norm 이 크게 차이 나지 않게됨. 즉 lower layer 업데이트를 더 잘할 수 있음

## 10. Effect of Feature Fusion (Table 8)

- Ablation Study 를 통해 fusion 이 없으면 deep model 에서 훈련이 실패함을 보임

# Paper Summary

---

## 트랜스포머 모델의 multi-level layer 들을 활용하여 성능을 향상시키는 방법 제안

➔ Multi-level layer features 를 encoder, decoder 단에서 잘 활용하는 fusion 방식을 제안.

### <기존 연구>

Transformer 모델은 top-level representation 만을 사용하기 때문에 lower-level layer 들의 정보가 잘 활용되지 못함.

이를 해결하기 위해 이전 연구들은 1) low level layer 정보에 더 집중 2) 전체 encoder layer 정보 모두 활용하는 연구 있었음

- 그러나 기존 연구는 decoder의 multi-layer features 를 충분히 활용하지 못함

- 그리고 shallow 한 모델에서의 성능 향상이 거의 없었음

### <방법론>

전체 레이어를 그룹으로 나누어, 각 그룹마다 가중치를 두어 정보를 취합하는 Encoder fusion, Decoder fusion 방식을 제안함

### <실험>

다양한 언어쌍 / bilingual & multilingual / high-med-low 크기 데이터셋 에서 기존 연구들보다 일관되게 뛰어난 성능을 보임

자세한 분석을 통해 multi layer feature 을 활용하는 것이 deep 한 모델, longer sentence 에서 매우 중요함을 보임.

---

**감사합니다.**