
Paper on

Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions

Gediminas Adomavicius and Alexander Tuzhili

IEEE Transactions on KNOWLEDGE AND DATA ENGINEERING 17.6 (2005): 734-749.

(Citation 10047회, 구글 스칼라 기준)

발표자 : 권성은

Contents

1. Introduction
2. The survey of Recommender Systems
 - 2.1 Content-Based Methods**
 - 2.2 Collaborative Methods**
 - 2.3 Hybrid Methods**
 - 2.4 Summary and Conclusions
3. Extending Capabilities of Recommender systems
 - 3.1 Comprehensive Understanding of Users and Items**
 - 3.2 Extensions for Model-Based Recommendation Techniques**
 - 3.3 Multidimensionality of Recommendations**
 - 3.4 Multicriteria Ratings**
 - 3.5 Nonintrusiveness**
 - 3.6 Flexibility**
 - 3.7 Effectiveness of Recommendations**
 - 3.8 Other Extensions**
4. Conclusion



추천시스템 첫
등장 ~ 2005년
방법론 또는
알고리즘들을
중간 정리한
기념비적 논문
10047회 인용!

추천시스템 선구적 논문

W. Hill, L. Stead, M. Rosenstein, and G. Furnas, “**Recommending and Evaluating Choices in a Virtual Community of Use,**” Proc. Conf. Human Factors in Computing Systems, 1995.

P. Resnick, N. Iakovou, M. Sushak, P. Bergstrom, and J. Riedl, “**GroupLens: An Open Architecture for Collaborative Filtering of Netnews,**” Proc. 1994 Computer Supported Cooperative Work Conf., 1994.

U. Shardanand and P. Maes, “**Social Information Filtering: Algorithms for Automating ‘Word of Mouth’,**” Proc. Conf. Human Factors in Computing Systems, 1995.

위 3편의 논문이 추천시스템 연구를 촉발한 최초의 논문들임

- 추천시스템은 알고 있는 Rating(Utility)에서 모르는 Rating(utility)를 추정하는 것

TABLE 1
A Fragment of a Rating Matrix for a Movie Recommender System

	K-PAX	Life of Brian	Memento	Notorious
Alice	4	3	2	4
Bob	∅	4	5	5
Cindy	2	2	4	∅
David	3	∅	5	2

Unknown
Utility

- Utility 표현식 : Item S의 Usefulness를 측정한 값들의의 표현식

$$\forall c \in C, \quad s'_c = \arg \max_{s \in S} u(c, s). \quad (1)$$

User space C

(성, 연령, 소득, 결혼 상태 등이 특징)

Item space S

(장르, 감독, 발표 연도, 주연배우 등이 특징)

1. Content-based recommendation


- User가 item를 추천받는 것으로, 예를 들어 과거 User가 좋아했던 item을 추천해 주는 것
- User C 의 (Item S에 대한) 과거 rating 기록을 바탕으로 (rating하지 않은) Item에 대한 rating(utility)을 추정하여 새로운 item을 추천

2. Collaborative recommendation

- 과거에 유사한 취향과 선호를 갖는 부류의 소비자들이 선호했던 item들을 선별해서 제안해주는 것

3. Hybrid approaches

- 위의 두 방법을 복합적으로 사용하는 것



Source: 구글링 이미지

■ Content-based 방식은 Textural information를 특성으로 갖고 있는 item 을 추천하던 업계에서 발전해 온 방식(예. 영화 추천, 신문 기사 추천 등).

✓ 근본이 text 기준 분류였기 때문에 Item의 Utility 산출도 text특성 기준

■ 메커니즘

- 1) TF- IDF라는 단어의 Score를 내고 (TF > DF > IDF > TF-IDF의 순으로 산출)
- 2) 이를 바탕으로 최종적으로는 Document의 Score를 내어서
- 3) 이 Score를 기준으로 개인 사용자(별도의 Score 산출)와 Item의 Score의 거리가 가까운 Item을 추천을 하는 메카니즘

Content-Based Recommendation

2. The survey of Recommender Systems



단어 점수1 : TF(Term-Frequency)

$$TF_{i,j} = \frac{f_{i,j}}{\max_j f_{i,j}}, \quad (2)$$

단어 점수2 : IDF(Inverse Document Frequency)

$$IDF_i = \log \frac{N}{\text{count}_i}. \quad (3)$$


단어 점수3 : TF-IDF

$$w_{i,j} = TF_{i,j} \times IDF_i \quad (4)$$



Document 점수

$$Content(d_j) = (w_{1,j}, \dots, w_{k,j}).$$



Utility 점수

$$u(c, s) = \text{score}(\text{ContentBasedProfile}(c), \text{Content}(s)). \quad (5)$$

(Cosine Similarity 산출 방식)

$$\left\{ \begin{aligned} u(c, s) &= \cos(\vec{w}_c, \vec{w}_s) = \frac{\vec{w}_c \cdot \vec{w}_s}{\|\vec{w}_c\|_2 \times \|\vec{w}_s\|_2} \\ &= \frac{\sum_{i=1}^K w_{i,c} w_{i,s}}{\sqrt{\sum_{i=1}^K w_{i,c}^2} \sqrt{\sum_{i=1}^K w_{i,s}^2}}, \end{aligned} \right. \quad (6)$$

참고) 기타 Utility 산출 방법

$$P(C_i | k_{1,j} \& \dots \& k_{n,j}). \quad (7)$$

$$P(C_i) \prod_x P(k_{x,j} | C_i). \quad (8)$$

■ Content-based Recommendation의 문제점

- 1) Overspecialization의 문제 : 늘 같은 유형의 것을 추천
- 2) New User의 문제 : 데이터 부족으로 부정확한 추천

- Collaborative-based 방식은 일군의 사용자들이 기존에 평가한 item의 평가 점수에 기초하여 특정 User를 위한 특정 Item의 Utility를 예측
 - ✓ User c와 유사한 취향을 갖고 있는 peer를 찾아내서 그 peer들이 가장 좋아했던 Item을 추천하는 방식

- Memory-base와 Model-based 두 가지가 있음
 - 1) Memory-based : unknown rating은 가장 유사한 일군의 사용자들이 특정 item에 부가한 평가 점수의 aggregate 수치로 추정함
 - 2) Model-based : Unknown ratings를 산출하기 위해 확률적 접근 방법 사용

1) Memory-based

■ Unknown Rating 측정 방법

- ① 단순 평균
- ② 가중평균 (유사도를 가중함)
- ③ 표준화 가중평균 (Adjusted weighted sum)

$$r_{c,s} = \text{aggr}_{c' \in \hat{C}} r_{c',s}, \quad (9)$$

$$\begin{aligned} \text{(a)} \quad r_{c,s} &= \frac{1}{N} \sum_{c' \in \hat{C}} r_{c',s}, \\ \text{(b)} \quad r_{c,s} &= k \sum_{c' \in \hat{C}} \text{sim}(c, c') \times r_{c',s}, \\ \text{(c)} \quad r_{c,s} &= \bar{r}_c + k \sum_{c' \in \hat{C}} \text{sim}(c, c') \times (r_{c',s} - \bar{r}_{c'}), \end{aligned} \quad (10)$$

■ User들 사이의 Similarity 측정 방법

- ① Correlation 이용
- ② Cosine Similarity 이용

$$\text{sim}(x, y) = \frac{\sum_{s \in S_{xy}} (r_{x,s} - \bar{r}_x)(r_{y,s} - \bar{r}_y)}{\sqrt{\sum_{s \in S_{xy}} (r_{x,s} - \bar{r}_x)^2} \sqrt{\sum_{s \in S_{xy}} (r_{y,s} - \bar{r}_y)^2}}. \quad (12)$$

$$\text{sim}(x, y) = \cos(\vec{x}, \vec{y}) = \frac{\vec{x} \cdot \vec{y}}{\|\vec{x}\|_2 \times \|\vec{y}\|_2} = \frac{\sum_{s \in S_{xy}} r_{x,s} r_{y,s}}{\sqrt{\sum_{s \in S_{xy}} r_{x,s}^2} \sqrt{\sum_{s \in S_{xy}} r_{y,s}^2}}, \quad (13)$$

2) Model-based

- 모델을 학습하기 위해(평가 점수를 예측하기 위해) 평가 점수의 집합을 이용
- Rating 값이 0과 n 사이의 정수라고 가정하면, Rating의 확률적 표현은 user c가 item s에 특정 평가값을 부여할 확률로 볼 수 있음

$$r_{c,s} = E(r_{c,s}) = \sum_{i=0}^n i \times \Pr(r_{c,s} = i | r_{c,s'}, s' \in S_c) \quad (14)$$

Cluster model

- user rating을 이용해서 like-minded users들을 class로 묶어내는 방식

Bayesian network model

- 특정 Domain에 있는 item을 일종의 node로 간주. 각 node의 states에 대한 rating을 부합시키는 것으로, 네트워크 구조와 조건부 확률을 모두 학습
- Markov chain, Markov decision process
- Generative semantics of Latent Dirichlet Allocation
- Probabilistic latent semantic analysis 등 다양한 알고리즘 등장

- Model-based 성능 > Memory-based 성능 ← ∵ Utility 학습을 머신러닝으로 하기 때문

■ Collaborative filtering의 문제점

1) New user problem

- 정확한 추천을 위해서 시스템은 먼저 user의 preference를 학습해야 함

2) New Item problem

- New item은 충분한 수의 user rating이 모이기 전까지는 추천을 하기 어렵다는 문제가 있음

3) Sparsity

- 성공적인 collaborative recommender system은 critical mass of users를 사용할 수 있는가에 달려있는데, 너무 user rating 수가 적으면 문제가 있음
- Rating sparsity를 극복하는 방법은
 - user profile information 을 사용하는 것임. 즉, demographic filtering 기법 사용 등
 - associative retrieval framework을 사용하는 방법도 있음 activation algorithms을 확장하여 transitive associations을 이용 등
 - dimensionality reduction technique(SVM)을 쓰는 것도 방법이 될 수 있음
 - > Matrix factorization

■ Hybrid Methods의 4가지 유형

1) 두 방식의 단순 합산

- rating의 Linear combination 또는 voting scheme을 통해 하나의 결론으로 합치는 방법

2) Content-based를 Collaborative model에 반영하는 방법

- 유사한 프로파일을 갖고 있는 user들이 높게 평가한 item을 추천해 줄 수도 있고, 해당 user profile이 과거에 높게 평가한 item들과 유사한 item을 추천해 줄 수 도 있는 장점이 있음

3) Collaborative model를 Content-based에 반영하는 방법

- content based profiles에 dimensionality reduction technique를 사용하는 것임. 예를 들어, Latent Semantic Indexing을 사용해서 user profile collection에 collaborative view를 만들어내는 것

4) Single Unifying Recommendation model을 구축하는 방법

- Probabilistic latent semantic analysis에 근거하여 Collaborative와 Content-based 추천 방식을 결합
- 또는MCMC를 사용해서 Bayesian mixed-effects regression model을 만드는 방법

TABLE 2
Classification of Recommender Systems Research

Recommendation Approach	Recommendation Technique	
	Heuristic-based	Model-based
Content-based	Commonly used techniques: • TF-IDF (information retrieval) • Clustering Representative research examples: • Lang 1995 • Balabanovic & Shoham 1997 • Pazzani & Billsus 1997	Commonly used techniques: • Bayesian classifiers • Clustering • Decision trees • Artificial neural networks Representative research examples: • Pazzani & Billsus 1997 • Mooney et al. 1998 • Mooney & Roy 1999 • Billsus & Pazzani 1999, 2000 • Zhang et al. 2002
Collaborative	Commonly used techniques: • Nearest neighbor (cosine, correlation) • Clustering • Graph theory Representative research examples: • Resnick et al. 1994 • Hill et al. 1995 • Shardanand & Maes 1995 • Breese et al. 1998 • Nakamura & Abe 1998 • Aggarwal et al. 1999 • Delgado & Ishii 1999 • Pennock & Horwitz 1999 • Sarwar et al. 2001	Commonly used techniques: • Bayesian networks • Clustering • Artificial neural networks • Linear regression • Probabilistic models Representative research examples: • Billsus & Pazzani 1998 • Breese et al. 1998 • Ungar & Foster 1998 • Chien & George 1999 • Getoor & Sahami 1999 • Pennock & Horwitz 1999 • Goldberg et al. 2001 • Kumar et al. 2001 • Pavlov & Pennock 2002 • Shani et al. 2002 • Yu et al. 2002, 2004 • Hofmann 2003, 2004 • Marlin 2003 • Si & Jin 2003
Hybrid	Combining content-based and collaborative components using: • Linear combination of predicted ratings • Various voting schemes • Incorporating one component as a part of the heuristic for the other Representative research examples: • Balabanovic & Shoham 1997 • Claypool et al. 1999 • Good et al. 1999 • Pazzani 1999 • Billsus & Pazzani 2000 • Tran & Cohen 2000 • Melville et al. 2002	Combining content-based and collaborative components by: • Incorporating one component as a part of the model for the other • Building one unifying model Representative research examples: • Basu et al. 1998 • Condliff et al. 1999 • Soboroff & Nicholas 1999 • Ansari et al. 2000 • Popescul et al. 2001 • Schein et al. 2002

- 기존의 추천시스템은 user와 item의 정보만 이용하고, user의 transaction histor를 이용하지는 않음
- 즉 user & item의 profile 정보도 rating 정보와 함께 추천시스템 구성에 활용하면 더욱 결과가 좋아짐
- 최근에 Web site 추천을 위해서 navigational Web usage pattern이 활용되었음

- Recommender systems에서 time과 같은 변수는 매우 중요한 상황 변수
- 즉 user x item으로 이루어진 two-dimensional method를 multidimensional setting으로 바꾸어야 함

$$u : D_1 \times \dots \times D_n \rightarrow R. \quad (19)$$

$$\begin{aligned} \forall (d_{j1}, \dots, d_{jl}) \in D_{j1} \times \dots \times D_{jl}, \\ (d_{i1}, \dots, d_{ik}) = \arg \max_{\substack{(d'_{i1}, \dots, d'_{ik}) \in D_{i1} \times \dots \times D_{ik} \\ (d'_{j1}, \dots, d'_{jl}) = (d_{j1}, \dots, d_{jl})}} u(d'_1, \dots, d'_n). \end{aligned} \quad (20)$$

- > 예를 들어 d1은 영화 특징, d2는 관람자 특징, d3는 Where and how 특징, d4는 동반자 특징, d4는 관람시간 특징
- > 즉 토요일 밤에 극장에 볼 영화를 추천한다고 하면, reduction-based approach는 week dimension의 시간과 장소 데이터에서 rating 자료를 찾아서 추천을 할 것임

■ 레스토랑 추천에서는 음식, 분위기, 서비스의 3가지 기준에서 rating을 제공하는데, 이와 같은 多 기준 rating도 가능

■ 해결 방안은

- 1) Pareto optimal solution을 찾고
- 2) Linear combination of multiple criteria를 적용해서 single-criterion optimization problem이 되도록 reducing
- 3) 가장 중요한 criterion을 최적화하고 다른 criterion은 constraints로 전환시킴
- 4) 특정 시점에 한 criterion을 최적화하고 optimal solution을 constraints를 전환하고 이 과정을 반복

- 추천시스템은 본래 user feedback이 필요하므로 어찌보면 user involvement가 필요한 intrusive한 시스템이라고 할 수 있음
- 신문의 기사 같이, 수많은 기사에 대해 다 User rating을 받는 것은 비현실적임
- 어떤 추천 시스템은 nonintrusive rating을 사용해서 추천을 함(정확도가 낮은 경우가 있음)
- 따라서 Nonintrusiveness 문제는 intrusiveness를 최소화하는 이슈가 되기도 함.
 - 어떤 user가 신문을 읽기 위해 소비한 시간 같은 것을 일종의 rating으로 간주하는 방식
 - 그런데 이러한 데이터는 정확성에 문제가 생기기도 함
 - 따라서 intrusiveness problem을 해결하는 한가지 방법은 user에게 물어볼 적정 rating 숫자를 정하는 것이 됨

- 대부분의 recommendation methods는 inflexible함 (hard-wired이기 때문)
 - 즉, end user는 real time으로 자신의 니즈에 따른 추천을 받을 수 없음
 - 이 문제를 해결하기 위해 Recommendation Query Language가 제안되었음
- aggregated recommended (브랜드, 카테고리, 세그먼트 등)도 중요한 이슈임
 - 이 경우에는 OLAP-based 접근 방식이 필요함.

- 추천의 효과를 측정하는 좋은 방법은 coverage와 accuracy metrics임
- Coverage는 % of 추천시스템이 예측할 수 있는 items
- Accuracy는 예측값과 실제 rating값 사이의 상관관계 또는 root mean squared error
- 전통적인 IR measure들도 사용 가능 : Precision, recall, F-measure, ROC 등등
- 비즈니스 관점에서 ROI나 Customer Lifetime Value 도 있음

